دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی ارشد
مهندسی کامپیوتر

حفظ حریم خصوصي تفاضلي محلي هنگام انتشار داده‌هاي با ابعاد بالا و در حال تغییر

نگارش

سید آرش ساعتچی

استاد راهنما

دکتر رسول جلیلی

شهریور ۱۴۰۴

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

چکیده

حریم خصوصی تفاضلی محلی یکی از رویکردهای پیشرو در حفاظت از داده‌های کاربران است که بدون اعتماد به کارپذیر، حریم خصوصی را تضمین می‌کند. این مفهوم با افزودن نوفه به داده‌های کاربران قبل از ارسال به سمت کارپذیر، امکان تحلیل داده‌ها را فراهم می‌سازد. این گزارش بر چالش‌های حفظ حریم خصوصی تفاضلی محلی در داده‌های با ابعاد بالا و در حال تغییر تمرکز دارد. از جمله چالش‌های اساسی در این زمینه، همبستگی میان ویژگی‌ها، افزایش حساسیت داده‌ها و مصرف سریع بودجه حریم خصوصی است که می‌تواند دقت و کارایی تحلیل‌های آماری را به شدت کاهش دهد. استفاده ایمن از این داده‌ها در حوزه‌هایی نظیر اینترنت اشیا، داده‌های سلامت و سیستم‌های نظارتی اهمیت بالایی دارد زیرا این داده‌ها معمولاً در تصمیم‌گیری‌های کلیدی و توسعه خدمات هوشمند مورد استفاده قرار می‌گیرند و حفظ حریم خصوصی کاربران در فرآیندها از اولویت بالایی برخوردار است. در این گزارش ضمن دسته‌بندی، مرور و مقایسه الگوریتم‌ها و کارهای پیشین راه‌کار جدیدی برای حل چالش داده‌های باابعاد بالا و در حال تغییر ارائه شده است. این راهکار با بهره‌گیری از تخصیص بهینه بودجه حریم خصوصی بر اساس همبستگی میان ویژگی‌ها، موجب کاهش نوفه اضافی می‌شود. همچنین با مدیریت و کاهش دامنه داده‌ها، از مصرف بیش از اندازه‌ی بودجه حریم خصوصی جلوگیری کرده و دقت و کارایی فرآیندها را افزایش می‌دهد. در نهایت، نتایج این پژوهش چارچوبی عملی و کارآمد برای تحلیل داده‌های باابعاد بالا و در حال تغییر فراهم می‌کند که می‌تواند به عنوان یک ابزار کاربردی در سیستم‌های مبتنی بر داده به کار گرفته شود.

کلیدواژه‌ها: حریم خصوصي تفاضلي محلي، انتشار داده، داده‌هاي در حال تغییر، داده‌هاي با ابعاد بالا

فهرست مطالب

۱ مقدمه ۱

۱ـ۱ تعریف مسئله ۲

۱ـ۲ اهمیت موضوع ۲

۱ـ۳ ادبیات موضوع ۴

۱ـ۳ـ۱ حریم خصوصی ۴

۱ـ۳ـ۲ داده‌های با ابعاد بالا ۴

۱ـ۳ـ۳ داده‌های در حال تغییر ۴

۱ـ۳ـ۴ پدیده نفرین ابعاد بالا ۴

۱ـ۴ اهداف پژوهش ۵

۱ـ۵ ساختار پایان‌نامه ۵

۲ مفاهیم اولیه ۶

۲ـ۱ حریم خصوصی تفاضلی ۶

۲ـ۲ بودجه حریم خصوصی ۷

۲ـ۳ حریم خصوصی تفاضلی محلی ۷

۲ـ۴ حساسیت ۸

۲ـ۵ الگوریتم‌های حافظ حریم خصوصی تفاضلی ۹

۲ـ۵ـ۱ سازوکار لاپلاس ۹

۲ـ۵ـ۲ سازوکار نمایی ۱۰
۲ـ۵ـ۳ پاسخ تصادفی ۱۱
۲ـ۵ـ۴ پاسخ تصادفی عمومی ۱۱
۲ـ۵ـ۵ الگوریتم تصادفی‌سازی متقارن ۱۲
۲ـ۶ ترکیب متوالی ۱۲
۲ـ۷ ترکیب موازی ۱۳
۲ـ۸ روش‌های کدگذاری ۱۴
۲ـ۸ـ۱ کدگذاری مستفیم ۱۴
۲ـ۸ـ۲ کدگذاری یکانی ۱۴
۲ـ۸ـ۳ کدگذاری یکانی متقارن ۱۵
۲ـ۸ـ۴ درهم‌سازی محلی ۱۵
۲ـ۸ـ۵ بلوم فیلتر ۱۷
۲ـ۸ـ۶ علائم ریاضی پرکاربرد ۱۸
۲ـ۸ـ۷ درج جدول ۱۹
۲ـ۸ـ۸ درج الگوریتم ۱۹
۲ـ۸ـ۹ محیط‌های ویژه ۲۰
۲ـ۹ برخی نکات نگارشی ۲۰
۲ـ۹ـ۱ فاصله‌گذاری ۲۰
۲ـ۹ـ۲ شکل حروف ۲۱
۲ـ۹ـ۳ جدانویسی ۲۱

۳ کارهای پیشین **۲۳**
۳ـ۱ داده‌های با ابعاد بالا ۲۳
۳ـ۱ـ۱ نمونه‌برداری ۲۴
۳ـ۱ـ۲ خوشه‌بندی ۲۷

۳ـ۱ـ۳ کاهش ابعاد ۳۶
۳ـ۲ نتیجه‌گیری ۴۲
۳ـ۳ مسائل خوشه‌بندی ۴۳
۳ـ۴ خوشه‌بندی kـ مرکز ۴۵
۳ـ۵ مدل جویبار داده ۴۷
۳ـ۶ تقریب‌پذیری ۴۸

۴ نتایج جدید **۴۹**

۵ نتیجه‌گیری **۵۰**

مراجع **۵۱**

واژه‌نامه **۵۵**

آ مطالب تکمیلی **۵۷**

فهرست جدول‌ها

۲ـ۱ عملگرهای مقایسه‌ای ۱۹

۳ـ۱ نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی ۴۸

فهرست شکل‌ها

۲ـ۱ نحوه عملکرد حریم خصوصی تفاضلی محلی ۹

۲ـ۲ شیوه‌ی درج عنصر با استفاده از بلوم فیلتر ۱۸

۳ـ۱ ساخت درخت اتصال از گراف همبستگی. برگرفته از [۱] ۳۰

۳ـ۲ استفاده از شبکه مارکوف در ساخت درخت اتصال. برگرفته از [۲] ۳۲

۳ـ۳ ساخت شبکه بیزی از پنج ویژگی. برگرفته از [۳] ۳۳

۳ـ۴ نحوه محاسبه‌ی بردار ویژه در تبدیل هار. $a_{i,j}$ نشان‌دهنده‌ی ویژگی jام از کاربر iام است.
برگرفته از [۴] ۳۸

۳ـ۵ آشفته‌سازی مقدار m_i بر اساس پی.دی.پی. برگرفته از [۴] ۴۰

۳ـ۶ نمونه‌ای از مسئله‌ی ۲ـ مرکز ۴۵

۳ـ۷ نمونه‌ای ازمسئله‌ی ۲ـ مرکز با داده‌های پرت ۴۶

فصل ۱

مقدمه

در دنیای امروز که داده‌ها به بخش مهمی از تصمیم‌گیری‌ها و توسعه سیستم‌های اطلاعاتی تبدیل شده‌اند، حفاظت از حریم خصوصی افراد از اهمیت بالایی برخوردار است. حریم خصوصی تفاضلی به عنوان یک چارچوب ریاضی، رویکرد نوینی را برای جلوگیری از افشای اطلاعات حساس افراد در تحلیل داده‌ها ارائه می‌دهد.

انتشار داده‌ها بر مبنای حریم خصوصی تفاضلی اخیراً توجه زیادی را به خود جلب کرده و همچنین الگوریتم‌های متنوعی برای بهبود آن ارائه شده‌است. تعریف ریاضی حریم خصوصی تفاضلی بیان می‌کند که نتیجه هر تحلیل آماری روی داده‌ها، چه شما در آن شرکت کنید و چه نه، یکسان باشد. یعنی اطلاعاتی که از داده‌ها استخراج می‌شود، به گونه‌ای طراحی شده‌است که هیچ فردی نتواند از مشارکت یا عدم مشارکت خود، آسیب یا مزیتی دریافت کند. به عبارت دیگر، حریم خصوصی تفاضلی تضمین می‌کند که داده‌های فردی در برابر تحلیل‌های جمعی محافظت می‌شوند و هیچ گونه اطلاعات خاصی درباره افراد در معرض خطر قرار نمی‌گیرد. این ویژگی باعث می‌شود که افراد با اطمینان بیشتری در تحلیل‌های آماری شرکت کنند.

طی چند سال گذشته، راه حل‌هایی ارائه شده‌است تا هر کاربر بتواند ابتدا روی داده‌های خود نوفه ایجاد کرده و سپس آن‌ها را به سمت کارپذیر ارسال کند. به این راه حل‌ها، الگوریتم‌های حریم خصوصی تفاضلی محلی گفته می‌شود. در این الگوریتم‌ها، حتی با وجود غیرقابل اعتماد بودن کارپذیر، حریم خصوصی کاربران محفوظ باقی می‌ماند. لازم به ذکر است در انتشار داده‌های خصوصی با ابعاد بالا با چالش‌هایی مانند روابط پیچیده بین ویژگی‌ها، پیچیدگی محاسباتی بالا و پراکندگی داده‌ها روبه‌رو هستیم. راه حل‌های موجود که با تمرکز روی داده با ابعاد پایین ارائه شده‌اند، بودجه حریم خصوصی را بین همه ویژگی‌ها تقسیم می‌کنند. با پیاده‌سازی این راه حل‌ها روی داده با ابعاد بالا، نوفه در مقیاس بالا تولید شده و سیستم کارایی خود را از دست می‌دهد. از طرفی یکی دیگر از چالش‌های حفظ حریم خصوصی تفاضلی، کار روی

داده‌های در حال تغییر است. یک نمونه بارز در چنین مسائلی، نظارت برخط روی برنامه‌های نرم‌افزاری و گزارش عملکرد آن‌ها است، زیرا داده‌های ارسالی همواره در حال تغییر هستند. پروتکل‌های فعلی جمع‌آوری داده‌ها می‌توانند حریم خصوصی تفاضلی را در داده‌های با دامنه تغییرات محدود ارضا کنند. در نتیجه برای دامنه‌های بزرگ، مانند دامنه تغییرات داده‌ها در اینترنت‌اشیاء، ناکارآمد خواهند بود. هدف از این پژوهش ارائه راهکاری به منظور حفظ حریم خصوصی کاربران در هنگام انتشار داده‌ها با ابعاد بالا و در حال تغییر است. به منظور ارزیابی عملکرد و کارایی این الگوریتم، ما به تحلیل و محاسبه فراوانی داده‌ها پرداخته و مقدار خطای بدست آمده را با خروجی سایر الگوریتم‌های موجود مقایسه می‌کنیم. این مقایسه، به ما کمک می‌کند تا نقاط قوت و ضعف روش پیشنهادی را شناسایی کرده و در جهت بهینه‌سازی بیشتر آن گام برداریم. در نهایت، نتایج حاصل از این پژوهش می‌تواند به عنوان یک چارچوب کاربردی برای حفظ حریم خصوصی داده‌های کاربران مورد استفاده قرار گیرد.

۱ـ۱ تعریف مسئله

اکثر مقالات و راهکارهای پیشین، فقط یکی از دو چالش اصلی که پیش‌تر ذکر شد را مورد بررسی قرار داده‌اند و برای ارزیابی راهکار خود مجموعه داده مختص با یک چالش را گردآوری کرده اند. مقالاتی که روی داده‌های با ابعاد بالا کار کرده‌اند، معمولا اختلاف میانگین یا اختلاف احتمال توزیع داده‌ها را به عنوان خطا ارائه می‌دهند. همچنین مقالاتی که روی داده‌های در حال تغییر کار می‌کنند، شمارش داده‌های یکسان را به عنوام معیار در نظر گرفته و سعی می‌کنند خطای مربوط به این معیار را کاهش دهند.

از آنجایی که ما هر دو چالش را مورد بررسی قرار داده‌ایم، مجموعه داده‌ای شامل هر دو نوع داده گردآوری شده‌است. یعنی یک مجموعه داده با ابعاد بالا داریم که بعضی از بعدهای آن دامنه‌ی بزرگی دارند و مدام در حال تغییر هستند. به صورت خلاصه راه‌حل ارائه شده، یک نوفه‌ی خاص را روی تمام ابعاد اعمال می‌کند. سپس به منظور ارزیابی راهکار، خطای دو معیار محاسبه می‌شود. معیار شمارش داده‌ها روی بعدهای در حال تغییر در نظر گرفته شده و همچنین معیار احتمال توزیع داده‌ها روی دیگر ابعاد بررسی می‌شود.

۱ـ۲ اهمیت موضوع

در دنیای امروزی برنامه‌های کاربردی بیشماری وجود دارد که مردم با کمک این برنامه‌ها، زندگی روزمره‌ی خود را سپری می‌کنند. داده‌های ورودی برای این برنامه‌ها شامل داده‌های با ابعاد بالا و در حال تغییر

می‌شوند. چندین نوع داده کاربردی مهم وجود دارند که حفظ حریم خصوصی افراد در آن حائز اهمیت است، از جمله:

- سوابق پزشکی، داده‌هایی با ابعاد بالا هستند و معمولاً با جمع‌آوری اطلاعات جدید، در طول زمان تغییر می‌کنند. برای مثال، سابقه پزشکی و داده‌های ژنتیکی یک بیمار ممکن است با هر مراجعه به‌روزرسانی شود.
- مؤسسات مالی با داده‌هایی مانند سوابق تراکنش‌ها و عوامل بازار مثل قیمت سهام و روندهای بازار سروکار دارند. این مجموعه‌داده به‌صورت پیوسته با انجام تراکنش‌ها، نوسان قیمت سهام و ظهور محصولات مالی جدید، تغییر می‌کنند.
- سکوهای رسانه اجتماعی داده‌های ابعاد بالا مانند اطلاعات حساب کاربران، تعاملات و ترجیحات را جمع‌آوری می‌کنند که با فعالیت کاربران در محتوا و سکو، تغییر می‌کنند.
- شبکه‌های هوشمند و دستگاه‌های اینترنت اشیا، داده‌هایی از حسگرها و دستگاه‌ها مانند الگوهای مصرف انرژی، عوامل محیطی و وضعیت دستگاه‌ها را جمع‌آوری می‌کنند. لازم به ذکر است که این داده‌ها هم بعدهای زیادی داردن و هم شامل داده‌های در حال تغییر می‌باشند.

تا کنون چندین پیاده‌سازی از الگوریتم‌های حریم خصوصی تفاضلی انجام شده است. به عنوان مثال، گوگل در مرورگر کروم از الگوریتم رپور[1] بهره می‌گیرد تا شاخص‌های کاربری و تنظیمات حساسی مانند صفحهٔ خانگی را از میلیون‌ها کاربر جمع‌آوری کند، بی‌آنکه هویت فردی آنان افشا شود. کروم روزانه حدود ۱۴ میلیون گزارش از کاربران داوطلب دریافت می‌کند و با اتکا به این داده‌ها می‌تواند اطلاعات مفیدی را بدون فاش شدن شناسه‌های شخصی در دسترس تحلیلگران قرار دهد [۵].

از طرفی مایکروسافت برای جمع‌آوری داده‌های دورسنجی[2] از سامانه‌هایش به‌جای ارسالِ داده خام، سازوکاری مبتنی بر حریم خصوصی تفاضلیِ محلی پیاده‌سازی کرده است. این فناوری از سال ۲۰۱۷ روی میلیون‌ها دستگاه فعال شده و اکنون معیارهایی[3] مثل مدت استفاده از هر برنامه را برای هر بازه‌ی شش‌ساعته ثبت می‌کند مرجع*. بدین‌ترتیب مایکروسافت تنها به نتایج تحلیل‌های آماری دست می‌یابد و هویت یا الگوی اطلاعات کاربران فاش نمی‌شود.

[1] Rappor
[2] Telemetry Data
[3] Metric

۱ـ۳ ادبیات موضوع

۱ـ۳ـ۱ حریم خصوصی

حریم خصوصی مفهومی است که به حق هر فرد برای کنترل دسترسی دیگران به اطلاعات، ارتباطات و قلمرو شخصی‌اش اشاره می‌کند. عنی هرکس بتواند خود تصمیم بگیرد چه داده‌هایی، در چه زمان و برای چه کسانی آشکار شود و چه بخش‌هایی از زندگی‌اش از نگاه دیگران دور بماند. این حق نه‌تنها شامل اطلاعات آشکار مانند نشانی، شماره تماس یا سوابق پزشکی است، بلکه ترجیحات، گفت‌وگوهای خصوصی و حتی الگوهای رفتاری ضمنی را نیز در بر می‌گیرد. حریم خصوصی با فراهم کردن فضایی امن، مشارکت آگاهانه و بدون ترس در جامعه دیجیتال را ممکن می‌سازد.

۱ـ۳ـ۲ داده‌های با ابعاد بالا

مقصود از داده‌های با ابعاد بالا مجموعه‌ای از داده‌هاست که هر مشاهده آن شامل شمار زیادی ویژگی یا بُعد است. به بیان دیگر، به‌جای سطرهایی با چند ستون محدود، با رکوردهایی روبه‌رو هستیم که ده‌ها یا صدها ستون دارند و هر ستون جنبه‌ای مجزا از پدیده را وصف می‌کند. این تکثر ابعاد، گرچه امکان استخراج الگوها و اطلاعات نهفته‌ی فراوان را فراهم می‌کند، اما هم‌زمان چالش‌هایی در حفظ حریم خصوصی به همراه می‌آورد. در این پژوهش راهکاری مربوط به حل اینگونه چالش‌ها بررسی و پیاده‌سازی شده‌است.

۱ـ۳ـ۳ داده‌های در حال تغییر

داده‌های در حال تغییر، مجموعه‌ای از اطلاعات را شامل می‌شود که مقدار ستون‌های آن با گذر زمان تغییر می‌کنند. برای نمونه، تعداد ثانیه‌های استفاده از یک اپلیکیشن یا هر شمارنده و مؤلفه‌ی دیگری که امروز ارزشی دارد و با گذشت زمان عوض می‌شود. این نوسانِ مداوم باعث می‌شود سامانه داده را به‌طور پی‌درپی جمع‌آوری و به‌روزرسانی کند. معولا دامنه تغییر این داده‌ها بالا است و چالش‌هایی در حفظ حریم خصوصی بوجود می‌آید که در ادامه به آن اشاره خواهیم کرد.

۱ـ۳ـ۴ پدیده نفرین ابعاد بالا

نفرین ابعاد بالا به مجموعه چالش‌ها و مشکلاتی گفته می‌شود که با زیاد شدن تعداد ویژگی‌ها در داده رخ می‌دهد. در واقع هر قدر بُعدها بیشتر می‌شوند، احتمال ارتباط میان ابعاد بالا رفته و سامانه برای حفظ حریم

خصوصی داده‌ها به ناچار باید نوقه‌ی بیشتری اضافه کند. هر چقدر نوفه بیشتر اعمال شود، دقت نتایج تحلیل داده‌ها کاهش میابد. بنابراین در این پژوهش راه‌حلی انتخاب و توسعه یافته است که موازنه[۴] بین حریم خصوصی و سودمندی[۵] رعایت شود.

۱ـ۴ اهداف پژوهش

راه‌حل‌های بیشماری تاکنون ارائه شده است ولی اکثر آنها یا حریم خصوصی را کامل ارضا نمی‌کنند یا سربار بالای زمانی و نوفه‌ای به سامانه اعمال می‌کنند. در نتیجه هزینه‌ی استفاده از الگوریتم برای حفظ حریم خصوصی بالا رفته و سازمان‌ها رغبتی به استفاده از آن نمی‌کنند. بنابراین هدف این پژوهش طراحی و پیاده‌سازی ابزاری سبک، کاربرپسند و سریع است که بتواند با تزریق بهینه نوفه به داده‌های خام، هم‌زمان هم سودمندی را داشته باشیم و هم حریم خصوصی حفظ شود.

۱ـ۵ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل به شرح زیر ارائه می‌شود. مفاهیم اولیه مورد استفاده در این پایان‌نامه در فصل دوم به اختصار اشاره شده است. فصل سوم به مطالعه و بررسی کارهای پیشین مرتبط با موضوع این پایان‌نامه می‌پردازد. در فصل چهارم، نتایج جدیدی که در این پایان‌نامه به‌دست آمده است، ارائه می‌شود. فصل پنجم به جمع‌بندی کارهای انجام شده در این پژوهش و ارائه‌ی پیشنهادهایی برای انجام کارهای آتی خواهد پرداخت.

[4] Trade off
[5] Utility

فصل ۲

مفاهیم اولیه

دومین فصل پایان‌نامه به طور معمول به معرفی مفاهیمی می‌پردازد که در پایان‌نامه مورد استفاده قرار می‌گیرند. در این فصل به عنوان یک نمونه، نکات کلی در خصوص نحوه‌ی نگارش پایان‌نامه و نیز برخی نکات نگارشی به اختصار توضیح داده می‌شوند.

۲ـ۱ حریم خصوصی تفاضلی

حریم خصوصی تفاضلی یک چارچوب ریاضی است که تضمین می‌کند خروجی هر تحلیل آماری به‌گونه‌ای ساخته شود که حضور یا عدم حضورِ هر فرد در داده‌ها تأثیری محسوس بر توزیع نتایج نگذارد. به بیان دیگر، حریم خصوصی تفاضلی محلی این اجازه را می‌دهد که بتوان روی یک مجموعه داده، تحلیل‌های آماری مانند میانگین و شمارش را انجام دهیم ولی نتوان اطلاعات مربوط به یک شخص را استخراج کرد. فرض کنید سازمانی می‌خواهد یک آمار تقریبی از تعداد افراد با یک بیماری خاص بدست‌آورد. این سازمان از تمام جامعه‌ی آماری خود میخواهد که با تکمیل فرمی بگویند که آیا آن بیماری خاص را دارند یا خیر. همگی فرم‌ها به سمت سازمان فرستاده می‌شود. سپس سازمان باید نتایج را با کاربران خود به اشتراک بگذارد. اگر نتایج به دور از هیچگونه سازوکار امنیتی منتشر شود، حریم خصوصی افراد شرکت کننده در رابطه با داشتن بیماری خاص نقض می‌شود. نوعی از الگوریتم‌های حفظ حریم خصوصی، الگوریتم‌های حریم خصوصی تفاضی هستند که با ایجاد نوفه در داده‌ها، باعث می‌شوند نتایج تحلیل‌های آماری به طوری تقریبی صحیح بوده و در عین حال، حریم خصوصی افراد حفظ شود.

تعریف حریم خصوصی تفاضلی برای اولین بار توسط خانم دُرک [۶] به صورت زیر مطرح شد:

تعریف ۲ـ۱ (حریم خصوصی تفاضلی) *الگوریتم M را در نظر بگیرید که به عنوان ورودی پایگاه داده D را دریافت می‌کند. این الگوریتم حریم خصوصی تفاضلی را در صورتی تضمین می‌کند که برای هر دو پایگاه داده مجاور D و D' و برای هر مجموعه خروجی S ممکن داشته باشیم:*

$$\Pr[\mathcal{M}(D) \in S] \leqslant e^{\epsilon} \times \Pr[\mathcal{M}(D') \in S] \qquad (۱ـ۲)$$

پایگاه داده‌هایی که تنها در یک عنصر تفاوت داشته باشند ، مجاور یا همسایه[1] نامیده می‌شوند. همچنین ϵ یک ورودی مثبت با مقدار کم است و سطح حریم خصوصی را نشان می‌دهد. بنابر عبارت بالا، هر چه مقدار کمتری برای ϵ در نظر بگیریم، در واقع قوانین سخت‌گیرانه‌تری برای حفظ حریم خصوصی اعمال کرده‌ایم.

۲ـ۲ بودجه حریم خصوصی

بودجه حریم خصوصی یکی از مفاهیم کلیدی در حریم خصوصی تفاضلی است که برای اندازه‌گیری و کنترل میزان حریم خصوصی در طی اجرای یک الگوریتم یا مجموعه‌ای از الگوریتم‌ها ، استفاده می‌شود. این مفهوم به‌طور مستقیم با پارامتر ϵ در ارتباط است.

معمولا بودجه‌ای که برای الگوریتم‌های حافظ حریم خصوصی در نظر می‌گیرند، برابر ۱ یا مقداری نزدیک به ۱ است. هرچه بودجه‌ی کمتری به الگوریتم اختصاص دهیم، در واقع حریم خصوصی قوی‌تری برایش اعمال کرده‌ایم. درنتیجه الگوریتم برای اینکه بتواند شرط حریم خصوصی در تعریف ۲ـ۱ را ارضا کند، باید نوفه‌ی بیشتری به داده‌ها اضافه کند. طبیعتا با اضافه کردن نوفه‌ی بیشتر، سودمندی کاهش خواهد یافت.

۲ـ۳ حریم خصوصی تفاضلی محلی

پس از معرفی حریم خصوصی تفاضلی، مشخص شد که ارسال داده‌های خام به سمت یک کارپذیر و اعتماد به آن، کار چندان درستی نیست. اگر به این کارپذیر حمله‌ی سایبری انجام می‌شد یا اینکه خود کارپذیر داده‌ها را به صورت غیر ایمن به سازمانی دیگر می‌داد، حریم خصوصی افراد جامعه نقض می‌شد. افزایش

[1] Neighbour

رخنه‌های امنیتی و سخت‌گیری‌های قانونی نیز این بی‌اعتمادی را تشدید کرد. از همین رو پژوهشگران به الگویی روی آوردند که در آن هر کاربر پیش از ارسال، پاسخ خود را به‌طور تصادفی نوفه‌دار می‌کند تا حریم خصوصی در همان مبدأ تضمین شود. نمایی از عملکرد حریم خصوصی تفاضلی محلی را می‌توانیم در شکل ۲ـ۱ مشاهده کنیم.

به بیانی دیگر، حریم خصوصی تفاضلی محلی مفهومی در حفاظت از داده‌های شخصی است که به کاربران اجازه می‌دهد اطلاعات خود را بدون نیاز به اعتماد به طرف ثالث در اختیار دیگران قرار دهند. در این مدل، پیش از آنکه داده‌ها به کارپذیر غیرقابل‌اعتماد ارسال شوند نوفه بر روی آنها اضافه می‌شود. اصطلاحا به این عملیات، «آشفته‌سازی داده[۲]» می‌گویند. سپس کارپذیر با پردازش داده‌ها به آمار قابل قبولی دست پیدا می‌کند که می‌تواند به صورت عمومی با کاربران به اشتراک گذاشته شود. مدل حریم خصوصی تفاضلی محلی برای اولین بار در سال ۲۰۱۱ [۷] ارائه شد و سپس دوچی و همکارانش [۸] تعریف بهتر و دقیق‌تری از نظر ریاضیاتی معرفی کردند. این مدل را به اختصار، مدل «ال دی پی» می‌نامند.

تعریف ۲ـ۲ (حریم خصوصی تفاضلی محلی) *فرض کنید $\mathcal{X}$ دامنه داده‌های کاربر باشد و $\mathcal{M} : \mathcal{X} \to \mathcal{Y}$ یک الگوریتم تصادفی باشد. این الگوریتم به صورت (ϵ, δ) حریم خصوصی تفاضلی محلی را برآورده می‌کند اگر برای هر جفت داده ورودی $x, x' \in \mathcal{X}$ و هر زیرمجموعه $S \subseteq \mathcal{Y}$ از خروجی‌های ممکن داشته باشیم:*

$$\Pr[\mathcal{M}(x) \in S] \leqslant e^{\epsilon} \Pr[\mathcal{M}(x') \in S] + \delta \qquad (۲ـ۲)$$

در نامساوی بالا، ϵ بودجه‌ی حریم خصوصی است و δ «پارامتر لغزش» تلقی می‌شود. ورودی δ کمی شرط تضمین حریم خصوصی تفاضلی را آسان‌تر می‌کند. به الگوریتم‌هایی که بتوانند شرط بالا را با δ برابر صفر ارضا کنند، حافظ حریم خصوصی تفاضلی خالص یا $\epsilon-LDP$ می‌گویند.

۲ـ۴ حساسیت

حساسیت[۳] در زمینه حریم خصوصی داده‌ها به حداکثر تغییر در خروجی یک تابع به دلیل تغییر یک ورودی واحد اشاره دارد [۹]. به عبارت دیگر، حساسیت اندازه‌گیری می‌کند که چقدر می‌توان با تغییر یک ورودی، خروجی تابع را تحت تأثیر قرار داد. این ویژگی در طراحی سازوکارهای حریم خصوصی تفاضلی محلی

[2] Data Perturbation
[3] Sensitivity

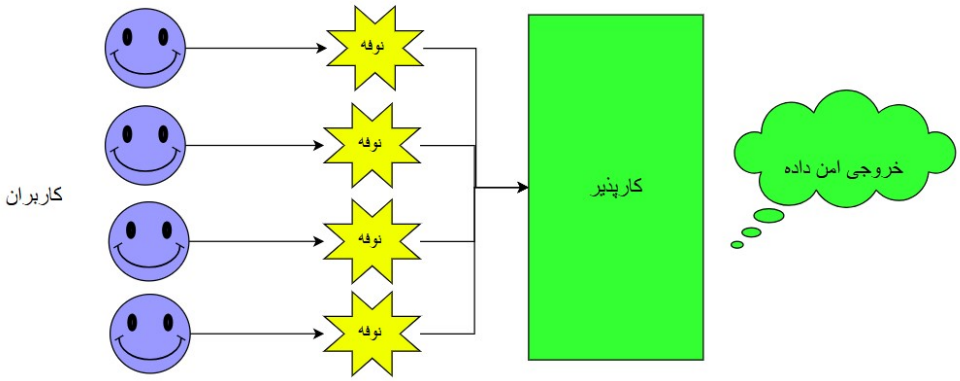

شکل ۲ـ۱: نحوه عملکرد حریم خصوصی تفاضلی محلی

بسیار مهم است، زیرا تعیین می‌کند که چه مقدار نوفه باید به خروجی اضافه شود تا حریم خصوصی کاربران حفظ گردد.

تعریف ۲ـ۳ (حساسیت) *حساسیت یک تابع* $f : \mathcal{X} \to \mathbb{R}^d$ *به صورت زیر تعریف می‌شود:*

$$\Delta f = \max_{x,x' \in \mathcal{X}} \|f(x) - f(x')\| \tag{۲ـ۳}$$

در عبارت بالا Δf حساسیت تابع f نامیده می‌شود و $\mathcal{X}$ دامنه ورودی ما است.

۲ـ۵ الگوریتم‌های حافظ حریم خصوصی تفاضلی

۲ـ۵ـ۱ سازوکار لاپلاس

سازوکار لاپلاس[۴] در حریم خصوصی تفاضلی ایده‌ای ساده و در عین حال توانمند است. هرگاه بخواهیم آماری از داده‌ها مانند مجموع، میانگین و تعداد را منتشر کنیم، به‌جای پاسخ دقیق، همان پاسخ را با نوفه‌ای که از توزیع لاپلاس بدست می‌آید می‌فرستیم. مقدار پراکندگی این نوفه طوری تنظیم می‌شود که اگر اطلاعات یک فرد در پایگاه‌داده حذف یا اضافه شود، توزیع خروجی تقریباً تغییر نکند. بدین‌ترتیب حضور یا عدم حضور آن فرد در نتیجه قابل تشخیص نیست. بزرگی نوفه به دو عامل بستگی دارد: حساسیت تابع

[4] Laplace

و همچنین بودجهٔ حریم خصوصی. هرچه بودجه‌ی کمتری اختصاص دهیم حفاظت قوی‌تر شده و نوفه بیشتری اعمال می‌شود.

تعریف ۲ـ۴ (سازوکار لاپلاس) *سازوکار لاپلاس روی یک تابع* $f : \mathcal{X} \to \mathbb{R}^d$ *به صورت زیر تعریف می‌شود:*

$$\mathcal{M}(D) = f(D) + Lap\left(\frac{\Delta f}{\epsilon}\right) \tag{۴ـ۲}$$

در عبارت بالا، ورودی مرکز یا μ در توزیع لاپلاس برابر صفر و همچنین ورودی مقیاس یا b برابر $\frac{\Delta f}{\epsilon}$ در نظر گرفته شده است.

۲ـ۵ـ۲ سازوکار نمایی

یکی از مشکلات سازوکار لاپلاس، عدم کارایی در مقادیر گسسته و غیر عددی است. از این رو سازوکار دیگری به نام سازوکار نمایی معرفی شد. این سازوکار چارچوبی فراهم می‌کند که در آن می‌توانیم تابع سودمنی دلخواه خود را تعریف کنیم. در واقع تابع u هر ورودی و خروجی تشکیل شده از پایگاه‌داده‌ی ما را به یک امتیاز سودمندی تبدیل می‌کند.

$$u : \mathbb{N}^{|X|} \times \mathcal{R} \to \mathbb{R} \tag{۵ـ۲}$$

پس از محاسبه‌ی امتیاز هر خروجی، سازوکار گزینه‌ها را با احتمالی متناسب با توزیع نماییِ آن امتیاز انتخاب می‌کند. این انتخاب به‌گونه‌ای انجام می‌شود که گزینه‌های دارای امتیاز بالاتر، با احتمال بیشتری انتخاب شوند. این روش برای پرسش‌های غیرعددی (مثل «کدام محصول پرفروش‌تر است؟») بسیار سودمند خواهد بود. دقت کنید که ما اینجا نیاز به محاسبه حساسیت تابع سودمندی خود به شکل زیر داریم:

$$\Delta u = \max_{r \in \mathcal{R}} \max_{\substack{x,y \in \mathbb{N}^{|X|} \\ \|x-y\|_۱ \leqslant ۱}} |u(x,r) - u(y,r)| \tag{۶ـ۲}$$

در نهایت سازوکار نمایی $\mathcal{M}_E(x, u, \mathcal{R})$ عنصر $r \in \mathcal{R}$ را با احتمالی متناسب با $\exp\left(\frac{\varepsilon\, u(x,r)}{۲\,\Delta u}\right)$ گزینش و اعلام می‌کند.

۲ـ۵ـ۳ پاسخ تصادفی

پاسخ تصادفی روشی است که در نظرسنجی‌ها و جمع‌آوری داده‌های حساس کاربرد دارد. در این روش، به جای اینکه کاربر به‌طور مستقیم به یک سؤال پاسخ دهد، از یک سازوکار تصادفی استفاده می‌کند تا عدم قطعیت را به پاسخ خود اضافه کند. با اضافه کردن عدم قطعیت، مهاجم یا شخص متخاصم حتی اگر پاسخ نوفه‌دار شده‌ی کاربر را داشته‌باشد، نمی‌تواند با قطعیت جواب اصلی را مشخص کند. به بیان دیگر، کاربر با احتمال مشخصی پاسخ واقعی خود را ارائه می‌دهد و با احتمال دیگری پاسخ تصادفی دیگری را انتخاب می‌کند. این کار باعث می‌شود که احتمال شناسایی پاسخ واقعی کاربر کاهش یابد. مدل ریاضی پاسخ تصادفی توسط وارنر [۱۰] معرفی شد.

تعریف ۲ـ۵ (پاسخ تصادفی) *فرض کنید کاربر می‌خواهد به یک سؤال دودویی[۵] (بله/خیر) پاسخ دهد. اگر x پاسخ واقعی کاربر باشد، سازوکار پاسخ تصادفی به صورت زیر عمل می‌کند:*

$$\Pr[y=t] = \begin{cases} p, & \textit{if} \quad t=x, \\ ۱-p, & \textit{if} \quad t \neq x \end{cases} \tag{۲ـ۷}$$

در عبارت بالا، y پاسخ ارائه شده به سؤال است. p احتمال اینکه کاربر پاسخ واقعی خود را ارائه دهد و $۱-p$ احتمال این است که کاربر به طور تصادفی پاسخ مخالف را انتخاب کند. سازوکار پاسخ تصادفی اگر بخواهد $\epsilon-LDP$ باشد، باید مقدار p را برابر $\frac{e^{\varepsilon}}{e^{\varepsilon}+۱}$ قرار دهیم.

۲ـ۵ـ۴ پاسخ تصادفی عمومی

پاسخ تصادفی به تنهایی جوابگوی مسائل پیچیده‌تر با دامنه بزرگتر نبود. پاسخ تصادفی عمومی[۶]، شکل عمومی‌تر و انعطاف‌پذیرتر پاسخ تصادفی است [۱۱، ۱۲]. این الگوریتم را به اختصار، «جی آر آر» می‌نامند.

تعریف ۲ـ۶ (پاسخ تصادفی عمومی) *فرض کنید کاربر می‌خواهد به یک سؤال با k گزینه پاسخ دهد. اگر x پاسخ واقعی کاربر باشد، سازوکار پاسخ تصادفی عمومی به صورت زیر عمل می‌کند:*

[5] Binary
[6] Generalized Randomized Response

$$\Pr[y=t] = \begin{cases} p, & \textit{if} \quad t = x, \\ \frac{1-p}{k-1}, & \textit{if} \quad t \neq x \end{cases} \tag{۸ـ۲}$$

سازوکار پاسخ تصادفی اگر بخواهد $\epsilon-LDP$ باشد، باید مقدار p را برابر $\frac{e^{\varepsilon}}{e^{\varepsilon}+k-1}$ قرار دهیم.

۲ـ۵ـ۵ الگوریتم تصادفی‌سازی متقارن

به الگوریتم‌هایی که در فرآیند تصادفی‌سازی برای حفظ حریم خصوصی کاربران، احتمال حفظ مقدار اصلی داده‌ها برابر با احتمال تغییر آن‌ها باشد، متقارن می‌گوییم. به عنوان مثال در مسائلی که ورودی با دامنه دودویی دارند، احتمال زیر برقرار است:

$$Pr[y=1|x=1] = Pr[y=0|x=0] \tag{۹ـ۲}$$

در عبارت بالا، x ورودی و y خروجی الگوریتم است.

۲ـ۶ ترکیب متوالی

در زمینه حریم خصوصی، ترکیب متوالی[7] به این صورت تعریف می‌شود که اگر شما چندین سازوکار تصادفی را به‌طور متوالی روی یک مجموعه داده اجرا کنید، حریم خصوصی شما به‌طور کلی نقض می‌شود. حتی اگر هر یک از این سازوکارها جداگانه ایمن باشند، در نهایت نمی‌توانید حریم خصوصی را تضمین کنید [۱۳]. این اصل ساده اما سرنوشت‌ساز، طراحان الگوریتم‌های حریم خصوصی را مجبور می‌کند بودجهٔ حریم خصوصی را میان سازوکارهای مختلف تقسیم کنند. از آنجایی که بوجه‌ی حریم خصوصی محدود است، اگر تعداد سازوکارهای مختلف زیاد باشد، بودجه‌ی کمی به هر کدام می‌رسد و به سبب آن سودمندی الگوریتم کاهش میابد.

به بیان ریاضی، پس از اجرای k سازوکار مستقل روی یک مجموعه داده که هرکدام $\epsilon-LDP$ هستند، می‌توان گفت الگوریتم کلی ما با بودجه‌ای برابر با مجموع تمام بودجه‌ها، حریم خصوصی تفاضلی را ارضا می‌کند:

[7] Sequential Composition

$$\mathcal{M}_i(x) \quad satisfies \quad \epsilon_i{-}LDP$$

$$\mathcal{M} = \{\mathcal{M}_۱, \mathcal{M}_۲, ..., \mathcal{M}_m\} \quad satisfies \quad \sum_{i=۱}^{m} \epsilon_i{-}LDP$$

در سامانه‌هایی که پرس‌وجوهای[۸] متعدد روی یک معیار داریم (مانند دریافت میزان مصرف باتری هر یک ساعت یکبار)، هر بار باید روی یک داده نوفه اعمال کنیم و به سمت کارپذیر بفرستیم. گرچه مقدار خام داده ممکن است هر بار تغییر کند، ولی چون از یک جنس است و مربوط به یک معیار می‌شود، قانون ترکیب متوالی روی آن صدق می‌کند. بودجه‌ی حریم خصوصی بین تعداد استفاده از سازوکار تصادفی‌سازی تقسیم شده و سودمندی کاهش میابد.

شایان ذکر است که در داده‌های با ابعاد بالا نیز، با چالش ترکیب متوالی روبه‌رو هستیم. در داده‌های با ابعاد بالا، احتمال وجود وابستگی میان ابعاد زیاد می‌شود (مانند ارتباط مستقیم بین سن و میزان درآمد). زمانیکه سازوکارهای تصادفی‌سازی را روی ابعاد وابسته به هم اعمال می‌کنیم، مانند این است که به یک مجموعه داده نوفه تزریق می‌کنیم. از این رو شامل قانون ترکیب متوالی شده و بوجه‌ی حریم خصوصی بین سازوکارها تقسیم می‌شود.

۲ـ۷ ترکیب موازی

در ترکیب موازی[۹]، الگوریتم‌های مختلف حریم خصوصی تفاضلی به طور همزمان روی یک یا چند پایگاه‌داده مجزا از یکدیگر اعمال می‌شوند [۱۴]. در این حالت، بودجه‌ی الگوریتم کلی برابر با حداکثر بودجه‌ی الگوریتم‌هاست:

$$\mathcal{M}_i(x) \quad satisfies \quad \epsilon_i{-}LDP$$

$$\mathcal{M} = \{\mathcal{M}_۱, \mathcal{M}_۲, ..., \mathcal{M}_m\} \quad satisfies \quad \max\{\epsilon_۱, \epsilon_۲, ..., \epsilon_m\}{-}LDP$$

[8] Query
[9] Parallel Composition

۲ـ۸ روش‌های کدگذاری

هر کاربر به منظور ارسال داده‌ها سمت کارپذیر، باید ابتدا اطلاعات خود را در فرمت خاصی کدگذاری[۱۰] کند. اینکار به دو دلیل نیاز است:

۱. افزایش سرعت ارسال پیام

۲. بهبود فرایند تصادفی‌سازی

۲ـ۸ـ۱ کدگذاری مستقیم

کدگذاری مستقیم[۱۱] یکی از روش‌های ساده برای کدگذاری مقادیر ورودی در پروتکل‌های حفاظت از حریم خصوصی محلی است. در این روش، داده‌ی هر کاربر بدون هیچ‌گونه تبدیل اولیه مستقیماً به عنوان خروجی کدگذاری‌شده و ارسال می‌شود. این روش برای مواردی که دامنه داده‌ها کوچک است (مانند داده‌های طبقه‌بندی‌شده یا مقادیر گسسته محدود) مناسب‌تر خواهد بود. این کدگذاری در پژوهش [۱۵] استفاده شده است.

$$v = Encode(v) \tag{۲ـ۱۰}$$

برای تصادفی‌سازی در این کدگذاری، باید از سازوکار تصادفی‌سازی عمومی استفاده کرد. دقت کنید که کارایی و عملکرد این روش با افزایش دامنه، به شدت کاهش میابد. از آنجایی که در الگوریتم تصادفی‌سازی عمومی، مقدار p برابر $\frac{e^{\varepsilon}}{e^{\varepsilon}+k-۱}$ است، با افزایش دامنه یا همان k، احتمال انتخاب شدن مقدار اصلی در تصادفی‌سازی کاهش یافته و به سبب آن، سودمندی دلخواه بدست نمی‌آید. همچنین یکی دیگر از معایب این روش، هزینه‌ی ارتباطی[۱۲] بالا است.

۲ـ۸ـ۲ کدگذاری یکانی

کدگذاری یکانی[۱۳] یکی از روش‌های متداول برای کدگذاری مقادیر ورودی در پروتکل‌های حفاظت از حریم خصوصی تفاضلی محلی است. در این روش، هر مقدار ورودی به یک بردار دودویی با طول ثابت تبدیل

[10] Encode
[11] Direct Encoding
[12] Communication Cost
[13] Unary Encoding

می‌شود. تنها یک بیت از این بردار که نماینده ورودی است، مقدار ۱ دارد و بقیه بیت‌ها ۰ هستند.

$$Encode(v) = [۰, \cdots, ۰, ۱, ۰, \cdots, ۰], \quad \text{only the v-th position is 1} \tag{۲ـ۱۱}$$

به منظور تصادفی‌سازی از فرمول زیر استفاده می‌کنیم. p احتمال ۱ شدن بیتی است که قبلا مقدار ۱ داشته است. همچنین q احتمال ۱ شدن بیتی است که قبلا مقدار ۰ داشته است:

$$\Pr[y = ۱] = \begin{cases} p, & \text{if} \quad x = ۱, \\ \\ q, & \text{if} \quad x = ۰. \end{cases} \tag{۲ـ۱۲}$$

اگر شرط زیر برقرار باشد، می‌توان گفت پروتکل کدگذاری یکانی، حریم خصوصی تفاضلی را ارضا کرده است:

$$\epsilon = \ln\left(\frac{p(۱-q)}{(۱-p)q}\right) \tag{۲ـ۱۳}$$

۲ـ۸ـ۳ کدگذاری یکانی متقارن

پروتکل کدگذاری یکانی متقارن[۱۴] به این صورت تعریف می‌شود که حاصل جمع مقادیر احتمال p و q برابر ۱ باشد:

$$p + q = ۱$$

با توجه به قاعده ۲ـ۱۳، مقادیر p و q به صورت زیر بدست می‌آیند:

$$p = \frac{e^{\epsilon/۲}}{e^{\epsilon/۲} + ۱}, \quad q = \frac{۱}{e^{\epsilon/۲} + ۱}$$

۲ـ۸ـ۴ درهم‌سازی محلی

در پروتکل کدگذاری یکانی، هزینه‌ی ارتباطی به صورت خطی با زیاد شدن دامنه‌ی ورودی، افزایش میابد. از افزایش هزینه در بعضی برنامه‌های کاربردی موجب بروز تاخیر بسیار زیاد در عملکرد سامانه می‌شود.

[14] Symmetric Unary Encoding

بنابراین به پروتکل دیگری نیاز داریم که بزرگ شدن دامنه‌ی ورودی، تاثیر چندانی در هزینه ارتباطی نداشته باشد.

ایده‌ی اولیه این است که از یک تابع درهم‌ساز[۱۵] استفاده کرده و اندازه دامنه‌ی ورودی را کاهش دهیم. این ایده مشکل تصادم[۱۶] را به همراه دارد. به بیان دیگر، دو ورودی به یک خروجی تبدیل شده و در زمان کدگشایی[۱۷] نمی‌توان مقدار درست ورودی را بدست آورد. در پژوهش رپور [۱۶] چندین راه برای حل این مشکل ارائه شده است:

۱. استفاده از چند تابع درهم‌ساز به منظور کاهش احتمال تصادم

۲. استفاده از مفهوم گروه[۱۸] که در آن هر گروه دارای مجموعه‌ای از توابع درهم‌ساز خواهد بود.

البته با توجه به روش‌های مذکور، نمی‌توان به صورت قطعی مشکل تصادم را حل کرد و این مشکل در کاهش سودمندی تأثیر می‌گذارد. روش بهتر این است که هر کاربر توابع درهم‌ساز محلی خود را داشته باشد. به این روش، درهم‌ساز محلی[۱۹] می‌گوییم. این روش به صورت کارا در الگوریتم‌های حفظ حریم خصوصی تفاضلی محلی استفاده می‌شود. کاربران با کمک توابع درهم‌ساز، ابتدا دامنه‌ی داده‌های خود را کاهش داده، تصادفی‌سازی کرده و در نهایت به سمت کارپذیر ارسال می‌کنند. در ادامه تعریف درهم‌ساز محلی دودویی را ارائه می‌دهیم:

تعریف ۲ـ۷ (درهم‌ساز محلی دودویی) *فرض کنید $\mathbb{H}$ یک خانواده جهانی از توابع درهم‌ساز باشد. هر تابع درهم‌ساز $H \in \mathbb{H}$، یک ورودی با دامنه‌ی d را به یک عدد تک بیتی تبدیل می‌کند. شرطی روی این خانواده از توابع درهم‌ساز اعمال می‌شود به صورت زیر خواهد بود:*

$$\forall x, y \in [d], x \neq y : \Pr_{H \in \mathbb{H}}[H(x) = H(y)] \leqslant \frac{۱}{۲} \qquad (۱۴ـ۲)$$

به منظور تصادفی‌سازی از فرمول زیر استفاده می‌کنیم:

$$\mathrm{Perturb}_{\mathrm{BLH}}(\langle H, b\rangle) = \langle H, b'\rangle, \quad \Pr[b' = ۱] = \begin{cases} p = \dfrac{e^{\epsilon}}{e^{\epsilon} + ۱}, & \text{if} \quad b = ۱ \\ q = \dfrac{۱}{e^{\epsilon} + ۱}, & \text{if} \quad b = ۰ \end{cases}$$

[15] Hash Function
[16] Collision
[17] Decode
[18] Cohort
[19] Local Hashing

۲ـ۸ـ۵ بلوم فیلتر

بلوم‌فیلتر[۲۰] یک ساختار داده‌ای است که هدف اصلی آن انجام عملیات بررسی عضویت (یعنی تعیین اینکه یک عنصر در مجموعه‌ای وجود دارد یا خیر) با استفاده حداقلی از حافظه است. این فیلتر به ما کمک می‌کند تا سریعاً امکان وجود یک عنصر را بدون نیاز به ذخیره کل مجموعه در حافظه تشخیص دهیم.

فرض کنید آرایه‌ای از بیت‌ها (معمولاً همه صفر) و چند تابع درهم‌ساز داریم. مطابق شکل ۲ـ۲ زمان درج هر عنصرِ جدید، آن را با همه توابع درهم‌سازی کرده و مقدار ۱ برای بیت‌های متناظر درنظر گرفته می‌شود. دقت کنید که ممکن است درهم‌سازی توابع، تصادم داشته باشد و چند بیت ۱ روی هم بیفتند. هنگام پرس‌وجوی عنصر، دوباره باید با همه‌ی توابع درهم‌سازی شود و اگر همه‌ی بیت‌های متناظر یک باشند، می‌گوییم این عنصر احتمالاً در آرایه وجود دارد. حتی اگر یکی صفر باشد قطعاً عنصر مورد نظر در آرایه وجود ندارد. با تنظیم اندازهٔ آرایه و تعداد توابع هش، می‌توان احتمال خطا را به دلخواه کم کرد. از همین ویژگی در پژوهش رپور نیز بهره گرفته شده تا رشته‌های دلخواه کاربران به‌صورت فشرده و بی‌نیاز از فهرست پیش‌تعریف‌شده گزارش شود و حریم خصوصی حفظ گردد.

بلوم فیلتر در بسیاری از سیستم‌ها و سرویس‌ها استفاده می‌شود از جمله:

- گوگل کروم: برای ویژگی مرور امن[۲۱] از بلوم فیلتر استفاده می‌شود تا به سرعت خطرناک بودن آدرس‌های اینترنتی را بررسی کند.
- مدیُم[۲۲]: از بلوم فیلتر برای جلوگیری از نمایش پست‌هایی که کاربر قبلاً دیده است، استفاده می‌کند.
- کساندرا[۲۳] و اچ بیس[۲۴]: برای بهینه‌سازی جستجوی داده‌ها در جدول‌های ذخیره‌شده در دیسک استفاده می‌شود.
- آکامای[۲۵]: در سرویس‌های حافظه نهان[۲۶] خود برای بهبود سرعت و کارایی تحویل محتوا از بلوم فیلتر استفاده می‌کند.

---

[20] Bloom Filter
[21] Safe Browsing
[22] Medium
[23] Cassandra
[24] HBase
[25] Akamai
[26] Cache

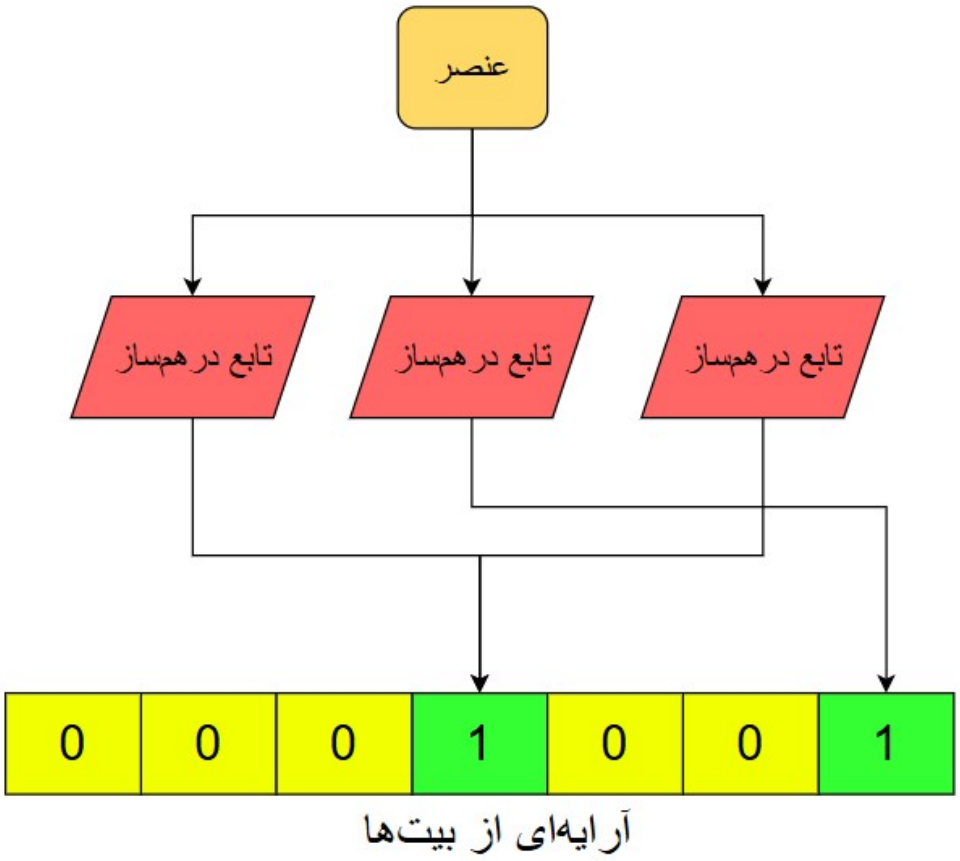

شکل ۲ـ۲: شیوه‌ی درج عنصر با استفاده از بلوم فیلتر

۲ـ۸ـ۶ علائم ریاضی پرکاربرد

برخی علائم ریاضی پرکاربرد در زیر فهرست شده‌اند. برای مشاهده‌ی دستور معادل پرونده‌ی منبع را ببینید.

- مجموعه‌های اعداد: $\mathbb{N}, \mathbb{Z}, \mathbb{Z}^+, \mathbb{Q}, \mathbb{R}, \mathbb{C}$
- مجموعه: $\{۱, ۲, ۳\}$
- دنباله: $\langle ۱, ۲, ۳ \rangle$
- سقف و کف: $\lceil x \rceil , \lfloor x \rfloor$
- اندازه و متمم: $|A| , \overline{A}$
- همنهشتی: $a \overset{n}{\equiv} ۱$ یا (پیمانه‌ی n) $a \equiv ۱$
- ضرب و تقسیم: $\times, \cdot, \div$

- سه‌نقطه: $۱, ۲, \ldots, n$
- کسر و ترکیب: $\frac{n}{k}, \binom{n}{k}$
- اجتماع و اشتراک: $A \cup (B \cap C)$
- عملگرهای منطقی: $\neg p \vee (q \wedge r)$
- پیکان‌ها: $\rightarrow, \Rightarrow, \leftarrow, \Leftarrow, \leftrightarrow, \Leftrightarrow$
- عملگرهای مقایسه‌ای: $\neq, \leqslant, \nleqslant, \geqslant, \ngeqslant$
- عملگرهای مجموعه‌ای: $\in, \notin, \setminus, \subset, \subseteq, \subsetneq, \supset, \supseteq, \supsetneq$
- جمع و ضرب چندتایی: $\sum_{i=۱}^{n} a_i, \prod_{i=۱}^{n} a_i$
- اجتماع و اشتراک چندتایی: $\bigcup_{i=۱}^{n} A_i, \bigcap_{i=۱}^{n} A_i$
- برخی نمادها: $\infty, \emptyset, \forall, \exists, \triangle, \angle, \ell, \equiv, \therefore$

۲ـ۸ـ۷ درج جدول

برای درج جدول می‌توانید با استفاده از دستور «جدول» جدول را ایجاد کرده و سپس با دستور «لوح» آن را درون متن درج کنید. برای نمونه جدول ۲ـ۱ را ببینید.

جدول ۲ـ۱: عملگرهای مقایسه‌ای

عملگر	عنوان
<	کوچک‌تر
>	بزرگ‌تر
==	مساوی
<>	نامساوی

۲ـ۸ـ۸ درج الگوریتم

برای درج الگوریتم می‌توانید از محیط «الگوریتم» استفاده کنید. یک نمونه در الگوریتم ۱ آمده است.

الگوریتم ۱ پوشش رأسی حریصانه

ورودی: گراف $G = (V, E)$

خروجی: یک پوشش رأسی از G

۱: قرار بده $C = \emptyset$

۲: تا وقتی E تهی نیست:

۳: یال دل‌خواه $uv \in E$ را انتخاب کن

۴: رأس‌های u و v را به C اضافه کن

۵: تمام یال‌های واقع بر u یا v را از E حذف کن

۶: C را برگردان

۲ـ۸ـ۹ محیط‌های ویژه

برای درج مثال‌ها، قضیه‌ها، لم‌ها و نتیجه‌ها به ترتیب از محیط‌های «مثال»، «قضیه»، «لم» و «نتیجه» استفاده کنید. برای درج اثبات قضیه‌ها و لم‌ها از محیط «اثبات» استفاده کنید.

تعریف‌های داخل متن را با استفاده از دستور «مهم» به صورت **تیره** نشان دهید. تعریف‌های پایه‌ای‌تر را درون محیط «تعریف» قرار دهید.

تعریف ۲ـ۸ (اصل لانه‌کبوتری) *اگر $n + ۱$ کبوتر یا بیش‌تر درون n لانه قرار گیرند، آن‌گاه لانه‌ای وجود دارد که شامل حداقل دو کبوتر است.*

۲ـ۹ برخی نکات نگارشی

این فصل حاوی برخی نکات ابتدایی ولی بسیار مهم در نگارش متون فارسی است. نکات گردآوری‌شده در این فصل به هیچ وجه کامل نیست، ولی دربردارنده‌ی حداقل مواردی است که رعایت آن‌ها در نگارش پایان‌نامه ضروری به نظر می‌رسد.

۲ـ۹ـ۱ فاصله‌گذاری

۱. علائم سجاوندی مانند نقطه، ویرگول، دونقطه، نقطه‌ویرگول، علامت سؤال و علامت تعجب بدون فاصله از کلمه‌ی پیشین خود نوشته می‌شوند، ولی بعد از آن‌ها باید یک فاصله قرار گیرد. مانند: من،

تو، او.

۲. علامت‌های پرانتز، آکولاد، کروشه، نقل قول و نظایر آن‌ها بدون فاصله با عبارات داخل خود نوشته می‌شوند، ولی با عبارات اطراف خود یک فاصله دارند. مانند: (این عبارت) یا {آن عبارت}.

۳. دو کلمه‌ی متوالی در یک جمله همواره با یک فاصله از هم جدا می‌شوند، ولی اجزای یک کلمه‌ی مرکب باید با نیم‌فاصله[۲۷] از هم جدا شوند. مانند: کتاب درس، محبت‌آمیز، دوبخشی.

۴. اجزای فعل‌های مرکب با فاصله از یک‌دیگر نوشته می‌شوند، مانند: تحریر کردن، به سر آمدن.

۲ـ۹ـ۲ شکل حروف

۱. در متون فارسی به جای حروف «ك» و «ي» عربی باید از حروف «ک» و «ی» فارسی استفاده شود. همچنین به جای اعداد عربی مانند ٥ و ٦ باید از اعداد فارسی مانند ۵ و ۶ استفاده نمود. برای این کار، توصیه می‌شود صفحه‌کلید فارسی استاندارد را روی سیستم خود فعال کنید.

۲. عبارات نقل‌قول‌شده یا مؤکد باید درون علامت نقل قولِ «» قرار گیرند، نه "". مانند: «کشور ایران».

۳. کسره‌ی اضافه‌ی بعد از «ه» غیرملفوظ به صورت «ه‌ی» یا «هٔ» نوشته می‌شود. مانند: خانه‌ی علی، دنباله‌ی فیبوناچی.
تبصره: اگر «ه» ملفوظ باشد، نیاز به «ی» ندارد. مانند: فرمانده دلیر، پادشه خوبان.

۴. پایه‌های همزه در کلمات، همیشه «ئـ» است، مانند: مسئله و مسئول، مگر در مواردی که همزه ساکن است که در این صورت باید متناسب با اعراب حرف پیش از خود نوشته شود. مانند: رأس، مؤمن.

۲ـ۹ـ۳ جدانویسی

۱. علامت استمرار، «می»، توسط نیم‌فاصله از جزء بعدی فعل جدا می‌شود. مانند: می‌رود، می‌توانیم.

۲. شناسه‌های «ام»، «ای»، «ایم»، «اید» و «اند» توسط نیم‌فاصله، و شناسه‌ی «است» توسط فاصله از کلمه‌ی پیش از خود جدا می‌شوند. مانند: گفته‌ام، گفته‌ای، گفته است.

۳. علامت جمع «ها» توسط نیم‌فاصله از کلمه‌ی پیش از خود جدا می‌شود. مانند: این‌ها، کتاب‌ها.

[۲۷] «نیم‌فاصله» فاصله‌ای مجازی است که در عین جدا کردن اجزای یک کلمه‌ی مرکب از یک‌دیگر، آن‌ها را نزدیک به هم نگه می‌دارد. معمولاً برای تولید این نوع فاصله در صفحه‌کلیدهای استاندارد از ترکیب Shift+Space استفاده می‌شود.

۴. «به» همیشه جدا از کلمه‌ی بعد از خود نوشته می‌شود، مانند: به نام و به آن‌ها، مگر در مواردی که «بـ» صفت یا فعل ساخته است. مانند: بسزا، ببینم.

۵. «به» همواره با فاصله از کلمه‌ی بعد از خود نوشته می‌شود، مگر در مواردی که «به» جزئی از یک اسم یا صفت مرکب است. مانند: تناظر یک‌به‌یک، سفر به تاریخ.

۶. علامت صفت برتری، «تر»، و علامت صفت برترین، «ترین»، توسط نیم‌فاصله از کلمه‌ی پیش از خود جدا می‌شوند. مانند: سنگین‌تر، مهم‌ترین.

تبصره: کلمات «بهتر» و «بهترین» را می‌توان از این قاعده مستثنی نمود.

۷. پیشوندها و پسوندهای جامد، چسبیده به کلمه‌ی پیش یا پس از خود نوشته می‌شوند. مانند: همسر، دانشکده، دانشگاه.

تبصره: در مواردی که خواندن کلمه دچار اشکال می‌شود، می‌توان پسوند یا پیشوند را جدا کرد. مانند: هم‌میهن، هم‌ارزی.

۸. ضمیرهای متصل چسبیده به کلمه‌ی پیش از خود نوشته می‌شوند. مانند: کتابم، نامت، کلامشان.

فصل ۳

کارهای پیشین

در این فصل به بررسی کارها و پژوهش‌های پیشین در دو حوزه داده‌های ابعاد بالا و داده‌های در حال تغییر می‌پردازیم. ابتدا چالش‌های هر کدام را بررسی کرده و راه‌حل‌های موجود را بیان می‌کنیم. همچنین مزایا و معایب هر کدام ارائه می‌شود تا مناسب‌ترین راه‌حل مشخص شود.

۳ـ۱ داده‌های با ابعاد بالا

هنگام جمع‌آوری داده‌های چندبُعدی با حفظ حریم خصوصی تفاضلی، کارپذیر ابتدا داده‌ی نوفه‌دار شده‌ی هر شخص یا برنامه کاربردی را دریافت کرده و سپس شروع به تحلیل آماری روی هر بعد می‌کند. در اغلب شیوه‌های رایجِ جمع‌آوری داده‌های چندبُعدی، برای صیانت از حریم خصوصی کاربران، هر ویژگی را جداگانه نوفه‌دار می‌کنند. با توجه به قانون ترکیب متوالی ناچارا بودجه‌ی محدود حریم خصوصی میان همهٔ ابعاد پخش می‌شود. کاهش بودجه موجب تزریق نوفه بیش از اندازه شده و در نتیجه سودمندی به شکل چشمگیری کاهش میابد.

به بیان دیگر در داده‌های با ابعاد بالا، چالش اصلی به همبستگی‌های احتمالی بین ابعاد مختلف بازمی‌گردد. این همبستگی‌ها باعث می‌شود تغییر در یک بعد به تغییرات در ابعاد دیگر منجر شود و حساسیت کل سیستم افزایش یابد. در اکثر الگوریتم‌های حافظ حریم خصوصی تفاضلی، افزایش حساسیت موجب اضافه‌شدن بیش از اندازه‌ی نوفه به داده‌ها خواهد شد. بنابراین، یافتن رویکردهایی که بتوانند حساسیت را کاهش دهند یا از روش‌های هوشمندانه‌تر برای تخصیص نوفه استفاده کنند، ضروری است.

برای نمونه، سازوکار کلاسیک لاپلاس [۱۷]، نوفه در توزیع لاپلاس را به صورت تصادفی روی تک‌تک

بُعدها اعمال می‌کند. در این روش، مقدار نوفه به‌شکلی بیش‌ازخطی با تعداد ابعاد رشد می‌کند و بدین ترتیب سودمندی داده‌های چندبُعدی به‌شدّت افت خواهد کرد. در ادامه با راه‌حل‌های این چالش بیشتر آشنا می‌شویم.

۳ـ۱ـ۱ نمونه‌برداری

معمولا مقالاتی که روی داده‌های با ابعاد بالا کار می‌کنند، از نمونه‌برداری استفاده می‌کنند. در واقع سعی می‌کنند بخشی از داده را به عنوان نماینده‌ی تمام داده‌ها در نظر گرفته و فقط برای آن بخش الگوریتم‌های حفظ حریم خصوصی تفاضلی اعمال شود. با این کار، تنها به بخشی از داده‌ها، نوفه تزریق می‌شود. البته یکی از مشکلات نمونه‌برداری این است که نیازمند تعداد بسیار زیادی کاربر خواهد بود تا بتوان اطلاعات آماری مفیدی از کل داده‌ها به دست آورد.

پژوهش دوچی و همکاران

سازوکار تکه‌ای[1] که توسط دوچی ارائه شده است [۱۸]، برای حل مشکل تقسیم بودجهٔ حریم خصوصی، سراغ نمونه‌گیری از داده می‌رود. در این پژوهش داده‌ها به صورت بردار و مختصات درنظر گرفته می‌شوند. در واقع هر رکورد (مثلاً یک کاربر، یک حسگر، یا یک آزمایش) دارای مجموعه‌ای از ویژگی‌ها است و می‌توانیم این ویژگی‌ها را مانند محورهای یک فضای چندبعدی تصور کنیم. فرض کنید سه ویژگی «سن»، «قد» و «درآمد» داریم؛ آن‌گاه هر فرد نقطه‌ای در فضای سه‌بعدی است که مختصاتش به‌ترتیب عدد سن، قد و درآمد اوست. برای نمونه اگر ۱۰۰ خصوصیت زیستی یا آماری داشته باشیم، همان نقطه اکنون در فضایی ۱۰۰بعدی قرار می‌گیرد و برداری با ۱۰۰ عدد پی‌درپی تشکیل می‌دهد. بنابراین «بردار» صرفاً لیستی منظم از مقادیر است و «مختصات» خانه‌های این لیست‌اند که به هر ویژگی برچسب می‌زنند.

سازوکار تکه‌ای برای آن‌که بتواند تحلیل‌های آماری روی بردارهای با ابعاد بالا را با حفظ حریم خصوصی محلی انجام دهد، به‌جای افزودن نوفه مستقل به تک‌تک مختصات (کاری که در ابعاد زیاد دقّت را نابود می‌کند)، نوفه به بردارهای «خلاصه» شده وارد می‌شود. به صورت خلاصه، در یک عملیات پیچیده، کاربر با پرتاب سکه، یک نوفه‌ی خاص را روی جهت بردار اعمال می‌کند. به بیان دیگر نوفه فقط به مختصات مؤثر، تزریق می‌شود و اندازه‌ی بردار دستکاری نمی‌گردد.

چندین پژوهش تلاش کردند تا از ویژگی‌های همبسته نمونه برداری کنند. با این کار، بودجه‌ی حریم خصوصی را به شکل هوشمندانه بین ابعاد داده پخش می‌کنند. به منظور یافتن ویژگی‌های همبسته، معمولا

[1] Piecewise

از دو مفهوم آماری **اطلاعات متقابل** و **بی‌نظمی** استفاده می‌شود.

اطلاعات متقابل معیاری ست که میزان اطلاعاتی را که یک متغیر تصادفی در مورد متغیر دیگر به ما می‌دهد، اندازه‌گیری می‌کند. یعنی اگر یکی را بدانیم، عدم قطعیتِ ما درباره‌ی دیگری تا چه حد کم می‌شود. هرچه مقدار این معیار بیشتر باشد، وابستگی یا هم‌بستگی میان آن دو متغیّر قوی‌تر است.

تعریف ۳ـ۱ (اطلاعات متقابل) *از دید ریاضی، برای دو متغیّر تصادفی گسسته‌ی X و Y با توزیع مشترک $p(x,y)$ و توزیع‌های حاشیه‌ای $p(x)$ و $p(y)$، اطلاعات متقابل چنین تعریف می‌شود:*

$$I(X;Y) = \sum_x \sum_y \hat{P}(x,y) \log \frac{\hat{P}(x,y)}{\hat{P}(x)\hat{P}(y)} \qquad (۳ـ۱)$$

بی‌نظمی[۲]، که در فیزیک و نظریه‌ی اطلاعات به نام «آنتروپی» شناخته می‌شود، معیاری برای سنجش پراکندگی حالت‌های یک سامانه است. هرچه تعداد حالت‌های ممکنِ سازگار با مشاهدهٔ ما بیش‌تر باشد، پیش‌بینی رفتار آینده‌ی سامانه دشوارتر و «بی‌نظمی» آن بالاتر است؛ برعکس، در سامانه‌های منظم، گزینه‌های کمتری برای چگونگی چیدمان اجزا وجود دارد و قطعیت بیش‌تری داریم. به زبان ساده، آنتروپی اندازه‌ای از بی‌خبری یا عدم قطعیت ما درباره‌ی وضعیت دقیق اجزاست.

پژوهش چن و همکاران

پژوهش چن و همکاران [۱۹] روشی به نام سم‌پرایوسین ارائه می‌دهد که براساس اطلاعات متقابل[۳]، ارتباط میان ویژگی‌ها را بدست آورده و تنها از جفت ویژگی‌هایی که بیشترین ارتباط را دارند، نمونه‌برداری می‌کند. این پژوهش به‌جای ارسالِ کلِ رکورد و نوفه‌دار کردن همه‌ی ابعاد، تنها یک جفت ویژگی از هر کاربر را انتخاب و پس از نوفه‌دار کردن همان دو مقدار، به کارپذیر می‌فرستد. انتخاب این جفت ویژگی تصادفی نیست؛ احتمال برگزیده‌شدن هر زوج، متناسب با اطلاعات متقابل به‌روزشده‌ی آن‌ها است. زوج‌هایی که بیش‌ترین هم‌بستگی را دارند، با احتمال بیشتری انتخاب شده و ساختار واقعیِ داده تا حد ممکن حفظ می‌شود. سپس هر یک از دو مقدار انتخاب‌شده با بودجهٔ $\epsilon/۲$ نوفه‌دار می‌شود. بدین ترتیب کل فرایند همچنان $\epsilon-LDP$ باقی می‌ماند، در حالی که حجم ارتباطی و نوفه تزریق‌شده فقط به همان دو بُعد محدود می‌شود. در ادامه، این داده‌های نمونه‌برداری‌شده برای بازسازی مجموعه داده‌های مصنوعی به کار می‌روند و همچنان ارتباط میان ویژگی‌ها حفظ می‌شود.

[2] Entropy
[3] Mutual Information

پژوهش وانگ و همکاران

پژوهشی که توسط وانگ و همکاران [۲۰] انجام شده است، یک الگوریتم حافظ حریم خصوصی تفاضلی برای جمع‌آوری داده‌های عددی ارائه می‌دهد. سپس الگوریتم خود را برای داده‌های چند بُعدی گسترش می‌دهد. این پژوهش ابتدا توضیح می‌دهد که واریانس[۴] کمتر در الگوریتم‌های حریم خصوصی به معنای دقت بیشتر در میانگین نتایج است. سازوکار تکه‌ای [۱۸] واریانس بالایی داشته و دقت نتایج پایین است. برای داده‌های چندبعدی، نویسندگان به دو مشکل اصلی سازوکار تکه‌ای اشاره می‌کنند. اول اینکه این الگوریتم پیچیدگی بالایی دارد و دوم اینکه تنها برای مقادیر عددی قابل استفاده است. به همین دلیل، نویسندگان دو الگوریتم جدید به نام‌های پی‌ـام و اچ‌ـام معرفی می‌کنند که با کاهش واریانس، نتایج دقیق‌تری ارائه می‌دهند. **سازوکار پی‌ـام** برای هر عدد در بازه‌ی $[-۱, ۱]$ سه ناحیه تعریف می‌کند: یک قطعه‌ی مرکزی و دو قطعه‌ی کناری در چپ و راست. ابتدا با یک پرتاب تصادفی تصمیم می‌گیرد در کدام ناحیه نمونه بردارد. احتمال افتادن در قطعهٔ مرکزی عمداً بیشتر است تا خروجی غالباً به مقدار حقیقی نزدیک بماند، ولی اگر به قطعات کناری برود فاصله‌ی بیشتری با مقدار اصلی پیدا می‌کند. این فاصله همان نوفه‌ای است که باعث حفظ حریم خصوصی تفاضلی می‌شود. به این ترتیب داده همچنان در بازه‌ای محدود باقی می‌مانند و با کوچک‌تر شدن مقدار نوفه، واریانس نیز پایین می‌آید، در نتیجه دقّت حفظ می‌شود.

سازوکار اِچ‌ـاِم ترکیبی هوشمندانه از پی‌ـاِم و تکه‌ای است. هر بار که می‌خواهد داده را نوفه‌دار کند، سکه‌ای پرتاب می‌شود که با احتمال α شیر می‌آید. اگر شیر آمد، پی‌ـاِم اجرا می‌شود؛ اگر خط آمد، همان روش تکه‌ای به کار می‌رود. مقدار α به‌طور تحلیلی طوری انتخاب می‌شود که کل واریانس نوفه را در بدترین حالت کمینه کند. با توجه به پی‌ـام ،برای ϵ بزرگ α تقریباً یک است، و با توجه به روش تکه‌ای، برای ϵ خیلی کوچک α به صفر میل خواهد کرد. بنابراین اِچ‌ـاِم در همهٔ شرایط از هر دو رقیب یا بهتر است یا دست‌کم بدتر نمی‌شود.

برای رفع مشکل داده‌های با ابعاد بالا، پژوهش یک الگوریتم جدید پیشنهاد می‌دهد. این الگوریتم بیان می‌کند که نیازی نیست همه ابعاد داده نوفه‌دار شوند. کافیست تنها به ابعاد محدودی که به صورت تصادفی انتخاب می‌شوند، نوفه اضافه کرد. اگر k بُعد را انتخاب کنیم، باید بودجه‌ی حریم خصوصی ϵ/k را به هر بُعد اختصاص دهیم. چون k معمولاً خیلی کوچک‌تر از تعداد کل ابعاد است، هر ویژگی سهم بودجه‌ی بزرگ‌تری می‌گیرد و نوفه‌ی کمتری به آن تزریق می‌شود. در نتیجه سامانه می‌تواند روی داده‌های با ابعاد بالا تحلیل‌های آماری مثل میانگین یا حتی گرادیان‌های یادگیری ماشین را با خطای کمی برآورد کند.

[4] Variance

پژوهش آرکولزی و همکاران

پژوهش [۲۱] نیز از نمونه‌برداری در الگوریتم خود استفاده کرده‌است. این مقاله یک راهکار جدید برای چالش جمع‌آوری داده‌های چندبُعدی و در حال تغییر تحت محدودیت‌های حریم خصوصی تفاضلی محلی ارائه می‌دهد. مشکل اصلی این است که وقتی چندین ویژگی از یک کاربر در بازه‌های زمانی مختلف جمع‌آوری می‌شود، حفظ حریم خصوصی به شدت دشوار شده و سودمندی کاهش می‌یابد. این پژوهش با بهبود پروتکل‌های موجود و ارائه یک الگوریتم جدید به نام الومفری[۵]، راهکار جامعی برای تخمین شمارش داده‌ها فراهم می‌کند.

راهکار این پژوهش برای مدیریت داده‌های با ابعاد بالا، بر یک ایده هوشمندانه استوار است. به جای اینکه هر کاربر بخشی از بودجه حریم خصوصی خود را به هر یک از ویژگی‌هایش اختصاص دهد، به صورت تصادفی تنها یک ویژگی را انتخاب کرده و تمام بودجه حریم خصوصی را به همان یک ویژگی اختصاص می‌دهد. روش الومفری برای حفظ کارایی به صورت تطبیقی و هوشمندانه عمل می‌کند. پس از اینکه کاربر یک ویژگی را به صورت تصادفی انتخاب کرد، روش الموفری بر اساس مشخصات آن ویژگی (به‌ویژه تعداد مقادیر ممکن برای آن) و پارامترهای حریم خصوصی، محاسبه می‌کند که کدام پروتکل از بین پاسخ تصادفی عمومی و کدگذاری یکانی متقارن خطای کمتری خواهد داشت.

در واقع پروتکلی که واریانس کمتری تولید می‌کند، برای ارسال داده انتخاب می‌شود. به عبارت دیگر، الومفری به‌جای استفاده از یک راه‌حل ثابت، بهترین ابزار را برای هر موقعیت خاص انتخاب می‌کند و در نتیجه دقت تخمین شمارش به شدت بهبود می‌یابد. این پژوهش علاوه بر فعالیت در زمینه‌ی داده‌های با ابعاد بالا، در خصوص داده‌های در حال تغییر نیز راه‌حل‌هایی ارائه می‌کند که در بخش‌های بعدی توضیح می‌دهیم.

۳ـ۱ـ۲ خوشه‌بندی

یک راه‌حل اساسی برای اختصاص هدفمند بودجه‌ی حریم خصوصی به ابعاد داده، خوشه‌بندی[۶] است. معمولا ابعاد همبسته در یک دسته قرار می‌گیرند. با توجه به اینکه درون هر دسته چند ویژگی قرار می‌گیرد، می‌توان بودجه‌ی حریم خصوصی را به شکل بهتری تقسیم کرد. به بیان دیگر، باید به خوشه‌ای که اعضای بیشتری دارد، بودجه‌ی بیشتری نیز تخصیص داد. زیرا بر اساس قانون ترکیب متوالی، بودجه‌ی هر دسته بین اعضای آن دسته تقسیم می‌شود و ممکن است بودجه‌ی بسیار کمی به یکی از ویژگی‌ها برسد.

[5] ALLOMFREE
[6] Clustering

در بدترین حالت تمام ابعاد داده‌ی یک سامانه یا برنامه کاربردی داخل یک دسته قرار می‌گیرند. در این حالت بودجه‌ی حریم خصوصی ما باید بین تمام ویژگی‌ها تقسیم شود و در نتیجه بودجه‌ی بسیار کمی به هر ویژگی می‌رسد. از آنجایی که این بودجه‌ی کلی محدود است، سودمندی داده‌ها به شدت افت خواهد کرد.

پیش‌نیاز دسته‌بندی مناسب، پیدا کردن ابعاد همسته یا تقریبا همبسته است. پژوهش‌های مختلف روش‌های متنوعی برای پیدا کردن ابعاد وابسته به هم، ارائه کرده‌اند. از جمله این روش‌ها می‌توان به اندازه‌گیری اطلاعات متقابل، بی‌نظمی و یادگیری ماشین اشاره کرد.

پژوهش رِن و همکاران

پژوهش [۱] جزو اصلی‌ترین پژوهش‌های مربوط به حوضه‌ی حفظ حریم خصوصی تفاضلی در داده‌های با ابعاد بالا است. این پژوهش راهکاری به اسم لوپاب[۷] ارائه می‌دهد که دارای چهار گام اصلی است.

در گام اول داده‌ها به صورت محلی نوفه‌دار شده و حفاظت از حریم خصوصی در مبدأ انجام می‌شود. این گام اولین و حیاتی‌ترین مرحله برای تضمین حریم خصوصی تفاضلی محلی است. هر کاربر قبل از ارسال داده‌های خود به کارپذیر، دو کار روی آن انجام می‌دهد:

۱. استفاده از بلوم فیلتر و تبدیل ویژگی‌های کاربر به رشته‌ای از بیت‌ها: این کار داده‌ها را به یک فرمت استاندارد و قابل پردازش تبدیل می‌کند.

۲. آشفته‌سازی داده‌ها با کمک سازوکار پاسخ تصادفی: پس از ایجاد رشته بیتی، هر بیت با یک احتمال مشخص به صورت تصادفی تغییر می‌کند.

در نهایت، کاربر این رشته بیت‌های نوفه‌دار شده و بی‌معنی را به کارپذیر ارسال می‌کند و داده‌های اصلی هرگز از دستگاه کاربر خارج نمی‌شوند.

در گام دوم تخمین احتمال توزیع داده‌های چند بُعدی انجام می‌گیرد. اکنون کارپذیر مجموعه‌ای عظیم از رشته بیت‌های نوفه‌دار شده را در اختیار دارد. چالش این است که چگونه از این داده‌های آشفته، الگوهای آماری و احتمال توزیع مشترک داده‌های اصلی را بازسازی کند. مقاله سه الگوریتم برای این کار پیشنهاد می‌کند:

۱. الگوریتم مبتنی بر حداکثر تابع درست‌نمایی[۸] (به اختصار، ای.اِم): روشی دقیق اما از نظر محاسباتی بسیار سنگین و کند است و برای داده‌های با ابعاد بالا عملی نیست.

[7] LoPub
[8] Expectation Maximization

۲. الگوریتم مبتنی بر رگرسیون لاسو [۹]: روشی بسیار سریع‌تر و کارآمدتر که به خصوص برای داده‌های پراکنده مناسب است. این روش با تخمین تعداد واقعی شمارش‌ها از روی شمارش‌های نوفه‌دار شده کار می‌کند.

۳. الگوریتم ترکیبی[۱۰]: این الگوریتم بهترین ویژگی‌های دو روش قبل را ترکیب می‌کند. ابتدا با استفاده از روش سریع لاسو یک تخمین اولیه و خوب از توزیع داده‌ها به دست می‌آورد و ترکیبات داده‌ای پرتکرار را شناسایی می‌کند. سپس با استفاده از روش دقیق ای.اِم این تخمین اولیه را روی داده‌های فیلتر شده پالایش می‌کند. این رویکرد تعادلی مناسب بین سرعت و دقت برقرار می‌کند.

در گام سوم کاهش ابعاد[۱۱] صورت می‌گیرد. پردازش همزمان تمام ویژگی‌ها در داده‌های با ابعاد بالا بسیار دشوار است. هدف در این مرحله، شناسایی و گروه‌بندی ویژگی‌های مرتبط با یکدیگر است تا بتوان آن‌ها را در دسته‌های کوچکتر پردازش کرد. با استفاده از توزیع‌های تخمین‌زده شده در گام قبل، میزان وابستگی از فرمول اطلاعات متقابل ۳ـ۱ محاسبه می‌شود. به منظور کاهش ابعاد، درخت اتصال[۱۲] در چهار مرحله ساخته می‌شود:

۱. ابتدا یک گراف همبستگی ساخته شده که در آن گره‌ها، همان ویژگی‌ها هستند. همچنین یال‌ها نمایانگر وجود وابستگی قوی بین دو ویژگی هستند. به بیان دیگر اگر میزان اطلاعات متقابل بین دو ویژگی از یک آستانه مشخص بیشتر باشد، یک یال بین آن‌ها کشیده می‌شود.

۲. در گراف وابستگی ممکن است دورهای طولانی وجود داشته باشد. یک دور، مسیری است که از یک گره شروع شده و دوباره به همان گره برمی‌گردد. وجود چنین دورهایی، تجزیه گراف به بخش‌های مستقل را بسیار دشوار می‌کند. به همین دلیل، مثلث‌سازی[۱۳] صورت می‌گیرد تا تمام این دورهای طولانی را از بین ببریم. در مثلث‌سازی، با رویکرد الگوریتمی یال‌هایی به گراف اضافه می‌شود. با اضافه کردن این یال‌ها، هر دور طولانی به مجموعه‌ای از مثلث‌ها شکسته می‌شود.

۳. در مرحله‌ی سوم «خوشه‌های بیشینه[۱۴]» شناسایی می‌شوند. به زیرمجموعه‌ای از گره‌های گراف که در آن هر گره به تمام گره‌های دیگر آن زیرمجموعه متصل است، خوشه می‌گویند. به خوشه‌ای که توان با اضافه کردن گره دیگری آن را بزرگتر کرد، خوشه‌ی بیشینه می‌گویند. این خوشه‌ها بزرگترین گروه‌های کاملاً همبسته در شبکه ما هستند.

[9] Lasso Regression
[10] Hybrid
[11] Dimensionality Reduction
[12] Junction Tree
[13] Triangulation
[14] Maximal Clique

۴. اکنون که خوشه‌های بیشینه را داریم، باید آن‌ها را به هم وصل کنیم تا درخت اتصال ساخته شود. بین هر دو خوشه‌ی بیشنیه که گره‌های مشترکی دارند، یک یال می‌کشیم. وزن این یال برابر با تعداد گره‌های مشترک بین آن دو خوشه است. گراف حاصل، هنوز یک درخت کامل نیست و ممکن است دور داشته باشد. برای تبدیل آن به درخت، از الگوریتم درخت پوشای بیشینه[۱۵] استفاده می‌کنیم. این الگوریتم به ما تضمین می‌دهد که مجموع وزن یال‌ها بیشینه باشد و همچنین هیچ دوری در گراف نهایی وجود نداشته باشد.

در شکل ۳ـ۱ یک مثال از ساخت درخت اتصال را مشاهده می‌کنید. این ساختار درختی تضمین می‌کند که ویژگی «تقاطع جاری[۱۶]» برقرار باشد. یعنی اگر یک ویژگی در دو خوشه مختلف در درخت وجود داشته باشد، حتماً در تمام خوشه‌هایی که در مسیر بین آن دو قرار دارند نیز وجود دارد. این ویژگی برای انجام محاسبات احتمالی به صورت بهینه و دقیق حیاتی است. به این ترتیب، یک شبکه پیچیده از وابستگی‌ها به یک ساختار درختی منظم تبدیل می‌شود که می‌توان محاسبات را به صورت محلی روی هر خوشه انجام داد و نتایج را در طول درخت منتشر کرد.

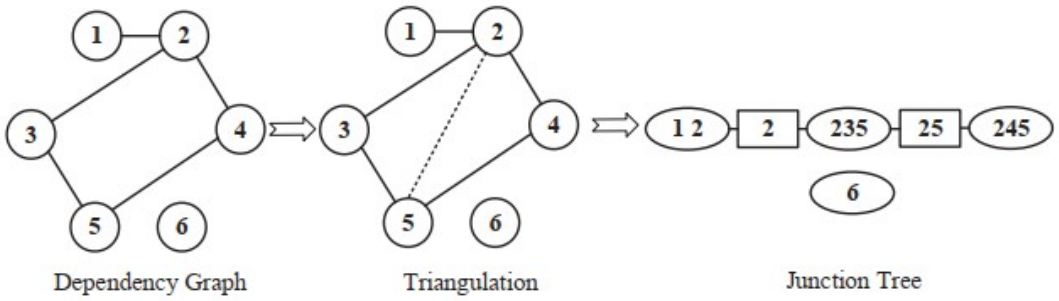

شکل ۳ـ۱: ساخت درخت اتصال از گراف همبستگی. برگرفته از [۱]

در گام چهارم مجموعه داده مصنوعی تولید می‌شود. هدف انتشار یک مجموعه داده کاملاً جدید و مصنوعی است که از نظر آماری شبیه به داده‌های اصلی باشد اما حاوی اطلاعات هیچ کاربر واقعی نباشد. کارپذیر با استفاده از توزیع احتمال مشترکی که برای هر خوشه در گام‌های قبل محاسبه کرده، شروع به تولید رکوردهای جدید و مصنوعی می‌کند. این رکوردهای مصنوعی برای هر خوشه با هم ترکیب شده و رکوردهای کامل با ابعاد بالا را می‌سازند.

خروجی نهایی، یک مجموعه داده مصنوعی است که می‌توان آن را با خیال راحت برای تحلیل و داده‌کاوی منتشر کرد، زیرا ضمن حفظ الگوهای کلی داده‌های اصلی، حریم خصوصی تک‌تک مشارکت‌کنندگان را به طور کامل حفظ کرده است. به طور خلاصه، لوپاب به کاربران اجازه می‌دهد در پروژه‌های جمع‌سپاری داده

[15] Maximum Spanning Tree
[16] Running Intersection Property

با ابعاد بالا شرکت کنند، بدون آنکه نگران افشای اطلاعات شخصی خود، حتی به کارپذیر جمع‌آوری‌کننده، باشند.

پژوهش ژانگ و همکاران

پژوهش ژانگ و همکاران [۲] روشی به اسم پرایوپی‌جِی ارائه می‌دهد که برای حفظ حریم خصوصی در هنگام انتشار داده‌های با ابعاد بالا کاربرد دارد. این روش به گونه‌ای طراحی شده است که ضمن محافظت از اطلاعات خصوصی کاربران، داده‌های مصنوعی تولید کند که از نظر آماری شباهت زیادی به داده‌های واقعی داشته باشند. روش پرایوپی‌جِی برای غلبه بر مشکلات داده‌های با ابعاد بالا در یک فرایند سه مرحله‌ای طراحی شده است.

مرحله‌ی اول مانند روش لوپاب، شامل آشفته‌سازی داده‌ها به صورت محلی می‌باشد. البته به جای ارسال تمام اطلاعات یک کاربر، به صورت تصادفی فقط یکی از ویژگی‌ها را انتخاب می‌کند. سپس اطلاعات این ویژگی انتخاب شده با استفاده از یک تکنیک پاسخ تصادفی نوفه‌دار می‌شود. این کار تضمین می‌کند که کارپذیر هرگز مقدار واقعی را به طور قطعی دریافت نمی‌کند. در نتیجه هر کاربر فقط یک گزارش کوچک و نوفه‌دار شده به کارپذیر ارسال می‌کند. این کار هم هزینه ارتباطی را کاهش می‌دهد و هم حریم خصوصی تفاضلی محلی را تضمین می‌کند.

در مرحله دوم تخمینی از توزیع مشترک داده‌ها تهیه می‌گردد. پس از اینکه کارپذیر گزارش‌های نوفه‌دار شده را از تمام کاربران دریافت کرد، از الگوریتم جدیدی به نام خودکدگذار چند متغیره[۱۷] (به اختصار اِم.وی.اِی.ای[۱۸]) به منظور تخمین توزیع مشترک داده‌ها استفاده می‌کند. این الگوریتم یک مدل یادگیری عمیق است که می‌تواند توزیع احتمال مشترک بین تمام ویژگی‌ها را تخمین بزند. به بیان دیگر با تحلیل داده‌های آشفته شده، الگوها و همبستگی‌های بین ویژگی‌های مختلف را یاد می‌گیرد. این کار با به حداقل رساندن خطا بین توزیع حاشیه‌ای و توزیع مشترک انجام می‌شود و به طور موثر اثر نوفه را کاهش می‌دهد.

در مرحله سوم کاهش ابعاد و تولید داده مصنوعی صورت می‌گیرد. اکنون که کارپذیر مدل آماری داده‌ها را در اختیار دارد، باید از آن برای تولید یک مجموعه داده مصنوعی جدید استفاده کند. از آنجایی که کار با توزیع کامل داده‌های با ابعاد بالا همچنان پیچیده است، پرایوپی‌جِی از شبکه مارکوف[۱۹] برای ساده‌سازی این فرآیند استفاده می‌کند.

ساخت شبکه مارکوف به این صورت است که ابتدا، کارپذیر با استفاده از اطلاعات همبستگی که در

[17] Multivariate Variational Autoencoder
[18] mVAE
[19] Markov Network

مرحله قبل به دست آورده، یک شبکه مارکوف می‌سازد. در این شبکه، هر ویژگی یک گره است و بین ویژگی‌هایی که همبستگی بالایی دارند، یک یال کشیده می‌شود. در قدم بعدی، شبکه مارکوف به ساختاری ساده‌تر به نام درخت اتصال تبدیل می‌شود. فرایند ساخت درخت اتصال مانند روش لوپاب است. شکل ۳ـ۲ یک مثال از شبکه مارکوف و ساخت درخت اتصال را نمایش می‌دهد. این درخت، ویژگی‌ها را در خوشه‌هایی که همبستگی بالایی با هم دارند گروه‌بندی می‌کند. این کار به طور موثری ابعاد داده را کاهش می‌دهد. در نهایت، سرور از این درخت اتصال برای تولید داده‌های مصنوعی جدید استفاده می‌کند. این فرآیند با نمونه‌برداری از خوشه‌ها، روابط آماری پیچیده در داده‌های اصلی را بازسازی می‌کند.

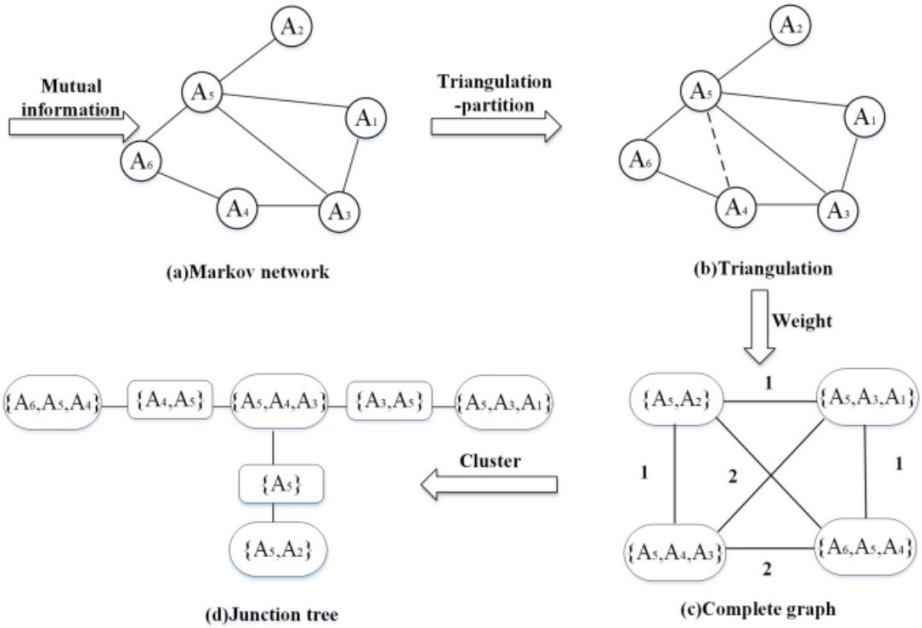

شکل ۳ـ۲: استفاده از شبکه مارکوف در ساخت درخت اتصال. برگرفته از [۲]

نتیجه نهایی یک مجموعه داده با ابعاد بالا است که از نظر آماری بسیار شبیه به داده‌های اصلی است، اما چون از ابتدا بر پایه گزارش‌های آشفته شده ساخته شده، حریم خصوصی هیچ‌یک از کاربران را نقض نمی‌کند.

پژوهش جیانگ و همکاران

پژوهش جیانگ و همکاران [۳]، راهکاری نوآورانه به نام دی.پی.تو.پاب[۲۰] به منظور حل چالش داده‌های با ابعاد بالا ارائه می‌دهد. هدف اصلی، به اشتراک گذاشتن این داده‌ها برای تحلیل و یادگیری ماشین است، بدون آنکه حریم خصوصی افراد در معرض خطر قرار گیرد. این راهکار در دو فاز اصلی و برای دو سناریوی متفاوت یعنی کارپذیر قابل اعتماد و کارپذیر نیمه‌صادق انجام می‌شود.

[20] DP2-Pub

در فاز اول خوشه‌بندی صفات انجام می‌شود. به جای کار با تمام ابعاد به صورت یکجا، ابتدا صفات مرتبط به هم را در گروه‌های کوچک‌تر و کم‌تعدادتر خوشه‌بندی می‌کند. در فاز دوم روی داده‌های هر خوشه، فرآیند افزودن نویز را برای تضمین حریم خصوصی اجرا می‌کند.

این فرآیند در دو مدل امنیتی مختلف ارائه می‌شود:

۱. کارپذیر قابل اعتماد: در این مدل، فرض بر این است که یک کارپذیر مرکزی به داده‌های اصلی دسترسی دارد و تمام عملیات حفظ حریم خصوصی روی آن انجام می‌شود. به منظور خوشه‌بندی صفات از شبکه بیزی[۲۱] استفاده می‌شود. الگوریتم با استفاده از روش حریم خصوصی تفاضلی، یک شبکه بیزی از روی داده‌ها می‌سازد. این شبکه وابستگی‌ها و روابط شرطی بین تمام صفات را مدل می‌کند. به عنوان مثال در شکل ۳ـ۳ یک شبکه‌ی بیزی از پنج ویژگی ساخته می‌شود.

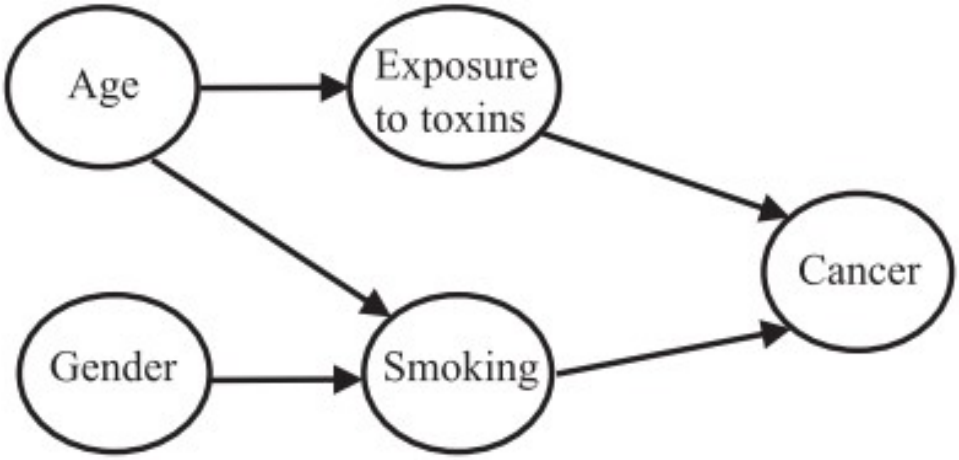

شکل ۳ـ۳: ساخت شبکه بیزی از پنج ویژگی. برگرفته از [۳]

پس از ساخت شبکه، برای هر صفت، «پوشش مارکوف[۲۲]» آن شناسایی می‌شود. پوشش مارکوف یک صفت، مجموعه‌ای حداقلی از صفات همسایه آن است که تمام اطلاعات لازم برای پیش‌بینی آن صفت را در خود دارد [۲۲]. الگوریتم با گروه‌بندی هر ویژگی به کمک پوشش مارکوف، داده‌های با ابعاد بالا را به چندین خوشه کم‌بعد و مستقل از هم تقسیم می‌کند.

تعریف ۳ـ۲ (پوشش مارکوف) *در یک شبکه بیزی، پوشش مارکوف برای یک گره x، مجموعه‌ای از گره‌هاست که از نظر احتمالی، x را از بقیه شبکه محافظت یا جدا می‌کنند. به این معنا که اگر مقادیر گره‌های موجود در پوشش مارکوف را بدانیم، گره x از تمام گره‌های دیگر شبکه مستقل می‌شود.*

[21] Bayesian Network
[22] Markov Blanket

$$MB(x) = Pa(x) \cup Ch(x) \cup \{Pa(y)|y \in Ch(x)\} \qquad (۲_۳)$$

در عبارت بالا:

- $MB(x)$: *پوشش مارکوف گره* x.
- $Pa(x)$: *مجموعه گره‌های والد گره* x.
- $Ch(x)$: *مجموعه گره‌های فرزند گره* x.

پس از خوشه‌بندی، باید روی داده‌ها آشفته‌سازی انجام شود. البته لازم است که کمترین آسیب به اطلاعات آماری کلان وارد شود. پژوهش الگوریتمی نوآورانه به نام پی.آر.اِی.اِم[۲۳] ارائه می‌کند. در این روش، مقادیر داده‌ها با یک احتمال مشخص به مقادیر دیگر تغییر می‌کنند. نکته‌ی مهم این است که الگوریتم پی.آر.اِی.اِم تضمین می‌کند که توزیع آماری کلی داده‌ها پس از افزودن نوفه، بدون تغییر باقی بماند. این کار باعث حفظ حداکثری کارایی داده می‌شود. به طور دقیق‌تر، ابتدا یک بار داده‌ها را با نوفه استاندارد آشفته می‌کند. سپس، با تخمین توزیع اصلی از روی داده‌های نوفه‌دار شده، یک آشفتگی دوم و معکوس اعمال می‌کند تا اثرات منفی نوفه بر توزیع کلی را خنثی کند.

۲. کارپذیر نیمه‌صادق: در این مدل، کاربران به کارپذیر اعتماد ندارند و می‌خواهند داده‌هایشان قبل از ارسال به کارپذیر، تصادفی‌سازی شود. هر کاربر ابتدا روی داده‌های خود یک فرآیند تصادفی‌سازی اعمال می‌کند تا داده‌هایش به صورت محلی آشفته شوند. سپس این داده‌های نوفه‌دار شده را به کارپذیر ارسال می‌کند. کارپذیر داده‌ها را از تمام کاربران جمع‌آوری کرده و سپس همان فرآیند دو فازی یعنی خوشه‌بندی و پی.آر.اِی.اِم را روی این داده‌ها اجرا می‌کند تا همبستگی‌ها را بازسازی کرده و کارایی نهایی داده‌ها را بهبود بخشد.

پژوهش دیو و همکاران

پژوهش دیو و همکاران [۲۳] الگوریتمی ارائه می‌دهد که هم حریم خصوصی کاربران حفظ شود و هم داده‌های جمع‌آوری شده کیفیت و کارایی بالایی داشته باشند. روش‌های قدیمی فرض می‌کنند که تمام ویژگی‌های داده کاملاً به هم مرتبط هستند (بدترین حالت ممکن)، در حالی که در دنیای واقعی اینطور نیست. برای مثال، دمای یک اتاق و میزان روشنایی آن ممکن است همبستگی داشته باشند، اما این همبستگی کامل

[23] PRAM

و صددرصدی نیست. این پژوهش نشان می‌دهد که اگر بتوانیم میزان همبستگی بین ویژگی‌های مختلف را اندازه‌گیری کنیم، می‌توانیم نوفه را به شکل هوشمندانه‌تر و بهینه‌تری توزیع کرده و کیفیت نهایی داده‌ها را به شدت افزایش دهیم. یک پروتکل جدید به نام آشفتگی محدود به همبستگی[۲۴] (به اختصار، سی.بی.پی[۲۵]) معرفی می‌گردد. این پروتکل بر اساس یک مدل حریم خصوصی جدید و منعطف‌تر به نام حریم خصوصی تفاضلی محلی با تسلط تک‌متغیره[۲۶] کار می‌کند.

این مدل یک نسخه انعطاف‌پذیرتر از حریم خصوصی تفاضلی محلی است که به طور خاص برای یک ویژگی واحد در داده‌های با ابعاد بالا طراحی شده است. به زبان ساده، این مدل تضمین می‌کند که اگر مقدار واقعی یک ویژگی را تغییر دهیم، احتمال اینکه الگوریتم یک خروجی نوفه‌دار شده‌ی مشخص تولید کند، تفاوت چندانی نخواهد کرد. این عدم قطعیت باعث می‌شود که یک مهاجم با دیدن خروجی، نتواند با اطمینان بگوید که مقدار اصلی چه بوده است.

تعریف ۳ـ۳ (حریم خصوصی تفاضلی محلی با تسلط تک‌متغیره) *برای هر ویژگی دلخواه x و برای هر دو ورودی ممکن s و s'، سازوکار M، شرایط حریم خصوصی تفاضلی محلی با تسلط تک‌متغیره را برآورده می‌کند، اگر برای هر خروجی ممکن Y از دامنه سازوکار M، شرط زیر برقرار باشد:*

$$e^{-\epsilon} \leqslant \frac{P[\mathcal{M}(x=s)=Y]}{P[\mathcal{M}(x=s')=Y]} \leqslant e^{\epsilon} \qquad (۳ـ۳)$$

کارپذیر با استفاده از داده‌های تاریخی یا دانش قبلی، ویژگی‌هایی را که به هم مرتبط هستند، شناسایی و دسته‌بندی می‌کند. سپس به جای تقسیم مساوی بودجه حریم خصوصی، پروتکل سی.بی.پی این بودجه را به صورت هوشمندانه بر اساس میزان همبستگی بین ویژگی‌ها تخصیص می‌دهد. ویژگی‌هایی که همبستگی بیشتری دارند، می‌توانند به شکل مؤثرتری بودجه حریم خصوصی را به اشتراک بگذارند.

در بسیاری از کاربردهای اینترنت اشیاء، پهنای باند یک محدودیت جدی است و نمی‌توان همیشه تمام داده‌ها را ارسال کرد. برای حل این مشکل، مقاله پروتکل سی.بی.پی را گسترش داده و از نمونه‌برداری نیز استفاده می‌کند. به این صورت که نه تنها بودجه حریم خصوصی را بهینه تخصیص می‌دهد، بلکه احتمال نمونه‌برداری از هر ویژگی را نیز بر اساس میزان اهمیت و همبستگی آن تعیین می‌کند. این کار باعث می‌شود که حتی با ارسال تعداد محدودی از ویژگی‌ها، بیشترین اطلاعات ممکن با حفظ حریم خصوصی استخراج شود.

[24] Correlation-Bounded Perturbation
[25] CBP
[26] Univariate Dominance LDP

از مشکلات این پژوهش می‌توان به این نکته اشاره کرد که وجود داده‌های تاریخی یا دانش قبلی همیشه میسر نخواهد بود. اگر این دانش را نداشته باشیم، نمی‌توانیم میزان همبستگی بین ابعاد داده را محاسبه کنیم و در نتیجه خوشه‌بندی مناسبی نخواهیم داشت.

۳ـ۱ـ۳ کاهش ابعاد

در بعضی از پژوهش‌هایی که قبل‌تر ذکر کردیم نیز کاهش ابعاد صورت می‌گرفت. برای مثال، خوشه‌بندی موجب کاهش ابعاد داده می‌شود. پژوهش‌هایی هم وجود دارند که خوشه‌بندی انجام نداده‌اند ولی به نوعی ابعاد داده را کاهش داده‌اند تا بودجه‌ی حریم خصوصی به صورت مناسب پخش شود.

پژوهش دونگیو ژانگ و همکاران

پژوهش دونگیو ژانگ و همکاران [۴] یک راهکار نوآورانه به نام پی.پی.اِم.سی[۲۷] برای جمع‌آوری داده‌های چندبعدی با حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد.پژوهش برای غلبه بر این چالش داده‌های با ابعاد بالا، یک فرآیند هوشمندانه سه مرحله‌ای را با استفاده از **تبدیل هار**[۲۸] پیشنهاد می‌کند. ایده اصلی این است که به جای افزودن نوفه به تک‌تک ابعاد داده‌ی اصلی، ابتدا ساختار داده را تغییر داده، ابعاد آن را کاهش دهیم و سپس به داده‌ی تبدیل‌شده نوفه اضافه کنیم.

تبدیل هار یکی از قدیمی‌ترین، ساده‌ترین و در عین حال بنیادی‌ترین ابزارهای ریاضی در خانواده تبدیل‌های موجک[۲۹] است. این تبدیل، یک سیگنال یا مجموعه‌ای از داده‌ها (مانند یک تصویر یا یک فایل صوتی) را به دو بخش اصلی تجزیه می‌کند:

- اطلاعات کلی
- اطلاعات جزئی

به بیان دیگر تبدیل هار یک تبدیل خطی است که سیگنال یا ورودی خاص را را به نمایشی تبدیل می کند که الگوها و جزئیات داده را در مقیاس های مختلف برجسته می کند. در رابطه با کاربرد این تبدیل در حریم خصوصی تفاضلی محلی، تبدیل هار، داده‌ها را به دو بخش اصلی تجزیه می‌کند:

[27] PPMC
[28] Haar Transform
[29] Wavelet Transforms

- مقدار میانگین[۳۰]: این یک مقدار واحد است که یک تقریب کلی و چکیده از تمام ابعاد داده را در خود نگه می‌دارد. بخش عمده‌ای از اطلاعات مهم داده‌ها در همین مقدار میانگین متمرکز می‌شود.
- بردار ویژه[۳۱]: این بردار، اطلاعات جزئی‌تر و تفاوت‌های بین ابعاد مختلف را نشان می‌دهد. این مقادیر معمولاً کوچک‌تر هستند و اطلاعات کمتری نسبت به مقدار میانگین در خود دارند.

مزیت کلیدی این کار این است به جای داشتن تعداد زیادی بُعد که همگی به یک اندازه مهم به نظر می‌رسند، ما یک «مقدار میانگین» بسیار مهم و یک «بردار ویژه» با اهمیت کمتر داریم. این‌ها پایه و اساس کاهش ابعاد را فراهم می‌کنند. در ادامه با یک مثال نحوه‌ی عملکرد این تبدیل را مشخص کنیم.

تصور کنید یک لیست از اعداد مانند [۹, ۷, ۳, ۵, ۸, ۴, ۵, ۷] داریم. به راحتی با جمع تک تک اعداد و تقسیم بر تعداد آنها، مقدار میانگین را محاسبه می کنیم:

$$m = \frac{۷ + ۵ + ۴ + ۸ + ۵ + ۳ + ۷ + ۹}{۸} = ۶$$

برای محاسبه‌ی بردار ویژه، ابتدا یک درخت دودویی کامل می‌سازیم که برگ‌های درخت همان اعداد (ابعاد داده) اصلی هستند. سپس، برای هر گره داخلی N، مقدار ویژه $e = (ml - mr)/۲$ محاسبه می‌شود، که در آن ml و mr مقدار میانگین گره‌های برگ در زیردرخت‌های چپ و راست N است. پس از پردازش تمام گره‌های داخلی، با نوشتن آنها به ترتیب جستجوی اول سطح[۳۲] مقدار بردار ویژه بدست می‌آید. دقت کنید مقدار میانگین را می‌توان به عنوان اطلاعات اصلی داده‌های چند بعدی در نظر گرفت و هر مقدار ویژه را می‌توان به چشم اطلاعات محلی داده‌های چند بعدی مشاهده کرد. بنابراین، هر بعد را می‌توان به عنوان مجموعه‌ای از مقدار میانگین و مقادیر ویژه در نظر گرفت. شکل ۳ـ۴ تبدیل هار را روی داده‌های چند بعدی نشان می‌دهد.

$$E = [۰, ۲, ۰, ۱, -۱, ۲, -۱]$$

نکته کلیدی: این فرآیند بازگشت‌پذیر است. یعنی با داشتن میانگین و بردار ویژه، می‌توان داده اصلی را دقیقاً بازسازی کرد. برای پیدا کردن مقدار هر داده (که در برگ‌های درخت قرار دارد)، از ریشه درخت (که همان مقدار میانگین m است) شروع کرده و با اضافه یا کم کردن مقادیر ویژه‌ای که در مسیر رسیدن به آن برگ قرار دارند، به مقدار نهایی می‌رسیم:

[30] Average Value
[31] Eigenvector
[32] Breadth First Search

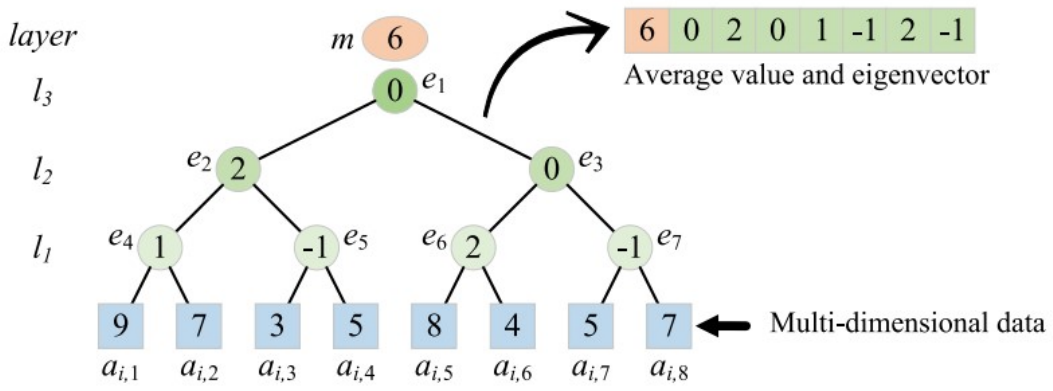

شکل ۳ـ۴: نحوه محاسبه‌ی بردار ویژه در تبدیل هار. $a_{i,j}$ **نشان‌دهنده‌ی ویژگی** j**ام از کاربر** i**ام است. برگرفته از [۴]**

$$a_{i,j} = m + \sum_{k=۱}^{l} (g_k \cdot e_k),$$

$$g_k = \begin{cases} ۱, & \text{if} \quad a_{i,j} \text{ in the left subtree of } e_k, \\ -۱, & \text{if} \quad a_{i,j} \text{ in the right subtree of } e_k. \end{cases}$$

$$l = \lfloor \log(d + ۱) - ۱ \rfloor$$

به عبارت دیگر، برای بازسازی یک مقدار، از میانگین کل شروع می‌کنیم و سپس در هر مرحله از مسیر درخت، مقدار ویژه آن مرحله را بر اساس اینکه در سمت چپ یا راست آن قرار داریم، اضافه یا کم می‌کنیم. به عنوان مثال در شکل ۳ـ۴ ویژگی $a_{i,۷}$ دارای اجداد $e_۷$، $e_۳$ و $e_۱$ است. معکوس تبدیل هار برای این ویژگی به شکل زیر محاسبه می‌شود:

$$a_{i,۷} = m - e_۱ - e_۳ + e_۷ = ۵$$

همانطور که می‌بینید، مقدار بازسازی شده دقیقاً با مقدار اصلی در داده‌های خام (عدد ۵) برابر است، که نشان می‌دهد فرآیند معکوس به درستی کار می‌کند.

سادگی و سرعت محاسباتی تبدیل هار باعث شده تا در حوزه‌های مختلفی کاربرد داشته باشد:

- فشرده‌سازی داده‌ها[۳۳]: فشرده‌سازی یکی از مهم‌ترین کاربردهای تبدیل هار است. بسیاری از داده‌ها

[33] Data Compression

(مانند تصاویر) شامل ضرایبی با مقادیر کوچک و نزدیک به صفر هستند. با حذف این ضرایب کم‌اهمیت و نگهداری ضرایب تقریبی و بزرگ، می‌توان حجم داده را به شدت کاهش داد بدون اینکه کیفیت آن به طور محسوس افت کند. فرمت تصویر JPEG از نسخه‌های پیشرفته‌تر موجک‌ها (که بر پایه همین ایده هستند) استفاده می‌کند.

- تشخیص لبه[۳۴]: ضرایب جزئی در یک تصویر، نماینده تغییرات ناگهانی روشنایی هستند که دقیقاً همان لبه‌های اشیاء را مشخص می‌کنند.
- کاهش نوفه[۳۵]: نوفه در تصویر معمولاً به صورت ضرایب جزئی کوچک ظاهر می‌شود. با حذف این ضرایب و بازسازی تصویر، می‌توان نوفه را تا حد زیادی از بین برد.
- تحلیل سیگنال‌های دیجیتال: برای بررسی و تحلیل فرکانس‌های مختلف در سیگنال‌های صوتی یا دیگر سیگنال‌های دیجیتال استفاده می‌شود.
- پایگاه داده: برای جستجوی سریع‌تر و بهینه در پایگاه داده‌های بزرگ به کار می‌رود.

به طور خلاصه، تبدیل هار یک ابزار قدرتمند برای تجزیه داده‌ها به بخش‌های کلی و جزئی است که این ویژگی آن را برای کاربردهای متنوعی از فشرده‌سازی گرفته تا حفظ حریم خصوصی، بسیار مفید می‌سازد. پژوهش [۴] در سه مرحله چالش حفظ حریم خصوصی برای داده‌های با ابعاد بالا را حل کرده است:

اولین و مهم‌ترین قدم، استفاده از تبدیل هار برای تبدیل داده‌های چندبعدی هر کاربر است.

در مرحله‌ی بعد حفاظت از حریم خصوصی داده‌های تبدیل‌شده صورت می‌گردد. اکنون به جای کار با داده خام، الگوریتم روی دو بخش تبدیل‌شده کار می‌کند و برای هر کدام، یک سازوکار بهینه‌سازی‌شده برای افزودن نوفه ارائه می‌دهد:

- حفاظت از مقدار میانگین: برای محافظت از مقدار میانگین، مقاله یک سازوکار به نام آشفته‌سازی مبتنی بر چگالی احتمال[۳۶] (به اختصار، پی.دی.پی[۳۷]) طراحی کرده است. این سازوکار به جای افزودن نوفه‌ی کاملاً تصادفی، به صورت هوشمندانه عمل می‌کند. مقدار نوفه به گونه‌ای اضافه می‌شود که مقدار نهایی با احتمال بالاتری نزدیک به مقدار واقعی باقی بماند و با احتمال کمتری از آن دور شود. این کار باعث می‌شود که با حفظ حریم خصوصی، دقت و کارایی این مقدار کلیدی

[34] Edge Detection
[35] Denoising
[36] Probability Density-based Perturbation
[37] PDP

تا حد امکان حفظ شود. به طور دقیق‌تر، مقدار نوفه‌دار شده‌ی $\tilde{m} \in [-b, b]$ از رابطه‌ی زیر بدست می‌آید.

$$\mathrm{PDF}[\psi(m) = \tilde{m}] = \begin{cases} q \cdot e^{\epsilon} & \text{if} \quad \tilde{m} \in L(\Delta, m), \\ q & \text{otherwise}, \end{cases} \tag{۴ـ۳}$$

در عبارت بالا q یک مقدار ثابت است که باعث می‌شود مجموع همه احتمالات در تابع چگالی احتمال برابر با ۱ شود. پارامترهای دیگر عبارت به صورت زیر بهینه سازی می‌شوند:

$$L(\delta, m) = \left[m - \frac{\delta}{۲}, m + \frac{\delta}{۲}\right]$$

$$\Delta = \frac{۲۴}{e^{\epsilon/۶}(۶ + ۵\epsilon) - ۶}$$

$$b = \frac{(e^{\epsilon} - ۱)\Delta(\Delta + ۲)}{۲[(e^{\epsilon} - ۱)\Delta - ۲]}$$

$$q = \frac{۲}{(e^{\epsilon} - ۱)\Delta(۲b - \Delta)}$$

در شکل ۳ـ۵ مثالی از آشفته‌سازی مقدار میانگین نمایش داده شده است.

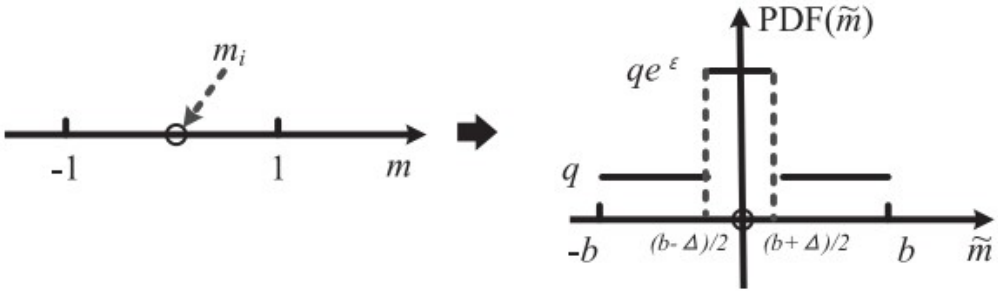

شکل ۳ـ۵: آشفته‌سازی مقدار m_i بر اساس پی.دی.پی. برگرفته از [۴]

- حفاظت از بردار ویژه: برای این بخش که هنوز چندبعدی است، ابتدا کاهش ابعاد صورت می‌گیرد. از آنجایی که بسیاری از مقادیر در بردار ویژه کوچک و کم‌اهمیت هستند، این مدل مقادیری را که از یک آستانه مشخصی کوچک‌تر هستند، حذف کرده و آن‌ها را با صفر جایگزین می‌کند. سپس از سازوکاری به اسم آشفته‌سازی سراسری[۳۸] به منظور اضافه کردن نوفه به بردار ویژه استفاده می‌شود. به جای تقسیم بودجه حریم خصوصی بین ابعاد باقی‌مانده‌ی بردار ویژه، این نوفه کل بردار را به عنوان

[38] Global Perturbation Mechanism

یک واحد در نظر گرفته و به صورت سراسری به آن نوفه اضافه می‌کند. این رویکرد از تقسیم بیش از حد بودجه جلوگیری کرده و کارایی آماری را به مراتب بهتر حفظ می‌کند.

الگوریتم ۲ سازوکار آشفته‌سازی برای بردار ویژه

ورودی: بردار ویژه‌ی $e_i \in [-1, 1]^{d-1}$ و بودجه‌ی حریم خصوصی ϵ_2 و حد آستانه‌ی θ.

خروجی: مقدار نوفه‌دار شده‌ی $\tilde{e}_i \in [-\frac{e^\epsilon+1}{e^\epsilon-1}, \frac{e^\epsilon+1}{e^\epsilon-1}]^{d-1}$

به ازای هر e_i از بردار ویژه:

اگر $|e_i| \leqslant \theta$:

$e_i = 0$

$V = \{0\}^{d-1-\theta d}$

به صورت تصادفی k بیت از لیست V را ۱ قرار بده.

قرار بده A را برابر با لیست‌هایی که kی آنها زوج است.

قرار بده B را برابر با لیست‌هایی که kی آنها فرد است.

یک متغیر برنولی X را با احتمال $\frac{e^\epsilon}{e^\epsilon+1}$ مقدار ۱ قرار بده.

اگر $X = 1$:

لیست $\tilde{V}$ را به صورت تصادفی یکنواخت از A انتخاب کن.

در غیر این صورت:

لیست $\tilde{V}$ را به صورت تصادفی یکنواخت از B انتخاب کن.

به ازای هر e_i از بردار ویژه:

اگر $v_i = 0$:

مقدار $\tilde{e}_i$ را به صورت تصادفی یکنواخت از $[\frac{e_i \cdot e^\epsilon-1}{e^\epsilon-1}, \frac{e_i \cdot e^\epsilon+1}{e^\epsilon-1}]$ انتخاب کن.

در غیر این صورت:

مقدار $\tilde{e}_i$ را به صورت تصادفی یکنواخت از $[-\frac{e^\epsilon+1}{e^\epsilon-1}, \frac{e_i \cdot e^\epsilon-1}{e^\epsilon-1}) \cup (\frac{e_i \cdot e^\epsilon+1}{e^\epsilon-1}, \frac{e^\epsilon+1}{e^\epsilon-1}]$ انتخاب کن.

$\tilde{e}_i \in [-\frac{e^\epsilon+1}{e^\epsilon-1}, \frac{e^\epsilon+1}{e^\epsilon-1}]^{d-1}$ را برگردان

مرحله سوم: بازسازی داده‌ها

در نهایت، هر کاربر "مقدار میانگین نویزی" و "بردار ویژه نویزی و کاهش‌یافته" را به سرور مرکزی (جمع‌آوری‌کننده داده) ارسال می‌کند. سرور با استفاده از تبدیل معکوس هار (Inverse Haar -Trans form)، این دو قطعه اطلاعات را با هم ترکیب کرده و یک نسخه نویزی و خصوصی‌شده از داده چندبعدی

اصلی را بازسازی می‌کند.

نکته مهم این است که سرور هرگز به داده‌های خام و اصلی کاربران دسترسی ندارد و تمام فرآیند بازسازی بر اساس داده‌های نویزی انجام می‌شود که حریم خصوصی آن‌ها تضمین شده است.

نتیجه‌گیری

به طور خلاصه، این مقاله با استفاده از تکنیک‌های زیر، مشکل حفظ حریم خصوصی در داده‌های با ابعاد بالا را حل می‌کند:

استفاده از تبدیل هار برای جداسازی اطلاعات کلی از جزئیات و فراهم کردن زمینه برای کاهش ابعاد.

طراحی مکانیزم‌های نویزدهی بهینه و جداگانه برای هر بخش از داده‌های تبدیل‌شده، که منجر به کاهش خطای کلی می‌شود.

کاهش ابعاد بردار ویژه برای حذف اطلاعات کم‌اهمیت و تمرکز بودجه حریم خصوصی روی اطلاعات مهم‌تر.

اجتناب از تقسیم بودجه حریم خصوصی با استفاده از یک مکانیزم اختلال سراسری برای بردار ویژه.

این رویکرد باعث می‌شود که داده‌های جمع‌آوری‌شده با وجود حفظ حریم خصوصی، کارایی آماری بسیار بالاتری نسبت به روش‌های قبلی داشته باشند، که این موضوع در آزمایش‌های مقاله نیز تأیید شده است.

۳ـ۲ نتیجه‌گیری

با بررسی سازوکارهای مروبط به حل چالش داده‌های با ابعاد بالا، مشکلاتی یافت می‌شود:

- نمونه‌برداری: سازوکارهای مربوط به این روش با در نظر گرفتن بخشی از داده به عنوان نماینده‌ی کل داده، موجب کاهش دقت تحلیل‌های آماری می‌شوند. مخصوصا اگر حجم داده‌ی دریافتی از کاربران کم باشد، سودمندی به شدت کاهش میابد.
- خوشه‌بندی: خوشه‌بندی به خودی خود روشی کارامد محسوب می‌شود. منتها برای بدست آوردن خوشه‌های مناسب، باید میزان وابستگی میان ابعاد داده مشخص گردد. طبیعتا سمت کاربر نمی‌توان این وابستگی‌ها را مشخص کرد، زیرا هم حجم داده سمت یک کاربر کم بوده و همچنین منابع محاسباتی محدودی خواهد داشت. پس کاربران باید داده‌ی خود را برای کارپذیر فرستاده و سپس کارپذیر همبستگی میان ابعاد را مشخص کند. اگر در همین ابتدا، کاربران داده‌ی خود را به صورت

خام برای کارپذیر بفرستند، حریم خصوصی نقض می‌گردد. بنابراین باید به داده‌های خود نوفه اضافه کنند تا حریم خصوصی حفظ گردد. با اضافه کردن نوفه، دیگر نمی‌توان تخمین درستی از احتمال توزیع مشترک داده‌ها بدست آورد. درنتیجه خوشه‌بندی انجام شده توسط کارپذیر سالم نخواهد بود و سودمندی الگوریتم‌ها زیر سوال می‌رود.

- یافتن میزان همبستگی با کمک داده‌های تاریخی یا دانش قبلی: به این نکته هم اشاره کردیم که نمی‌توان همیشه روی داشتن این اطلاعات حساب باز کرد و بنابراین نیازمند الگوریتم مطمئن‌تری هستیم.

۳ـ۳ مسائل خوشه‌بندی

مسئله‌ی **خوشه‌بندی**[۳۹] یکی از مهم‌ترین مسائل در زمینه‌ی داده‌کاوی به حساب می‌آید. در این مسئله، هدف دسته‌بندی تعدادی شیء به‌گونه‌ای است که اشیاء درون یک دسته (خوشه)، نسبت به یکدیگر در برابر دسته‌های دیگر شبیه‌تر باشند (معیارهای متفاوتی برای تشابه تعریف می‌گردد). این مسئله در حوزه‌های مختلفی از علوم کامپیوتر از جمله داده‌کاوی، جست‌وجوی الگو[۴۰]، پردازش تصویر[۴۱]، بازیابی اطلاعات[۴۲] و رایانش زیستی[۴۳] مورد استفاده قرار می‌گیرد [۲۴].

تا کنون راه‌حل‌های زیادی برای این مسئله ارائه شده است که از لحاظ معیار تشخیص خوشه‌ها و نحوه‌ی انتخاب یک خوشه، با یک‌دیگر تفاوت بسیاری دارند. به همین خاطر مسئله‌ی خوشه‌بندی یک مسئله‌ی بهینه‌سازی چندهدفه[۴۴] محسوب می‌شود.

همان طور که در مرجع [۲۵] ذکر شده است، خوشه در خوشه‌بندی تعریف واحدی ندارد و یکی از دلایل وجود الگوریتم‌های متفاوت، همین تفاوت تعریف‌ها از خوشه است. بنابراین با توجه به مدلی که برای خوشه‌ها ارائه می‌شود، الگوریتم متفاوتی نیز ارائه می‌گردد. در ادامه به بررسی تعدادی از معروف‌ترین مدل‌های مطرح می‌پردازیم:

- **مدل‌های مرکزگرا:** در این مدل‌ها، هر دسته با یک مرکز نشان داده می‌شود. از جمله معروف‌ترین روش‌های خوشه‌بندی بر اساس این مدل، خوشه‌بندی kـ مرکز، خوشه‌بندی kـ میانگین[۴۵] و

[۳۹] Clustering
[۴۰] Pattern recognition
[۴۱] Image analysis
[۴۲] Information retrieval
[۴۳] Bioinformatics
[۴۴] Multi-objective
[۴۵] k-Means

خوشه‌بندی kـ میانه[۴۶] است.

- **مدل‌های مبتی بر توزیع نقاط**: در این مدل، دسته‌ها با فرض پیروی از یک توزیع احتمالی مشخص می‌شوند. از جمله الگوریتم‌های معروف ارائه شده در این مدل، الگوریتم بیشینه‌سازی امید ریاضی[۴۷] است.

- **مدل‌های مبتنی بر تراکم نقاط**: در این مدل، خوشه‌ها متناسب با ناحیه‌های متراکم نقاط در مجموعه داده مورد استفاده قرار می‌گیرد.

- **مدل‌های مبتنی بر گراف**: در این مدل، هر خوشه به مجموعه از رئوس گفته می‌شود که تمام رئوس آن با یک‌دیگر همسایه باشند. از جمله الگوریتم‌های معروف این مدل، الگوریتم خوشه‌بندی HCS[۴۸] است.

الگوریتم‌های ارائه شده تنها از نظر نوع مدل با یک‌دیگر متفاوت نیستند. بلکه، می‌توان آن‌ها را از لحاظ نحوه‌ی تخصیص نقاط بین خوشه‌ها نیز تقسیم‌بندی کرد:

- **تخصیص قطعی داده‌ها**: در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

- **تخصیص قطعی داده‌ها با داده‌ی پرت**: در این نوع خوشه‌بندی ممکن است بعضی از داده‌ها به هیچ خوشه‌ای اختصاص نیابد، اما بقیه داده‌ها هر کدام دقیقاً به یک خوشه اختصاص می‌یابد.

- **تخصیص قطعی داده**: در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

- **خوشه‌بندی هم‌پوشان**: در این نوع خوشه‌بندی هر داده می‌تواند به چند خوشه اختصاص داده شود. در گونه‌ای از این مدل، می‌توان هر نقطه را با احتمالی به هر خوشه اختصاص می‌یابد. به این گونه از خوشه‌بندی، خوشه‌بندی نرم[۴۹] گفته می‌شود.

- **خوشه‌بندی سلسه‌مراتبی**: در این نوع خوشه‌ها، داده‌ها به گونه‌ای به خوشه‌ها تخصیص داده می‌شود که دو خوشه یا اشتراک ندارند یا یکی به طور کامل دیگری را می‌پوشاند. در واقع در بین خوشه‌ها، رابطه‌ی پدر فرزندی برقرار است.

در بین دسته‌بندی‌های ذکر شده، تمرکز اصلی این پایان‌نامه بر روی مدل مرکزگرا و خوشه‌بندی قطعی با داده‌های پرت با مدل kـ مرکز است. همان‌طور که ذکر شد علاوه بر مسئله‌ی kـ مرکز که به تفصیل مورد

[۴۶] k-Median
[۴۷] Expectation-maximization
[۴۸] Highly Connected Subgraphs
[۴۹] Soft clustering

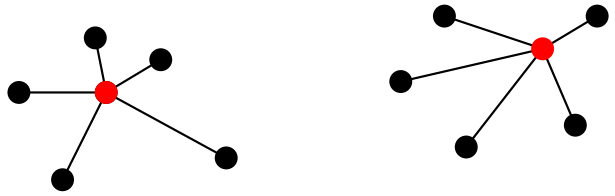

شکل ۳ـ۶: نمونه‌ای از مسئله‌ی ۲ـ مرکز

بررسی قرار می‌گیرد، kـ میانه و kـ میانگین از جمله معروف‌ترین خوشه‌بندی‌های مدل مرکزگرا هستند. در خوشه‌بندی kـ میانه، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع مربع فاصله‌ی هر نقطه از میانه‌ی نقاط آن خوشه، کمینه گردد. در خوشه‌بندی kـ میانگین، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع فاصله‌ی هر نقطه از میانگین نقاط داخل خوشه (یا مرکز آن خوشه) کمینه گردد.

۳ـ۴ خوشه‌بندی kـ مرکز

یکی از رویکردهای شناخته‌شده برای مسئله‌ی خوشه‌بندی، مسئله‌ی ***k*ـ مرکز** است. در این مسئله هدف، پیدا کردن k نقطه به عنوان مرکز دسته‌ها است به‌طوری‌که شعاع دسته‌ها تا حد ممکن کمینه شود. مثالی از مسئله‌ی ۲ـ مرکز در شکل ۳ـ۶ نشان داده شده است. در این پژوهش، مسئله‌ی kـ مرکز با متریک‌های خاص و برای kهای کوچک مورد بررسی قرار گرفته است و هر کدام از تعریف رسمی مسئله‌ی kـ مرکز در زیر آمده است:

مسئله‌ی ۳ـ۱ **(kـ مرکز)** *گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d، که از نامساوی مثلثی پیروی می‌کند داده شده است. زیرمجموعه‌ی $S \subseteq V$ با اندازه‌ی k را به‌گونه‌ای انتخاب کنید که عبارت زیر را کمینه کند:*

$$\max_{v \in V}\{\min_{s \in S} d(v, s)\} \qquad (۳ـ۵)$$

گونه‌های مختلفی از مسئله‌ی kـ مرکز با محدودیت‌های متفاوت توسط پژوهشگران مورد مطالعه قرار گرفته است. از جمله‌ی این گونه‌ها، می‌توان به حالتی که در بین داده‌های ورودی، داده‌های پرت وجود دارد، اشاره کرد. در واقع در این مسئله، قبل از خوشه‌بندی می‌توانیم تعدادی از نقاط ورودی را حذف نموده و سپس به خوشه‌بندی نقاط بپردازیم. سختی این مسئله از آنجاست که نه تنها باید مسئله‌ی خوشه‌بندی را حل نمود، بلکه در ابتدا باید تصمیم گرفت که کدام یک از داده‌ها را به‌عنوان داده‌ی پرت در نظر گرفت که بهترین جواب در زمان خوشه‌بندی به دست آید. در واقع اگر تعداد نقاط پرتی که مجاز به حذف است، برابر

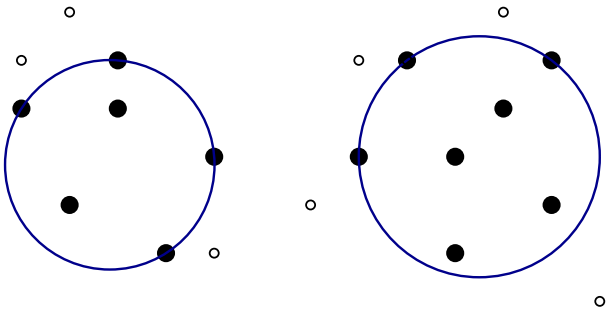

شکل ۳ـ۷: نمونه‌ای ازمسئله‌ی ۲ـ مرکز با داده‌های پرت

صفر باشد، مسئله به مسئله‌ی kـ مرکز تبدیل می‌شود. نمونه‌ای از مسئله‌ی ۲ـ مرکز با ۷ داده‌ی پرت را در شکل ۳ـ۷ می‌توانید ببینید. تعریف دقیق‌تر این مسئله در زیر آمده است:

مسئله‌ی ۳ـ۲ (kـ مرکز با داده‌های پرت) *یک گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d، که از نامساوی مثلثی پیروی می‌کند داده‌شده است. زیرمجموعه‌ی $Z \subseteq V$ با اندازه‌ی z و مجموعه‌ی $S \subseteq V - Z$ با اندازه‌ی k را انتخاب کنید به طوری‌که عبارت زیر را کمینه کند:*

$$\max_{v \in V-Z} \{\min_{s \in S} d(v, s)\} \qquad (۶ـ۳)$$

گونه‌ی دیگری از مسئله‌ی kـ مرکز که در سال‌های اخیر مورد توجه قرار گرفته است، حالت جویبار داده‌ی آن است. در این‌گونه از مسئله‌ی kـ مرکز، در ابتدا تمام نقاط در دسترس نیستند، بلکه به‌مرور زمان نقاط در دسترس قرار می‌گیرند. محدودیت دومی که وجود دارد، محدودیت حافظه است، به‌طوری‌که نمی‌توان تمام نقاط را در حافظه نگه داشت و بعضاً حتی امکان نگه‌داری در حافظه‌ی جانبی نیز وجود ندارد و به‌طور معمول باید مرتبه‌ی حافظه‌ای کم‌تر از مرتبه حافظه‌ی **خطی**[۵۰] متناسب با تعداد نقاط استفاده نمود. از این به بعد به چنین مرتبه‌ای، مرتبه‌ی **زیرخطی**[۵۱] می‌گوییم. مدلی که ما در این پژوهش بر روی آن تمرکز داریم مدل جویبار داده تک‌گذره[۵۲] [۲۶] است. یعنی تنها یک بار می‌توان از ابتدا تا انتهای داده‌ها را بررسی کرد و پس از عبور از یک داده، اگر آن داده در حافظه ذخیره نشده باشد، دیگر به آن دسترسی وجود ندارد. علاوه بر این، در هر لحظه باید بتوان به پرسمان (برای تمام نقاطی از جویبار داده که تاکنون به آن دسترسی داشته‌ایم) پاسخ داد.

مسئله‌ی ۳ـ۳ (kـ مرکز در حالت جویبار داده) *مجموعه‌ای از نقاط در فضای dـ بعدی به مرور زمان داده می‌شود. در هر لحظه از زمان، به ازای مجموعه‌ی U از نقاطی که تا کنون وارد شده‌اند، زیرمجموعه‌ی*

[۵۰] Linear
[۵۱] sublinear
[۵۲] Single pass

$S \subseteq U$ *با اندازه‌ی* k *را انتخاب کنید به طوری که عبارت زیر کمینه شود:*

$$\max_{u \in U}\{\min_{s \in S} d(u, s)\} \qquad (۷ـ۳)$$

از آنجایی که گونه‌ی جویبار داده و داده پرت مسئله‌ی kـ مرکز به علت به‌روز بودن مبحث داده‌های حجیم[۵۳]، به تازگی مورد توجه قرار گرفته است. در این تحقیق سعی شده است که تمرکز بر روی این‌گونه‌ی خاص از مسئله باشد. همچنین در این پژوهش سعی می‌شود گونه‌های مسئله را برای انواع متریک‌ها و برای kهای کوچک نیز مورد بررسی قرار داد.

۳ـ۵ مدل جویبار داده

همان‌طور که ذکر شد مسئله‌ی kـ مرکز در حالت داده‌های پرت و جویبار داده، گونه‌های تعمیم‌یافته از مسئله‌ی kـ مرکز هستند و در حالت‌های خاص به مسئله‌ی kـ مرکز کاهش پیدا می‌کنند. مسئله‌ی kـ مرکز در حوزه‌ی مسائل ان‌پی‌ـ سخت[۵۴] قرار می‌گیرد و با فرض $P \neq NP$ الگوریتم دقیق با زمان چندجمله‌ای برای آن وجود ندارد [۲۷]. بنابراین برای حل کارای[۵۵] این مسائل از الگوریتم‌های تقریبی[۵۶] استفاده می‌شود.

برای مسئله‌ی kـ مرکز، دو الگوریتم تقریبی معروف وجود دارد. در الگوریتم اول، که به روش حریصانه[۵۷] عمل می‌کند، در هر مرحله بهترین مرکز ممکن را انتخاب می‌کند به طوری تا حد ممکن از مراکز قبلی دور باشد [۲۸]. این الگوریتم، الگوریتم تقریبی با ضریب تقریب ۲ ارائه می‌دهد. در الگوریتم دوم، با استفاده از مسئله‌ی مجموعه‌ی غالب کمینه[۵۸]، الگوریتمی با ضریب تقریب ۲ ارائه می‌گردد [۲۹]. همچنین ثابت شده است، که بهتر از این ضریب تقریب، الگوریتمی نمی‌توان ارائه داد مگر آن‌که $P = NP$ باشد.

برای مسئله‌ی kـ مرکز در حالت جویبار داده برای ابعاد بالا، بهترین الگوریتم موجود ضریب تقریب $۲ + \varepsilon$ دارد [۳۰، ۳۱، ۳۲] و ثابت می‌شود الگوریتمی با ضریب تقریب بهتر از ۲ نمی‌توان ارائه داد. برای مسئله‌ی kـ مرکز با داده‌ی پرت در حالت جویبار داده نیز، بهترین الگوریتم ارائه شده، الگوریتمی با ضریب تقریب $۴ + \varepsilon$ است که با کران پایین ۳ هنوز اختلاف قابل توجهی دارد [۳۳].

برای kهای کوچک به خصوص، $k = ۱, ۲$، الگوریتم‌های بهتری ارائه شده است. بهترین الگوریتم ارائه شده برای مسئله‌ی ۱ ـ مرکز در حالت جویبار داده برای ابعاد بالا، دارای ضریب تقریب ۱/۲۲ است و کران

[۵۳] Big data
[۵۴] NP-hard
[۵۵] Efficient
[۵۶] Approximation algorithm
[۵۷] Greedy
[۵۸] Dominating set

جدول ۳ـ۱: نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی

مسئله	کران پایین تقریب‌پذیری
kـ مرکز	۲ [۲۹]
kـ مرکز در فضای اقلیدسی	۱/۸۲۲ [۳۸]
۱ ـ مرکز در حالت جویبار داده	$\frac{1+\sqrt{2}}{2}$ [۳۴]
kـ مرکز با نقاط پرت و نقاط اجباری	۳ [۳۳]

پایین $\frac{1+\sqrt{2}}{2}$ نیز برای این مسئله اثبات شده است [۳۴، ۳۵]. برای مسئله ۲ ـ مرکز در حالت جویبار داده برای ابعاد بالا، اخیرا راه‌حلی با ضریب تقریب $1/8 + \varepsilon$ ارائه شده است [۳۶]. برای مسئله‌ی ۱ ـ مرکز با داده‌ی پرت، تنها الگوریتم موجود، الگوریتمی با ضریب تقریب ۱/۷۳ است [۳۷].

۳ـ۶ تقریب‌پذیری

یکی از راه‌کارهایی که برای کارآمد کردن راه‌حل ارائه شده برای یک مسئله وجود دارد، استفاده از الگوریتم‌های تقریبی برای حل آن مسئله است. یکی از عمده‌ترین دغدغه‌های مطرح در الگوریتم‌های تقریبی کاهش ضریب تقریب است. در بعضی از موارد حتی امکان ارائه‌ی الگوریتم تقریبی با ضریبی ثابت نیز وجود ندارد. به طور مثال، الگوریتم تقریبی با ضریب تقریب کم‌تر از ۲، برای مسئله‌ی kـ مرکز وجود ندارد مگر این‌که $P = NP$ باشد. برای مسائل مختلف، معمولاً می‌توان کران پایینی برای میزان تقریب‌پذیری آن‌ها ارائه داد. در واقع برای برخی مسائل ان‌پی‌ـ سخت، علاوه بر این که الگوریتم کارآمدی وجود ندارد، بعضاً الگوریتم تقریبی با ضریبی تقریب کم و نزدیک به یک نیز وجود ندارد. در جدول ۳ـ۱ میزان تقریب‌پذیری مسائل مختلفی که در این پایان‌نامه مورد استفاده قرار می‌گیرد را می‌بینید.

فصل ۴

نتایج جدید

در این فصل نتایج جدید به‌دست‌آمده در پایان‌نامه توضیح داده می‌شود. در صورت نیاز می‌توان نتایج جدید را در قالب چند فصل ارائه نمود. همچنین در صورت وجود پیاده‌سازی، بهتر است نتایج پیاده‌سازی را در فصل مستقلی پس از این فصل قرار داد.

فصل ۵

نتیجه‌گیری

در این فصل، ضمن جمع‌بندی نتایج جدید ارائه‌شده در پایان‌نامه یا رساله، مسائل باز باقی‌مانده و همچنین پیشنهادهایی برای ادامه‌ی کار ارائه می‌شوند.

مراجع

[1] X. Ren, C.-M. Yu, W. Yu, S. Yang, X. Yang, J. A. McCann, and S. Y. Philip. Lopub: high-dimensional crowdsourced data publication with local differential privacy. *IEEE Transactions on Information Forensics and Security*, 13(9):2151–2166, 2018.

[2] H. Zhang, K. Li, T. Huang, X. Zhang, W. Li, Z. Jin, F. Gao, and M. Gao. Publishing locally private high-dimensional synthetic data efficiently. *Information Sciences*, 633:343–356, 2023.

[3] H. Jiang, H. Yu, X. Cheng, J. Pei, R. Pless, and J. Yu. Dp2-pub: Differentially private high-dimensional data publication with invariant post randomization. *IEEE Transactions on Knowledge and Data Engineering*, 2023.

[4] D. Zhang, W. Ni, N. Fu, L. Hou, and R. Zhang. Locally differentially private multi-dimensional data collection via haar transform. *Comput. Secur.*, 130:103291, 2023.

[5] Google. Source code of rappor in chromium. https://chromium.googlesource.com/chromium/src/+/71.0.3553.2/components/rappor/, 2015.

[6] C. Dwork, K. Kenthapadi, F. McSherry, I. Mironov, and M. Naor. Our data, ourselves: Privacy via distributed noise generation. In *Advances in Cryptology-EUROCRYPT 2006: 24th Annual International Conference on the Theory and Applications of Cryptographic Techniques, St. Petersburg, Russia, May 28-June 1, 2006. Proceedings 25*, pages 486–503. Springer, 2006.

[7] S. P. Kasiviswanathan, H. K. Lee, K. Nissim, S. Raskhodnikova, and A. Smith. What can we learn privately? *SIAM Journal on Computing*, 40(3):793–826, 2011.

[8] J. C. Duchi, M. I. Jordan, and M. J. Wainwright. Local privacy and statistical minimax rates. *2013 IEEE 54th Annual Symposium on Foundations of Computer Science*, pages 429–438, 2013.

[9] C. Dwork. A firm foundation for private data analysis. *Communications of the ACM*, 54:86 – 95, 2011.

[10] S. L. Warner. Randomized response: a survey technique for eliminating evasive answer bias. *Journal of the American Statistical Association*, 60 309:63–6, 1965.

[11] P. Kairouz, K. A. Bonawitz, and D. Ramage. Discrete distribution estimation under local privacy. In *International Conference on Machine Learning*, 2016.

[12] P. Kairouz, S. Oh, and P. Viswanath. Extremal mechanisms for local differential privacy. *J. Mach. Learn. Res.*, 17:17:1–17:51, 2014.

[13] K. Nissim, R. Smorodinsky, and M. Tennenholtz. Approximately optimal mechanism design via differential privacy. In *Proceedings of the 3rd innovations in theoretical computer science conference*, pages 203–213, 2012.

[14] F. D. McSherry. Privacy integrated queries: an extensible platform for privacy-preserving data analysis. In *Proceedings of the 2009 ACM SIGMOD International Conference on Management of data*, pages 19–30, 2009.

[15] S. Wang, L. Huang, P. Wang, H. Deng, H. Xu, and W. Yang. Private weighted histogram aggregation in crowdsourcing. In *Wireless Algorithms, Systems, and Applications*, 2016.

[16] Ú. Erlingsson, V. Pihur, and A. Korolova. Rappor: Randomized aggregatable privacy-preserving ordinal response. In *Proceedings of the 2014 ACM SIGSAC conference on computer and communications security*, pages 1054–1067, 2014.

[17] C. Dwork, F. McSherry, K. Nissim, and A. Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of Cryptography: Third Theory of Cryptography Conference, TCC 2006, New York, NY, USA, March 4-7, 2006. Proceedings 3*, pages 265–284. Springer, 2006.

[18] J. C. Duchi, M. J. Wainwright, and M. I. Jordan. Minimax optimal procedures for locally private estimation. *Journal of the American Statistical Association*, 113:182 – 201, 2016.

[19] X. Chen, C. Wang, Q. Yang, T. Hu, and C. Jiang. Locally differentially private high-dimensional data synthesis. *Science China Information Sciences*, 66(1):1–18, 2023.

[20] N. Wang, X. Xiao, Y. D. Yang, J. Zhao, S. C. Hui, H. Shin, J. Shin, and G. Yu. Collecting and analyzing multidimensional data with local differential privacy. *2019*

IEEE 35th International Conference on Data Engineering (ICDE), pages 638–649, 2019.

[21] H. H. Arcolezi, J.-F. Couchot, B. al Bouna, and X. Xiao. Improving the utility of locally differentially private protocols for longitudinal and multidimensional frequency estimates. *Digit. Commun. Networks*, 10:369–379, 2021.

[22] K. Yu, X. Wu, W. Ding, Y. Mu, and H. Wang. Markov blanket feature selection using representative sets. *IEEE Transactions on Neural Networks and Learning Systems*, 28:2775–2788, 2017.

[23] R. Du, Q. Ye, Y. Fu, and H. Hu. Collecting high-dimensional and correlation-constrained data with local differential privacy. In *2021 18th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON)*, pages 1–9. IEEE, 2021.

[24] J. Han and M. Kamber. *Data Mining, Southeast Asia Edition: Concepts and Techniques.* Morgan kaufmann, 2006.

[25] V. Estivill-Castro. Why so many clustering algorithms: a position paper. *ACM SIGKDD explorations newsletter*, 4(1):65–75, 2002.

[26] C. C. Aggarwal. *Data streams: models and algorithms.* Springer Science & Business Media, 2007.

[27] M. R. Garey and D. S. Johnson. Computers and intractability: a guide to the theory of NP-completeness. *Freeman & Co.*, 1979.

[28] N. Megiddo and K. J. Supowit. On the complexity of some common geometric location problems. *SIAM Journal on Computing*, 13(1):182–196, 1984.

[29] V. V. Vazirani. *Approximation Algorithms.* Springer-Verlag New York, Inc., 2001.

[30] R. M. McCutchen and S. Khuller. Streaming algorithms for k-center clustering with outliers and with anonymity. In *Proceedings of the 11th International Workshop on Approximation Algorithms*, pages 165–178, 2008.

[31] S. Guha. Tight results for clustering and summarizing data streams. In *Proceedings of the 12th International Conference on Database Theory*, pages 268–275, 2009.

[32] H.-K. Ahn, H.-S. Kim, S.-S. Kim, and W. Son. Computing k centers over streaming data for small k. *International Journal of Computational Geometry and Applications*, 24(02):107–123, 2014.

[33] M. Charikar, S. Khuller, D. M. Mount, and G. Narasimhan. Algorithms for facility location problems with outliers. In *Proceedings of the 12th ACM-SIAM Symposium on Discrete Algorithms*, pages 642–651, 2001.

[34] P. K. Agarwal and R. Sharathkumar. Streaming algorithms for extent problems in high dimensions. In *Proceedings of the 21st ACM-SIAM Symposium on Discrete Algorithms*, pages 1481–1489, 2010.

[35] T. M. Chan and V. Pathak. Streaming and dynamic algorithms for minimum enclosing balls in high dimensions. *Computational Geometry: Theory and Applications*, 47(2):240–247, 2014.

[36] S.-S. Kim and H.-K. Ahn. An improved data stream algorithm for clustering. In *Proceedings of the 11th Latin American Symposium on Theoretical Informatics*, pages 273–284, 2014.

[37] H. Zarrabi-Zadeh and A. Mukhopadhyay. Streaming 1-center with outliers in high dimensions. In *Proceedings of the 21st Canadian Conference on Computational Geometry*, pages 83–86, 2009.

[38] M. Bern and D. Eppstein. Approximation algorithms for geometric problems. In D. S. Hochbaum, editor, *Approximation Algorithms for NP-hard Problems*, pages 296–345. PWS Publishing Co., 1997.

واژه‌نامه

الف

ابتکاری ..... heuristic
ابعاد بالا ..... high dimensions
اریب ..... bias
آستانه ..... threshold
اصل لانه‌ی کبوتری ..... pigeonhole principle
ان‌پی‌ـ‌سخت ..... NP-Hard
انتقال ..... transition

ب

برخط ..... online
برنامه‌ریزی خطی ..... linear programming
بهینه ..... optimum
بیشینه ..... maximum

پ

پرت ..... outlier
پرسمان ..... query
پوشش ..... cover
پیچیدگی ..... complexity

ت

تجربی ..... experimental
تراکم ..... density
تقریب ..... approximation
تقسیم‌بندی ..... partition
توری ..... mesh
توزیع‌شده ..... distributed

ج

جداپذیر ..... separable
جعبه سیاه ..... black box
جویبار داده ..... data stream

ح

حدی ..... extreme
حریصانه ..... greedy

خ

خوشه ..... cluster
خطی ..... linear

د

داده ..... data
داده‌کاوی ..... data mining
داده‌ی پرت ..... outlier data
دوبرابرسازی ..... doubling
دودویی ..... binary

ر

رأس ..... vertex
رسمی ..... formal

ز

زیرخطی ..... sublinear

س

سرشکن ..... amortized
سلسه‌مراتبی ..... hierarchichal

ش

شبه کد ..... pseudocode
شیء ..... object

ص

صدق‌پذیری ..... satisfiability

غ

غلبه ..... dominate

ف

فاصله ..... distance
فضا ..... space

ق

قطعی ..... deterministic

ک

کارا ..... efficient
کاندیدا ..... candidate
کمینه ..... minimum

م

مجموعه ..... set
مجموعه هسته ..... coreset
مسطح ..... planar
موازی‌سازی ..... parallelization
میان‌گیر ..... buffer

ن

نابه‌جایی ..... inversion
ناوردا ..... invariant
نقطه‌ی مرکزی ..... center point
نیم‌فضا ..... half space

هـ

هزینه‌ی آشوب ..... price of anarchy (POA)

ی

یال ..... edge

پیوست آ

مطالب تکمیلی

پیوست‌های خود را در صورت وجود می‌توانید در این قسمت قرار دهید.

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the XƎPersian package for the LaTeX typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, XƎPersian

Sharif University of Technology

Department of Computer Engineering

M.Sc. Thesis

A Standard Template for Typesetting Theses in Persian

By:

The Author

Supervisor:

Dr. Supervisor

September 2024