دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان‌نامه کارشناسی ارشد
مهندسی کامپیوتر

حفظ حریم خصوصي تفاضلي محلي هنگام انتشار داده‌هاي با ابعاد بالا و در حال تغییر

نگارش

سید آرش ساعتچی

استاد راهنما

دکتر رسول جلیلی

شهریور ۱۴۰۴

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

چکیده

حریم خصوصی تفاضلی محلی یکی از رویکردهای پیشرو در حفاظت از داده‌های کاربران است که بدون اعتماد به کارپذیر، حریم خصوصی را تضمین می‌کند. این مفهوم با افزودن نوفه به داده‌های کاربران قبل از ارسال به سمت کارپذیر، امکان تحلیل داده‌ها را فراهم می‌سازد. این گزارش بر چالش‌های حفظ حریم خصوصی تفاضلی محلی در داده‌های با ابعاد بالا و در حال تغییر تمرکز دارد. از جمله چالش‌های اساسی در این زمینه، همبستگی میان ویژگی‌ها، افزایش حساسیت داده‌ها و مصرف سریع بودجه حریم خصوصی است که می‌تواند دقت و کارایی تحلیل‌های آماری را به شدت کاهش دهد. استفاده ایمن از این داده‌ها در حوزه‌هایی نظیر اینترنت اشیا، داده‌های سلامت و سیستم‌های نظارتی اهمیت بالایی دارد زیرا این داده‌ها معمولاً در تصمیم‌گیری‌های کلیدی و توسعه خدمات هوشمند مورد استفاده قرار می‌گیرند و حفظ حریم خصوصی کاربران در فرآیندها از اولویت بالایی برخوردار است. در این گزارش ضمن دسته‌بندی، مرور و مقایسه الگوریتم‌ها و کارهای پیشین راه‌کار جدیدی برای حل چالش داده‌های باابعاد بالا و در حال تغییر ارائه شده است. این راهکار با بهره‌گیری از تخصیص بهینه بودجه حریم خصوصی بر اساس همبستگی میان ویژگی‌ها، موجب کاهش نوفه اضافی می‌شود. همچنین با مدیریت و کاهش دامنه داده‌ها، از مصرف بیش از اندازه‌ی بودجه حریم خصوصی جلوگیری کرده و دقت و کارایی فرآیندها را افزایش می‌دهد. در نهایت، نتایج این پژوهش چارچوبی عملی و کارآمد برای تحلیل داده‌های باابعاد بالا و در حال تغییر فراهم می‌کند که می‌تواند به عنوان یک ابزار کاربردی در سیستم‌های مبتنی بر داده به کار گرفته شود.

کلیدواژه‌ها: حریم خصوصي تفاضلي محلي، انتشار داده، داده‌هاي در حال تغییر، داده‌هاي با ابعاد بالا

فهرست مطالب

۱ مقدمه ۱

۱ـ۱ تعریف مسئله ۲

۱ـ۲ اهمیت موضوع ۲

۱ـ۳ ادبیات موضوع ۴

۱ـ۳ـ۱ حریم خصوصی ۴

۱ـ۳ـ۲ داده‌های با ابعاد بالا ۴

۱ـ۳ـ۳ داده‌های در حال تغییر ۴

۱ـ۳ـ۴ پدیده نفرین ابعاد بالا ۴

۱ـ۴ اهداف پژوهش ۵

۱ـ۵ ساختار پایان‌نامه ۵

۲ مفاهیم اولیه ۶

۲ـ۱ حریم خصوصی تفاضلی ۶

۲ـ۲ بودجه حریم خصوصی ۷

۲ـ۳ حریم خصوصی تفاضلی محلی ۷

۲ـ۴ حساسیت ۸

۲ـ۵ الگوریتم‌های حافظ حریم خصوصی تفاضلی ۹

۲ـ۵ـ۱ سازوکار لاپلاس ۹

۲ـ۵ـ۲ سازوکار نمایی ۱۰
۲ـ۵ـ۳ پاسخ تصادفی ۱۰
۲ـ۵ـ۴ پاسخ تصادفی عمومی ۱۱
۲ـ۵ـ۵ الگوریتم تصادفی‌سازی متقارن ۱۲
۲ـ۶ ترکیب متوالی ۱۲
۲ـ۷ ترکیب موازی ۱۳
۲ـ۸ روش‌های کدگذاری ۱۳
۲ـ۸ـ۱ کدگذاری مستقیم ۱۴
۲ـ۸ـ۲ کدگذاری یکانی ۱۴
۲ـ۸ـ۳ کدگذاری یکانی متقارن ۱۵
۲ـ۸ـ۴ درهم‌سازی محلی ۱۵
۲ـ۸ـ۵ بلوم فیلتر ۱۶
۲ـ۸ـ۶ علائم ریاضی پرکاربرد ۱۷
۲ـ۸ـ۷ لیست‌ها ۱۹
۲ـ۸ـ۸ درج شکل ۱۹
۲ـ۸ـ۹ درج جدول ۲۰
۲ـ۸ـ۱۰ درج الگوریتم ۲۰
۲ـ۸ـ۱۱ محیط‌های ویژه ۲۰
۲ـ۹ برخی نکات نگارشی ۲۱
۲ـ۹ـ۱ فاصله‌گذاری ۲۱
۲ـ۹ـ۲ شکل حروف ۲۲
۲ـ۹ـ۳ جدانویسی ۲۲

۳ کارهای پیشین **۲۴**
۳ـ۱ داده‌های با ابعاد بالا ۲۴

۳ـ۱ـ۱ نمونه برداری ۲۵
۳ـ۲ مسائل خوشه‌بندی ۲۷
۳ـ۳ خوشه‌بندی kـ مرکز ۲۹
۳ـ۴ مدل جویبار داده ۳۱
۳ـ۵ تقریب‌پذیری ۳۲

۴ نتایج جدید **۳۴**

۵ نتیجه‌گیری **۳۵**

مراجع **۳۶**

واژه‌نامه **۳۹**

آ مطالب تکمیلی **۴۱**

فهرست جدول‌ها

۲ـ۱ عملگرهای مقایسه‌ای ۲۰

۳ـ۱ نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی ۳۳

فهرست شکل‌ها

۲ـ۱ نحوه عملکرد حریم خصوصی تفاضلی محلی ۹

۲ـ۲ شیوه‌ی درج عنصر با استفاده از بلوم فیلتر ۱۸

۲ـ۳ یک گراف و پوشش رأسی آن ۱۹

۲ـ۴ نمونه شکل ایجادشده توسط نرم‌افزار Ipe ۲۰

۳ـ۱ نمونه‌ای از مسئله‌ی ۲ـ مرکز ۳۰

۳ـ۲ نمونه‌ای ازمسئله‌ی ۲ـ مرکز با داده‌های پرت ۳۱

فصل ۱

مقدمه

در دنیای امروز که داده‌ها به بخش مهمی از تصمیم‌گیری‌ها و توسعه سیستم‌های اطلاعاتی تبدیل شده‌اند، حفاظت از حریم خصوصی افراد از اهمیت بالایی برخوردار است. حریم خصوصی تفاضلی به عنوان یک چارچوب ریاضی، رویکرد نوینی را برای جلوگیری از افشای اطلاعات حساس افراد در تحلیل داده‌ها ارائه می‌دهد.

انتشار داده‌ها بر مبنای حریم خصوصی تفاضلی اخیراً توجه زیادی را به خود جلب کرده و همچنین الگوریتم‌های متنوعی برای بهبود آن ارائه شده‌است. تعریف ریاضی حریم خصوصی تفاضلی بیان می‌کند که نتیجه هر تحلیل آماری روی داده‌ها، چه شما در آن شرکت کنید و چه نه، یکسان باشد. یعنی اطلاعاتی که از داده‌ها استخراج می‌شود، به گونه‌ای طراحی شده‌است که هیچ فردی نتواند از مشارکت یا عدم مشارکت خود، آسیب یا مزیتی دریافت کند. به عبارت دیگر، حریم خصوصی تفاضلی تضمین می‌کند که داده‌های فردی در برابر تحلیل‌های جمعی محافظت می‌شوند و هیچ گونه اطلاعات خاصی درباره افراد در معرض خطر قرار نمی‌گیرد. این ویژگی باعث می‌شود که افراد با اطمینان بیشتری در تحلیل‌های آماری شرکت کنند.

طی چند سال گذشته، راه حل‌هایی ارائه شده‌است تا هر کاربر بتواند ابتدا روی داده‌های خود نوفه ایجاد کرده و سپس آن‌ها را به سمت کارپذیر ارسال کند. به این راه حل‌ها، الگوریتم‌های حریم خصوصی تفاضلی محلی گفته می‌شود. در این الگوریتم‌ها، حتی با وجود غیرقابل اعتماد بودن کارپذیر، حریم خصوصی کاربران محفوظ باقی می‌ماند. لازم به ذکر است در انتشار داده‌های خصوصی با ابعاد بالا با چالش‌هایی مانند روابط پیچیده بین ویژگی‌ها، پیچیدگی محاسباتی بالا و پراکندگی داده‌ها روبه‌رو هستیم. راه حل‌های موجود که با تمرکز روی داده با ابعاد پایین ارائه شده‌اند، بودجه حریم خصوصی را بین همه ویژگی‌ها تقسیم می‌کنند. با پیاده‌سازی این راه حل‌ها روی داده با ابعاد بالا، نوفه در مقیاس بالا تولید شده و سیستم کارایی خود را از دست می‌دهد. از طرفی یکی دیگر از چالش‌های حفظ حریم خصوصی تفاضلی، کار روی

داده‌های در حال تغییر است. یک نمونه بارز در چنین مسائلی، نظارت برخط روی برنامه‌های نرم‌افزاری و گزارش عملکرد آن‌ها است، زیرا داده‌های ارسالی همواره در حال تغییر هستند. پروتکل‌های فعلی جمع‌آوری داده‌ها می‌توانند حریم خصوصی تفاضلی را در داده‌های با دامنه تغییرات محدود ارضا کنند. در نتیجه برای دامنه‌های بزرگ، مانند دامنه تغییرات داده‌ها در اینترنت‌اشیاء، ناکارآمد خواهند بود. هدف از این پژوهش ارائه راهکاری به منظور حفظ حریم خصوصی کاربران در هنگام انتشار داده‌ها با ابعاد بالا و در حال تغییر است. به منظور ارزیابی عملکرد و کارایی این الگوریتم، ما به تحلیل و محاسبه فراوانی داده‌ها پرداخته و مقدار خطای بدست آمده را با خروجی سایر الگوریتم‌های موجود مقایسه می‌کنیم. این مقایسه، به ما کمک می‌کند تا نقاط قوت و ضعف روش پیشنهادی را شناسایی کرده و در جهت بهینه‌سازی بیشتر آن گام برداریم. در نهایت، نتایج حاصل از این پژوهش می‌تواند به عنوان یک چارچوب کاربردی برای حفظ حریم خصوصی داده‌های کاربران مورد استفاده قرار گیرد.

۱ـ۱ تعریف مسئله

اکثر مقالات و راهکارهای پیشین، فقط یکی از دو چالش اصلی که پیش‌تر ذکر شد را مورد بررسی قرار داده‌اند و برای ارزیابی راهکار خود مجموعه داده مختص با یک چالش را گردآوری کرده اند. مقالاتی که روی داده‌های با ابعاد بالا کار کرده‌اند، معمولا اختلاف میانگین یا اختلاف احتمال توزیع داده‌ها را به عنوان خطا ارائه می‌دهند. همچنین مقالاتی که روی داده‌های در حال تغییر کار می‌کنند، شمارش داده‌های یکسان را به عنوام معیار در نظر گرفته و سعی می‌کنند خطای مربوط به این معیار را کاهش دهند.

از آنجایی که ما هر دو چالش را مورد بررسی قرار داده‌ایم، مجموعه داده‌ای شامل هر دو نوع داده گردآوری شده‌است. یعنی یک مجموعه داده با ابعاد بالا داریم که بعضی از بعدهای آن دامنه‌ی بزرگی دارند و مدام در حال تغییر هستند. به صورت خلاصه راه‌حل ارائه شده، یک نوفه‌ی خاص را روی تمام ابعاد اعمال می‌کند. سپس به منظور ارزیابی راهکار، خطای دو معیار محاسبه می‌شود. معیار شمارش داده‌ها روی بعدهای در حال تغییر در نظر گرفته شده و همچنین معیار احتمال توزیع داده‌ها روی دیگر ابعاد بررسی می‌شود.

۱ـ۲ اهمیت موضوع

در دنیای امروزی برنامه‌های کاربردی بیشماری وجود دارد که مردم با کمک این برنامه‌ها، زندگی روزمره‌ی خود را سپری می‌کنند. داده‌های ورودی برای این برنامه‌ها شامل داده‌های با ابعاد بالا و در حال تغییر

می‌شوند. چندین نوع داده کاربردی مهم وجود دارند که حفظ حریم خصوصی افراد در آن حائز اهمیت است، از جمله:

- سوابق پزشکی، داده‌هایی با ابعاد بالا هستند و معمولاً با جمع‌آوری اطلاعات جدید، در طول زمان تغییر می‌کنند. برای مثال، سابقه پزشکی و داده‌های ژنتیکی یک بیمار ممکن است با هر مراجعه به‌روزرسانی شود.
- مؤسسات مالی با داده‌هایی مانند سوابق تراکنش‌ها و عوامل بازار مثل قیمت سهام و روندهای بازار سروکار دارند. این مجموعه‌داده به‌صورت پیوسته با انجام تراکنش‌ها، نوسان قیمت سهام و ظهور محصولات مالی جدید، تغییر می‌کنند.
- سکوهای رسانه اجتماعی داده‌های ابعاد بالا مانند اطلاعات حساب کاربران، تعاملات و ترجیحات را جمع‌آوری می‌کنند که با فعالیت کاربران در محتوا و سکو، تغییر می‌کنند.
- شبکه‌های هوشمند و دستگاه‌های اینترنت اشیا، داده‌هایی از حسگرها و دستگاه‌ها مانند الگوهای مصرف انرژی، عوامل محیطی و وضعیت دستگاه‌ها را جمع‌آوری می‌کنند. لازم به ذکر است که این داده‌ها هم بعدهای زیادی داردن و هم شامل داده‌های در حال تغییر می‌باشند.

تا کنون چندین پیاده‌سازی از الگوریتم‌های حریم خصوصی تفاضلی انجام شده است. به عنوان مثال، گوگل در مرورگر کروم از الگوریتم رپور[1] بهره می‌گیرد تا شاخص‌های کاربری و تنظیمات حساسی مانند صفحهٔ خانگی را از میلیون‌ها کاربر جمع‌آوری کند، بی‌آنکه هویت فردی آنان افشا شود. کروم روزانه حدود ۱۴ میلیون گزارش از کاربران داوطلب دریافت می‌کند و با اتکا به این داده‌ها می‌تواند اطلاعات مفیدی را بدون فاش شدن شناسه‌های شخصی در دسترس تحلیلگران قرار دهد [۱].

از طرفی مایکروسافت برای جمع‌آوری داده‌های دورسنجی[2] از سامانه‌هایش به‌جای ارسالِ داده خام، سازوکاری مبتنی بر حریم خصوصی تفاضلیِ محلی پیاده‌سازی کرده است. این فناوری از سال ۲۰۱۷ روی میلیون‌ها دستگاه فعال شده و اکنون معیارهایی[3] مثل مدت استفاده از هر برنامه را برای هر بازه‌ی شش‌ساعته ثبت می‌کند مرجع*. بدین‌ترتیب مایکروسافت تنها به نتایج تحلیل‌های آماری دست می‌یابد و هویت یا الگوی اطلاعات کاربران فاش نمی‌شود.

[1] Rappor
[2] Telemetry Data
[3] Metric

۱ـ۳ ادبیات موضوع

۱ـ۳ـ۱ حریم خصوصی

حریم خصوصی مفهومی است که به حق هر فرد برای کنترل دسترسی دیگران به اطلاعات، ارتباطات و قلمرو شخصی‌اش اشاره می‌کند. عنی هرکس بتواند خود تصمیم بگیرد چه داده‌هایی، در چه زمان و برای چه کسانی آشکار شود و چه بخش‌هایی از زندگی‌اش از نگاه دیگران دور بماند. این حق نه‌تنها شامل اطلاعات آشکار مانند نشانی، شماره تماس یا سوابق پزشکی است، بلکه ترجیحات، گفت‌وگوهای خصوصی و حتی الگوهای رفتاری ضمنی را نیز در بر می‌گیرد. حریم خصوصی با فراهم کردن فضایی امن، مشارکت آگاهانه و بدون ترس در جامعه دیجیتال را ممکن می‌سازد.

۱ـ۳ـ۲ داده‌های با ابعاد بالا

مقصود از داده‌های با ابعاد بالا مجموعه‌ای از داده‌هاست که هر مشاهده آن شامل شمار زیادی ویژگی یا بُعد است. به بیان دیگر، به‌جای سطرهایی با چند ستون محدود، با رکوردهایی روبه‌رو هستیم که ده‌ها یا صدها ستون دارند و هر ستون جنبه‌ای مجزا از پدیده را وصف می‌کند. این تکثر ابعاد، گرچه امکان استخراج الگوها و اطلاعات نهفته‌ی فراوان را فراهم می‌کند، اما هم‌زمان چالش‌هایی در حفظ حریم خصوصی به همراه می‌آورد. در این پژوهش راهکاری مربوط به حل اینگونه چالش‌ها بررسی و پیاده‌سازی شده‌است.

۱ـ۳ـ۳ داده‌های در حال تغییر

داده‌های در حال تغییر، مجموعه‌ای از اطلاعات را شامل می‌شود که مقدار ستون‌های آن با گذر زمان تغییر می‌کنند. برای نمونه، تعداد ثانیه‌های استفاده از یک اپلیکیشن یا هر شمارنده و مؤلفه‌ی دیگری که امروز ارزشی دارد و با گذشت زمان عوض می‌شود. این نوسانِ مداوم باعث می‌شود سامانه داده را به‌طور پی‌درپی جمع‌آوری و به‌روزرسانی کند. معولا دامنه تغییر این داده‌ها بالا است و چالش‌هایی در حفظ حریم خصوصی بوجود می‌آید که در ادامه به آن اشاره خواهیم کرد.

۱ـ۳ـ۴ پدیده نفرین ابعاد بالا

نفرین ابعاد بالا به مجموعه چالش‌ها و مشکلاتی گفته می‌شود که با زیاد شدن تعداد ویژگی‌ها در داده رخ می‌دهد. در واقع هر قدر بُعدها بیشتر می‌شوند، احتمال ارتباط میان ابعاد بالا رفته و سامانه برای حفظ حریم

خصوصی داده‌ها به ناچار باید نوقه‌ی بیشتری اضافه کند. هر چقدر نوفه بیشتر اعمال شود، دقت نتایج تحلیل داده‌ها کاهش میابد. بنابراین در این پژوهش راه‌حلی انتخاب و توسعه یافته است که موازنه[۴] بین حریم خصوصی و سودمندی[۵] رعایت شود.

۱ـ۴ اهداف پژوهش

راه‌حل‌های بیشماری تاکنون ارائه شده است ولی اکثر آنها یا حریم خصوصی را کامل ارضا نمی‌کنند یا سربار بالای زمانی و نوفه‌ای به سامانه اعمال می‌کنند. در نتیجه هزینه‌ی استفاده از الگوریتم برای حفظ حریم خصوصی بالا رفته و سازمان‌ها رغبتی به استفاده از آن نمی‌کنند. بنابراین هدف این پژوهش طراحی و پیاده‌سازی ابزاری سبک، کاربرپسند و سریع است که بتواند با تزریق بهینه نوفه به داده‌های خام، هم‌زمان هم سودمندی را داشته باشیم و هم حریم خصوصی حفظ شود.

۱ـ۵ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل به شرح زیر ارائه می‌شود. مفاهیم اولیه مورد استفاده در این پایان‌نامه در فصل دوم به اختصار اشاره شده است. فصل سوم به مطالعه و بررسی کارهای پیشین مرتبط با موضوع این پایان‌نامه می‌پردازد. در فصل چهارم، نتایج جدیدی که در این پایان‌نامه به‌دست آمده است، ارائه می‌شود. فصل پنجم به جمع‌بندی کارهای انجام شده در این پژوهش و ارائه‌ی پیشنهادهایی برای انجام کارهای آتی خواهد پرداخت.

[4] Trade off
[5] Utility

فصل ۲

مفاهیم اولیه

دومین فصل پایان‌نامه به طور معمول به معرفی مفاهیمی می‌پردازد که در پایان‌نامه مورد استفاده قرار می‌گیرند. در این فصل به عنوان یک نمونه، نکات کلی در خصوص نحوه‌ی نگارش پایان‌نامه و نیز برخی نکات نگارشی به اختصار توضیح داده می‌شوند.

۲ـ۱ حریم خصوصی تفاضلی

حریم خصوصی تفاضلی یک چارچوب ریاضی است که تضمین می‌کند خروجی هر تحلیل آماری به‌گونه‌ای ساخته شود که حضور یا عدم حضورِ هر فرد در داده‌ها تأثیری محسوس بر توزیع نتایج نگذارد. به بیان دیگر، حریم خصوصی تفاضلی محلی این اجازه را می‌دهد که بتوان روی یک مجموعه داده، تحلیل‌های آماری مانند میانگین و شمارش را انجام دهیم ولی نتوان اطلاعات مربوط به یک شخص را استخراج کرد. فرض کنید سازمانی می‌خواهد یک آمار تقریبی از تعداد افراد با یک بیماری خاص بدست‌آورد. این سازمان از تمام جامعه‌ی آماری خود میخواهد که با تکمیل فرمی بگویند که آیا آن بیماری خاص را دارند یا خیر. همگی فرم‌ها به سمت سازمان فرستاده می‌شود. سپس سازمان باید نتایج را با کاربران خود به اشتراک بگذارد. اگر نتایج به دور از هیچگونه سازوکار امنیتی منتشر شود، حریم خصوصی افراد شرکت کننده در رابطه با داشتن بیماری خاص نقض می‌شود. نوعی از الگوریتم‌های حفظ حریم خصوصی، الگوریتم‌های حریم خصوصی تفاضی هستند که با ایجاد نوفه در داده‌ها، باعث می‌شوند نتایج تحلیل‌های آماری به طوری تقریبی صحیح بوده و در عین حال، حریم خصوصی افراد حفظ شود.

تعریف حریم خصوصی تفاضلی برای اولین بار توسط خانم دُرک [۲] به صورت زیر مطرح شد:

تعریف ۲ـ۱ (حریم خصوصی تفاضلی) *الگوریتم M را در نظر بگیرید که به عنوان ورودی پایگاه داده D را دریافت می‌کند. این الگوریتم حریم خصوصی تفاضلی را در صورتی تضمین می‌کند که برای هر دو پایگاه داده مجاور D و D' و برای هر مجموعه خروجی S ممکن داشته باشیم:*

$$\Pr[\mathcal{M}(D) \in S] \leqslant e^{\epsilon} \times \Pr[\mathcal{M}(D') \in S] \qquad (۱ـ۲)$$

پایگاه داده‌هایی که تنها در یک عنصر تفاوت داشته باشند ، مجاور یا همسایه[1] نامیده می‌شوند. همچنین ϵ یک ورودی مثبت با مقدار کم است و سطح حریم خصوصی را نشان می‌دهد. بنابر عبارت بالا، هر چه مقدار کمتری برای ϵ در نظر بگیریم، در واقع قوانین سخت‌گیرانه‌تری برای حفظ حریم خصوصی اعمال کرده‌ایم.

۲ـ۲ بودجه حریم خصوصی

بودجه حریم خصوصی یکی از مفاهیم کلیدی در حریم خصوصی تفاضلی است که برای اندازه‌گیری و کنترل میزان حریم خصوصی در طی اجرای یک الگوریتم یا مجموعه‌ای از الگوریتم‌ها ، استفاده می‌شود. این مفهوم به‌طور مستقیم با پارامتر ϵ در ارتباط است.

معمولا بودجه‌ای که برای الگوریتم‌های حافظ حریم خصوصی در نظر می‌گیرند، برابر ۱ یا مقداری نزدیک به ۱ است. هرچه بودجه‌ی کمتری به الگوریتم اختصاص دهیم، در واقع حریم خصوصی قوی‌تری برایش اعمال کرده‌ایم. درنتیجه الگوریتم برای اینکه بتواند شرط حریم خصوصی در تعریف ۲ـ۱ را ارضا کند، باید نوفه‌ی بیشتری به داده‌ها اضافه کند. طبیعتا با اضافه کردن نوفه‌ی بیشتر، سودمندی کاهش خواهد یافت.

۲ـ۳ حریم خصوصی تفاضلی محلی

پس از معرفی حریم خصوصی تفاضلی، مشخص شد که ارسال داده‌های خام به سمت یک کارپذیر و اعتماد به آن، کار چندان درستی نیست. اگر به این کارپذیر حمله‌ی سایبری انجام می‌شد یا اینکه خود کارپذیر داده‌ها را به صورت غیر ایمن به سازمانی دیگر می‌داد، حریم خصوصی افراد جامعه نقض می‌شد. افزایش

[1] Neighbour

رخنه‌های امنیتی و سخت‌گیری‌های قانونی نیز این بی‌اعتمادی را تشدید کرد. از همین رو پژوهشگران به الگویی روی آوردند که در آن هر کاربر پیش از ارسال، پاسخ خود را به‌طور تصادفی نوفه‌دار می‌کند تا حریم خصوصی در همان مبدأ تضمین شود. نمایی از عملکرد حریم خصوصی تفاضلی محلی را می‌توانیم در شکل ۲ـ۱ مشاهده کنیم.

به بیانی دیگر، حریم خصوصی تفاضلی محلی مفهومی در حفاظت از داده‌های شخصی است که به کاربران اجازه می‌دهد اطلاعات خود را بدون نیاز به اعتماد به طرف ثالث در اختیار دیگران قرار دهند. در این مدل، پیش از آنکه داده‌ها به کارپذیر غیرقابل‌اعتماد ارسال شوند نوفه بر روی آنها اضافه می‌شود. سپس کارپذیر با پردازش داده‌ها به آمار قابل قبولی دست پیدا می‌کند که می‌تواند به صورت عمومی با کاربران به اشتراک گذاشته شود. مدل حریم خصوصی تفاضلی محلی برای اولین بار در سال ۲۰۱۱ [۳] ارائه شد و سپس دوچی و همکارانش [۴] تعریف بهتر و دقیق‌تری از نظر ریاضیاتی معرفی کردند. این مدل را به اختصار، مدل «ال دی پی» می‌نامند.

تعریف ۲ـ۲ (حریم خصوصی تفاضلی محلی) *فرض کنید $\mathcal{X}$ دامنه داده‌های کاربر باشد و $\mathcal{M} : \mathcal{X} \to \mathcal{Y}$ یک الگوریتم تصادفی باشد. این الگوریتم به صورت (ϵ, δ) حریم خصوصی تفاضلی محلی را برآورده می‌کند اگر برای هر جفت داده ورودی $x, x' \in \mathcal{X}$ و هر زیرمجموعه $S \subseteq \mathcal{Y}$ از خروجی‌های ممکن داشته باشیم:*

$$\Pr[\mathcal{M}(x) \in S] \leqslant e^{\epsilon} \Pr[\mathcal{M}(x') \in S] + \delta \qquad (۲ـ۲)$$

در نامساوی بالا، ϵ بودجه‌ی حریم خصوصی است و δ «پارامتر لغزش» تلقی می‌شود. ورودی δ کمی شرط تضمین حریم خصوصی تفاضلی را آسان‌تر می‌کند. به الگوریتم‌هایی که بتوانند شرط بالا را با δ برابر صفر ارضا کنند، حافظ حریم خصوصی تفاضلی خالص یا $\epsilon-LDP$ می‌گویند.

۲ـ۴ حساسیت

حساسیت[۲] در زمینه حریم خصوصی داده‌ها به حداکثر تغییر در خروجی یک تابع به دلیل تغییر یک ورودی واحد اشاره دارد [۵]. به عبارت دیگر، حساسیت اندازه‌گیری می‌کند که چقدر می‌توان با تغییر یک ورودی، خروجی تابع را تحت تأثیر قرار داد. این ویژگی در طراحی سازوکارهای حریم خصوصی تفاضلی محلی بسیار مهم است، زیرا تعیین می‌کند که چه مقدار نوفه باید به خروجی اضافه شود تا حریم خصوصی کاربران حفظ گردد.

[2] sensitivity

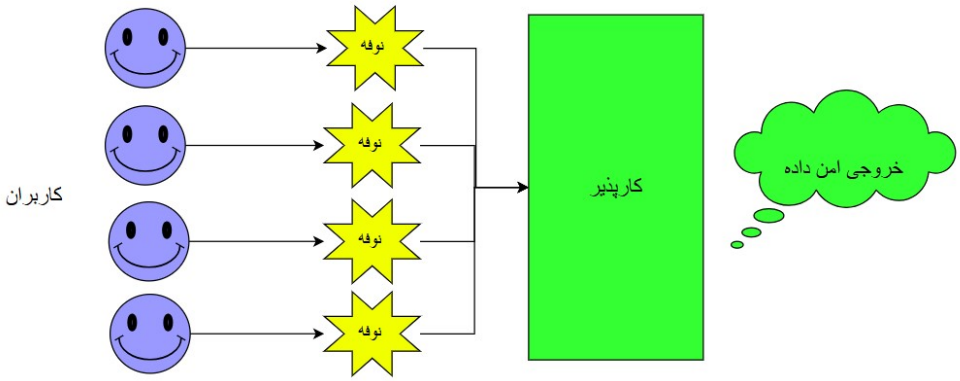

شکل ۲ـ۱: نحوه عملکرد حریم خصوصی تفاضلی محلی

تعریف ۲ـ۳ (حساسیت) *حساسیت یک تابع* $f : \mathcal{X} \to \mathbb{R}^d$ *به صورت زیر تعریف می‌شود:*

$$\Delta f = \max_{x,x' \in \mathcal{X}} \|f(x) - f(x')\| \tag{۲ـ۳}$$

در عبارت بالا Δf حساسیت تابع f نامیده می‌شود و $\mathcal{X}$ دامنه ورودی ما است.

۲ـ۵ الگوریتم‌های حافظ حریم خصوصی تفاضلی

۲ـ۵ـ۱ سازوکار لاپلاس

سازوکار لاپلاس[۳] در حریم خصوصی تفاضلی ایده‌ای ساده و در عین حال توانمند است. هرگاه بخواهیم آماری از داده‌ها مانند مجموع، میانگین و تعداد را منتشر کنیم، به‌جای پاسخ دقیق، همان پاسخ را با نوفه‌ای که از توزیع لاپلاس بدست می‌آید می‌فرستیم. مقدار پراکندگی این نوفه طوری تنظیم می‌شود که اگر اطلاعات یک فرد در پایگاه‌داده حذف یا اضافه شود، توزیع خروجی تقریباً تغییر نکند. بدین‌ترتیب حضور یا عدم حضور آن فرد در نتیجه قابل تشخیص نیست. بزرگی نوفه به دو عامل بستگی دارد: حساسیت تابع و همچنین بودجهٔ حریم خصوصی. هرچه بودجه‌ی کمتری اختصاص دهیم حفاظت قوی‌تر شده و نوفه بیشتری اعمال می‌شود.

تعریف ۲ـ۴ (سازوکار لاپلاس) *سازوکار لاپلاس روی یک تابع* $f : \mathcal{X} \to \mathbb{R}^d$ *به صورت زیر تعریف می‌شود:*

[3] Laplace

$$\mathcal{M}(D) = f(D) + Lap\left(\frac{\Delta f}{\epsilon}\right) \qquad (۴_۲)$$

در عبارت بالا، ورودی مرکز یا μ در توزیع لاپلاس برابر صفر و همچنین ورودی مقیاس یا b برابر $\frac{\Delta f}{\epsilon}$ در نظر گرفته شده است.

۲ـ۵ـ۲ سازوکار نمایی

یکی از مشکلات سازوکار لاپلاس، عدم کارایی در مقادیر گسسته و غیر عددی است. از این رو سازوکار دیگری به نام سازوکار نمایی معرفی شد. این سازوکار چارچوبی فراهم می‌کند که در آن می‌توانیم تابع سودمنی دلخواه خود را تعریف کنیم. در واقع تابع u هر ورودی و خروجی تشکیل شده از پایگاه‌داده‌ی ما را به یک امتیاز سودمندی تبدیل می‌کند.

$$u : \mathbb{N}^{|X|} \times \mathcal{R} \to \mathbb{R} \qquad (۵_۲)$$

پس از محاسبه‌ی امتیاز هر خروجی، سازوکار گزینه‌ها را با احتمالی متناسب با توزیع نماییِ آن امتیاز انتخاب می‌کند. این انتخاب به‌گونه‌ای انجام می‌شود که گزینه‌های دارای امتیاز بالاتر، با احتمال بیشتری انتخاب شوند. این روش برای پرسش‌های غیرعددی (مثل «کدام محصول پرفروش‌تر است؟») بسیار سودمند خواهد بود. دقت کنید که ما اینجا نیاز به محاسبه حساسیت تابع سودمندی خود به شکل زیر داریم:

$$\Delta u = \max_{r \in \mathcal{R}} \max_{\substack{x,y \in \mathbb{N}^{|X|} \\ \|x-y\|_۱ \leqslant ۱}} |u(x,r) - u(y,r)| \qquad (۶_۲)$$

در نهایت سازوکار نمایی $\mathcal{M}_E(x, u, \mathcal{R})$ عنصر $r \in \mathcal{R}$ را با احتمالی متناسب با $\exp\left(\frac{\varepsilon\, u(x,r)}{۲\,\Delta u}\right)$ گزینش و اعلام می‌کند.

۲ـ۵ـ۳ پاسخ تصادفی

پاسخ تصادفی روشی است که در نظرسنجی‌ها و جمع‌آوری داده‌های حساس کاربرد دارد. در این روش، به جای اینکه کاربر به‌طور مستقیم به یک سؤال پاسخ دهد، از یک سازوکار تصادفی استفاده می‌کند تا عدم

قطعیت را به پاسخ خود اضافه کند. با اضافه کردن عدم قطعیت، مهاجم یا شخص متخاصم حتی اگر پاسخ نوفه‌دار شده‌ی کاربر را داشته‌باشد، نمی‌تواند با قطعیت جواب اصلی را مشخص کند. به بیان دیگر، کاربر با احتمال مشخصی پاسخ واقعی خود را ارائه می‌دهد و با احتمال دیگری پاسخ تصادفی دیگری را انتخاب می‌کند. این کار باعث می‌شود که احتمال شناسایی پاسخ واقعی کاربر کاهش یابد. مدل ریاضی پاسخ تصادفی توسط وارنر [۶] معرفی شد.

تعریف ۲ـ۵ (پاسخ تصادفی) *فرض کنید کاربر می‌خواهد به یک سؤال دودویی[۴] (بله/خیر) پاسخ دهد. اگر x پاسخ واقعی کاربر باشد، سازوکار پاسخ تصادفی به صورت زیر عمل می‌کند:*

$$\Pr[y=t] = \begin{cases} p, & \textit{if} \quad t = x, \\ 1-p, & \textit{if} \quad t \neq x \end{cases} \tag{۲ـ۷}$$

در عبارت بالا، y پاسخ ارائه شده به سؤال است. p احتمال اینکه کاربر پاسخ واقعی خود را ارائه دهد و $1-p$ احتمال این است که کاربر به طور تصادفی پاسخ مخالف را انتخاب کند. سازوکار پاسخ تصادفی اگر بخواهد $\epsilon-LDP$ باشد، باید مقدار p را برابر $\frac{e^{\varepsilon}}{e^{\varepsilon}+1}$ قرار دهیم.

۲ـ۵ـ۴ پاسخ تصادفی عمومی

پاسخ تصادفی به تنهایی جوابگوی مسائل پیچیده‌تر با دامنه بزرگتر نبود. پاسخ تصادفی عمومی[۵]، شکل عمومی‌تر و انعطاف‌پذیرتر پاسخ تصادفی است [۷، ۸]. این الگوریتم را به اختصار، «جی آر آر» می‌نامند.

تعریف ۲ـ۶ (پاسخ تصادفی عمومی) *فرض کنید کاربر می‌خواهد به یک سؤال با k گزینه پاسخ دهد. اگر x پاسخ واقعی کاربر باشد، سازوکار پاسخ تصادفی عمومی به صورت زیر عمل می‌کند:*

$$\Pr[y=t] = \begin{cases} p, & \textit{if} \quad t = x, \\ \frac{1-p}{k-1}, & \textit{if} \quad t \neq x \end{cases} \tag{۲ـ۸}$$

سازوکار پاسخ تصادفی اگر بخواهد $\epsilon-LDP$ باشد، باید مقدار p را برابر $\frac{e^{\varepsilon}}{e^{\varepsilon}+k-1}$ قرار دهیم.

[4] Binary
[5] Generalized Randomized Response

۲ـ۵ـ۵ الگوریتم تصادفی‌سازی متقارن

به الگوریتم‌هایی که در فرآیند تصادفی‌سازی برای حفظ حریم خصوصی کاربران، احتمال حفظ مقدار اصلی داده‌ها برابر با احتمال تغییر آن‌ها باشد، متقارن می‌گوییم. به عنوان مثال در مسائلی که ورودی با دامنه دودویی دارند، احتمال زیر برقرار است:

$$Pr[y = ۱|x = ۱] = Pr[y = ۰|x = ۰] \tag{۹ـ۲}$$

در عبارت بالا، x ورودی و y خروجی الگوریتم است.

۲ـ۶ ترکیب متوالی

در زمینه حریم خصوصی، ترکیب متوالی[۶] به این صورت تعریف می‌شود که اگر شما چندین سازوکار تصادفی را به‌طور متوالی روی یک مجموعه داده اجرا کنید، حریم خصوصی شما به‌طور کلی نقض می‌شود. حتی اگر هر یک از این سازوکارها جداگانه ایمن باشند، در نهایت نمی‌توانید حریم خصوصی را تضمین کنید [۹]. این اصل ساده اما سرنوشت‌ساز، طراحان الگوریتم‌های حریم خصوصی را مجبور می‌کند بودجهٔ حریم خصوصی را میان سازوکارهای مختلف تقسیم کنند. از آنجایی که بوجه‌ی حریم خصوصی محدود است، اگر تعداد سازوکارهای مختلف زیاد باشد، بودجه‌ی کمی به هر کدام می‌رسد و به سبب آن سودمندی الگوریتم کاهش میابد.

به بیان ریاضی، پس از اجرای k سازوکار مستقل روی یک مجموعه داده که هرکدام $\epsilon-LDP$ هستند، می‌توان گفت الگوریتم کلی ما با بودجه‌ای برابر با مجموع تمام بودجه‌ها، حریم خصوصی تفاضلی را ارضا می‌کند:

$$\mathcal{M}_i(x) \quad satisfies \quad \epsilon_i-LDP$$
$$\mathcal{M} = \{\mathcal{M}_۱, \mathcal{M}_۲, ..., \mathcal{M}_m\} \quad satisfies \quad \sum_{i=۱}^{m} \epsilon_i-LDP$$

در سامانه‌هایی که پرس‌وجوهای[۷] متعدد روی یک معیار داریم (مانند دریافت میزان مصرف باتری هر یک ساعت یکبار)، هر بار باید روی یک داده نوفه اعمال کنیم و به سمت کارپذیر بفرستیم. گرچه مقدار

[6] Sequential Composition
[7] Query

خام داده ممکن است هر بار تغییر کند، ولی چون از یک جنس است و مربوط به یک معیار می‌شود، قانون ترکیب متوالی روی آن صدق می‌کند. بودجه‌ی حریم خصوصی بین تعداد استفاده از سازوکار تصادفی‌سازی تقسیم شده و سودمندی کاهش میابد.

شایان ذکر است که در داده‌های با ابعاد بالا نیز، با چالش ترکیب متوالی روبه‌رو هستیم. در داده‌های با ابعاد بالا، احتمال وجود وابستگی میان ابعاد زیاد می‌شود (مانند ارتباط مستقیم بین سن و میزان درآمد). زمانیکه سازوکارهای تصادفی‌سازی را روی ابعاد وابسته به هم اعمال می‌کنیم، مانند این است که به یک مجموعه داده نوفه تزریق می‌کنیم. از این رو شامل قانون ترکیب متوالی شده و بوجه‌ی حریم خصوصی بین سازوکارها تقسیم می‌شود.

۲ـ۷ ترکیب موازی

در ترکیب موازی[۸]، الگوریتم‌های مختلف حریم خصوصی تفاضلی به طور همزمان روی یک یا چند پایگاه‌داده مجزا از یکدیگر اعمال می‌شوند [۱۰]. در این حالت، بودجه‌ی الگوریتم کلی برابر با حداکثر بودجه‌ی الگوریتم‌هاست:

$$\mathcal{M}_i(x) \quad satisfies \quad \epsilon_i{-}LDP$$

$$\mathcal{M} = \{\mathcal{M}_۱, \mathcal{M}_۲, ..., \mathcal{M}_m\} \quad satisfies \quad \max\{\epsilon_۱, \epsilon_۲, ..., \epsilon_m\}{-}LDP$$

۲ـ۸ روش‌های کدگذاری

هر کاربر به منظور ارسال داده‌ها سمت کارپذیر، باید ابتدا اطلاعات خود را در فرمت خاصی کدگذاری[۹] کند. اینکار به دو دلیل نیاز است:

۱. افزایش سرعت ارسال پیام

۲. بهبود فرایند تصادفی‌سازی

[8] Parallel Composition
[9] Encode

۲ـ۸ـ۱ کدگذاری مستقیم

کدگذاری مستقیم[10] یکی از روش‌های ساده برای کدگذاری مقادیر ورودی در پروتکل‌های حفاظت از حریم خصوصی محلی است. در این روش، داده‌ی هر کاربر بدون هیچ‌گونه تبدیل اولیه مستقیماً به عنوان خروجی کدگذاری‌شده و ارسال می‌شود. این روش برای مواردی که دامنه داده‌ها کوچک است (مانند داده‌های طبقه‌بندی‌شده یا مقادیر گسسته محدود) مناسب‌تر خواهد بود. این کدگذاری در پژوهش [۱۱] استفاده شده است.

$$v = Encode(v) \tag{۲ـ۱۰}$$

برای تصادفی‌سازی در این کدگذاری، باید از سازوکار تصادفی‌سازی عمومی استفاده کرد. دقت کنید که کارایی و عملکرد این روش با افزایش دامنه، به شدت کاهش میابد. از آنجایی که در الگوریتم تصادفی‌سازی عمومی، مقدار p برابر $\frac{e^{\varepsilon}}{e^{\varepsilon}+k-۱}$ است، با افزایش دامنه یا همان k، احتمال انتخاب شدن مقدار اصلی در تصادفی‌سازی کاهش یافته و به سبب آن، سودمندی دلخواه بدست نمی‌آید. همچنین یکی دیگر از معایب این روش، هزینه‌ی ارتباطی[11] بالا است.

۲ـ۸ـ۲ کدگذاری یکانی

کدگذاری یکانی[12] یکی از روش‌های متداول برای کدگذاری مقادیر ورودی در پروتکل‌های حفاظت از حریم خصوصی تفاضلی محلی است. در این روش، هر مقدار ورودی به یک بردار دودویی با طول ثابت تبدیل می‌شود. تنها یک بیت از این بردار که نماینده ورودی است، مقدار ۱ دارد و بقیه بیت‌ها ۰ هستند.

$$Encode(v) = [۰, \cdots, ۰, ۱, ۰, \cdots, ۰], \quad \text{only the v-th position is 1} \tag{۲ـ۱۱}$$

به منظور تصادفی‌سازی از فرمول زیر استفاده می‌کنیم. p احتمال ۱ شدن بیتی است که قبلا مقدار ۱ داشته است. همچنین q احتمال ۱ شدن بیتی است که قبلا مقدار ۰ داشته است:

[10] Direct Encoding
[11] Communication Cost
[12] Unary Encoding

$$\Pr[y = ۱] = \begin{cases} p, & \text{if} \quad x = ۱, \\ q, & \text{if} \quad x = ۰. \end{cases} \tag{۲ـ۱۲}$$

اگر شرط زیر برقرار باشد، می‌توان گفت پروتکل کدگذاری یکانی، حریم خصوصی تفاضلی را ارضا کرده است:

$$\epsilon = \ln\left(\frac{p(۱-q)}{(۱-p)q}\right) \tag{۲ـ۱۳}$$

۲ـ۸ـ۳ کدگذاری یکانی متقارن

پروتکل کدگذاری یکانی متقارن[۱۳] به این صورت تعریف می‌شود که حاصل جمع مقادیر احتمال p و q برابر ۱ باشد:

$$p + q = ۱$$

با توجه به قاعده ۲ـ۱۳، مقادیر p و q به صورت زیر بدست می‌آیند:

$$p = \frac{e^{\epsilon/۲}}{e^{\epsilon/۲} + ۱}, \quad q = \frac{۱}{e^{\epsilon/۲} + ۱}$$

۲ـ۸ـ۴ درهم‌سازی محلی

در پروتکل کدگذاری یکانی، هزینه‌ی ارتباطی به صورت خطی با زیاد شدن دامنه‌ی ورودی، افزایش میابد. از افزایش هزینه در بعضی برنامه‌های کاربردی موجب بروز تاخیر بسیار زیاد در عملکرد سامانه می‌شود. بنابراین به پروتکل دیگری نیاز داریم که بزرگ شدن دامنه‌ی ورودی، تاثیر چندانی در هزینه ارتباطی نداشته باشد.

ایده‌ی اولیه این است که از یک تابع درهم‌ساز[۱۴] استفاده کرده و اندازه دامنه‌ی ورودی را کاهش دهیم. این ایده مشکل تصادم[۱۵] را به همراه دارد. به بیان دیگر، دو ورودی به یک خروجی تبدیل شده و در زمان کدگشایی[۱۶] نمی‌توان مقدار درست ورودی را بدست آورد. در پژوهش رپور [۱۲] چندین راه برای حل این

[13] Symmetric Unary Encoding
[14] Hash Function
[15] Collision
[16] Decode

مشکل ارائه شده است:

۱. استفاده از چند تابع درهم‌ساز به منظور کاهش احتمال تصادم

۲. استفاده از مفهوم گروه[۱۷] که در آن هر گروه دارای مجموعه‌ای از توابع درهم‌ساز خواهد بود.

البته با توجه به روش‌های مذکور، نمی‌توان به صورت قطعی مشکل تصادم را حل کرد و این مشکل در کاهش سودمندی تأثیر می‌گذارد. روش بهتر این است که هر کاربر توابع درهم‌ساز محلی خود را داشته باشد. به این روش، درهم‌ساز محلی[۱۸] می‌گوییم. این روش به صورت کارا در الگوریتم‌های حفظ حریم خصوصی تفاضلی محلی استفاده می‌شود. کاربران با کمک توابع درهم‌ساز، ابتدا دامنه‌ی داده‌های خود را کاهش داده، تصادفی‌سازی کرده و در نهایت به سمت کارپذیر ارسال می‌کنند. در ادامه تعریف درهم‌ساز محلی دودویی را ارائه می‌دهیم:

تعریف ۲ـ۷ (درهم‌ساز محلی دودویی) *فرض کنید $\mathbb{H}$ یک خانواده جهانی از توابع درهم‌ساز باشد. هر تابع درهم‌ساز $H \in \mathbb{H}$، یک ورودی با دامنه‌ی d را به یک عدد تک بیتی تبدیل می‌کند. شرطی روی این خانواده از توابع درهم‌ساز اعمال می‌شود به صورت زیر خواهد بود:*

$$\forall x, y \in [d], x \neq y : \Pr_{H \in \mathbb{H}}[H(x) = H(y)] \leqslant \frac{۱}{۲} \qquad (۱۴ـ۲)$$

به منظور تصادفی‌سازی از فرمول زیر استفاده می‌کنیم:

$$\mathrm{Perturb}_{\mathrm{BLH}}(\langle H, b\rangle) = \langle H, b'\rangle, \quad \Pr[b' = ۱] = \begin{cases} p = \dfrac{e^{\epsilon}}{e^{\epsilon} + ۱}, & \text{if} \quad b = ۱ \\ q = \dfrac{۱}{e^{\epsilon} + ۱}, & \text{if} \quad b = ۰ \end{cases}$$

۲ـ۸ـ۵ بلوم فیلتر

بلوم‌فیلتر[۱۹] یک ساختار داده‌ای است که هدف اصلی آن انجام عملیات بررسی عضویت (یعنی تعیین اینکه یک عنصر در مجموعه‌ای وجود دارد یا خیر) با استفاده حداقلی از حافظه است. این فیلتر به ما کمک می‌کند تا سریعاً امکان وجود یک عنصر را بدون نیاز به ذخیره کل مجموعه در حافظه تشخیص دهیم.

[17] Cohort
[18] Local Hashing
[19] Bloom Filter

فرض کنید آرایه‌ای از بیت‌ها (معمولاً همه صفر) و چند تابع درهم‌ساز داریم. مطابق شکل ۲ـ۲ زمان درج هر عنصرِ جدید، آن را با همه توابع درهم‌سازی کرده و مقدار ۱ برای بیت‌های متناظر درنظر گرفته می‌شود. دقت کنید که ممکن است درهم‌سازی توابع، تصادم داشته باشد و چند بیت ۱ روی هم بیفتند. هنگام پرس‌وجوی عنصر، دوباره باید با همه‌ی توابع درهم‌سازی شود و اگر همه‌ی بیت‌های متناظر یک باشند، می‌گوییم این عنصر احتمالاً در آرایه وجود دارد. حتی اگر یکی صفر باشد قطعاً عنصر مورد نظر در آرایه وجود ندارد. با تنظیم اندازهٔ آرایه و تعداد توابع هش، می‌توان احتمال خطا را به دلخواه کم کرد. از همین ویژگی در پژوهش رپور نیز بهره گرفته شده تا رشته‌های دلخواه کاربران به‌صورت فشرده و بی‌نیاز از فهرست پیش‌تعریف‌شده گزارش شود و حریم خصوصی حفظ گردد.

بلوم فیلتر در بسیاری از سیستم‌ها و سرویس‌ها استفاده می‌شود از جمله:

- گوگل کروم: برای ویژگی مرور امن[۲۰] از بلوم فیلتر استفاده می‌شود تا به سرعت خطرناک بودن آدرس‌های اینترنتی را بررسی کند.
- مدیُم[۲۱]: از بلوم فیلتر برای جلوگیری از نمایش پست‌هایی که کاربر قبلاً دیده است، استفاده می‌کند.
- کساندرا[۲۲] و اچ بیس[۲۳]: برای بهینه‌سازی جستجوی داده‌ها در جدول‌های ذخیره‌شده در دیسک استفاده می‌شود.
- آکامای[۲۴]: در سرویس‌های حافظه نهان[۲۵] خود برای بهبود سرعت و کارایی تحویل محتوا از بلوم فیلتر استفاده می‌کند.

۲ـ۸ـ۶ علائم ریاضی پرکاربرد

برخی علائم ریاضی پرکاربرد در زیر فهرست شده‌اند. برای مشاهده‌ی دستور معادل پرونده‌ی منبع را ببینید.

- مجموعه‌های اعداد: $\mathbb{N}, \mathbb{Z}, \mathbb{Z}^+, \mathbb{Q}, \mathbb{R}, \mathbb{C}$
- مجموعه: $\{۱, ۲, ۳\}$

[20] Safe Browsing
[21] Medium
[22] Cassandra
[23] HBase
[24] Akamai
[25] Cache

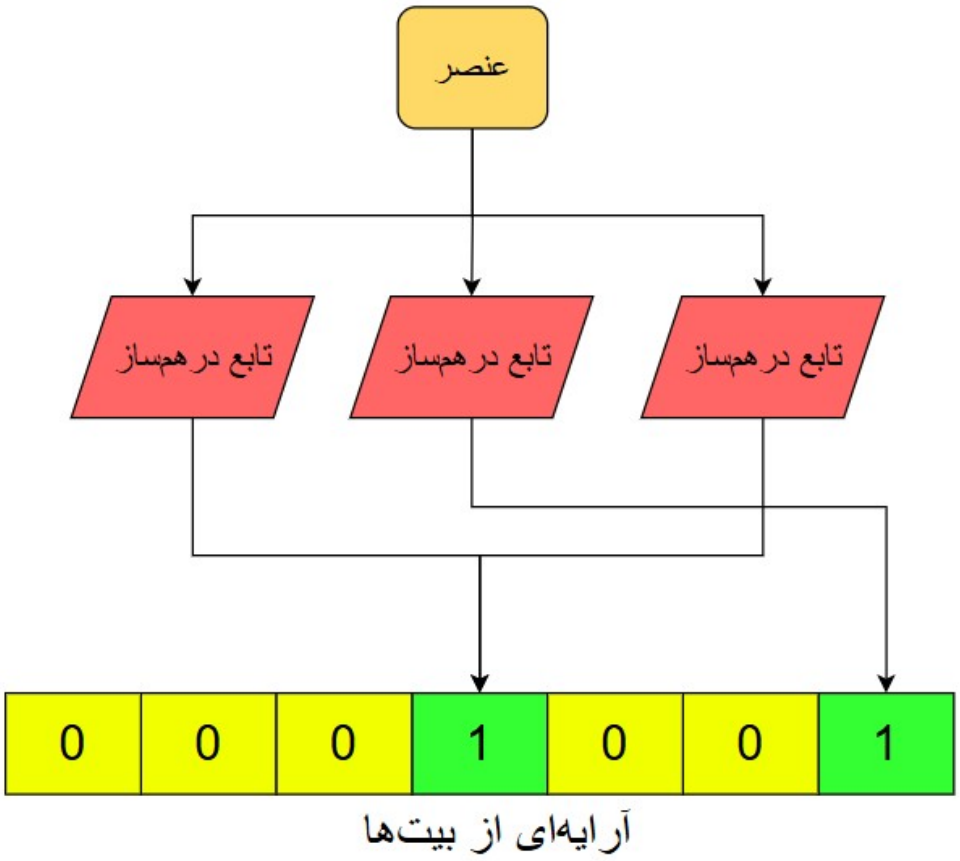

شکل ۲ـ۲: شیوه‌ی درج عنصر با استفاده از بلوم فیلتر

- دنباله: $\langle ۱, ۲, ۳ \rangle$
- سقف و کف: $\lceil x \rceil , \lfloor x \rfloor$
- اندازه و متمم: $|A| , \overline{A}$
- همنهشتی: $a \overset{n}{\equiv} ۱$ یا (پیمانه‌ی n) $a \equiv ۱$
- ضرب و تقسیم: $\times, \cdot, \div$
- سه‌نقطه: $۱, ۲, \ldots, n$
- کسر و ترکیب: $\frac{n}{k}, \binom{n}{k}$
- اجتماع و اشتراک: $A \cup (B \cap C)$
- عملگرهای منطقی: $\neg p \vee (q \wedge r)$

- پیکان‌ها: $\rightarrow, \Rightarrow, \leftarrow, \Leftarrow, \leftrightarrow, \Leftrightarrow$
- عملگرهای مقایسه‌ای: $\neq, \leqslant, \nleqslant, \geqslant, \ngeqslant$
- عملگرهای مجموعه‌ای: $\in, \notin, \setminus, \subset, \subseteq, \subsetneq, \supset, \supseteq, \supsetneq$
- جمع و ضرب چندتایی: $\sum_{i=1}^{n} a_i, \prod_{i=1}^{n} a_i$
- اجتماع و اشتراک چندتایی: $\bigcup_{i=1}^{n} A_i, \bigcap_{i=1}^{n} A_i$
- برخی نمادها: $\infty, \emptyset, \forall, \exists, \triangle, \angle, \ell, \equiv, \therefore$

۲ـ۸ـ۷ لیست‌ها

برای ایجاد یک لیست می‌توانید از محیط‌های «فقرات» و «شمارش» همانند زیر استفاده کنید.

- مورد اول
- مورد دوم
- مورد سوم

۱. مورد اول
۲. مورد دوم
۳. مورد سوم

۲ـ۸ـ۸ درج شکل

یکی از روش‌های مناسب برای ایجاد شکل استفاده از نرم‌افزار LaTeX Draw و سپس درج خروجی آن به صورت یک فایل tex درون متن با استفاده از دستور fig یا centerfig است. شکل ۲ـ۳ نمونه‌ای از اشکال ایجادشده با این ابزار را نشان می‌دهد.

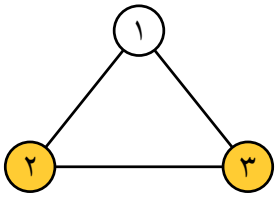

شکل ۲ـ۳: یک گراف و پوشش رأسی آن

همچنین می‌توانید با استفاده از نرم‌افزار Ipe شکل‌های خود را مستقیما به صورت pdf ایجاد نموده و آن‌ها را با دستورات img یا centerimg درون متن درج کنید. برای نمونه، شکل ۲ـ۴ را ببینید.

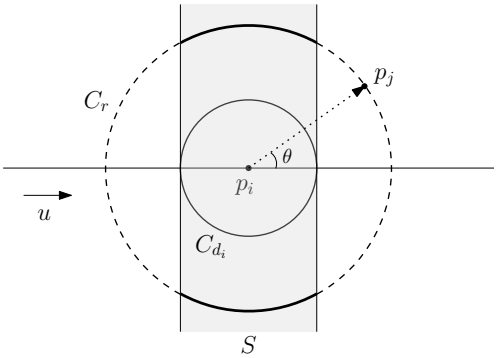

شکل ۲ـ۴: نمونه شکل ایجادشده توسط نرم‌افزار Ipe

۲ـ۸ـ۹ درج جدول

برای درج جدول می‌توانید با استفاده از دستور «جدول» جدول را ایجاد کرده و سپس با دستور «لوح» آن را درون متن درج کنید. برای نمونه جدول ۲ـ۱ را ببینید.

جدول ۲ـ۱: عملگرهای مقایسه‌ای

عملگر	عنوان
<	کوچک‌تر
>	بزرگ‌تر
==	مساوی
<>	نامساوی

۲ـ۸ـ۱۰ درج الگوریتم

برای درج الگوریتم می‌توانید از محیط «الگوریتم» استفاده کنید. یک نمونه در الگوریتم ۱ آمده است.

۲ـ۸ـ۱۱ محیط‌های ویژه

برای درج مثال‌ها، قضیه‌ها، لم‌ها و نتیجه‌ها به ترتیب از محیط‌های «مثال»، «قضیه»، «لم» و «نتیجه» استفاده کنید. برای درج اثبات قضیه‌ها و لم‌ها از محیط «اثبات» استفاده کنید.

الگوریتم ۱ پوشش رأسی حریصانه

ورودی: گراف $G = (V, E)$

خروجی: یک پوشش رأسی از G

۱: قرار بده $C = \emptyset$

۲: تا وقتی E تهی نیست:

۳: یال دل‌خواه $uv \in E$ را انتخاب کن

۴: رأس‌های u و v را به C اضافه کن

۵: تمام یال‌های واقع بر u یا v را از E حذف کن

۶: C را برگردان

تعریف‌های داخل متن را با استفاده از دستور «مهم» به صورت **تیره** نشان دهید. تعریف‌های پایه‌ای‌تر را درون محیط «تعریف» قرار دهید.

تعریف ۲ـ۸ (اصل لانه‌کبوتری) *اگر $n + ۱$ کبوتر یا بیش‌تر درون n لانه قرار گیرند، آن‌گاه لانه‌ای وجود دارد که شامل حداقل دو کبوتر است.*

۲ـ۹ برخی نکات نگارشی

این فصل حاوی برخی نکات ابتدایی ولی بسیار مهم در نگارش متون فارسی است. نکات گردآوری‌شده در این فصل به هیچ وجه کامل نیست، ولی دربردارنده‌ی حداقل مواردی است که رعایت آن‌ها در نگارش پایان‌نامه ضروری به نظر می‌رسد.

۲ـ۹ـ۱ فاصله‌گذاری

۱. علائم سجاوندی مانند نقطه، ویرگول، دونقطه، نقطه‌ویرگول، علامت سؤال و علامت تعجب بدون فاصله از کلمه‌ی پیشین خود نوشته می‌شوند، ولی بعد از آن‌ها باید یک فاصله قرار گیرد. مانند: من، تو، او.

۲. علامت‌های پرانتز، آکولاد، کروشه، نقل قول و نظایر آن‌ها بدون فاصله با عبارات داخل خود نوشته می‌شوند، ولی با عبارات اطراف خود یک فاصله دارند. مانند: (این عبارت) یا {آن عبارت}.

۳. دو کلمه‌ی متوالی در یک جمله همواره با یک فاصله از هم جدا می‌شوند، ولی اجزای یک کلمه‌ی مرکب باید با نیم‌فاصله[۲۶] از هم جدا شوند. مانند: کتاب درس، محبت‌آمیز، دوبخشی.

۴. اجزای فعل‌های مرکب با فاصله از یک‌دیگر نوشته می‌شوند، مانند: تحریر کردن، به سر آمدن.

۲ـ۹ـ۲ شکل حروف

۱. در متون فارسی به جای حروف «ك» و «ي» عربی باید از حروف «ک» و «ی» فارسی استفاده شود. همچنین به جای اعداد عربی مانند ٥ و ٦ باید از اعداد فارسی مانند ۵ و ۶ استفاده نمود. برای این کار، توصیه می‌شود صفحه‌کلید فارسی استاندارد را روی سیستم خود فعال کنید.

۲. عبارات نقل‌قول‌شده یا مؤکد باید درون علامت نقل قولِ «» قرار گیرند، نه "". مانند: «کشور ایران».

۳. کسره‌ی اضافه‌ی بعد از «ه» غیرملفوظ به صورت «ه‌ی» یا «هٔ» نوشته می‌شود. مانند: خانه‌ی علی، دنباله‌ی فیبوناچی.
تبصره: اگر «ه» ملفوظ باشد، نیاز به «ی» ندارد. مانند: فرمانده دلیر، پادشه خوبان.

۴. پایه‌های همزه در کلمات، همیشه «ئـ» است، مانند: مسئله و مسئول، مگر در مواردی که همزه ساکن است که در این صورت باید متناسب با اعراب حرف پیش از خود نوشته شود. مانند: رأس، مؤمن.

۲ـ۹ـ۳ جدانویسی

۱. علامت استمرار، «می»، توسط نیم‌فاصله از جزء بعدی فعل جدا می‌شود. مانند: می‌رود، می‌توانیم.

۲. شناسه‌های «ام»، «ای»، «ایم»، «اید» و «اند» توسط نیم‌فاصله، و شناسه‌ی «است» توسط فاصله از کلمه‌ی پیش از خود جدا می‌شوند. مانند: گفته‌ام، گفته‌ای، گفته است.

۳. علامت جمع «ها» توسط نیم‌فاصله از کلمه‌ی پیش از خود جدا می‌شود. مانند: این‌ها، کتاب‌ها.

۴. «به» همیشه جدا از کلمه‌ی بعد از خود نوشته می‌شود، مانند: به نام و به آن‌ها، مگر در مواردی که «بـ» صفت یا فعل ساخته است. مانند: بسزا، ببینم.

۵. «به» همواره با فاصله از کلمه‌ی بعد از خود نوشته می‌شود، مگر در مواردی که «به» جزئی از یک اسم یا صفت مرکب است. مانند: تناظر یک‌به‌یک، سفر به تاریخ.

[۲۶] «نیم‌فاصله» فاصله‌ای مجازی است که در عین جدا کردن اجزای یک کلمه‌ی مرکب از یک‌دیگر، آن‌ها را نزدیک به هم نگه می‌دارد. معمولاً برای تولید این نوع فاصله در صفحه‌کلیدهای استاندارد از ترکیب Shift+Space استفاده می‌شود.

۶. علامت صفت برتری، «تر»، و علامت صفت برترین، «ترین»، توسط نیم‌فاصله از کلمه‌ی پیش از خود جدا می‌شوند. مانند: سنگین‌تر، مهم‌ترین.

تبصره: کلمات «بهتر» و «بهترین» را می‌توان از این قاعده مستثنی نمود.

۷. پیشوندها و پسوندهای جامد، چسبیده به کلمه‌ی پیش یا پس از خود نوشته می‌شوند. مانند: همسر، دانشکده، دانشگاه.

تبصره: در مواردی که خواندن کلمه دچار اشکال می‌شود، می‌توان پسوند یا پیشوند را جدا کرد. مانند: هم‌میهن، هم‌ارزی.

۸. ضمیرهای متصل چسبیده به کلمه‌ی پیش از خود نوشته می‌شوند. مانند: کتابم، نامت، کلامشان.

فصل ۳

کارهای پیشین

در این فصل به بررسی کارها و پژوهش‌های پیشین در دو حوزه داده‌های ابعاد بالا و داده‌های در حال تغییر می‌پردازیم. ابتدا چالش‌های هر کدام را بررسی کرده و راه‌حل‌های موجود را بیان می‌کنیم. همچنین مزایا و معایب هر کدام ارائه می‌شود تا مناسب‌ترین راه‌حل مشخص شود.

۳ـ۱ داده‌های با ابعاد بالا

هنگام جمع‌آوری داده‌های چندبُعدی با حفظ حریم خصوصی تفاضلی، کارپذیر ابتدا داده‌ی نوفه‌دار شده‌ی هر شخص یا برنامه کاربردی را دریافت کرده و سپس شروع به تحلیل آماری روی هر بعد می‌کند. در اغلب شیوه‌های رایجِ جمع‌آوری داده‌های چندبُعدی، برای صیانت از حریم خصوصی کاربران، هر ویژگی را جداگانه نوفه‌دار می‌کنند. با توجه به قانون ترکیب متوالی ناچارا بودجه‌ی محدود حریم خصوصی میان همهٔ ابعاد پخش می‌شود. کاهش بودجه موجب تزریق نوفه بیش از اندازه شده و در نتیجه سودمندی به شکل چشمگیری کاهش میابد.

به بیان دیگر در داده‌های با ابعاد بالا، چالش اصلی به همبستگی‌های احتمالی بین ابعاد مختلف بازمی‌گردد. این همبستگی‌ها باعث می‌شود تغییر در یک بعد به تغییرات در ابعاد دیگر منجر شود و حساسیت کل سیستم افزایش یابد. در اکثر الگوریتم‌های حافظ حریم خصوصی تفاضلی، افزایش حساسیت موجب اضافه‌شدن بیش از اندازه‌ی نوفه به داده‌ها خواهد شد. بنابراین، یافتن رویکردهایی که بتوانند حساسیت را کاهش دهند یا از روش‌های هوشمندانه‌تر برای تخصیص نوفه استفاده کنند، ضروری است.

برای نمونه، سازوکار کلاسیک لاپلاس [۱۳]، نوفه در توزیع لاپلاس را به صورت تصادفی روی تک‌تک

بُعدها اعمال می‌کند. در این روش، مقدار نوفه به‌شکلی بیش‌ازخطی با تعداد ابعاد رشد می‌کند و بدین ترتیب سودمندی داده‌های چندبُعدی به‌شدّت افت خواهد کرد. در ادامه با راه‌حل‌های این چالش بیشتر آشنا می‌شویم.

۳ـ۱ـ۱ نمونه برداری

معمولا مقالاتی که روی داده‌های با ابعاد بالا کار می‌کنند، از نمونه برداری استفاده می‌کنند. در واقع سعی می‌کنند بخشی از داده را به عنوان نماینده‌ی تمام داده‌ها در نظر گرفته و فقط برای آن بخش الگوریتم‌های حفظ حریم خصوصی تفاضلی اعمال شود. با این کار، تنها به بخشی از داده‌ها، نوفه تزریق می‌شود.

سازوکار تکه‌ای[1] که توسط دوچی ارائه شده است [۱۴]، برای حل مشکل تقسیم بودجهٔ حریم خصوصی، سراغ نمونه‌گیری از داده می‌رود. در این پژوهش داده‌ها به صورت بردار و مختصات درنظر گرفته می‌شوند. در واقع هر رکورد (مثلاً یک کاربر، یک حسگر، یا یک آزمایش) داراری مجموعه‌ای از ویژگی‌ها است و می‌توانیم این ویژگی‌ها را مانند محورهای یک فضای چندبعدی تصور کنیم. فرض کنید سه ویژگی «سن»، «قد» و «درآمد» داریم؛ آن‌گاه هر فرد نقطه‌ای در فضای سه‌بعدی است که مختصاتش به‌ترتیب عدد سن، قد و درآمد اوست. اگر ویژگی‌ها بیشتر شوند—برای نمونه ۱۰۰ خصوصیت زیستی یا آماری—همان نقطه اکنون در فضایی ۱۰۰ بعدی قرار می‌گیرد و برداری با ۱۰۰ عدد پی‌درپی تشکیل می‌دهد. بنابراین «بردار» صرفاً لیستی منظم از مقادیر است و «مختصات» خانه‌های این لیست‌اند که به هر ویژگی برچسب می‌زنند.

سازوکار تکه‌ای برای آن‌که بتواند تحلیل‌های آماری روی بردارهای با ابعاد بالا را با حفظ حریم خصوصی محلی انجام دهد، به‌جای افزودن نوفه مستقل به تک‌تک مختصات (کاری که در ابعاد زیاد دقّت را نابود می‌کند)، نوفه به بردارهای «خلاصه» شده وارد می‌شود. به صورت خلاصه، در یک عملیات پیچیده، کاربر با پرتاب سکه، یک نوفه‌ی خاص را روی جهت بردار اعمال می‌کند. به بیان دیگر نوفه فقط به مختصات مؤثر، تزریق می‌شود و اندازه‌ی بردار دستکاری نمی‌گردد.

چندین پژوهش تلاش کردند تا از ویژگی‌های همبسته نمونه برداری کنند. با این کار، بودجه‌ی حریم خصوصی را به شکل هوشمندانه بین ابعاد داده پخش می‌کنند. به منظور یافتن ویژگی‌های همبسته، معمولا از دو مفهوم آماری **اطلاعات متقابل** و **بی‌نظمی** استفاده می‌شود.

اطلاعات متقابل معیاری ست که میزان اطلاعاتی را که یک متغیر تصادفی در مورد متغیر دیگر به ما می‌دهد، اندازه‌گیری می‌کند. یعنی اگر یکی را بدانیم، عدم قطعیتِ ما درباره‌ی دیگری تا چه حد کم می‌شود. هرچه مقدار این معیار بیشتر باشد، وابستگی یا هم‌بستگی میان آن دو متغیّر قوی‌تر است.

[1] Piecewise

تعریف ۳ـ۱ (اطلاعات متقابل) *از دید ریاضی، برای دو متغیّر تصادفی گسسته‌ی X و Y با توزیع مشترک $p(x,y)$ و توزیع‌های حاشیه‌ای $p(x)$ و $p(y)$، اطلاعات متقابل چنین تعریف می‌شود:*

$$I(X;Y) = \sum_x \sum_y \hat{P}(x,y) \log \frac{\hat{P}(x,y)}{\hat{P}(x)\hat{P}(y)} \qquad (۱ـ۳)$$

بی‌نظمی[2]، که در فیزیک و نظریه‌ی اطلاعات به نام «آنتروپی» شناخته می‌شود، معیاری برای سنجش پراکندگی حالت‌های یک سامانه است. هرچه تعداد حالت‌های ممکنِ سازگار با مشاهدهٔ ما بیش‌تر باشد، پیش‌بینی رفتار آینده‌ی سامانه دشوارتر و «بی‌نظمی» آن بالاتر است؛ برعکس، در سامانه‌های منظم، گزینه‌های کمتری برای چگونگی چیدمان اجزا وجود دارد و قطعیت بیش‌تری داریم. به زبان ساده، آنتروپی اندازه‌ای از بی‌خبری یا عدم قطعیت ما درباره‌ی وضعیت دقیق اجزاست.

پژوهش سم‌پرایوسین [۱۵] براساس اطلاعات متقابل[3]، ارتباط میان ویژگی‌ها را بدست آورده و تنها از جفت ویژگی‌هایی که بیشترین ارتباط را دارند، نمونه‌برداری می‌کند. این پژوهش به‌جای ارسالِ کلِ رکورد و نوفه‌دار کردن همه‌ی ابعاد، تنها یک جفت ویژگی از هر کاربر را انتخاب و پس از نوفه‌دار کردن همان دو مقدار، به کارپذیر می‌فرستد. انتخاب این جفت ویژگی تصادفی نیست؛ احتمال برگزیده‌شدن هر زوج، متناسب با اطلاعات متقابل به‌روزشده‌ی آن‌ها است. زوج‌هایی که بیش‌ترین هم‌بستگی را دارند، با احتمال بیشتری انتخاب شده و ساختار واقعیِ داده تا حد ممکن حفظ می‌شود. سپس هر یک از دو مقدار انتخاب‌شده با بودجهٔ $\epsilon/۲$ نوفه‌دار می‌شود. بدین ترتیب کل فرایند همچنان $\epsilon-LDP$ باقی می‌ماند، در حالی که حجم ارتباطی و نوفه تزریق‌شده فقط به همان دو بُعد محدود می‌شود. در ادامه، این داده‌های نمونه‌برداری‌شده برای بازسازی مجموعه داده‌های مصنوعی به کار می‌روند و همچنان ارتباط میان ویژگی‌ها حفظ می‌شود.

پژوهشی که توسط وانگ [۱۶] انجام شده است، یک الگوریتم حافظ حریم خصوصی تفاضلی برای جمع‌آوری داده‌های عددی ارائه می‌دهد. سپس الگوریتم خود را برای داده‌های چند بُعدی گسترش می‌دهد. این پژوهش ابتدا توضیح می‌دهد که واریانس[4] کمتر در الگوریتم‌های حریم خصوصی به معنای دقت بیشتر در میانگین نتایج است. سازوکار تکه‌ای [۱۴] واریانس بالایی داشته و دقت نتایج پایین است. برای داده‌های چندبعدی، نویسندگان به دو مشکل اصلی سازوکار تکه‌ای اشاره می‌کنند. اول اینکه این الگوریتم پیچیدگی بالایی دارد و دوم اینکه تنها برای مقادیر عددی قابل استفاده است. به همین دلیل، نویسندگان دو الگوریتم جدید به نام‌های پی‌ـام و اچ‌ـام معرفی می‌کنند که با کاهش واریانس، نتایج دقیق‌تری ارائه

[2] Entropy
[3] Mutual Information
[4] Variance

می‌دهند. سازوکار پی‌ـ‌ام برای هر عدد در بازه‌ی $[-۱, ۱]$ سه ناحیه تعریف می‌کند: یک قطعه‌ی مرکزی و دو قطعه‌ی کناری در چپ و راست. ابتدا با یک پرتاب تصادفی تصمیم می‌گیرد در کدام ناحیه نمونه بردارد. احتمال افتادن در قطعهٔ مرکزی عمداً بیشتر است تا خروجی غالباً به مقدار حقیقی نزدیک بماند، ولی اگر به قطعات کناری برود فاصله‌ی بیشتری با مقدار اصلی پیدا می‌کند. این فاصله همان نوفه‌ای است که باعث حفظ حریم خصوصی تفاضلی می‌شود. به این ترتیب داده همچنان در بازه‌ای محدود باقی می‌مانند و با کوچک‌تر شدن مقدار نوفه، واریانس نیز پایین می‌آید، در نتیجه دقّت حفظ می‌شود.

سازوکار اِچ‌ـ‌اِم ترکیبی هوشمندانه از پی‌ـ‌اِم و تکه‌ای است. هر بار که می‌خواهد داده را نوفه‌دار کند، سکه‌ای پرتاب می‌شود که با احتمال α شیر می‌آید. اگر شیر آمد، پی‌ـ‌اِم اجرا می‌شود؛ اگر خط آمد، همان روش تکه‌ای به کار می‌رود. مقدار α به‌طور تحلیلی طوری انتخاب می‌شود که کل واریانس نوفه را در بدترین حالت کمینه کند. با توجه به پی‌ـ‌ام ،برای ϵ بزرگ α تقریباً یک است، و با توجه به روش تکه‌ای، برای ϵ خیلی کوچک α به صفر میل خواهد کرد. بنابراین اِچ‌ـ‌اِم در همهٔ شرایط از هر دو رقیب یا بهتر است یا دست‌کم بدتر نمی‌شود.

برای رفع مشکل داده‌های با ابعاد بالا، پژوهش یک الگوریتم جدید پیشنهاد می‌دهد. این الگوریتم بیان می‌کند که نیازی نیست همه ابعاد داده به‌صورت تصادفی‌سازی‌شده پردازش شوند. کافیست تنها به ابعاد محدودی که به صورت تصادف انتخاب می‌شوند، نوفه اضافه کرد. اگر k بُعد را انتخاب کنیم، باید بودجه‌ی حریم خصوصی ϵ/k را به هر بُعد اختصاص دهیم. چون k معمولاً خیلی کوچک‌تر از تعداد کل ابعاد است، هر ویژگی سهم بودجه‌ی بزرگ‌تری می‌گیرد و نوفه‌ی کمتری به آن تزریق می‌شود. در نتیجه سامانه می‌تواند روی داده‌های با ابعاد بالا تحلیل‌های آماری مثل میانگین یا حتی گرادیان‌های یادگیری ماشین را با خطای کمی برآورد کند.

۳ـ۲ مسائل خوشه‌بندی

مسئله‌ی **خوشه‌بندی**[۵] یکی از مهم‌ترین مسائل در زمینه‌ی داده‌کاوی به حساب می‌آید. در این مسئله، هدف دسته‌بندی تعدادی شیء به‌گونه‌ای است که اشیاء درون یک دسته (خوشه)، نسبت به یکدیگر در برابر دسته‌های دیگر شبیه‌تر باشند (معیارهای متفاوتی برای تشابه تعریف می‌گردد). این مسئله در حوزه‌های مختلفی از علوم کامپیوتر از جمله داده‌کاوی، جست‌وجوی الگو[۶]، پردازش تصویر[۷]، بازیابی اطلاعات[۸] و

[۵] Clustering
[۶] Pattern recognition
[۷] Image analysis
[۸] Information retrieval

رایانش زیستی[۹] مورد استفاده قرار می‌گیرد [۱۷].

تا کنون راه‌حل‌های زیادی برای این مسئله ارائه شده است که از لحاظ معیار تشخیص خوشه‌ها و نحوه‌ی انتخاب یک خوشه، با یک‌دیگر تفاوت بسیاری دارند. به همین خاطر مسئله‌ی خوشه‌بندی یک مسئله‌ی بهینه‌سازی چندهدفه[۱۰] محسوب می‌شود.

همان طور که در مرجع [۱۸] ذکر شده است، خوشه در خوشه‌بندی تعریف واحدی ندارد و یکی از دلایل وجود الگوریتم‌های متفاوت، همین تفاوت تعریف‌ها از خوشه است. بنابراین با توجه به مدلی که برای خوشه‌ها ارائه می‌شود، الگوریتم متفاوتی نیز ارائه می‌گردد. در ادامه به بررسی تعدادی از معروف‌ترین مدل‌های مطرح می‌پردازیم:

- **مدل‌های مرکزگرا:** در این مدل‌ها، هر دسته با یک مرکز نشان داده می‌شود. از جمله معروف‌ترین روش‌های خوشه‌بندی بر اساس این مدل، خوشه‌بندی kـ مرکز، خوشه‌بندی kـ میانگین[۱۱] و خوشه‌بندی kـ میانه[۱۲] است.

- **مدل‌های مبتی بر توزیع نقاط:** در این مدل، دسته‌ها با فرض پیروی از یک توزیع احتمالی مشخص می‌شوند. از جمله الگوریتم‌های معروف ارائه شده در این مدل، الگوریتم بیشینه‌سازی امید ریاضی[۱۳] است.

- **مدل‌های مبتنی بر تراکم نقاط:** در این مدل، خوشه‌ها متناسب با ناحیه‌های متراکم نقاط در مجموعه داده مورد استفاده قرار می‌گیرد.

- **مدل‌های مبتنی بر گراف:** در این مدل، هر خوشه به مجموعه از رئوس گفته می‌شود که تمام رئوس آن با یک‌دیگر همسایه باشند. از جمله الگوریتم‌های معروف این مدل، الگوریتم خوشه‌بندی HCS[۱۴] است.

الگوریتم‌های ارائه شده تنها از نظر نوع مدل با یک‌دیگر متفاوت نیستند. بلکه، می‌توان آن‌ها را از لحاظ نحوه‌ی تخصیص نقاط بین خوشه‌ها نیز تقسیم‌بندی کرد:

- **تخصیص قطعی داده‌ها:** در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

---

[۹] Bioinformatics
[۱۰] Multi-objective
[۱۱] k-Means
[۱۲] k-Median
[۱۳] Expectation-maximization
[۱۴] Highly Connected Subgraphs

- **تخصیص قطعی داده‌ها با داده‌ی پرت:** در این نوع خوشه‌بندی ممکن است بعضی از داده‌ها به هیچ خوشه‌ای اختصاص نیابد، اما بقیه داده‌ها هر کدام دقیقاً به یک خوشه اختصاص می‌یابد.
- **تخصیص قطعی داده:** در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.
- **خوشه‌بندی هم‌پوشان:** در این نوع خوشه‌بندی هر داده می‌تواند به چند خوشه اختصاص داده شود. در گونه‌ای از این مدل، می‌توان هر نقطه را با احتمالی به هر خوشه اختصاص می‌یابد. به این گونه از خوشه‌بندی، خوشه‌بندی نرم[۱۵] گفته می‌شود.
- **خوشه‌بندی سلسه‌مراتبی:** در این نوع خوشه‌ها، داده‌ها به گونه‌ای به خوشه‌ها تخصیص داده می‌شود که دو خوشه یا اشتراک ندارند یا یکی به طور کامل دیگری را می‌پوشاند. در واقع در بین خوشه‌ها، رابطه‌ی پدر فرزندی برقرار است.

در بین دسته‌بندی‌های ذکر شده، تمرکز اصلی این پایان‌نامه بر روی مدل مرکزگرا و خوشه‌بندی قطعی با داده‌های پرت با مدل kـ مرکز است. همان‌طور که ذکر شد علاوه بر مسئله‌ی kـ مرکز که به تفصیل مورد بررسی قرار می‌گیرد، kـ میانه و kـ میانگین از جمله معروف‌ترین خوشه‌بندی‌های مدل مرکزگرا هستند. در خوشه‌بندی kـ میانه، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع مربع فاصله‌ی هر نقطه از میانه‌ی نقاط آن خوشه، کمینه گردد. در خوشه‌بندی kـ میانگین، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع فاصله‌ی هر نقطه از میانگین نقاط داخل خوشه (یا مرکز آن خوشه) کمینه گردد.

۳ـ۳ خوشه‌بندی kـ مرکز

یکی از رویکردهای شناخته‌شده برای مسئله‌ی خوشه‌بندی، مسئله‌ی ***k*ـ مرکز** است. در این مسئله هدف، پیدا کردن k نقطه به عنوان مرکز دسته‌ها است به‌طوری‌که شعاع دسته‌ها تا حد ممکن کمینه شود. مثالی از مسئله‌ی ۲ـ مرکز در شکل ۳ـ۱ نشان داده شده است. در این پژوهش، مسئله‌ی kـ مرکز با متریک‌های خاص و برای kهای کوچک مورد بررسی قرار گرفته است و هر کدام از تعریف رسمی مسئله‌ی kـ مرکز در زیر آمده است:

مسئله‌ی ۳ـ۱ (kـ **مرکز**) *گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d، که از نامساوی مثلثی پیروی می‌کند داده شده است. زیرمجموعه‌ی $S \subseteq V$ با اندازه‌ی k را به‌گونه‌ای انتخاب کنید که عبارت زیر*

[۱۵] Soft clustering

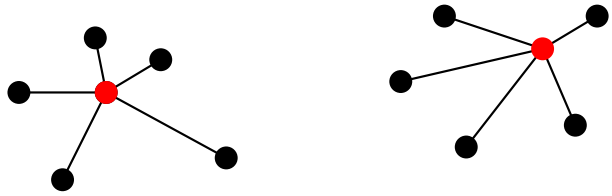

شکل ۳ـ۱: نمونه‌ای از مسئله‌ی ۲ـ مرکز

را کمینه کند:

$$\max_{v\in V}\{\min_{s\in S} d(v,s)\} \qquad (۳ـ۲)$$

گونه‌های مختلفی از مسئله‌ی kـ مرکز با محدودیت‌های متفاوت توسط پژوهشگران مورد مطالعه قرار گرفته است. از جمله‌ی این گونه‌ها، می‌توان به حالتی که در بین داده‌های ورودی، داده‌های پرت وجود دارد، اشاره کرد. در واقع در این مسئله، قبل از خوشه‌بندی می‌توانیم تعدادی از نقاط ورودی را حذف نموده و سپس به خوشه‌بندی نقاط بپردازیم. سختی این مسئله از آنجاست که نه تنها باید مسئله‌ی خوشه‌بندی را حل نمود، بلکه در ابتدا باید تصمیم گرفت که کدام یک از داده‌ها را به‌عنوان داده‌ی پرت در نظر گرفت که بهترین جواب در زمان خوشه‌بندی به دست آید. در واقع اگر تعداد نقاط پرتی که مجاز به حذف است، برابر صفر باشد، مسئله به مسئله‌ی kـ مرکز تبدیل می‌شود. نمونه‌ای از مسئله‌ی ۲ـ مرکز با ۷ داده‌ی پرت را در شکل ۳ـ۲ می‌توانید ببینید. تعریف دقیق‌تر این مسئله در زیر آمده است:

مسئله‌ی ۳ـ۲ (kـ مرکز با داده‌های پرت) *یک گراف کامل بدون جهت $G=(V,E)$ با تابع فاصله‌ی d، که از نامساوی مثلثی پیروی می‌کند داده‌شده است. زیرمجموعه‌ی $Z\subseteq V$ با اندازه‌ی z و مجموعه‌ی $S\subseteq V-Z$ با اندازه‌ی k را انتخاب کنید به طوری‌که عبارت زیر را کمینه کند:*

$$\max_{v\in V-Z}\{\min_{s\in S} d(v,s)\} \qquad (۳ـ۳)$$

گونه‌ی دیگری از مسئله‌ی kـ مرکز که در سال‌های اخیر مورد توجه قرار گرفته است، حالت جویبار داده‌ی آن است. در این‌گونه از مسئله‌ی kـ مرکز، در ابتدا تمام نقاط در دسترس نیستند، بلکه به‌مرور زمان نقاط در دسترس قرار می‌گیرند. محدودیت دومی که وجود دارد، محدودیت حافظه است، به‌طوری‌که نمی‌توان تمام نقاط را در حافظه نگه داشت و بعضاً حتی امکان نگه‌داری در حافظه‌ی جانبی نیز وجود ندارد و به‌طور معمول باید مرتبه‌ی حافظه‌ای کم‌تر از مرتبه حافظه‌ی **خطی**[۱۶] متناسب با تعداد نقاط استفاده نمود. از این به بعد به چنین مرتبه‌ای، مرتبه‌ی **زیرخطی**[۱۷] می‌گوییم. مدلی که ما در این پژوهش بر روی آن تمرکز

[۱۶] Linear
[۱۷] sublinear

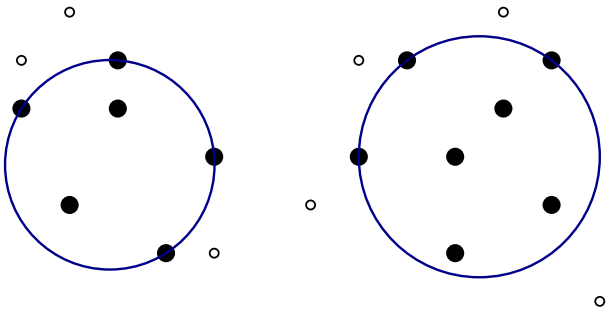

شکل ۳ـ۲: نمونه‌ای ازمسئله‌ی ۲ـ مرکز با داده‌های پرت

داریم مدل جویبار داده تک‌گذره[۱۸] [۱۹] است. یعنی تنها یک بار می‌توان از ابتدا تا انتهای داده‌ها را بررسی کرد و پس از عبور از یک داده، اگر آن داده در حافظه ذخیره نشده باشد، دیگر به آن دسترسی وجود ندارد. علاوه بر این، در هر لحظه باید بتوان به پرسمان (برای تمام نقاطی از جویبار داده که تاکنون به آن دسترسی داشته‌ایم) پاسخ داد.

مسئله‌ی ۳ـ۳ (***kـ مرکز در حالت جویبار داده***) *مجموعه‌ای از نقاط در فضای dـ بعدی به مرور زمان داده می‌شود. در هر لحظه از زمان، به ازای مجموعه‌ی U از نقاطی که تا کنون وارد شده‌اند، زیرمجموعه‌ی $S \subseteq U$ با اندازه‌ی k را انتخاب کنید به طوری که عبارت زیر کمینه شود:*

$$\max_{u \in U}\{\min_{s \in S} d(u, s)\} \qquad (۴ـ۳)$$

از آنجایی که گونه‌ی جویبار داده و داده پرت مسئله‌ی kـ مرکز به علت به‌روز بودن مبحث داده‌های حجیم[۱۹]، به تازگی مورد توجه قرار گرفته است. در این تحقیق سعی شده است که تمرکز بر روی این‌گونه‌ی خاص از مسئله باشد. همچنین در این پژوهش سعی می‌شود گونه‌های مسئله را برای انواع متریک‌ها و برای kهای کوچک نیز مورد بررسی قرار داد.

۳ـ۴ مدل جویبار داده

همان‌طور که ذکر شد مسئله‌ی kـ مرکز در حالت داده‌های پرت و جویبار داده، گونه‌های تعمیم‌یافته از مسئله‌ی kـ مرکز هستند و در حالت‌های خاص به مسئله‌ی kـ مرکز کاهش پیدا می‌کنند. مسئله‌ی kـ مرکز در حوزه‌ی مسائل ان‌پی‌ـ سخت[۲۰] قرار می‌گیرد و با فرض $P \neq NP$ الگوریتم دقیق با زمان چندجمله‌ای

[۱۸] Single pass
[۱۹] Big data
[۲۰] NP-hard

برای آن وجود ندارد [۲۰]. بنابراین برای حل کارای[۲۱] این مسائل از الگوریتم‌های تقریبی[۲۲] استفاده می‌شود.

برای مسئله‌ی kـ مرکز، دو الگوریتم تقریبی معروف وجود دارد. در الگوریتم اول، که به روش حریصانه[۲۳] عمل می‌کند، در هر مرحله بهترین مرکز ممکن را انتخاب می‌کند به طوری تا حد ممکن از مراکز قبلی دور باشد [۲۱]. این الگوریتم، الگوریتم تقریبی با ضریب تقریب ۲ ارائه می‌دهد. در الگوریتم دوم، با استفاده از مسئله‌ی مجموعه‌ی غالب کمینه[۲۴]، الگوریتمی با ضریب تقریب ۲ ارائه می‌گردد [۲۲]. همچنین ثابت شده است، که بهتر از این ضریب تقریب، الگوریتمی نمی‌توان ارائه داد مگر آن‌که $P = NP$ باشد.

برای مسئله‌ی kـ مرکز در حالت جویبار داده برای ابعاد بالا، بهترین الگوریتم موجود ضریب تقریب $۲ + \varepsilon$ دارد [۲۳، ۲۴، ۲۵] و ثابت می‌شود الگوریتمی با ضریب تقریب بهتر از ۲ نمی‌توان ارائه داد. برای مسئله‌ی kـ مرکز با داده‌ی پرت در حالت جویبار داده نیز، بهترین الگوریتم ارائه شده، الگوریتمی با ضریب تقریب $۴ + \varepsilon$ است که با کران پایین ۳ هنوز اختلاف قابل توجهی دارد [۲۶].

برای kهای کوچک به خصوص، $k = ۱, ۲$، الگوریتم‌های بهتری ارائه شده است. بهترین الگوریتم ارائه شده برای مسئله‌ی ۱ ـ مرکز در حالت جویبار داده برای ابعاد بالا، دارای ضریب تقریب ۱/۲۲ است و کران پایین $\frac{۱+\sqrt{۲}}{۲}$ نیز برای این مسئله اثبات شده است [۲۷، ۲۸]. برای مسئله ۲ ـ مرکز در حالت جویبار داده برای ابعاد بالا، اخیرا راه‌حلی با ضریب تقریب $۱/۸ + \varepsilon$ ارائه شده است [۲۹]. برای مسئله‌ی ۱ ـ مرکز با داده‌ی پرت، تنها الگوریتم موجود، الگوریتمی با ضریب تقریب ۱/۷۳ است [۳۰].

۳ـ۵ تقریب‌پذیری

یکی از راه‌کارهایی که برای کارآمد کردن راه‌حل ارائه شده برای یک مسئله وجود دارد، استفاده از الگوریتم‌های تقریبی برای حل آن مسئله است. یکی از عمده‌ترین دغدغه‌های مطرح در الگوریتم‌های تقریبی کاهش ضریب تقریب است. در بعضی از موارد حتی امکان ارائه‌ی الگوریتم تقریبی با ضریبی ثابت نیز وجود ندارد. به طور مثال، الگوریتم تقریبی با ضریب تقریب کم‌تر از ۲، برای مسئله‌ی kـ مرکز وجود ندارد مگر این‌که $P = NP$ باشد. برای مسائل مختلف، معمولاً می‌توان کران پایینی برای میزان تقریب‌پذیری آن‌ها ارائه داد. در واقع برای برخی مسائل ان‌پی‌ـ سخت، علاوه بر این که الگوریتم کارآمدی وجود ندارد، بعضاً الگوریتم تقریبی با ضریبی تقریب کم و نزدیک به یک نیز وجود ندارد. در جدول ۳ـ۱ میزان تقریب‌پذیری

[۲۱] Efficient
[۲۲] Approximation algorithm
[۲۳] Greedy
[۲۴] Dominating set

جدول ۳ـ۱: نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی

مسئله	کران پایین تقریب‌پذیری
kـ مرکز	۲ [۲۲]
kـ مرکز در فضای اقلیدسی	۱/۸۲۲ [۳۱]
۱ ـ مرکز در حالت جویبار داده	$\frac{۱+\sqrt{۲}}{۲}$ [۲۷]
kـ مرکز با نقاط پرت و نقاط اجباری	۳ [۲۶]

مسائل مختلفی که در این پایان‌نامه مورد استفاده قرار می‌گیرد را می‌بینید.

فصل ۴

نتایج جدید

در این فصل نتایج جدید به‌دست‌آمده در پایان‌نامه توضیح داده می‌شود. در صورت نیاز می‌توان نتایج جدید را در قالب چند فصل ارائه نمود. همچنین در صورت وجود پیاده‌سازی، بهتر است نتایج پیاده‌سازی را در فصل مستقلی پس از این فصل قرار داد.

فصل ۵

نتیجه‌گیری

در این فصل، ضمن جمع‌بندی نتایج جدید ارائه‌شده در پایان‌نامه یا رساله، مسائل باز باقی‌مانده و همچنین پیشنهادهایی برای ادامه‌ی کار ارائه می‌شوند.

مراجع

[1] Google. Source code of rappor in chromium. https://chromium.googlesource.com/chromium/src/+/71.0.3553.2/components/rappor/, 2015.

[2] C. Dwork, K. Kenthapadi, F. McSherry, I. Mironov, and M. Naor. Our data, ourselves: Privacy via distributed noise generation. In *Advances in Cryptology-EUROCRYPT 2006: 24th Annual International Conference on the Theory and Applications of Cryptographic Techniques, St. Petersburg, Russia, May 28-June 1, 2006. Proceedings 25*, pages 486–503. Springer, 2006.

[3] S. P. Kasiviswanathan, H. K. Lee, K. Nissim, S. Raskhodnikova, and A. Smith. What can we learn privately? *SIAM Journal on Computing*, 40(3):793–826, 2011.

[4] J. C. Duchi, M. I. Jordan, and M. J. Wainwright. Local privacy and statistical minimax rates. *2013 IEEE 54th Annual Symposium on Foundations of Computer Science*, pages 429–438, 2013.

[5] C. Dwork. A firm foundation for private data analysis. *Communications of the ACM*, 54:86 – 95, 2011.

[6] S. L. Warner. Randomized response: a survey technique for eliminating evasive answer bias. *Journal of the American Statistical Association*, 60 309:63–6, 1965.

[7] P. Kairouz, K. A. Bonawitz, and D. Ramage. Discrete distribution estimation under local privacy. In *International Conference on Machine Learning*, 2016.

[8] P. Kairouz, S. Oh, and P. Viswanath. Extremal mechanisms for local differential privacy. *J. Mach. Learn. Res.*, 17:17:1–17:51, 2014.

[9] K. Nissim, R. Smorodinsky, and M. Tennenholtz. Approximately optimal mechanism design via differential privacy. In *Proceedings of the 3rd innovations in theoretical computer science conference*, pages 203–213, 2012.

[10] F. D. McSherry. Privacy integrated queries: an extensible platform for privacy-preserving data analysis. In *Proceedings of the 2009 ACM SIGMOD International Conference on Management of data*, pages 19–30, 2009.

[11] S. Wang, L. Huang, P. Wang, H. Deng, H. Xu, and W. Yang. Private weighted histogram aggregation in crowdsourcing. In *Wireless Algorithms, Systems, and Applications*, 2016.

[12] Ú. Erlingsson, V. Pihur, and A. Korolova. Rappor: Randomized aggregatable privacy-preserving ordinal response. In *Proceedings of the 2014 ACM SIGSAC conference on computer and communications security*, pages 1054–1067, 2014.

[13] C. Dwork, F. McSherry, K. Nissim, and A. Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of Cryptography: Third Theory of Cryptography Conference, TCC 2006, New York, NY, USA, March 4-7, 2006. Proceedings 3*, pages 265–284. Springer, 2006.

[14] J. C. Duchi, M. J. Wainwright, and M. I. Jordan. Minimax optimal procedures for locally private estimation. *Journal of the American Statistical Association*, 113:182 – 201, 2016.

[15] X. Chen, C. Wang, Q. Yang, T. Hu, and C. Jiang. Locally differentially private high-dimensional data synthesis. *Science China Information Sciences*, 66(1):1–18, 2023.

[16] N. Wang, X. Xiao, Y. D. Yang, J. Zhao, S. C. Hui, H. Shin, J. Shin, and G. Yu. Collecting and analyzing multidimensional data with local differential privacy. *2019 IEEE 35th International Conference on Data Engineering (ICDE)*, pages 638–649, 2019.

[17] J. Han and M. Kamber. *Data Mining, Southeast Asia Edition: Concepts and Techniques.* Morgan kaufmann, 2006.

[18] V. Estivill-Castro. Why so many clustering algorithms: a position paper. *ACM SIGKDD explorations newsletter*, 4(1):65–75, 2002.

[19] C. C. Aggarwal. *Data streams: models and algorithms.* Springer Science & Business Media, 2007.

[20] M. R. Garey and D. S. Johnson. Computers and intractability: a guide to the theory of NP-completeness. *Freeman & Co.*, 1979.

[21] N. Megiddo and K. J. Supowit. On the complexity of some common geometric location problems. *SIAM Journal on Computing*, 13(1):182–196, 1984.

[22] V. V. Vazirani. *Approximation Algorithms*. Springer-Verlag New York, Inc., 2001.

[23] R. M. McCutchen and S. Khuller. Streaming algorithms for k-center clustering with outliers and with anonymity. In *Proceedings of the 11th International Workshop on Approximation Algorithms*, pages 165–178, 2008.

[24] S. Guha. Tight results for clustering and summarizing data streams. In *Proceedings of the 12th International Conference on Database Theory*, pages 268–275, 2009.

[25] H.-K. Ahn, H.-S. Kim, S.-S. Kim, and W. Son. Computing k centers over streaming data for small k. *International Journal of Computational Geometry and Applications*, 24(02):107–123, 2014.

[26] M. Charikar, S. Khuller, D. M. Mount, and G. Narasimhan. Algorithms for facility location problems with outliers. In *Proceedings of the 12th ACM-SIAM Symposium on Discrete Algorithms*, pages 642–651, 2001.

[27] P. K. Agarwal and R. Sharathkumar. Streaming algorithms for extent problems in high dimensions. In *Proceedings of the 21st ACM-SIAM Symposium on Discrete Algorithms*, pages 1481–1489, 2010.

[28] T. M. Chan and V. Pathak. Streaming and dynamic algorithms for minimum enclosing balls in high dimensions. *Computational Geometry: Theory and Applications*, 47(2):240–247, 2014.

[29] S.-S. Kim and H.-K. Ahn. An improved data stream algorithm for clustering. In *Proceedings of the 11th Latin American Symposium on Theoretical Informatics*, pages 273–284, 2014.

[30] H. Zarrabi-Zadeh and A. Mukhopadhyay. Streaming 1-center with outliers in high dimensions. In *Proceedings of the 21st Canadian Conference on Computational Geometry*, pages 83–86, 2009.

[31] M. Bern and D. Eppstein. Approximation algorithms for geometric problems. In D. S. Hochbaum, editor, *Approximation Algorithms for NP-hard Problems*, pages 296–345. PWS Publishing Co., 1997.

واژه‌نامه

الف

ابتکاری ..... heuristic
ابعاد بالا ..... high dimensions
اریب ..... bias
آستانه ..... threshold
اصل لانه‌ی کبوتری ..... pigeonhole principle
ان‌پی‌ـ‌سخت ..... NP-Hard
انتقال ..... transition

ب

برخط ..... online
برنامه‌ریزی خطی ..... linear programming
بهینه ..... optimum
بیشینه ..... maximum

پ

پرت ..... outlier
پرسمان ..... query
پوشش ..... cover
پیچیدگی ..... complexity

ت

تجربی ..... experimental
تراکم ..... density
تقریب ..... approximation
تقسیم‌بندی ..... partition
توری ..... mesh
توزیع‌شده ..... distributed

ج

جداپذیر ..... separable
جعبه سیاه ..... black box
جویبار داده ..... data stream

ح

حدی ..... extreme
حریصانه ..... greedy

خ

خوشه ..... cluster
خطی ..... linear

د

داده ..... data
داده‌کاوی ..... data mining
داده‌ی پرت ..... outlier data
دوبرابرسازی ..... doubling
دودویی ..... binary

ر

رأس ..... vertex
رسمی ..... formal

ز

زیرخطی ..... sublinear

س

سرشکن ..... amortized
سلسه‌مراتبی ..... hierarchichal

ش

شبه کد ..... pseudocode
شیء ..... object

ص

صدق‌پذیری ..... satisfiability

غ

غلبه ..... dominate

ف

فاصله ..... distance
فضا ..... space

ق

قطعی ..... deterministic

ک

کارا ..... efficient
کاندیدا ..... candidate
کمینه ..... minimum

م

مجموعه ..... set
مجموعه هسته ..... coreset
مسطح ..... planar
موازی‌سازی ..... parallelization
میان‌گیر ..... buffer

ن

نابه‌جایی ..... inversion
ناوردا ..... invariant
نقطه‌ی مرکزی ..... center point
نیم‌فضا ..... half space

هـ

هزینه‌ی آشوب ..... price of anarchy (POA)

ی

یال ..... edge

پیوست آ

مطالب تکمیلی

پیوست‌های خود را در صورت وجود می‌توانید در این قسمت قرار دهید.

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the XƎPersian package for the LaTeX typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, XƎPersian

Sharif University of Technology

Department of Computer Engineering

M.Sc. Thesis

A Standard Template for Typesetting Theses in Persian

By:

The Author

Supervisor:

Dr. Supervisor

September 2024