



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
مهندسی کامپیوتر

حفظ حریم خصوصی تفاضلی محلی هنگام انتشار داده‌های با ابعاد بالا و در حال تغییر

نگارش

سید آرش ساعتچی

استاد راهنما

دکتر رسول جلیلی

شهریور ۱۴۰۴

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

چکیده

حریم خصوصی تفاضلی محلی یکی از رویکردهای پیشرو در حفاظت از داده‌های کاربران است که بدون اعتماد به کارپذیر، حریم خصوصی را تضمین می‌کند. این مفهوم با افزودن نوفه به داده‌های کاربران قبل از ارسال به سمت کارپذیر، امکان تحلیل داده‌ها را فراهم می‌سازد. استفاده از داده‌ها با رعایت الزامات حریم خصوصی در حوزه‌های حساس نظیر سلامت و اینترنت اشیاء بسیار حیاتی است؛ چرا که بهره‌برداری از این منابع در تصمیم‌گیری‌های کلیدی، مستلزم تضمین عدم نشت اطلاعات شخصی کاربران در فرآیندهای تحلیلی است. این پژوهش برای حفظ حریم خصوصی تفاضلی محلی در داده‌های با ابعاد بالا و در حال تغییر تمرکز دارد. از جمله چالش‌های اساسی در این زمینه، همبستگی میان ویژگی‌ها، افزایش حساسیت داده‌ها و مصرف سریع بودجه حریم خصوصی است که می‌تواند دقت و کارایی تحلیل‌های آماری را به شدت کاهش دهد. در این پژوهش ضمن دسته‌بندی، مرور و مقایسه الگوریتم‌ها و کارهای پیشین راهکار جدیدی برای حفظ حریم خصوصی در داده‌های با ابعاد بالا و در حال تغییر ارائه شده است.

نوآوری اصلی این پژوهش در تلفیق روش تبدیل هار¹ و سازوکار گرد کردن نقطه آلفا² نهفته است. داده‌ها ابتدا به کمک تبدیل هار تجزیه می‌شوند تا بخش عمده اطلاعات در تعداد محدودی از ضرایب متمرکز گردد؛ این فرآیند، مدیریت بهینه‌تر بودجه حریم خصوصی را امکان‌پذیر می‌سازد. برای مدیریت داده‌های پویا، از سازوکار گرد کردن نقطه آلفا استفاده شده است. این راه‌حل برخلاف روش‌های سنتی که هر تغییر جزئی را نیازمند مصرف مجدد بودجه می‌دانند، با حذف نوسانات بی‌اهمیت و گذرا، پایداری پاسخ‌های کاربران را در طول زمان تضمین کرده و مانع از هدررفت بودجه حریم خصوصی می‌شود. کارایی راهکار پیشنهادی با پیاده‌سازی و مقایسه آن با روش‌های شناخته‌شده مورد ارزیابی قرار گرفته است. آزمایش‌ها نشان می‌دهد که الگوریتم پیشنهادی با حفظ حریم خصوصی، سودمندی بهتری نیز برای تحلیل‌های آماری ارائه می‌دهد.

کلیدواژه‌ها: حریم خصوصی تفاضلی محلی، داده‌های در حال تغییر، داده‌های با ابعاد بالا، تبدیل هار، گرد کردن نقطه آلفا

¹Haar Transform

²Alpha-point Rounding

فهرست مطالب

۱	۱ مقدمه
۲	۱-۱ تعریف مسئله
۳	۲-۱ اهمیت موضوع
۴	۳-۱ ادبیات موضوع
۵	۴-۱ اهداف پژوهش
۶	۵-۱ ساختار پایان نامه
۷	۲ مفاهیم اولیه
۷	۱-۲ حریم خصوصی تفاضلی
۸	۲-۲ بودجه حریم خصوصی
۸	۳-۲ حریم خصوصی تفاضلی محلی
۹	۴-۲ حساسیت
۱۰	۵-۲ الگوریتم‌های حافظ حریم خصوصی تفاضلی
۱۱	۱-۵-۲ سازوکار لاپلاس
۱۱	۲-۵-۲ سازوکار نمایی
۱۲	۳-۵-۲ پاسخ تصادفی
۱۳	۴-۵-۲ پاسخ تصادفی عمومی
۱۳	۵-۵-۲ الگوریتم تصادفی سازی متقارن

۱۴	۶-۲ ترکیب متوالی
۱۵	۷-۲ ترکیب موازی
۱۵	۸-۲ روش های کدگذاری
۱۵	۱-۸-۲ کدگذاری مستقیم
۱۶	۲-۸-۲ کدگذاری یکانی
۱۷	۳-۸-۲ کدگذاری یکانی متقارن
۱۷	۴-۸-۲ درهم سازی محلی
۱۸	۵-۸-۲ بلوم فیلتر

۳ کارهای پیشین ۲۱

۲۱	۱-۳ داده های با ابعاد بالا
۲۲	۱-۱-۳ نمونه برداری
۲۲	۱-۱-۳-۱ پژوهش دوچی و همکاران
۲۳	۱-۱-۳-۲ پژوهش چن و همکاران
۲۴	۱-۱-۳-۳ پژوهش وانگ و همکاران
۲۵	۱-۱-۳-۴ پژوهش آرکولزی و همکاران
۲۵	۱-۱-۳-۵ پژوهش رحمان صیام و همکاران
۲۶	۱-۱-۳-۶ پژوهش یوان و همکاران
۲۶	۱-۳-۲ خوشه بندی
۲۷	۱-۳-۲-۱ پژوهش رِن و همکاران
۳۰	۱-۳-۲-۲ پژوهش ماتاموروس و همکاران
۳۰	۱-۳-۲-۳ پژوهش ژانگ و همکاران
۳۱	۱-۳-۲-۴ پژوهش جیانگ و همکاران
۳۴	۱-۳-۲-۵ پژوهش دیو و همکاران
۳۵	۱-۳-۲-۶ پژوهش گو هوا شِن و همکاران

۳۶	۳-۱-۲-۷ پژوهش کیکوچی و همکاران
۳۶	۳-۱-۲-۸ پژوهش سانگ و همکاران
۳۶	۳-۱-۳ کاهش ابعاد
۳۶	۳-۱-۳-۱ پژوهش دونگیو ژانگ و همکاران
۴۲	۳-۲ داده‌های در حال تغییر
۴۵	۳-۲-۱ حفظ کردن
۴۵	۳-۲-۱-۱ پژوهش الینگسون و همکاران
۴۷	۳-۲-۲ رُند کردن
۴۷	۳-۲-۲-۱ پژوهش دینگ و همکاران
۵۱	۳-۲-۳ ارسال تغییرات داده
۵۲	۳-۲-۳-۱ پژوهش کیائو ژو و همکاران
۵۴	۳-۲-۴ درهم‌سازی محلی
۵۶	۳-۲-۴-۱ پژوهش تیانهائو وانگ و همکاران
۵۷	۳-۲-۵ ترکیب حفظ کردن و درهم‌سازی محلی
۵۷	۳-۲-۵-۱ پژوهش آرکولزی و همکاران
۶۲	۳-۲-۶ سایر روش‌ها
۶۲	۳-۲-۶-۱ پژوهش سونر و همکاران
۶۳	۳-۲-۶-۲ پژوهش یومین و همکاران
۶۳	۳-۲-۶-۳ پژوهش ژنگ و همکاران
۶۴	۳-۲-۶-۴ پژوهش یونفی لی و همکاران
۶۴	۳-۲-۶-۵ پژوهش بو جیانگ و همکاران
۶۵	۳-۲-۶-۶ پژوهش ماریراس نتو و همکاران
۶۵	۳-۳ جمع‌بندی

۶۷	۱-۴ نوآوری پژوهش
۶۸	۲-۴ بررسی چارچوب راهکار پیشنهادی
۶۹	۳-۴ یافتن ابعاد در حال تغییر
۷۰	۴-۴ اعمال سازوکار گرد کردن نقطه آلفا
۷۱	۴-۴-۱ تخمین گام گسسته سازی بهینه
۷۳	۴-۴-۲ اثبات اریب ناپذیری
۷۴	۴-۴-۳ تحلیل خطای میانگین مربعات
۷۵	۵-۴ استفاده از روش تبدیل هار به همراه حفظ کردن
۷۵	۶-۴ جمع آوری و تحلیل داده ها توسط کارپذیر
۷۶	۷-۴ یکنواخت سازی
۷۷	۸-۴ تضمین حریم خصوصی تفاضلی
۷۷	۴-۸-۱ اثبات امن بودن سازوکار جی.پی.ام
۷۸	۴-۸-۲ اثبات امن بودن سازوکار پی.دی.پی
۷۸	۴-۹ جمع بندی

۵ ارزیابی روش پیشنهادی

۸۰	۱-۵ مجموعه داده ی ورودی
۸۲	۲-۵ ارزیابی روی داده های با ابعاد بالا
۸۲	۵-۲-۱ ارزیابی حین تغییر بودجه ی حریم خصوصی
۸۳	۵-۲-۲ ارزیابی حین تغییر تعداد ابعاد داده
۸۴	۵-۲-۳ ارزیابی روی مجموعه داده های مختلف
۸۶	۵-۳ ارزیابی روی داده های در حال تغییر
۸۷	۵-۴ جمع بندی

۶ جمع بندی

۹۰ ۱-۶ دستاوردها

۹۰ ۲-۶ کارهای آتی

۹۲ مراجع

۹۶ واژه‌نامه

فهرست جدول‌ها

۳-۱ مقایسه‌ی یک بیت فلیپ.پی.ام و دی.بیت فلیپ.پی.ام ۴۹

فهرست شکل‌ها

۱-۲	نحوه عملکرد حریم خصوصی تفاضلی محلی	۱۰
۲-۲	شیوه‌ی درج عنصر با استفاده از بلوم فیلتر	۲۰
۱-۳	ساخت درخت اتصال از گراف همبستگی [۱]	۲۹
۲-۳	استفاده از شبکه مارکوف در ساخت درخت اتصال [۲]	۳۲
۳-۳	ساخت شبکه بیزی از پنج ویژگی [۳]	۳۳
۴-۳	ساختار روش پی.پی.ام.سی [۴]	۳۷
۵-۳	نحوه محاسبه‌ی بردار ویژه در تبدیل هار. $a_{i,j}$ نشان‌دهنده‌ی ویژگی z ام از کاربر i ام است	
	[۴].	۳۸
۶-۳	آشفته‌سازی مقدار m_i بر اساس پی.دی.پی [۴]	۴۱
۷-۳	تهیه‌ی درخت تفاوت از داده‌ها [۵]	۵۳
۱-۴	عملکرد روش پیشنهادی سمت کاربر	۶۹
۱-۵	نحوه ترکیب دو مجموعه داده‌ی بزرگسالان و سین. مشخصه‌ی $A_{i,j}$ نشان‌دهنده‌ی ویژگی z ام از کاربر i ام است. همچنین نشان $B_{i,t}$ ، داده‌ی پویای کاربر i ام در واحد زمانی t ام را نمایش می‌دهد.	۸۱
۲-۵	مقایسه‌ی میانگین مربعات خطای روش پیشنهادی با دو روش پی.ام و تکه‌ای	۸۲
۳-۵	مقایسه‌ی میانگین اختلاف توزیع احتمال داده‌ها در روش پیشنهادی با دو روش پی.ام و تکه‌ای	۸۳
۴-۵	مقایسه‌ی خطا در روش پیشنهادی حین تغییر تعداد ابعاد با دو روش پی.ام و تکه‌ای	۸۴

- ۵-۵ مقایسه‌ی میانگین مربعات خطا در روش پیشنهادی حین تغییر مجموعه داده ورودی . . ۸۵
- ۶-۵ مقایسه‌ی میانگین اختلاف توزیع احتمال داده‌ها حین تغییر مجموعه داده ورودی . . . ۸۵
- ۷-۵ مقایسه‌ی میانگین خطای تخمین شمارش در روش پیشنهادی حین تغییر بودجه‌ی حریم خصوصی ۸۶
- ۸-۵ مقایسه‌ی زمان اجرای الگوریتم پیشنهادی با سه روش رپور ، لولوها و دی.بیت.فلیپ.پی.ام ۸۷

فصل ۱

مقدمه

در دنیای امروز که داده‌ها به بخش مهمی از تصمیم‌گیری‌ها و توسعه سیستم‌های اطلاعاتی تبدیل شده‌اند، حفاظت از حریم خصوصی افراد از اهمیت بالایی برخوردار است. حریم خصوصی تفاضلی^۱ به عنوان یک چارچوب ریاضی، رویکرد نوینی را برای جلوگیری از افشای اطلاعات حساس افراد در تحلیل داده‌ها ارائه می‌دهد.

انتشار داده‌ها بر مبنای حریم خصوصی تفاضلی اخیراً توجه زیادی را به خود جلب کرده و همچنین الگوریتم‌های متنوعی برای بهبود آن ارائه شده‌است. تعریف ریاضی حریم خصوصی تفاضلی بیان می‌کند که نتیجه هر تحلیل آماری روی داده‌ها، چه شما در آن شرکت کنید و چه نه، یکسان باشد. یعنی اطلاعاتی که از داده‌ها استخراج می‌شود، به گونه‌ای طراحی شده‌است که هیچ فردی نتواند از مشارکت یا عدم مشارکت خود، آسیب یا مزیتی دریافت کند. به عبارت دیگر، حریم خصوصی تفاضلی تضمین می‌کند که داده‌های فردی در برابر تحلیل‌های جمعی محافظت می‌شوند و هیچ گونه اطلاعات خاصی درباره افراد در معرض خطر قرار نمی‌گیرد. این ویژگی باعث می‌شود که افراد با اطمینان بیشتری در تحلیل‌های آماری شرکت کنند.

طی چند سال گذشته، راه حل‌هایی ارائه شده‌است تا هر کاربر بتواند ابتدا روی داده‌های خود نوفه^۲ ایجاد کرده و سپس آن‌ها را به سمت کارپذیر ارسال کند. به این راه حل‌ها، الگوریتم‌های حریم خصوصی تفاضلی^۳ محلی گفته می‌شود. در این الگوریتم‌ها، حتی با وجود غیرقابل اعتماد بودن کارپذیر، حریم خصوصی کاربران محفوظ باقی می‌ماند. لازم به ذکر است در انتشار داده‌های خصوصی با ابعاد بالا^۴ با چالش‌هایی مانند روابط پیچیده بین ویژگی‌ها، پیچیدگی محاسباتی بالا و پراکندگی داده‌ها روبه‌رو هستیم.

¹Differential Privacy

²Noise

³Local Differential Privacy

⁴High Dimensional

راه حل‌های موجود که با تمرکز روی داده با ابعاد پایین ارائه شده‌اند، بودجه حریم خصوصی را بین همه ویژگی‌ها تقسیم می‌کنند. با پیاده‌سازی این راه حل‌ها روی داده با ابعاد بالا، نوفه در مقیاس بالا تولید شده و سیستم کارایی خود را از دست می‌دهد. از طرفی یکی دیگر از چالش‌های حفظ حریم خصوصی تفاضلی، کار روی داده‌های در حال تغییر^۵ است. یک نمونه بارز در چنین مسائلی، نظارت بر خط^۶ روی برنامه‌های نرم‌افزاری و گزارش عملکرد آن‌ها است، زیرا داده‌های ارسالی همواره در حال تغییر هستند. پروتکل‌های فعلی جمع‌آوری داده‌ها می‌توانند حریم خصوصی تفاضلی را در داده‌های با دامنه تغییرات محدود ارضا کنند. در نتیجه برای دامنه‌های بزرگ، مانند دامنه تغییرات داده‌ها در اینترنت اشیا^۷، ناکارآمد خواهند بود. هدف از این پژوهش ارائه راهکاری به منظور حفظ حریم خصوصی کاربران در هنگام انتشار داده‌ها با ابعاد بالا و در حال تغییر است. به منظور ارزیابی عملکرد و کارایی این الگوریتم، ما به تحلیل و محاسبه فراوانی داده‌ها پرداخته و مقدار خطای به دست آمده را با خروجی سایر الگوریتم‌های موجود مقایسه می‌کنیم. این مقایسه، به ما کمک می‌کند تا نقاط قوت و ضعف روش پیشنهادی را شناسایی کرده و در جهت بهینه‌سازی بیشتر آن گام برداریم. در نهایت، نتایج حاصل از این پژوهش می‌تواند به عنوان یک چارچوب کاربردی برای حفظ حریم خصوصی داده‌های کاربران مورد استفاده قرار گیرد.

۱-۱ تعریف مسئله

اکثر مقالات و راهکارهای پیشین، فقط یکی از دو چالش اصلی که پیش‌تر ذکر شد را مورد بررسی قرار داده‌اند و برای ارزیابی راهکار خود مجموعه داده مختص با یک چالش را گردآوری کرده‌اند. مقالاتی که روی داده‌های با ابعاد بالا کار کرده‌اند، معمولاً اختلاف میانگین یا اختلاف احتمال توزیع^۸ داده‌ها را به عنوان خطا ارائه می‌دهند. همچنین مقالاتی که روی داده‌های در حال تغییر کار می‌کنند، شمارش داده‌های یکسان را به عنوان معیار در نظر گرفته و سعی می‌کنند خطای مربوط به این معیار را کاهش دهند.

از آنجایی که ما هر دو چالش را مورد بررسی قرار داده‌ایم، مجموعه داده‌ای شامل هر دو نوع داده گردآوری شده‌است. یعنی یک مجموعه داده با ابعاد بالا داریم که بعضی از بعدهای آن دامنه‌ی بزرگی دارند و مدام در حال تغییر هستند. به صورت خلاصه راه حل ارائه شده، یک نوفه‌ی خاص را روی تمام ابعاد اعمال می‌کند. سپس به منظور ارزیابی راهکار، خطای دو معیار محاسبه می‌شود. معیار شمارش داده‌ها روی بعدهای در حال تغییر در نظر گرفته شده و همچنین معیار احتمال توزیع داده‌ها روی دیگر ابعاد بررسی می‌شود.

^۵Evolving Data

^۶Online

^۷Internet of Things

^۸Probability Distribution

۱-۲ اهمیت موضوع

در دنیای امروزی برنامه‌های کاربردی بیشماری وجود دارد که مردم با کمک این برنامه‌ها، زندگی روزمره‌ی خود را سپری می‌کنند. داده‌های ورودی برای این برنامه‌ها شامل داده‌های با ابعاد بالا و در حال تغییر می‌شوند. چندین نوع داده کاربردی مهم وجود دارند که حفظ حریم خصوصی افراد در آن حائز اهمیت است، از جمله:

- سوابق پزشکی، داده‌هایی با ابعاد بالا هستند و معمولاً با جمع‌آوری اطلاعات جدید، در طول زمان تغییر می‌کنند. برای مثال، سابقه پزشکی و داده‌های ژنتیکی یک بیمار ممکن است با هر مراجعه به‌روزرسانی شود.
- مؤسسات مالی با داده‌هایی مانند سوابق تراکنش‌ها و عوامل بازار مثل قیمت سهام و روندهای بازار سروکار دارند. این مجموعه داده به‌صورت پیوسته با انجام تراکنش‌ها، نوسان قیمت سهام و ظهور محصولات مالی جدید، تغییر می‌کنند.
- سکویای رسانه اجتماعی داده‌های ابعاد بالا مانند اطلاعات حساب کاربران، تعاملات و ترجیحات را جمع‌آوری می‌کنند که با فعالیت کاربران در محتوا و سکو، تغییر می‌کنند.
- شبکه‌های هوشمند و دستگاه‌های اینترنت اشیا، داده‌هایی از حسگرها و دستگاه‌ها مانند الگوهای مصرف انرژی، عوامل محیطی و وضعیت دستگاه‌ها را جمع‌آوری می‌کنند. لازم به ذکر است که این داده‌ها هم بعدها زیادی دارند و هم شامل داده‌های در حال تغییر می‌باشند.

تا کنون چندین پیاده‌سازی از الگوریتم‌های حریم خصوصی تفاضلی انجام شده است. به عنوان مثال، گوگل^۹ در مرورگر کروم^{۱۰} از الگوریتم رپور^{۱۱} بهره می‌گیرد تا شاخص‌های کاربری و تنظیمات حساسی مانند صفحه‌خانگی را از میلیون‌ها کاربر جمع‌آوری کند؛ بی‌آنکه هویت فردی آنان افشا شود. کروم روزانه حدود ۱۴ میلیون گزارش از کاربران داوطلب دریافت می‌کند و با اتکا به این داده‌ها می‌تواند اطلاعات مفیدی را بدون فاش شدن شناسه‌های شخصی در دسترس تحلیلگران قرار دهد [۶].

از طرفی مایکروسافت^{۱۲} برای جمع‌آوری داده‌های دورسنجی^{۱۳} از سامانه‌هایش به‌جای ارسال داده خام، سازوکاری مبتنی بر حریم خصوصی تفاضلی محلی پیاده‌سازی کرده است. این فناوری از سال ۲۰۱۷

^۹Google

^{۱۰}Chrome

^{۱۱}Rappor

^{۱۲}Microsoft

^{۱۳}Telemetry Data

روی میلیون‌ها دستگاه فعال شده و اکنون معیارهایی^{۱۴} مثل مدت استفاده از هر برنامه را برای هر بازه‌ی شش ساعته ثبت می‌کند [۷]. بدین ترتیب مایکروسافت تنها به نتایج تحلیل‌های آماری دست می‌یابد و هویت یا الگوی اطلاعات کاربران فاش نمی‌شود.

۳-۱ ادبیات موضوع

برای درک عمیق‌تر چالش‌های پژوهش و راهکارهای ارائه‌شده، لازم است ابتدا با مفاهیم و تعاریف بنیادین این حوزه آشنا شویم. در این بخش، مبانی نظری مرتبط با حریم خصوصی، ویژگی‌های داده‌های چندبعدی و ماهیت داده‌های پویا مورد بررسی قرار می‌گیرد. شناخت دقیق این تعاریف، زیربنای لازم برای درک پدیده «نفرین ابعاد» و تحلیل الگوریتم‌های پیشنهادی در فصول آتی را فراهم می‌آورد:

۱. حریم خصوصی:

حریم خصوصی مفهومی است که به حق هر فرد برای کنترل دسترسی دیگران به اطلاعات، ارتباطات و قلمرو شخصی‌اش اشاره می‌کند. یعنی هرکس بتواند خود تصمیم بگیرد چه داده‌هایی، در چه زمان و برای چه کسانی آشکار شود و چه بخش‌هایی از زندگی‌اش از نگاه دیگران دور بماند. این حق نه تنها شامل اطلاعات آشکار مانند نشانی، شماره تماس یا سوابق پزشکی است، بلکه ترجیحات، گفت‌وگوهای خصوصی و حتی الگوهای رفتاری ضمنی را نیز در بر می‌گیرد. حریم خصوصی با فراهم کردن فضایی امن، مشارکت آگاهانه و بدون ترس در جامعه دیجیتال را ممکن می‌سازد.

۲. داده‌های با ابعاد بالا:

مقصود از داده‌های با ابعاد بالا مجموعه‌ای از داده‌هاست که هر مشاهده آن شامل شمار زیادی ویژگی یا بُعد است. به بیان دیگر، به جای سطرهایی با چند ستون محدود، با رکوردهایی روبه‌رو هستیم که ده‌ها یا صدها ستون دارند و هر ستون جنبه‌ای مجزا از پدیده را وصف می‌کند. این تکثر ابعاد، گرچه امکان استخراج الگوها و اطلاعات نهفته‌ی فراوان را فراهم می‌کند، اما هم‌زمان چالش‌هایی در حفظ حریم خصوصی به همراه می‌آورد. در این پژوهش راهکاری مربوط به حل اینگونه چالش‌ها بررسی و پیاده‌سازی شده‌است.

۳. داده‌های طولی:

داده‌های طولی^{۱۵} به اطلاعاتی اطلاق می‌شود که در طول زمان و در بازه‌های متوالی از افراد یا

¹⁴Metric

¹⁵Longitudinal Data

موجودیت‌های یکسان جمع‌آوری می‌گردد. در این نوع داده‌ها، هر فرد در چندین نوبت یک نمونه از اطلاعات خود را برای کارپذیر ارسال می‌کند. به عبارت ساده‌تر، این داده‌ها تکامل و تغییرات یک پدیده را در طول زمان دنبال می‌کنند.

۴. داده‌های در حال تغییر:

داده‌های در حال تغییر، مجموعه‌ای از اطلاعات را شامل می‌شود که مقدار ستون‌های آن با گذر زمان تغییر می‌کنند. برای نمونه، تعداد ثانیه‌های استفاده از یک برنامه کاربردی یا هر شمارنده و مؤلفه‌ی دیگری که امروز ارزشی دارد و با گذشت زمان عوض می‌شود. این نوسان مداوم باعث می‌شود سامانه داده را به‌طور پی‌درپی جمع‌آوری و به‌روزرسانی کند. معمولاً دامنه تغییر این داده‌ها بالا است و چالش‌هایی در حفظ حریم خصوصی بوجود می‌آید که در ادامه به آن اشاره خواهیم کرد.

۵. پدیده نفرین ابعاد بالا:

نفرین ابعاد بالا به مجموعه چالش‌ها و مشکلاتی گفته می‌شود که با زیاد شدن تعداد ویژگی‌ها در داده رخ می‌دهد. در واقع هر قدر بُعدها بیشتر می‌شوند، احتمال ارتباط میان ابعاد بالا رفته و سامانه برای حفظ حریم خصوصی داده‌ها به ناچار باید نوفه‌ی بیشتری اضافه کند. هرچقدر نوفه بیشتر اعمال شود، دقت نتایج تحلیل داده‌ها کاهش می‌یابد. بنابراین در این پژوهش راه‌حلی انتخاب و توسعه یافته است که موازنه^{۱۶} بین حریم خصوصی و سودمندی^{۱۷} رعایت شود.

۴-۱ اهداف پژوهش

راه‌حل‌های بیشماري تاکنون ارائه شده است ولی اکثر آنها یا حریم خصوصی را کامل ارضا نمی‌کنند یا سربار بالای زمانی و نوفه‌ای به سامانه اعمال می‌کنند. در نتیجه هزینه‌ی استفاده از الگوریتم برای حفظ حریم خصوصی بالا رفته و سازمان‌ها رغبتی به استفاده از آن ندارند. بنابراین هدف این پژوهش طراحی و پیاده‌سازی ابزاری سبک، کاربرپسند و سریع است که بتواند با تزریق بهینه نوفه به داده‌های خام، هم‌زمان هم سودمندی را داشته باشیم و هم حریم خصوصی حفظ شود.

¹⁶Trade off

¹⁷Utility

۵-۱ ساختار پایان‌نامه

این پایان‌نامه در شش فصل به شرح زیر ارائه می‌شود. مفاهیم اولیه و مورد استفاده برای حفظ حریم خصوصی تفاضلی در فصل دوم به اختصار اشاره شده است. فصل سوم به مطالعه و بررسی کارهای پیشین مرتبط با حریم خصوصی تفاضلی محلی می‌پردازد. در فصل چهارم، راهکار پیشنهادی توضیح داده شده و جزئیات پیاده‌سازی آن بیان می‌شود. در فصل پنجم، نحوه ارزیابی راهکار پیشنهادی و مقایسه‌ی آن با دیگر راهکارها شرح داده می‌شود. همچنین نتایج جدیدی که در این پایان‌نامه به دست آمده است، ارائه خواهد شد. فصل ششم به جمع‌بندی کارهای انجام شده در این پژوهش و ارائه‌ی پیشنهادهایی برای انجام کارهای آتی خواهد پرداخت.

فصل ۲

مفاهیم اولیه

بخش مفاهیم پایه، شامل کلیه مفاهیم اولیه‌ی مورد نیاز در ارتباط با این پژوهش می‌باشد. این بخش ابتدا تعاریف و توضیحاتی در رابطه با حریم خصوصی تفاضلی ارائه می‌دهد. سپس به بیان سازوکارهای مرتبط با حفظ حریم خصوصی پرداخته می‌شود. در نهایت برخی از چالش‌های اساسی که پیش روی سازوکارهای حفظ حریم خصوصی هستند، بیان خواهد شد.

۲-۱ حریم خصوصی تفاضلی

حریم خصوصی تفاضلی یک چارچوب ریاضی است که تضمین می‌کند خروجی هر تحلیل آماری به‌گونه‌ای ساخته شود که حضور یا عدم حضور هر فرد در داده‌ها تأثیر محسوسی بر توزیع نتایج نگذارد. به بیان دیگر، حریم خصوصی تفاضلی این اجازه را می‌دهد که بتوان روی یک مجموعه داده، تحلیل‌های آماری مانند میانگین و شمارش را انجام دهیم ولی نتوان اطلاعات مربوط به یک شخص را استخراج کرد. فرض کنید سازمانی می‌خواهد یک آمار تقریبی از تعداد افراد با یک بیماری خاص بدست‌آورد. این سازمان از تمام جامعه‌ی آماری خود درخواست می‌کند که با تکمیل فرمی بگویند آیا آن بیماری خاص را دارند یا خیر. همگی فرم‌ها به سمت سازمان فرستاده می‌شود. سپس سازمان باید نتایج تحلیل‌های آماری مرتبط به فرم‌های جمع‌آوری شده را با کاربران خود به اشتراک بگذارد. اگر نتایج به دور از هیچگونه سازوکار امنیتی منتشر شود، حریم خصوصی افراد شرکت کننده در رابطه با داشتن بیماری خاص نقض می‌شود. نوعی از الگوریتم‌های حفظ حریم خصوصی، الگوریتم‌های حریم خصوصی تفاضلی هستند که با ایجاد نوفه در داده‌ها، باعث می‌شوند نتایج تحلیل‌های آماری به طور تقریبی صحیح بوده و در عین حال، حریم خصوصی افراد حفظ شود.

تعریف حریم خصوصی تفاضلی برای اولین بار توسط خانم دُرک [۸] به صورت زیر مطرح شد:

تعریف ۱-۲ (حریم خصوصی تفاضلی) الگوریتم M را در نظر بگیرید که به عنوان ورودی پایگاه داده D را دریافت می‌کند. این الگوریتم حریم خصوصی تفاضلی را در صورتی تضمین می‌کند که برای هر دو پایگاه داده مجاور D و D' و برای هر مجموعه خروجی از دامنه خروجی‌های S ممکن داشته باشیم:

$$\Pr[M(D) \in S] \leq e^\epsilon \times \Pr[M(D') \in S] \quad (۱-۲)$$

پایگاه داده‌هایی که تنها در یک عنصر تفاوت داشته باشند، مجاور یا همسایه^۱ نامیده می‌شوند. همچنین ϵ یک ورودی مثبت با مقدار کم است و سطح حریم خصوصی را نشان می‌دهد. بنابر عبارت بالا، هر چه مقدار کمتری برای ϵ در نظر بگیریم، در واقع قوانین سخت‌گیرانه‌تری برای حفظ حریم خصوصی اعمال کرده‌ایم.

۲-۲ بودجه حریم خصوصی

بودجه حریم خصوصی یکی از مفاهیم کلیدی در حریم خصوصی تفاضلی است که برای اندازه‌گیری و کنترل میزان حریم خصوصی در طی اجرای یک الگوریتم یا مجموعه‌ای از الگوریتم‌ها استفاده می‌شود. این مفهوم به‌طور مستقیم با پارامتر ϵ در ارتباط است.

معمولاً بودجه‌ای که برای الگوریتم‌های حافظ حریم خصوصی در نظر می‌گیرند، برابر ۱ یا مقداری نزدیک به ۱ است. هرچه بودجه‌ی کمتری به الگوریتم اختصاص دهیم، در واقع حریم خصوصی قوی‌تری برایش اعمال کرده‌ایم. در نتیجه الگوریتم برای اینکه بتواند شرط حریم خصوصی در تعریف ۱-۲ را ارضا کند، باید نوفه‌ی بیشتری به داده‌ها اضافه کند. طبیعتاً با اضافه کردن نوفه‌ی بیشتر، سودمندی کاهش خواهد یافت.

۳-۲ حریم خصوصی تفاضلی محلی

پس از معرفی حریم خصوصی تفاضلی، مشخص شد که ارسال داده‌های خام به سمت یک کارپذیر و اعتماد به آن، کارچندان درستی نیست. اگر به این کارپذیر حمله‌ی سایبری انجام شود یا اینکه خود کارپذیر داده‌ها

¹Neighbour

را به صورت غیر مجاز به سازمانی دیگر دهد، حریم خصوصی افراد جامعه نقض می‌شود. افزایش رخنه‌های امنیتی و سخت‌گیری‌های قانونی نیز این بی‌اعتمادی را تشدید کرد. از همین رو پژوهشگران به الگویی روی آوردند که در آن هر کاربر پیش از ارسال، پاسخ خود را به‌طور تصادفی نوفه‌دار می‌کند تا حریم خصوصی در همان مبدأ تضمین شود. نمایی از عملکرد حریم خصوصی تفاضلی محلی را می‌توانیم در شکل ۲-۱ مشاهده کنیم.

به بیانی دیگر، حریم خصوصی تفاضلی محلی مفهومی در حفاظت از داده‌های شخصی است که به کاربران اجازه می‌دهد اطلاعات خود را بدون نیاز به اعتماد به طرف ثالث در اختیار دیگران قرار دهند. در این مدل، پیش از آنکه داده‌ها به کاربر پذیر غیر قابل اعتماد ارسال شوند نوفه بر روی آنها اضافه می‌شود. اصطلاحاً به این عملیات، «آشفته‌سازی داده»^۲ می‌گویند. سپس کاربر پذیر با پردازش داده‌ها به آمار قابل قبولی دست پیدا می‌کند که می‌تواند به صورت عمومی با کاربران به اشتراک گذاشته شود. مدل حریم خصوصی تفاضلی محلی برای اولین بار در سال ۲۰۱۱ [۹] ارائه شد و سپس دوجی و همکارانش [۱۰] تعریف بهتر و دقیق‌تری از نظر ریاضیاتی معرفی کردند. این مدل را به اختصار، مدل «ال دی پی» می‌نامند.

تعریف ۲-۲ (حریم خصوصی تفاضلی محلی) فرض کنید \mathcal{X} دامنه داده‌های کاربر باشد و $\mathcal{M} : \mathcal{X} \rightarrow \mathcal{Y}$ یک الگوریتم تصادفی باشد. این الگوریتم به صورت (ϵ, δ) حریم خصوصی تفاضلی محلی را برآورده می‌کند اگر برای هر جفت داده ورودی $x, x' \in \mathcal{X}$ و هر زیرمجموعه $S \subseteq \mathcal{Y}$ از خروجی‌های ممکن داشته باشیم:

$$\Pr[\mathcal{M}(x) \in S] \leq e^\epsilon \Pr[\mathcal{M}(x') \in S] + \delta \quad (2-2)$$

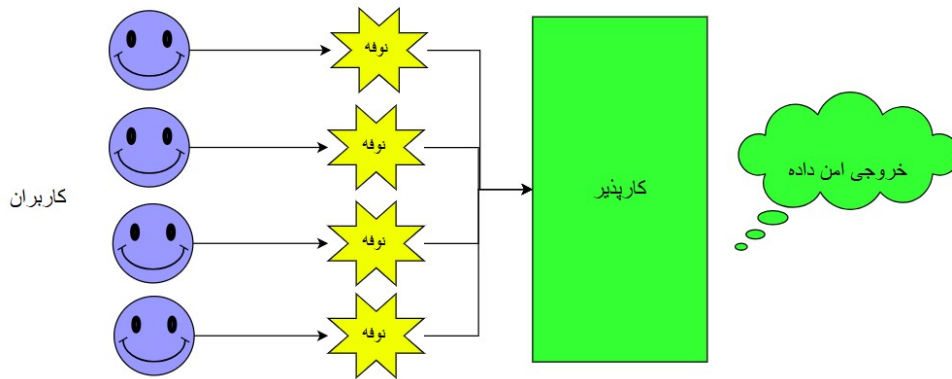
در نامساوی بالا، ϵ بودجه‌ی حریم خصوصی است و δ «پارامتر لغزش» تلقی می‌شود. ورودی δ کمی شرط تضمین حریم خصوصی تفاضلی را آسان‌تر می‌کند. به الگوریتم‌هایی که بتوانند شرط بالا را با δ برابر صفر ارضا کنند، حافظ حریم خصوصی تفاضلی خالص یا ϵ -LDP می‌گویند.

۲-۴ حساسیت

حساسیت^۳ در زمینه حریم خصوصی داده‌ها به حداکثر تغییر در خروجی یک تابع به دلیل تغییر یک ورودی واحد اشاره دارد [۱۱]. به عبارت دیگر، حساسیت اندازه‌گیری می‌کند که چقدر می‌توان با تغییر یک ورودی،

^۲Data Perturbation

^۳Sensitivity



شکل ۲-۱: نحوه عملکرد حریم خصوصی تفاضلی محلی

خروجی تابع را تحت تأثیر قرار داد. این ویژگی در طراحی سازوکارهای حریم خصوصی تفاضلی محلی بسیار مهم است، زیرا تعیین می‌کند که چه مقدار نوفه باید به خروجی اضافه شود تا حریم خصوصی کاربران حفظ گردد.

تعریف ۲-۳ (حساسیت) حساسیت یک تابع $f: \mathcal{X} \rightarrow \mathbb{R}^d$ به صورت زیر تعریف می‌شود:

$$\Delta f = \max_{x, x' \in \mathcal{X}} \|f(x) - f(x')\| \quad (2-3)$$

در عبارت بالا Δf حساسیت تابع f نامیده می‌شود و \mathcal{X} دامنه ورودی ما است.

۲-۵ الگوریتم‌های حافظ حریم خصوصی تفاضلی

برای پیاده‌سازی عملی مفهوم حریم خصوصی تفاضلی، نیاز به سازوکارهای ریاضی مشخصی است که چگونگی و میزان تزریق نوفه به داده‌ها را تعیین کنند. در این بخش، به معرفی و تشریح بنیادین‌ترین الگوریتم‌های این حوزه می‌پردازیم. این سازوکارها به عنوان اجزای سازنده در پروتکل‌های پیچیده‌تر مورد استفاده قرار می‌گیرند و بسته به نوع داده‌ها و مدل پیاده‌سازی، کاربردهای متفاوتی دارند. در ادامه، از روش‌های کلاسیک مانند سازوکار لاپلاس تا روش‌های مدرن‌تر مبتنی بر پاسخ تصادفی بررسی خواهند شد.

۲-۵-۱ سازوکار لاپلاس

سازوکار لاپلاس^۴ در حریم خصوصی تفاضلی ایده‌ای ساده و در عین حال توانمند است. هرگاه بخواهیم آماری از داده‌ها مانند مجموع، میانگین و تعداد را منتشر کنیم، به جای پاسخ دقیق، همان پاسخ را با نوفه‌ای که از توزیع لاپلاس بدست می‌آید می‌فرستیم. مقدار پراکندگی این نوفه طوری تنظیم می‌شود که اگر اطلاعات یک فرد در پایگاه داده حذف یا اضافه شود، توزیع خروجی تقریباً تغییر نکند. بدین ترتیب حضور یا عدم حضور آن فرد در نتیجه قابل تشخیص نیست. بزرگی نوفه به دو عامل بستگی دارد: حساسیت تابع و همچنین بودجه حریم خصوصی. هرچه بودجه‌ی کمتری اختصاص دهیم حفاظت قوی‌تر شده و نوفه بیشتری اعمال می‌شود.

تعریف ۲-۴ (سازوکار لاپلاس) سازوکار لاپلاس روی یک تابع $f : \mathcal{X} \rightarrow \mathbb{R}^d$ به صورت زیر تعریف می‌شود:

$$\mathcal{M}(D) = f(D) + \text{Lap}\left(\frac{\Delta f}{\epsilon}\right) \quad (۲-۴)$$

در عبارت بالا، ورودی مرکز یا μ در توزیع لاپلاس برابر صفر و همچنین ورودی مقیاس یا b برابر $\frac{\Delta f}{\epsilon}$ در نظر گرفته شده است.

۲-۵-۲ سازوکار نمایی

یکی از مشکلات سازوکار لاپلاس، عدم کارایی در مقادیر گسسته و غیر عددی است. از این رو سازوکار دیگری به نام سازوکار نمایی معرفی شد. این سازوکار چارچوبی فراهم می‌کند که در آن می‌توانیم تابع سودمندی دلخواه خود را تعریف کنیم. در واقع تابع u هر ورودی و خروجی تشکیل شده از پایگاه داده‌ی ما را به یک امتیاز سودمندی تبدیل می‌کند.

$$u : \mathbb{N}^{|X|} \times \mathcal{R} \rightarrow \mathbb{R} \quad (۲-۵)$$

پس از محاسبه‌ی امتیاز هر خروجی، سازوکار گزینه‌ها را با احتمالی متناسب با توزیع نمایی آن امتیاز انتخاب می‌کند. این انتخاب به‌گونه‌ای انجام می‌شود که گزینه‌های دارای امتیاز بالاتر، با احتمال بیشتری

^۴Laplace

انتخاب شوند. این روش برای پرسش‌های غیر عددی (مثل «کدام محصول پرفروش‌تر است؟») بسیار سودمند خواهد بود. دقت کنید که ما اینجا نیاز به محاسبه حساسیت تابع سودمندی خود به شکل زیر داریم:

$$\Delta u = \max_{r \in \mathcal{R}} \max_{\substack{x, y \in \mathbb{N}^{|X|} \\ \|x-y\|_1 \leq 1}} |u(x, r) - u(y, r)| \quad (6-2)$$

در نهایت سازوکار نمایی $\mathcal{M}_E(x, u, \mathcal{R})$ عنصر $r \in \mathcal{R}$ را با احتمالی متناسب با $\exp\left(\frac{\varepsilon u(x, r)}{2 \Delta u}\right)$ گزینش و اعلام می‌کند.

۲-۵-۳ پاسخ تصادفی

پاسخ تصادفی روشی است که در نظرسنجی‌ها و جمع‌آوری داده‌های حساس کاربرد دارد. در این روش، به جای اینکه کاربر به‌طور مستقیم به یک سؤال پاسخ دهد، از یک سازوکار تصادفی استفاده می‌کند تا عدم قطعیت را به پاسخ خود اضافه کند. با اضافه کردن عدم قطعیت، مهاجم یا شخص متخاصم حتی اگر پاسخ نوفه‌دار شده‌ی کاربر را داشته باشد، نمی‌تواند با قطعیت جواب اصلی را مشخص کند. به بیان دیگر، کاربر با احتمال مشخصی پاسخ واقعی خود را ارائه می‌دهد و با احتمال دیگری پاسخ تصادفی دیگری را انتخاب می‌کند. این کار باعث می‌شود که احتمال شناسایی پاسخ واقعی کاربر کاهش یابد. مدل ریاضی پاسخ تصادفی توسط وارنر [۱۲] معرفی شد.

تعریف ۲-۵ (پاسخ تصادفی) فرض کنید کاربر می‌خواهد به یک سؤال دودویی^۵ (بله/خیر) پاسخ دهد. اگر x پاسخ واقعی کاربر باشد، سازوکار پاسخ تصادفی به صورت زیر عمل می‌کند:

$$\Pr[y = t] = \begin{cases} p, & \text{if } t = x, \\ 1 - p, & \text{if } t \neq x \end{cases} \quad (7-2)$$

در عبارت بالا، y پاسخ ارائه شده به سؤال است. p احتمال اینکه کاربر پاسخ واقعی خود را ارائه دهد و $1-p$ احتمال این است که کاربر به‌طور تصادفی پاسخ مخالف را انتخاب کند. سازوکار پاسخ تصادفی اگر بخواهد ϵ -LDP باشد، باید مقدار p را برابر $\frac{e^\epsilon}{e^\epsilon + 1}$ قرار دهیم.

⁵Binary

۲-۵-۴ پاسخ تصادفی عمومی

پاسخ تصادفی به تنهایی جوابگوی مسائل پیچیده‌تر با دامنه بزرگتر نبود. پاسخ تصادفی عمومی^۶، شکل عمومی‌تر و انعطاف‌پذیرتر پاسخ تصادفی است [۱۳، ۱۴]. این الگوریتم را به اختصار، «جی آر آر» می‌نامند.

تعریف ۲-۶ (پاسخ تصادفی عمومی) فرض کنید کاربر می‌خواهد به یک سؤال با k گزینه پاسخ دهد. اگر x پاسخ واقعی کاربر باشد، سازوکار پاسخ تصادفی عمومی به صورت زیر عمل می‌کند:

$$\Pr[y = t] = \begin{cases} p, & \text{if } t = x, \\ \frac{1-p}{k-1}, & \text{if } t \neq x \end{cases} \quad (۲-۸)$$

سازوکار پاسخ تصادفی اگر بخواهد ϵ -LDP باشد، باید مقدار p را برابر $\frac{e^\epsilon}{e^\epsilon + k - 1}$ قرار دهیم.

پژوهش آرکولزی و همکاران [۱۵] یک چارچوب نرم‌افزاری را برای حسابرسی و ارزیابی عملی پروتکل‌های حریم خصوصی تفاضلی محلی معرفی می‌کند. در نتیجه آزمایشات این پژوهش، پاسخ تصادفی عمومی بهترین عملکرد را داشته است. به بیان دیگر اتلاف حریم خصوصی که به صورت عملی برای پاسخ تصادفی عمومی اندازه‌گیری شد، بسیار نزدیک به تضمین نظری آن بوده است. یعنی این سازوکار دقیقاً همان سطحی از حریم خصوصی را که ادعا می‌کند، در عمل نیز ارائه می‌دهد و بیش از حد محافظه‌کارانه عمل نمی‌کند. دلیل این امر، سادگی آن و عدم وجود مراحل کدگذاری پیچیده است که باعث از دست رفتن اطلاعات نمی‌شود.

۲-۵-۵ الگوریتم تصادفی‌سازی متقارن

به الگوریتم‌هایی که در فرآیند تصادفی‌سازی برای حفظ حریم خصوصی کاربران، احتمال تغییر داده‌ها برای تمام مقادیر ورودی یکسان باشد، متقارن می‌گوییم. به عنوان مثال در مسائلی که ورودی با دامنه دودویی دارند، احتمال زیر برقرار است:

$$\Pr[y = 1 | x = 1] = \Pr[y = 0 | x = 0] \quad (۲-۹)$$

^۶Generalized Randomized Response

در عبارت بالا، x ورودی و y خروجی الگوریتم است. همچنین احتمال اینکه ورودی ۱ باشد و خروجی ۱ گزارش شود (راستگویی در مورد ۱) برابر است با احتمال اینکه ورودی ۰ باشد و خروجی ۰ گزارش شود (راستگویی در مورد ۰). به عبارت دیگر، سیستم نسبت به ورودی‌های مختلف (۰ یا ۱) رفتار یکسانی دارد و سوگیری^۷ ایجاد نمی‌کند.

۶-۲ ترکیب متوالی

در زمینه حریم خصوصی، ترکیب متوالی^۸ به این صورت تعریف می‌شود که اگر شما چندین سازوکار تصادفی را به‌طور متوالی روی یک مجموعه داده اجرا کنید، حریم خصوصی شما به‌طور کلی نقض می‌شود. حتی اگر هر یک از این سازوکارها جداگانه ایمن باشند، در نهایت نمی‌توانید حریم خصوصی را تضمین کنید [۱۶]. این اصل ساده اما سرنوشت‌ساز، طراحان الگوریتم‌های حریم خصوصی را مجبور می‌کند بودجه حریم خصوصی را میان سازوکارهای مختلف تقسیم کنند. از آنجایی که بودجه حریم خصوصی محدود است، اگر تعداد سازوکارهای مختلف زیاد باشد، بودجه کمی به هر کدام می‌رسد و به سبب آن سودمندی الگوریتم کاهش می‌یابد.

به بیان ریاضی، پس از اجرای k سازوکار مستقل روی یک مجموعه داده که هر کدام $\epsilon-LDP$ هستند، می‌توان گفت الگوریتم کلی ما با بودجه‌ای برابر با مجموع تمام بودجه‌ها، حریم خصوصی تفاضلی را ارضا می‌کند:

$$\mathcal{M}_i(x) \text{ satisfies } \epsilon_i-LDP$$

$$\mathcal{M} = \{\mathcal{M}_1, \mathcal{M}_2, \dots, \mathcal{M}_m\} \text{ satisfies } \sum_{i=1}^m \epsilon_i-LDP$$

در سامانه‌هایی که پرس‌وجوهای^۹ متعدد روی یک معیار داریم (مانند دریافت میزان مصرف باتری هر یک ساعت یکبار)، هر بار باید روی یک داده نوفه اعمال کنیم و به سمت کارپذیر بفرستیم. گرچه مقدار خام داده ممکن است هر بار تغییر کند، ولی چون از یک جنس است و مربوط به یک معیار می‌شود، قانون ترکیب متوالی روی آن صدق می‌کند. بودجه حریم خصوصی بین تعداد استفاده از سازوکار تصادفی‌سازی تقسیم شده و سودمندی کاهش می‌یابد.

شایان ذکر است که در داده‌های با ابعاد بالا نیز، با چالش ترکیب متوالی روبه‌رو هستیم. در داده‌های با

^۷Bias

^۸Sequential Composition

^۹Query

ابعاد بالا، احتمال وجود وابستگی میان ابعاد زیاد می‌شود (مانند ارتباط مستقیم بین سن و میزان درآمد). زمانیکه سازوکارهای تصادفی‌سازی را روی ابعاد وابسته به هم اعمال می‌کنیم، مانند این است که یک فرایند تصادفی‌سازی را چندین بار روی یک مجموعه داده انجام داده و به آن نوبه تزریق کنیم. از این رو شامل قانون ترکیب متوالی شده و بودجه‌ی حریم خصوصی بین سازوکارها تقسیم می‌شود.

۷-۲ ترکیب موازی

در مقابل ترکیب متوالی که در آن چندین سازوکار روی یک مجموعه داده واحد اجرا می‌شوند، ترکیب موازی^{۱۰} زمانی به کار می‌رود که سازوکارهای تصادفی‌سازی روی زیرمجموعه‌های مجزا^{۱۱} از داده‌ها اعمال شوند [۱۷]. در این حالت، بودجه‌ی حریم خصوصی کل سیستم برابر با حداکثر بودجه‌ی الگوریتم‌هاست:

$$\mathcal{M}_i(x) \text{ satisfies } \epsilon_i\text{-LDP}$$

$$\mathcal{M} = \{\mathcal{M}_1, \mathcal{M}_2, \dots, \mathcal{M}_m\} \text{ satisfies } \max\{\epsilon_1, \epsilon_2, \dots, \epsilon_m\}\text{-LDP}$$

۸-۲ روش‌های کدگذاری

هر کاربر به منظور ارسال داده‌ها سمت کارپذیر، باید ابتدا اطلاعات خود را در فرمت خاصی کدگذاری^{۱۲} کند. اینکار به دو دلیل نیاز است:

۱. افزایش سرعت ارسال پیام

۲. بهبود فرایند تصادفی‌سازی

۱-۸-۲ کدگذاری مستقیم

کدگذاری مستقیم^{۱۳} یکی از روش‌های ساده برای کدگذاری مقادیر ورودی در پروتکل‌های حفاظت از حریم خصوصی محلی است. در این روش، داده‌ی هر کاربر بدون هیچ‌گونه تبدیل اولیه مستقیماً به عنوان خروجی

¹⁰Parallel Composition

¹¹Disjoint

¹²Encode

¹³Direct Encoding

کدگذاری شده و ارسال می‌شود. این روش برای مواردی که دامنه داده‌ها کوچک است (مانند داده‌های طبقه‌بندی شده یا مقادیر گسسته محدود) مناسب‌تر خواهد بود. این کدگذاری در پژوهش [۱۸] استفاده شده است.

$$v = \text{Encode}(v) \quad (10-2)$$

برای تصادفی‌سازی در این کدگذاری، باید از سازوکار تصادفی‌سازی عمومی استفاده کرد. دقت کنید که کارایی و عملکرد این روش با افزایش دامنه، به شدت کاهش می‌یابد. از آنجایی که در الگوریتم تصادفی‌سازی عمومی، مقدار p برابر $\frac{e^\epsilon}{e^\epsilon + k - 1}$ است، با افزایش دامنه یا همان k ، احتمال انتخاب شدن مقدار اصلی در تصادفی‌سازی کاهش یافته و به سبب آن، سودمندی دلخواه بدست نمی‌آید. همچنین یکی دیگر از معایب این روش، هزینه ارتباطی^{۱۴} بالا است.

۲-۸-۲ کدگذاری یکانی

کدگذاری یکانی^{۱۵} یکی از روش‌های متداول برای کدگذاری مقادیر ورودی در پروتکل‌های حفاظت از حریم خصوصی تفاضلی محلی است. در این روش، هر مقدار ورودی به یک بردار دودویی با طول ثابت تبدیل می‌شود. تنها یک بیت از این بردار که نماینده ورودی است، مقدار ۱ دارد و بقیه بیت‌ها ۰ هستند.

$$\text{Encode}(v) = [0, \dots, 0, 1, 0, \dots, 0], \quad \text{only the } v\text{-th position is } 1 \quad (11-2)$$

به منظور تصادفی‌سازی از فرمول زیر استفاده می‌کنیم. p احتمال ۱ شدن بیتی است که قبلاً مقدار ۱ داشته است. همچنین q احتمال ۱ شدن بیتی است که قبلاً مقدار ۰ داشته است:

$$\Pr[y = 1] = \begin{cases} p, & \text{if } x = 1, \\ q, & \text{if } x = 0. \end{cases} \quad (12-2)$$

اگر شرط زیر برقرار باشد، می‌توان گفت پروتکل کدگذاری یکانی، حریم خصوصی تفاضلی را ارضا کرده است:

¹⁴Communication Cost

¹⁵Unary Encoding

$$\epsilon = \ln \left(\frac{p(1-q)}{(1-p)q} \right) \quad (۱۳-۲)$$

۳-۸-۲ کدگذاری یکانی متقارن

پروتکل کدگذاری یکانی متقارن^{۱۶} به این صورت تعریف می‌شود که حاصل جمع مقادیر احتمال p و q برابر ۱ باشد:

$$p + q = 1$$

با توجه به قاعده ۲-۱۳، مقادیر p و q به صورت زیر بدست می‌آیند:

$$p = \frac{e^{\epsilon/2}}{e^{\epsilon/2} + 1}, \quad q = \frac{1}{e^{\epsilon/2} + 1}$$

۴-۸-۲ درهم‌سازی محلی

در پروتکل کدگذاری یکانی، هزینه‌ی ارتباطی به صورت خطی با زیاد شدن دامنه‌ی ورودی، افزایش می‌یابد. این افزایش هزینه در بعضی برنامه‌های کاربردی موجب بروز تاخیر بسیار زیاد در عملکرد سامانه می‌شود. بنابراین به پروتکل دیگری نیاز داریم که بزرگ شدن دامنه‌ی ورودی، تاثیر چندانی در هزینه ارتباطی نداشته باشد.

ایده‌ی اولیه این است که از یک تابع درهم‌ساز^{۱۷} استفاده کرده و اندازه دامنه‌ی ورودی را کاهش دهیم. این ایده مشکل تصادم^{۱۸} را به همراه دارد. به بیان دیگر، دو ورودی به یک خروجی تبدیل شده و در زمان کدگذاری^{۱۹} نمی‌توان مقدار درست ورودی را بدست آورد. در پژوهش رپور [۱۹] چندین راه برای حل این مشکل ارائه شده است:

۱. استفاده از چند تابع درهم‌ساز به منظور کاهش احتمال تصادم

۲. استفاده از مفهوم گروه^{۲۰} که در آن هر گروه دارای مجموعه‌ای از توابع درهم‌ساز خواهد بود.

¹⁶Symmetric Unary Encoding

¹⁷Hash Function

¹⁸Collision

¹⁹Decode

²⁰Cohort

البته با توجه به روش‌های مذکور، نمی‌توان به صورت قطعی مشکل تصادم را حل کرد و این مشکل در کاهش سودمندی تأثیر می‌گذارد. روش بهتر این است که هر کاربر توابع درهم‌ساز محلی خود را داشته باشد. به این روش، درهم‌ساز محلی^{۲۱} می‌گوییم. این روش به صورت کارا در الگوریتم‌های حفظ حریم خصوصی تفاضلی محلی استفاده می‌شود. کاربران با کمک توابع درهم‌ساز، ابتدا دامنه‌ی داده‌های خود را کاهش داده، تصادفی‌سازی کرده و در نهایت به سمت کارپذیر ارسال می‌کنند. در ادامه تعریف درهم‌ساز محلی دودویی را ارائه می‌دهیم:

تعریف ۲-۷ (درهم‌ساز محلی دودویی) فرض کنید \mathbb{H} یک خانواده جهانی از توابع درهم‌ساز باشد. هر تابع درهم‌ساز $H \in \mathbb{H}$ ، یک ورودی با دامنه‌ی d را به یک عدد تک بیتی تبدیل می‌کند. شرطی روی این خانواده از توابع درهم‌ساز اعمال می‌شود به صورت زیر خواهد بود:

$$\forall x, y \in [d], x \neq y : \Pr_{H \in \mathbb{H}}[H(x) = H(y)] \leq \frac{1}{\epsilon} \quad (۲-۱۴)$$

به منظور تصادفی‌سازی از فرمول زیر استفاده می‌کنیم:

$$\text{Perturb}_{\text{BLH}}(\langle H, b \rangle) = \langle H, b' \rangle, \quad \Pr[b' = 1] = \begin{cases} p = \frac{e^\epsilon}{e^\epsilon + 1}, & \text{if } b = 1 \\ q = \frac{1}{e^\epsilon + 1}, & \text{if } b = 0 \end{cases}$$

۲-۸-۵ بلوم فیلتر

بلوم فیلتر^{۲۲} یک ساختار داده‌ای است که هدف اصلی آن انجام عملیات بررسی عضویت (یعنی تعیین اینکه یک عنصر در مجموعه‌ای وجود دارد یا خیر) با استفاده حداقلی از حافظه است. این فیلتر به ما کمک می‌کند تا سریعاً امکان وجود یک عنصر را بدون نیاز به ذخیره کل مجموعه در حافظه تشخیص دهیم.

فرض کنید آرایه‌ای از بیت‌ها (معمولاً همه صفر) و چند تابع درهم‌ساز داریم. مطابق شکل ۲-۲ زمان درج هر عنصر جدید، آن را با همه توابع درهم‌سازی کرده و مقدار ۱ برای بیت‌های متناظر در نظر گرفته می‌شود. دقت کنید که ممکن است تصادم داشته باشد و چند بیت ۱ روی هم بیفتند. هنگام پرس‌وجوی عنصر، دوباره باید با همه توابع درهم‌سازی شود و اگر همه بیت‌های متناظر یک باشند، می‌گوییم این عنصر احتمالاً در آرایه وجود دارد. حتی اگر یکی صفر باشد قطعاً عنصر مورد نظر در

²¹Local Hashing

²²Bloom Filter

آرایه وجود ندارد. با تنظیم اندازه آرایه و تعداد توابع هش، می‌توان احتمال خطا را به دلخواه کم کرد. از همین ویژگی در پژوهش رپور نیز بهره گرفته شده تا رشته‌های دلخواه کاربران به صورت فشرده و بی‌نیاز از فهرست پیش‌تعریف‌شده گزارش شود و حریم خصوصی حفظ گردد.

بلوم فیلتر در بسیاری از سیستم‌ها و سرویس‌ها استفاده می‌شود از جمله:

- گوگل کروم: برای ویژگی مرور امن^{۲۳} از بлум فیلتر استفاده می‌شود تا به سرعت خطرناک بودن آدرس‌های اینترنتی را بررسی کند.
- مدیوم^{۲۴}: از بлум فیلتر برای جلوگیری از نمایش پست‌هایی که کاربر قبلاً دیده است، استفاده می‌کند.
- کساندرا^{۲۵} و اچ بیس^{۲۶}: برای بهینه‌سازی جستجوی داده‌ها در جدول‌های ذخیره‌شده در دیسک استفاده می‌شود.
- آکامای^{۲۷}: در سرویس‌های حافظه نهان^{۲۸} خود برای بهبود سرعت و کارایی تحویل محتوا از بлум فیلتر استفاده می‌کند.

²³Safe Browsing

²⁴Medium

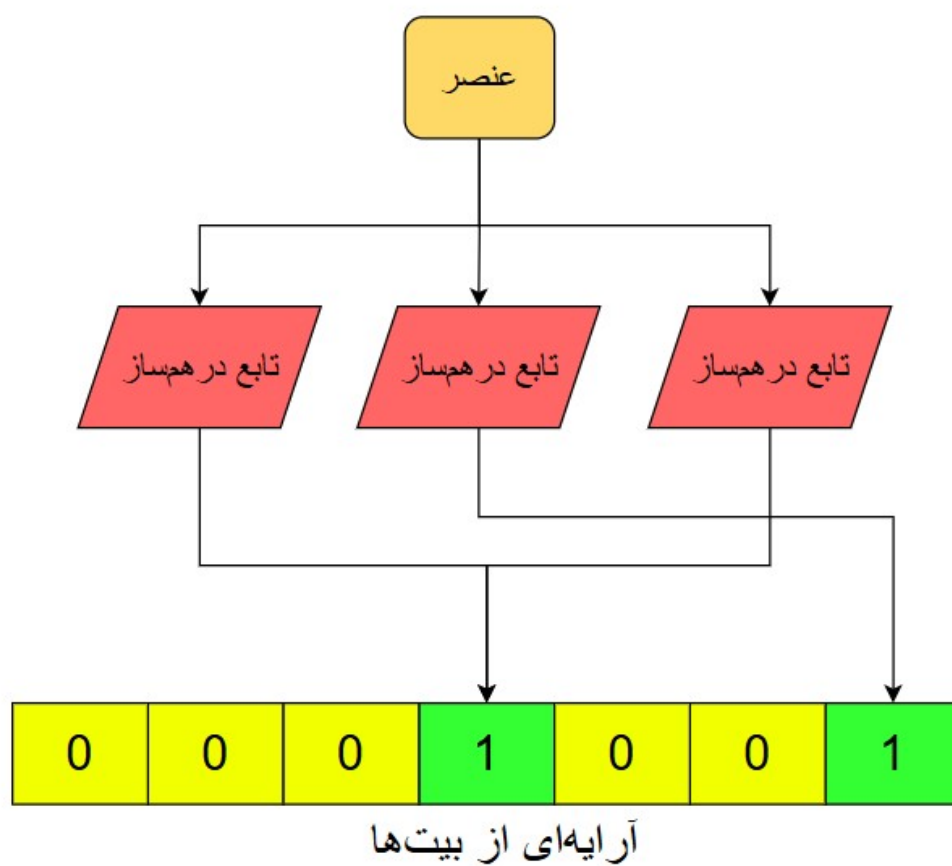
²⁵Cassandra

²⁶HBase

²⁷Akamai

²⁸Cache

حفظ حریم خصوصی تفاضلی محلی هنگام انتشار داده‌های با ابعاد بالا و در حال تغییر



شکل ۲-۲: شیوهی درج عنصر با استفاده از بلوم فیلتر

فصل ۳

کارهای پیشین

در این فصل به بررسی کارها و پژوهش‌های پیشین در دو حوزه داده‌های ابعاد بالا و داده‌های در حال تغییر می‌پردازیم. ابتدا چالش‌های هر کدام را بررسی کرده و راه‌حل‌های موجود را بیان می‌کنیم. همچنین مزایا و معایب هر کدام ارائه می‌شود تا مناسب‌ترین راه‌حل مشخص شود.

۳-۱ داده‌های با ابعاد بالا

هنگام جمع‌آوری داده‌های چندبُعدی با حفظ حریم خصوصی تفاضلی، کارپذیر ابتدا داده‌ی نوفه‌دار شده‌ی هر شخص یا برنامه کاربردی را دریافت کرده و سپس شروع به تحلیل آماری روی هر بعد می‌کند. در اغلب شیوه‌های رایج جمع‌آوری داده‌های چندبُعدی، برای صیانت از حریم خصوصی کاربران، هر ویژگی را جداگانه نوفه‌دار می‌کنند. با توجه به قانون ترکیب متوالی ناچاراً بودجه‌ی محدود حریم خصوصی میان همه ابعاد پخش می‌شود. کاهش بودجه موجب تزریق نوفه بیش از اندازه شده و در نتیجه سودمندی به شکل چشمگیری کاهش می‌یابد.

به بیان دیگر در داده‌های با ابعاد بالا، چالش اصلی به همبستگی‌های احتمالی بین ابعاد مختلف بازمی‌گردد. این همبستگی‌ها باعث می‌شود تغییر در یک بعد به تغییرات در ابعاد دیگر منجر شود و حساسیت کل سیستم افزایش یابد. در اکثر الگوریتم‌های حافظ حریم خصوصی تفاضلی، افزایش حساسیت موجب اضافه‌شدن بیش از اندازه‌ی نوفه به داده‌ها خواهد شد. بنابراین، یافتن رویکردهایی که بتوانند حساسیت را کاهش دهند یا از روش‌های هوشمندانه‌تر برای تخصیص نوفه استفاده کنند، ضروری است.

برای نمونه، سازوکار کلاسیک لاپلاس [۲۰]، نوفه در توزیع لاپلاس را به صورت تصادفی روی تک‌تک

بُدها اعمال می‌کند. در این روش، مقدار نوفه به شکلی بیش از خطی با تعداد ابعاد رشد می‌کند و بدین ترتیب سودمندی داده‌های چندبُعدی به شدت افت خواهد کرد. در ادامه با راه‌حل‌های این چالش بیشتر آشنا می‌شویم.

۳-۱-۱ نمونه برداری

معمولاً مقالاتی که روی داده‌های با ابعاد بالا کار می‌کنند، از نمونه برداری استفاده می‌کنند. در واقع سعی می‌کنند بخشی از داده را به عنوان نماینده‌ی تمام داده‌ها در نظر گرفته و فقط برای آن بخش الگوریتم‌های حفظ حریم خصوصی تفاضلی اعمال شود. با این کار، تنها به بخشی از داده‌ها، نوفه تزریق می‌شود. البته یکی از مشکلات نمونه برداری این است که نیازمند تعداد بسیار زیادی کاربر خواهد بود تا بتوان اطلاعات آماری مفیدی از کل داده‌ها به دست آورد.

۳-۱-۱-۱ پژوهش دوجی و همکاران

سازوکار تکه‌ای^۱ که توسط دوجی ارائه شده است [۲۱]، برای حل مشکل تقسیم بودجه حریم خصوصی، سراغ نمونه‌گیری از داده می‌رود. در این پژوهش داده‌ها به صورت بردار و مختصات در نظر گرفته می‌شوند. در واقع هر رکورد (مثلاً یک کاربر، یک حسگر، یا یک آزمایش) دارای مجموعه‌ای از ویژگی‌ها است و می‌توانیم این ویژگی‌ها را مانند محورهای یک فضای چندبُعدی تصور کنیم. فرض کنید سه ویژگی «سن»، «قد» و «درآمد» داریم؛ آن‌گاه هر فرد نقطه‌ای در فضای سه‌بُعدی است که مختصاتش به ترتیب عدد سن، قد و درآمد اوست. برای نمونه اگر ۱۰۰ خصوصیت زیستی یا آماری داشته باشیم، همان نقطه اکنون در فضایی ۱۰۰ بُعدی قرار می‌گیرد و برداری با ۱۰۰ عدد پی‌درپی تشکیل می‌دهد. بنابراین «بردار» صرفاً لیستی منظم از مقادیر است و «مختصات» خانه‌های این لیست‌اند که به هر ویژگی برجسب می‌زنند.

سازوکار تکه‌ای برای آن‌که بتواند تحلیل‌های آماری روی بردارهای با ابعاد بالا را با حفظ حریم خصوصی محلی انجام دهد، به جای افزودن نوفه مستقل به تک‌تک مختصات (کاری که در ابعاد زیاد دقت را نابود می‌کند)، نوفه به بردارهای «خلاصه» شده وارد می‌شود. به صورت خلاصه، در یک عملیات پیچیده، کاربر با پرتاب سکه، یک نوفه‌ی خاص را روی جهت بردار اعمال می‌کند. به بیان دیگر نوفه فقط به مختصات مؤثر، تزریق می‌شود و اندازه‌ی بردار دستکاری نمی‌گردد.

چندین پژوهش تلاش کردند تا از ویژگی‌های همبسته نمونه برداری کنند. با این کار، بودجه‌ی حریم خصوصی را به شکل هوشمندانه بین ابعاد داده پخش می‌کنند. به منظور یافتن ویژگی‌های همبسته، معمولاً

¹Piecewise

از دو مفهوم آماری اطلاعات متقابل و بی‌نظمی استفاده می‌شود.

اطلاعات متقابل معیاری است که میزان اطلاعاتی را که یک متغیر تصادفی در مورد متغیر دیگر به ما می‌دهد، اندازه‌گیری می‌کند. یعنی اگر یکی را بدانیم، عدم قطعیت ما درباره‌ی دیگری تا چه حد کم می‌شود. هرچه مقدار این معیار بیشتر باشد، وابستگی یا هم‌بستگی میان آن دو متغیر قوی‌تر است.

تعریف ۱-۳ (اطلاعات متقابل) از دید ریاضی، برای دو متغیر تصادفی گسسته‌ی X و Y با توزیع مشترک $p(x, y)$ و توزیع‌های حاشیه‌ای $p(x)$ و $p(y)$ ، اطلاعات متقابل چنین تعریف می‌شود:

$$I(X; Y) = \sum_x \sum_y \hat{P}(x, y) \log \frac{\hat{P}(x, y)}{\hat{P}(x) \hat{P}(y)} \quad (۱-۳)$$

بی‌نظمی^۲، که در فیزیک و نظریه‌ی اطلاعات به نام «آنتروپی» شناخته می‌شود، معیاری برای سنجش پراکندگی حالت‌های یک سامانه است. هرچه تعداد حالت‌های ممکن سازگار با مشاهده ما بیشتر باشد، پیش‌بینی رفتار آینده‌ی سامانه دشوارتر و «بی‌نظمی» آن بالاتر است؛ برعکس، در سامانه‌های منظم، گزینه‌های کمتری برای چگونگی چیدمان اجزا وجود دارد و قطعیت بیشتری داریم. به زبان ساده، آنتروپی اندازه‌ای از بی‌خبری یا عدم قطعیت ما درباره‌ی وضعیت دقیق اجزا است.

۳-۱-۱ پژوهش چن و همکاران

پژوهش چن و همکاران [۲۲] روشی به نام سم‌پرایوسین ارائه می‌دهد که براساس اطلاعات متقابل^۳، ارتباط میان ویژگی‌ها را بدست آورده و تنها از جفت ویژگی‌هایی که بیشترین ارتباط را دارند، نمونه‌برداری می‌کند. این پژوهش به‌جای ارسال کل رکورد و نوفه‌دار کردن همه‌ی ابعاد، تنها یک جفت ویژگی از هر کاربر را انتخاب و پس از نوفه‌دار کردن همان دو مقدار، به کارپذیر می‌فرستد. انتخاب این جفت ویژگی تصادفی نیست؛ احتمال برگزیده‌شدن هر زوج، متناسب با اطلاعات متقابل به‌روزشده‌ی آن‌ها است. زوج‌هایی که بیشترین هم‌بستگی را دارند، با احتمال بیشتری انتخاب شده و ساختار واقعی داده تا حد ممکن حفظ می‌شود. سپس هر یک از دو مقدار انتخاب‌شده با بودجه $\epsilon/2$ نوفه‌دار می‌شود. بدین ترتیب کل فرایند همچنان ϵ -LDP باقی می‌ماند، در حالی که حجم ارتباطی و نوفه تزریق‌شده فقط به همان دو بُعد محدود می‌شود. در ادامه، این داده‌های نمونه‌برداری‌شده برای بازسازی مجموعه داده‌های مصنوعی به کار می‌روند و همچنان ارتباط میان ویژگی‌ها حفظ می‌شود.

²Entropy

³Mutual Information

۳-۱-۱-۳ پژوهش وانگ و همکاران

پژوهشی که توسط وانگ و همکاران [۲۳] انجام شده است، یک الگوریتم حافظ حریم خصوصی تفاضلی برای جمع‌آوری داده‌های عددی ارائه می‌دهد. سپس الگوریتم خود را برای داده‌های چند بُعدی گسترش می‌دهد. این پژوهش ابتدا توضیح می‌دهد که واریانس^۴ کمتر در الگوریتم‌های حریم خصوصی به معنای دقت بیشتر در میانگین نتایج است. سازوکار تکه‌ای [۲۱] واریانس بالایی داشته و دقت نتایج پایین است. برای داده‌های چندبعدی، نویسندگان به دو مشکل اصلی سازوکار تکه‌ای اشاره می‌کنند. اول اینکه این الگوریتم پیچیدگی بالایی دارد و دوم اینکه تنها برای مقادیر عددی قابل استفاده است. به همین دلیل، نویسندگان دو الگوریتم جدید به نام‌های پی-ام و اچ-ام معرفی می‌کنند که با کاهش واریانس، نتایج دقیق‌تری ارائه می‌دهند. سازوکار پی-ام برای هر عدد در بازه‌ی $[-1, 1]$ سه ناحیه تعریف می‌کند: یک قطعه‌ی مرکزی و دو قطعه‌ی کناری در چپ و راست. ابتدا با یک پرتاب تصادفی تصمیم می‌گیرد در کدام ناحیه نمونه بردارد. احتمال افتادن در قطعه‌ی مرکزی عمداً بیشتر است تا خروجی غالباً به مقدار حقیقی نزدیک بماند، ولی اگر به قطعات کناری برود فاصله‌ی بیشتری با مقدار اصلی پیدا می‌کند. این فاصله همان نوفه‌ای است که باعث حفظ حریم خصوصی تفاضلی می‌شود. به این ترتیب داده همچنان در بازه‌ای محدود باقی می‌ماند و با کوچک‌تر شدن مقدار نوفه، واریانس نیز پایین می‌آید، در نتیجه دقت حفظ می‌شود.

سازوکار اچ-ام ترکیبی هوشمندانه از پی-ام و تکه‌ای است. هر بار که می‌خواهد داده را نوفه‌دار کند، سکه‌ای پرتاب می‌شود که با احتمال α شیر می‌آید. اگر شیر آمد، پی-ام اجرا می‌شود؛ اگر خط آمد، همان روش تکه‌ای به کار می‌رود. مقدار α به‌طور تحلیلی طوری انتخاب می‌شود که کل واریانس نوفه را در بدترین حالت کمینه کند. با توجه به پی-ام، برای ϵ بزرگ α تقریباً یک است، و با توجه به روش تکه‌ای، برای ϵ خیلی کوچک α به صفر میل خواهد کرد. بنابراین اچ-ام در همه‌ی شرایط از هر دو رقیب یا بهتر است یا دست‌کم بدتر نمی‌شود.

برای رفع مشکل داده‌های با ابعاد بالا، پژوهش یک الگوریتم جدید پیشنهاد می‌دهد. این الگوریتم بیان می‌کند که نیازی نیست همه ابعاد داده نوفه‌دار شوند. کافیهست تنها به ابعاد محدودی که به صورت تصادفی انتخاب می‌شوند، نوفه اضافه کرد. اگر k بُعد را انتخاب کنیم، باید بودجه‌ی حریم خصوصی ϵ/k را به هر بُعد اختصاص دهیم. چون k معمولاً خیلی کوچک‌تر از تعداد کل ابعاد است، هر ویژگی سهم بودجه‌ی بزرگ‌تری می‌گیرد و نوفه‌ی کمتری به آن تزریق می‌شود. در نتیجه سامانه می‌تواند روی داده‌های با ابعاد بالا تحلیل‌های آماری مثل میانگین یا حتی گرادین‌های یادگیری ماشین را با خطای کمی برآورد کند.

⁴Variance

۳-۱-۱- پژوهش آرکولزی و همکاران

پژوهش [۲۴] نیز از نمونه‌برداری در الگوریتم خود استفاده کرده‌است. این مقاله یک راهکار جدید برای چالش جمع‌آوری داده‌های چندبُعدی و در حال تغییر تحت محدودیت‌های حریم خصوصی تفاضلی محلی ارائه می‌دهد. مشکل اصلی این است که وقتی چندین ویژگی از یک کاربر در بازه‌های زمانی مختلف جمع‌آوری می‌شود، حفظ حریم خصوصی به شدت دشوار شده و سودمندی کاهش می‌یابد. این پژوهش با بهبود پروتکل‌های موجود و ارائه یک الگوریتم جدید به نام الومفری^۵، راهکار جامعی برای تخمین شمارش داده‌ها فراهم می‌کند.

راهکار این پژوهش برای مدیریت داده‌های با ابعاد بالا، بر یک ایده هوشمندانه استوار است. به جای اینکه هر کاربر بخشی از بودجه حریم خصوصی خود را به هر یک از ویژگی‌های اختصاص دهد، به صورت تصادفی تنها یک ویژگی را انتخاب کرده و تمام بودجه حریم خصوصی را به همان یک ویژگی اختصاص می‌دهد. روش الومفری برای حفظ کارایی به صورت تطبیقی و هوشمندانه عمل می‌کند. پس از اینکه کاربر یک ویژگی را به صورت تصادفی انتخاب کرد، روش الومفری بر اساس مشخصات آن ویژگی (به‌ویژه تعداد مقادیر ممکن برای آن) و پارامترهای حریم خصوصی، محاسبه می‌کند که کدام پروتکل از بین پاسخ تصادفی عمومی و کدگذاری یکانی متقارن خطای کمتری خواهد داشت.

در واقع پروتکلی که واریانس کمتری تولید می‌کند، برای ارسال داده انتخاب می‌شود. به عبارت دیگر، الومفری به‌جای استفاده از یک راه‌حل ثابت، بهترین ابزار را برای هر موقعیت خاص انتخاب می‌کند و در نتیجه دقت تخمین شمارش به شدت بهبود می‌یابد. این پژوهش علاوه بر فعالیت در زمینه‌ی داده‌های با ابعاد بالا، در خصوص داده‌های در حال تغییر نیز راه‌حل‌هایی ارائه می‌کند که در بخش‌های بعدی توضیح می‌دهیم.

۳-۱-۱- پژوهش رحمان صیام و همکاران

پژوهش رحمان صیام و همکاران [۲۵] یک راهکار نوآورانه به نام «پاسخ تصادفی همبسته» برای جمع‌آوری و تحلیل داده‌های چندبُعدی با حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد. این پژوهش برای غلبه بر مشکلات داده‌های با ابعاد بالا، یک رویکرد هوشمندانه را معرفی می‌کند که از همبستگی بین داده‌ها به نفع خود استفاده می‌کند. رویکرد معرفی شده شامل مراحل زیر است:

- یادگیری همبستگی‌ها به صورت خصوصی: در این مرحله، گروه کوچکی از کاربران تمام داده‌های خود را با استفاده از یک روش معمول حریم خصوصی تفاضلی محلی (که نوفه‌ی زیادی دارد)

⁵ALLOMFREE

ارسال می‌کنند. هدف این است که کارپذیر مرکزی بتواند الگوها و روابط آماری (همبستگی) بین خصوصیات مختلف را به صورت کاملاً خصوصی و بدون دیدن داده‌های واقعی، تخمین بزند.

- جمع‌آوری داده مبتنی بر همبستگی: اکنون هر کاربر به جای ارسال تمام اطلاعات، به صورت تصادفی فقط یکی از خصوصیات خود را انتخاب می‌کند. سپس تمام بودجه حریم خصوصی را فقط روی همان یک خصوصیت متمرکز کرده و آن را ارسال می‌کند. سایر خصوصیات فرد، به جای ارسال مستقیم، بر اساس همبستگی‌های یادگرفته شده در مرحله اول و مقدار ارسال‌شده‌ی همان یک خصوصیت، به صورت مصنوعی و احتمالی بازسازی می‌شوند.

۳-۱-۶ پژوهش یوان و همکاران

پژوهش یوان و همکاران [۲۶] مانند پژوهش‌های پیشین راهکاری مبتنی بر نمونه‌برداری برای حفظ حریم خصوصی داده‌های چندبُعدی در سیستم‌های محاسباتی توزیع‌شده ارائه می‌دهد. راهکار پیشنهادی به جای اینکه به تمام اجزای داده نوفه اضافه کند، برای هر جزء از داده یک تصمیم احتمالی می‌گیرد:

- با احتمال بالا (مثلاً ۹۹٪)، مقدار اصلی داده را دست‌نخورده و بدون تغییر باقی می‌گذارد.
 - با احتمال پایین (مثلاً ۱٪)، به آن مقدار، نوفه کنترل‌شده (از نوع گوسی یا لاپلاس) اضافه می‌کند.
- این رویکرد باعث می‌شود که مجموع نوفه تزریق‌شده به کل داده به مراتب کمتر از روش‌های سنتی باشد. علاوه بر این، پژوهشگران نسخه‌ای پیشرفته‌تر از الگوریتم خود را نیز معرفی می‌کنند که در آن می‌توان با استفاده از یک «ماتریس وزن»، بخش‌های مهم‌تر یا حساس‌تر داده (مانند چهره افراد در یک تصویر) را شناسایی کرد و سطح بالاتری از حفاظت را برای آن‌ها اعمال نمود؛ در حالی که به بخش‌های کم‌اهمیت‌تر (مانند پس‌زمینه تصویر) نوفه‌ی کمتری اضافه می‌شود.

۳-۱-۲ خوشه‌بندی

یک راه‌حل اساسی برای اختصاص هدفمند بودجه‌ی حریم خصوصی به ابعاد داده، خوشه‌بندی^۶ است. معمولاً ابعاد همبسته در یک دسته قرار می‌گیرند. با توجه به اینکه درون هر دسته چند ویژگی قرار می‌گیرد، می‌توان بودجه‌ی حریم خصوصی را به شکل بهتری تقسیم کرد. به بیان دیگر، باید به خوشه‌ای که اعضای بیشتری دارد، بودجه‌ی بیشتری نیز تخصیص داد. زیرا بر اساس قانون ترکیب متوالی، بودجه‌ی هر دسته بین اعضای آن دسته تقسیم می‌شود و ممکن است بودجه‌ی بسیار کمی به یکی از ویژگی‌ها برسد.

^۶Clustering

در بدترین حالت تمام ابعاد داده‌ی یک سامانه یا برنامه کاربردی داخل یک دسته قرار می‌گیرند. در این حالت بودجه‌ی حریم خصوصی ما باید بین تمام ویژگی‌ها تقسیم شود و در نتیجه بودجه‌ی بسیار کمی به هر ویژگی می‌رسد. از آنجایی که این بودجه‌ی کلی محدود است، سودمندی داده‌ها به شدت افت خواهد کرد. پیش‌نیاز دسته‌بندی مناسب، پیدا کردن ابعاد همبسته یا تقریباً همبسته است. پژوهش‌های مختلف روش‌های متنوعی برای پیدا کردن ابعاد وابسته به هم، ارائه کرده‌اند. از جمله این روش‌ها می‌توان به اندازه‌گیری اطلاعات متقابل، بی‌نظمی و یادگیری ماشین اشاره کرد.

۳-۱-۲-۱ پژوهش رن و همکاران

پژوهش [۱] جزو اصلی‌ترین پژوهش‌های مربوط به حوزه‌ی حفظ حریم خصوصی تفاضلی در داده‌های با ابعاد بالا است. این پژوهش راهکاری به اسم **لوپاب^۷** ارائه می‌دهد که دارای چهار گام اصلی است. در گام اول داده‌ها به صورت محلی نوفه‌دار شده و حفاظت از حریم خصوصی در مبدأ انجام می‌شود. این گام اولین و حیاتی‌ترین مرحله برای تضمین حریم خصوصی تفاضلی محلی است. هر کاربر قبل از ارسال داده‌های خود به کاربرپذیر، دو کار روی آن انجام می‌دهد:

۱. استفاده از بلوم فیلتر و تبدیل ویژگی‌های کاربر به رشته‌ای از بیت‌ها: این کار داده‌ها را به یک فرمت استاندارد و قابل پردازش تبدیل می‌کند.

۲. آشفته‌سازی داده‌ها با کمک سازوکار پاسخ تصادفی: پس از ایجاد رشته بیت، هر بیت با یک احتمال مشخص به صورت تصادفی تغییر می‌کند.

در نهایت، کاربر این رشته بیت‌های نوفه‌دار شده و بی‌معنی را به کاربرپذیر ارسال می‌کند و داده‌های اصلی هرگز از دستگاه کاربر خارج نمی‌شوند.

در گام دوم تخمین احتمال توزیع داده‌های چند بُعدی انجام می‌گیرد. اکنون کاربرپذیر مجموعه‌ای عظیم از رشته بیت‌های نوفه‌دار شده را در اختیار دارد. چالش این است که چگونه از این داده‌های آشفته، الگوهای آماری و احتمال توزیع مشترک داده‌های اصلی را بازسازی کند. مقاله سه الگوریتم برای این کار پیشنهاد می‌کند:

۱. الگوریتم مبتنی بر حداکثر تابع درست‌نمایی^۸ (به اختصار، ای.ام): روشی دقیق اما از نظر محاسباتی بسیار سنگین و کند است و برای داده‌های با ابعاد بالا عملی نیست.

^۷LoPub

^۸Expectation Maximization

۲. الگوریتم مبتنی بر رگرسیون لاسو^۹: روشی بسیار سریع‌تر و کارآمدتر که به خصوص برای داده‌های پراکنده مناسب است. این روش با تخمین تعداد واقعی شمارش‌ها از روی شمارش‌های نوفه‌دار شده کار می‌کند.

۳. الگوریتم ترکیبی^{۱۰}: این الگوریتم بهترین ویژگی‌های دو روش قبل را ترکیب می‌کند. ابتدا با استفاده از روش سریع لاسو یک تخمین اولیه و خوب از توزیع داده‌ها به دست می‌آورد و ترکیبات داده‌ای پرتکرار را شناسایی می‌کند. سپس با استفاده از روش دقیق ای.ام این تخمین اولیه را روی داده‌های فیلتر شده پالایش می‌کند. این رویکرد تعادلی مناسب بین سرعت و دقت برقرار می‌کند.

در گام سوم کاهش ابعاد^{۱۱} صورت می‌گیرد. پردازش همزمان تمام ویژگی‌ها در داده‌های با ابعاد بالا بسیار دشوار است. هدف در این مرحله، شناسایی و گروه‌بندی ویژگی‌های مرتبط با یکدیگر است تا بتوان آن‌ها را در دسته‌های کوچکتر پردازش کرد. با استفاده از توزیع‌های تخمین‌زده شده در گام قبل، میزان وابستگی از فرمول اطلاعات متقابل^{۱۲-۳} محاسبه می‌شود. به منظور کاهش ابعاد، درخت اتصال^{۱۲} در چهار مرحله ساخته می‌شود:

۱. ابتدا یک گراف همبستگی ساخته شده که در آن گره‌ها، همان ویژگی‌ها هستند. همچنین یال‌ها نمایانگر وجود وابستگی قوی بین دو ویژگی هستند. به بیان دیگر اگر میزان اطلاعات متقابل بین دو ویژگی از یک آستانه مشخص بیشتر باشد، یک یال بین آن‌ها کشیده می‌شود.

۲. در گراف وابستگی ممکن است دوره‌های طولانی وجود داشته باشد. یک دور، مسیری است که از یک گره شروع شده و دوباره به همان گره برمی‌گردد. وجود چنین دوره‌هایی، تجزیه گراف به بخش‌های مستقل را بسیار دشوار می‌کند. به همین دلیل، مثلث‌سازی^{۱۳} صورت می‌گیرد تا تمام این دوره‌های طولانی را از بین ببریم. در مثلث‌سازی، با رویکرد الگوریتمی یال‌هایی به گراف اضافه می‌شود. با اضافه کردن این یال‌ها، هر دور طولانی به مجموعه‌ای از مثلث‌ها شکسته می‌شود.

۳. در مرحله سوم «خوشه‌های بیشینه^{۱۴}» شناسایی می‌شوند. به زیرمجموعه‌ای از گره‌های گراف که در آن هر گره به تمام گره‌های دیگر آن زیرمجموعه متصل است، خوشه می‌گویند. به خوشه‌ای که بتوان با اضافه کردن گره دیگری آن را بزرگتر کرد، خوشه‌ی بیشینه می‌گویند. این خوشه‌ها بزرگترین گروه‌های کاملاً همبسته در شبکه ما هستند.

⁹Lasso Regression

¹⁰Hybrid

¹¹Dimensionality Reduction

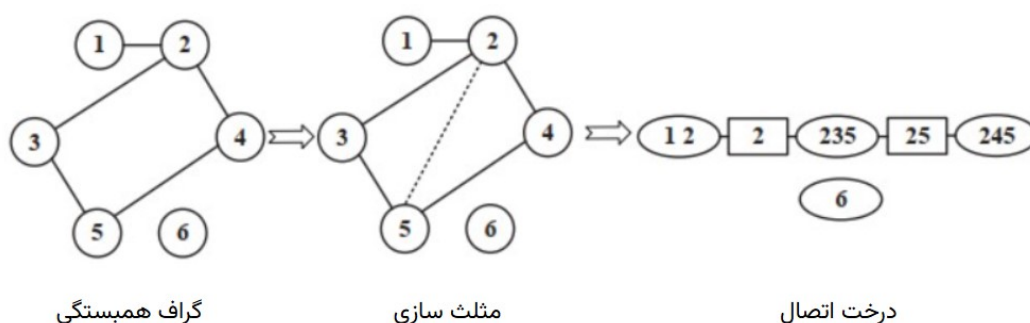
¹²Junction Tree

¹³Triangulation

¹⁴Maximal Clique

۴. اکنون که خوشه‌های بیشینه را داریم، باید آن‌ها را به هم وصل کنیم تا درخت اتصال ساخته شود. بین هر دو خوشه‌ی بیشینه که گره‌های مشترکی دارند، یک یال می‌کشیم. وزن این یال برابر با تعداد گره‌های مشترک بین آن دو خوشه است. گراف حاصل، هنوز یک درخت کامل نیست و ممکن است دور داشته باشد. برای تبدیل آن به درخت، از الگوریتم درخت پوشای بیشینه^{۱۵} استفاده می‌کنیم. این الگوریتم به ما تضمین می‌دهد که مجموع وزن یال‌ها بیشینه باشد و همچنین هیچ دوری در گراف نهایی وجود نداشته باشد.

در شکل ۱-۳ یک مثال از ساخت درخت اتصال را مشاهده می‌کنید. این ساختار درختی تضمین می‌کند که ویژگی «تقاطع جاری»^{۱۶} برقرار باشد. یعنی اگر یک ویژگی در دو خوشه مختلف در درخت وجود داشته باشد، حتماً در تمام خوشه‌هایی که در مسیر بین آن دو قرار دارند نیز وجود دارد. این ویژگی برای انجام محاسبات احتمالی به صورت بهینه و دقیق حیاتی است. به این ترتیب، یک شبکه پیچیده از وابستگی‌ها به یک ساختار درختی منظم تبدیل می‌شود که می‌توان محاسبات را به صورت محلی روی هر خوشه انجام داد و نتایج را در طول درخت منتشر کرد.



شکل ۱-۳: ساخت درخت اتصال از گراف همبستگی [۱]

در گام چهارم مجموعه داده مصنوعی تولید می‌شود. هدف انتشار یک مجموعه داده کاملاً جدید و مصنوعی است که از نظر آماری شبیه به داده‌های اصلی باشد اما حاوی اطلاعات هیچ کاربر واقعی نباشد. کارپذیر با استفاده از توزیع احتمال مشترکی که برای هر خوشه در گام‌های قبل محاسبه کرده، شروع به تولید رکوردهای جدید و مصنوعی می‌کند. این رکوردهای مصنوعی برای هر خوشه با هم ترکیب شده و رکوردهای کامل با ابعاد بالا را می‌سازند.

خروجی نهایی، یک مجموعه داده مصنوعی است که می‌توان آن را با خیال راحت برای تحلیل و داده‌کاوی منتشر کرد، زیرا ضمن حفظ الگوهای کلی داده‌های اصلی، حریم خصوصی تک‌تک مشارکت‌کنندگان را به طور کامل حفظ کرده است. به طور خلاصه، لوپاب به کاربران اجازه می‌دهد در پروژه‌های جمع‌سپاری داده

¹⁵Maximum Spanning Tree

¹⁶Running Intersection Property

با ابعاد بالا شرکت کنند، بدون آنکه نگران افشای اطلاعات شخصی خود، حتی به کارپذیر جمع‌آوری‌کننده، باشند.

۳-۱-۲-۲ پژوهش ماتاموروس و همکاران

پژوهش ماتاموروس و همکاران [۲۷] راهکار خود را در حوزه حریم خصوصی تفاضلی محلی برای حفاظت از داده‌های حساس، به ویژه در بخش مراقبت‌های بهداشتی، ارائه می‌دهد. مشکل داده‌های با ابعاد بالا به خصوص در داده‌های حوزه سلامت که ویژگی‌های متعددی با همبستگی بالا دارند (مانند سوابق پزشکی و نتایج آزمایش‌ها)، بسیار مشهود است. محققان برای غلبه بر این چالش‌ها، استفاده از «رگرسیون بیزی خطی^{۱۷}» را به جای روش‌های متداول پیشنهاد می‌کنند. راهکارهای قبلی مانند لوپاب از رگرسیون لاسو استفاده می‌کردند که در مواجهه با داده‌های با ابعاد بالا و همبستگی زیاد، کارایی خود را از دست می‌دهند. محققان این پژوهش نشان می‌دهند که در مقابله با همبستگی بالا، استفاده از رگرسیون بیزی خطی عملکرد بهتری داشته و با مصرف کمتر بودجه‌ی حریم خصوصی سودمندی بهتری کسب می‌شود.

۳-۱-۲-۳ پژوهش ژانگ و همکاران

پژوهش ژانگ و همکاران [۲] روشی به اسم پرایوپی جی^{۱۸} ارائه می‌دهد که برای حفظ حریم خصوصی در هنگام انتشار داده‌های با ابعاد بالا کاربرد دارد. این روش به گونه‌ای طراحی شده است که ضمن محافظت از اطلاعات خصوصی کاربران، داده‌های مصنوعی تولید کند که از نظر آماری شباهت زیادی به داده‌های واقعی داشته باشند. روش پرایوپی جی برای غلبه بر مشکلات داده‌های با ابعاد بالا در یک فرایند سه مرحله‌ای طراحی شده است.

مرحله‌ی اول مانند روش لوپاب، شامل آشفته‌سازی داده‌ها به صورت محلی می‌باشد. البته به جای ارسال تمام اطلاعات یک کاربر، به صورت تصادفی فقط یکی از ویژگی‌ها را انتخاب می‌کند. سپس اطلاعات این ویژگی انتخاب شده با استفاده از یک تکنیک پاسخ تصادفی نوفه‌دار می‌شود. این کار تضمین می‌کند که کارپذیر هرگز مقدار واقعی را به طور قطعی دریافت نمی‌کند. در نتیجه هر کاربر فقط یک گزارش کوچک و نوفه‌دار شده به کارپذیر ارسال می‌کند. این کار هم هزینه ارتباطی را کاهش می‌دهد و هم حریم خصوصی تفاضلی محلی را تضمین می‌کند.

در مرحله دوم تخمینی از توزیع مشترک داده‌ها تهیه می‌گردد. پس از اینکه کارپذیر گزارش‌های نوفه‌دار

¹⁷Bayesian Ridge Regression

¹⁸PrivPJ

شده را از تمام کاربران دریافت کرد، از الگوریتم جدیدی به نام خودکدگذار چند متغیره^{۱۹} (به اختصار ام.وی.ای.ای^{۲۰}) به منظور تخمین توزیع مشترک داده‌ها استفاده می‌کند. این الگوریتم یک مدل یادگیری عمیق است که می‌تواند توزیع احتمال مشترک بین تمام ویژگی‌ها را تخمین بزند. به بیان دیگر با تحلیل داده‌های آشفته شده، الگوها و همبستگی‌های بین ویژگی‌های مختلف را یاد می‌گیرد. این کار با به حداقل رساندن خطا بین توزیع حاشیه‌ای و توزیع مشترک انجام می‌شود و به طور موثر اثر نوفه را کاهش می‌دهد. در مرحله سوم کاهش ابعاد و تولید داده مصنوعی صورت می‌گیرد. اکنون که کارپذیر مدل آماری داده‌ها را در اختیار دارد، باید از آن برای تولید یک مجموعه داده مصنوعی جدید استفاده کند. از آنجایی که کار با توزیع کامل داده‌های با ابعاد بالا همچنان پیچیده است، پرایوپی جی از شبکه مارکوف^{۲۱} برای ساده‌سازی این فرآیند استفاده می‌کند.

ساخت شبکه مارکوف به این صورت است که ابتدا، کارپذیر با استفاده از اطلاعات همبستگی که در مرحله قبل به دست آورده، یک شبکه مارکوف می‌سازد. در این شبکه، هر ویژگی یک گره است و بین ویژگی‌هایی که همبستگی بالایی دارند، یک یال کشیده می‌شود. در قدم بعدی، شبکه مارکوف به ساختاری ساده‌تر به نام درخت اتصال تبدیل می‌شود. فرایند ساخت درخت اتصال مانند روش لوپاب است. شکل ۲-۳ یک مثال از شبکه مارکوف و ساخت درخت اتصال را نمایش می‌دهد. این درخت، ویژگی‌ها را در خوشه‌هایی که همبستگی بالایی با هم دارند گروه‌بندی می‌کند. این کار به طور موثری ابعاد داده را کاهش می‌دهد. در نهایت، سرور از این درخت اتصال برای تولید داده‌های مصنوعی جدید استفاده می‌کند. این فرآیند با نمونه‌برداری از خوشه‌ها، روابط آماری پیچیده در داده‌های اصلی را بازسازی می‌کند.

نتیجه نهایی یک مجموعه داده با ابعاد بالا است که از نظر آماری بسیار شبیه به داده‌های اصلی است، اما چون از ابتدا بر پایه گزارش‌های آشفته شده ساخته شده، حریم خصوصی هیچ‌یک از کاربران را نقض نمی‌کند.

۳-۱-۲-۴ پژوهش جیانگ و همکاران

پژوهش جیانگ و همکاران [۳]، راهکاری نوآورانه به نام دی.پی.تو.پاب^{۲۲} به منظور حل چالش داده‌های با ابعاد بالا ارائه می‌دهد. هدف اصلی، به اشتراک گذاشتن این داده‌ها برای تحلیل و یادگیری ماشین است، بدون آنکه حریم خصوصی افراد در معرض خطر قرار گیرد. این راهکار در دو فاز اصلی و برای دو حالت متفاوت یعنی کارپذیر قابل اعتماد و کارپذیر نیمه‌صادق انجام می‌شود.

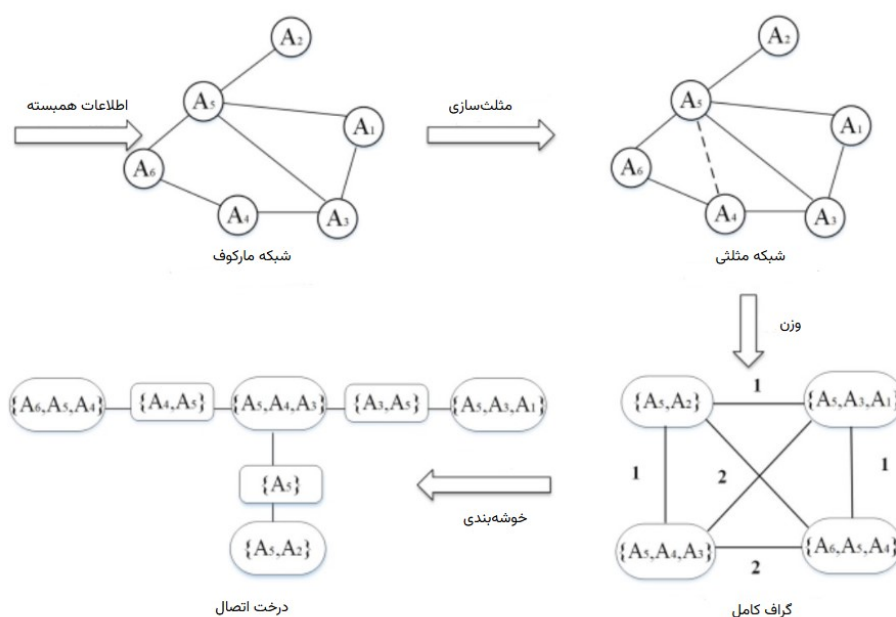
¹⁹Multivariate Variational Autoencoder

²⁰mVAE

²¹Markov Network

²²DP2-Pub

حفظ حریم خصوصی تفاضلی محلی هنگام انتشار داده‌های با ابعاد بالا و در حال تغییر



شکل ۳-۲: استفاده از شبکه مارکوف در ساخت درخت اتصال [۲]

در فاز اول خوشه‌بندی صفات انجام می‌شود. به جای کار با تمام ابعاد به صورت یکجا، ابتدا صفات مرتبط به هم را در گروه‌های کوچک‌تر و کم‌تعدادتر خوشه‌بندی می‌کند. در فاز دوم روی داده‌های هر خوشه، فرآیند افزودن نویز را برای تضمین حریم خصوصی اجرا می‌کند.

این فرآیند در دو مدل امنیتی مختلف ارائه می‌شود:

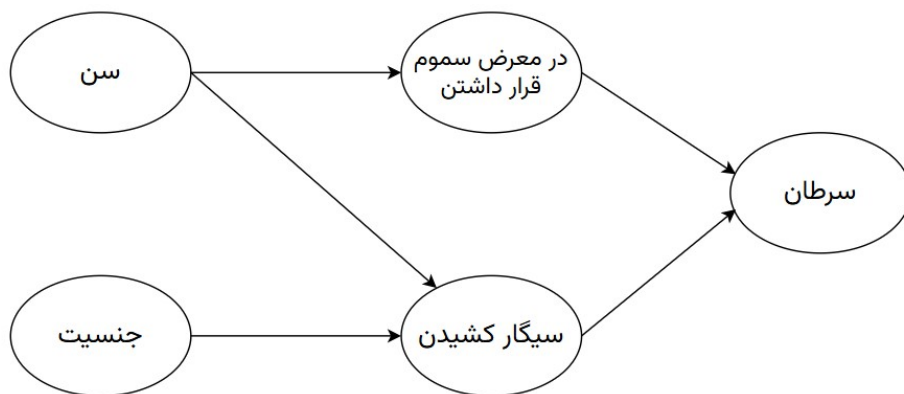
۱. **کارپذیر قابل اعتماد:** در این مدل، فرض بر این است که یک کارپذیر مرکزی به داده‌های اصلی دسترسی دارد و تمام عملیات حفظ حریم خصوصی روی آن انجام می‌شود. به منظور خوشه‌بندی صفات از شبکه بیزی^{۲۳} استفاده می‌شود. الگوریتم با استفاده از روش حریم خصوصی تفاضلی، یک شبکه بیزی از روی داده‌ها می‌سازد. این شبکه وابستگی‌ها و روابط شرطی بین تمام صفات را مدل می‌کند. به عنوان مثال در شکل ۳-۳ یک شبکه‌ی بیزی از پنج ویژگی ساخته می‌شود.

پس از ساخت شبکه، برای هر صفت، «پوشش مارکوف^{۲۴}» آن شناسایی می‌شود. پوشش مارکوف یک صفت، مجموعه‌ای حداقلی از صفات همسایه آن است که تمام اطلاعات لازم برای پیش‌بینی آن صفت را در خود دارد [۲۸]. الگوریتم با گروه‌بندی هر ویژگی به کمک پوشش مارکوف، داده‌های با ابعاد بالا را به چندین خوشه کم‌بعد و مستقل از هم تقسیم می‌کند.

تعریف ۳-۲ (پوشش مارکوف) در یک شبکه بیزی، پوشش مارکوف برای یک گره x ، مجموعه‌ای

²³Bayesian Network

²⁴Markov Blanket



شکل ۳-۳: ساخت شبکه بیزی از پنج ویژگی [۲]

از گره‌هاست که از نظر احتمالی، x را از بقیه شبکه محافظت یا جدا می‌کنند. به این معنا که اگر مقادیر گره‌های موجود در پوشش مارکوف را بدانیم، گره x از تمام گره‌های دیگر شبکه مستقل می‌شود.

$$MB(x) = Pa(x) \cup Ch(x) \cup \{Pa(y) | y \in Ch(x)\} \quad (۲-۳)$$

در عبارت بالا:

- $MB(x)$: پوشش مارکوف گره x .
- $Pa(x)$: مجموعه گره‌های والد گره x .
- $Ch(x)$: مجموعه گره‌های فرزند گره x .

پس از خوشه‌بندی، باید روی داده‌ها آشفته‌سازی انجام شود. البته لازم است که کمترین آسیب به اطلاعات آماری کلان وارد شود. پژوهش الگوریتمی نوآورانه به نام پی.آر.ای.ام.^{۲۵} ارائه می‌کند. در این روش، مقادیر داده‌ها با یک احتمال مشخص به مقادیر دیگر تغییر می‌کنند. نکته‌ی مهم این است که الگوریتم پی.آر.ای.ام. تضمین می‌کند که توزیع آماری کلی داده‌ها پس از افزودن نوفه، بدون تغییر باقی بماند. این کار باعث حفظ حداکثری کارایی داده می‌شود. به طور دقیق‌تر، ابتدا یک بار داده‌ها را با نوفه استاندارد آشفته می‌کند. سپس، با تخمین توزیع اصلی از روی داده‌های نوفه‌دار شده، یک آشفته‌گی دوم و معکوس اعمال می‌کند تا اثرات منفی نوفه بر توزیع کلی را خنثی کند.

²⁵PRAM

۲. کارپذیر نیمه‌صادق: در این مدل، کاربران به کارپذیر اعتماد ندارند و می‌خواهند داده‌هایشان قبل از ارسال به کارپذیر، تصادفی‌سازی شود. هر کاربر ابتدا روی داده‌های خود یک فرآیند تصادفی‌سازی اعمال می‌کند تا داده‌هایش به صورت محلی آشفته شوند. سپس این داده‌های نوفه‌دار شده را به کارپذیر ارسال می‌کند. کارپذیر داده‌ها را از تمام کاربران جمع‌آوری کرده و سپس همان فرآیند دو فازی یعنی خوشه‌بندی و پی.آر.ای.ام را روی این داده‌ها اجرا می‌کند تا همبستگی‌ها را بازسازی کرده و کارایی نهایی داده‌ها را بهبود بخشد.

۳-۱-۲-۵ پژوهش دیو و همکاران

پژوهش دیو و همکاران [۲۹] الگوریتمی ارائه می‌دهد که هم حریم خصوصی کاربران حفظ شود و هم داده‌های جمع‌آوری شده کیفیت و کارایی بالایی داشته باشند. روش‌های قدیمی فرض می‌کنند که تمام ویژگی‌های داده کاملاً به هم مرتبط هستند (بدترین حالت ممکن)، در حالی که در دنیای واقعی اینطور نیست. برای مثال، دمای یک اتاق و میزان روشنایی آن ممکن است همبستگی داشته باشند، اما این همبستگی کامل و صددرصدی نیست. این پژوهش نشان می‌دهد که اگر بتوانیم میزان همبستگی بین ویژگی‌های مختلف را اندازه‌گیری کنیم، می‌توانیم نوفه را به شکل هوشمندانه‌تر و بهینه‌تری توزیع کرده و کیفیت نهایی داده‌ها را به شدت افزایش دهیم. یک پروتکل جدید به نام آشفته‌گی محدود به همبستگی^{۲۶} (به اختصار، سی.بی.پی^{۲۷}) معرفی می‌گردد. این پروتکل بر اساس یک مدل حریم خصوصی جدید و منعطف‌تر به نام حریم خصوصی تفاضلی محلی با تسلط تک‌متغیره^{۲۸} کار می‌کند.

این مدل یک نسخه انعطاف‌پذیرتر از حریم خصوصی تفاضلی محلی است که به طور خاص برای یک ویژگی واحد در داده‌های با ابعاد بالا طراحی شده است. به زبان ساده، این مدل تضمین می‌کند که اگر مقدار واقعی یک ویژگی را تغییر دهیم، احتمال اینکه الگوریتم یک خروجی نوفه‌دار شده‌ی مشخص تولید کند، تفاوت چندانی نخواهد کرد. این عدم قطعیت باعث می‌شود که یک مهاجم با دیدن خروجی، نتواند با اطمینان بگوید که مقدار اصلی چه بوده است.

تعریف ۳-۳ (حریم خصوصی تفاضلی محلی با تسلط تک‌متغیره) برای هر ویژگی دلخواه x و برای هر دو ورودی ممکن s و s' ، سازوکار M ، شرایط حریم خصوصی تفاضلی محلی با تسلط تک‌متغیره را برآورده می‌کند، اگر برای هر خروجی ممکن Y از دامنه سازوکار M ، شرط زیر برقرار باشد:

²⁶ Correlation-Bounded Perturbation

²⁷ CBP

²⁸ Univariate Dominance LDP

$$e^{-\epsilon} \leq \frac{P[\mathcal{M}(x=s)=Y]}{P[\mathcal{M}(x=s')=Y]} \leq e^{\epsilon} \quad (3-3)$$

کارپذیر با استفاده از داده‌های تاریخی یا دانش قبلی، ویژگی‌هایی را که به هم مرتبط هستند، شناسایی و دسته‌بندی می‌کند. سپس به جای تقسیم مساوی بودجه حریم خصوصی، پروتکل سی.بی.پی این بودجه را به صورت هوشمندانه بر اساس میزان همبستگی بین ویژگی‌ها تخصیص می‌دهد. ویژگی‌هایی که همبستگی بیشتری دارند، می‌توانند به شکل مؤثرتری بودجه حریم خصوصی را به اشتراک بگذارند.

در بسیاری از کاربردهای اینترنت اشیاء، پهنای باند یک محدودیت جدی است و نمی‌توان همیشه تمام داده‌ها را ارسال کرد. برای حل این مشکل، مقاله پروتکل سی.بی.پی را گسترش داده و از نمونه‌برداری نیز استفاده می‌کند. به این صورت که نه تنها بودجه حریم خصوصی را بهینه تخصیص می‌دهد، بلکه احتمال نمونه‌برداری از هر ویژگی را نیز بر اساس میزان اهمیت و همبستگی آن تعیین می‌کند. این کار باعث می‌شود که حتی با ارسال تعداد محدودی از ویژگی‌ها، بیشترین اطلاعات ممکن با حفظ حریم خصوصی استخراج شود.

از مشکلات این پژوهش می‌توان به این نکته اشاره کرد که وجود داده‌های تاریخی یا دانش قبلی همیشه میسر نخواهد بود. اگر این دانش را نداشته باشیم، نمی‌توانیم میزان همبستگی بین ابعاد داده را محاسبه کنیم و در نتیجه خوشه‌بندی مناسبی نخواهیم داشت.

۳-۱-۲-۶ پژوهش گوهوا شین و همکاران

پژوهش گوهوا شین و همکاران [۳۰] نیز مانند پژوهش‌های پیشین راهکاری مبتنی بر خوشه‌بندی برای انتشار داده‌های چندبُعدی ارائه می‌دهد که حریم خصوصی افراد را با استفاده از روش حریم خصوصی تفاضلی محلی حفظ می‌کند. ایده اصلی این راهکار بر دو بخش استوار است.

ابتدا محاسبه‌ی توزیع حاشیه‌ای انجام می‌شود. به جای تقسیم بودجه حریم خصوصی که باعث کاهش دقت می‌شود، این روش از تکنیک‌های مبتنی بر نمونه‌گیری برای افزودن نوفه به داده‌های کاربران استفاده می‌کند. سپس به صورت هوشمند و انطباقی، توزیع حاشیه‌ای از ویژگی‌های داده را محاسبه می‌کند. این کار به کارپذیر اجازه می‌دهد تا الگوهای آماری مهم را با دقت بیشتری تخمین بزند.

سپس ویژگی‌ها به صورت مؤثر خوشه‌بندی می‌شوند. این راهکار با یک روش کارآمد، میزان ارتباط و وابستگی بین ویژگی‌های مختلف داده را اندازه‌گیری می‌کند. سپس ویژگی‌های مرتبط را در خوشه‌هایی دسته‌بندی کرده و با استفاده از شبکه مارکوف، این ارتباطات را مدل‌سازی می‌نماید. در نهایت، کارپذیر

مرکزی با استفاده از توزیع‌های آماری و خوشه‌های به‌دست‌آمده، یک مجموعه داده مصنوعی تولید می‌کند.

۷-۲-۱-۳ پژوهش کیکوچی و همکاران

پژوهش کیکوچی و همکاران [۳۱] نیز از خوشه‌بندی استفاده کرده تا چالش موجود در داده‌های با ابعاد بالا را حل کند. ابتدا به جای تحلیل تمام ابعاد داده به صورت یکجا، ویژگی‌های مرتبط و وابسته به یکدیگر را در خوشه‌های کوچکتر دسته‌بندی می‌کند. وابستگی میان صفات بدون افشای مقادیر اصلی و خصوصی داده‌ها تخمین زده می‌شود. در نهایت نوفه بر اساس خوشه‌ها تزریق می‌شود.

۸-۲-۱-۳ پژوهش سانگ و همکاران

پژوهش سانگ و همکاران [۳۲] راهکار خود را برای جمع‌آوری داده‌های چندبُعدی به این صورت بیان می‌کند که ابتدا خوشه‌بندی انجام شود و سپس مقدار نوفه بر اساس این خوشه‌بندی بهینه شود. این تحقیق در ابتدا سازوکارهای جدیدی برای جمع‌آوری داده‌های عددی ارائه می‌دهد که دقت بالاتری نسبت به راهکارهای موجود دارند و واریانس نوفه در آن‌ها کمتر است. سپس، این سازوکارها برای داده‌های چندبُعدی که شامل هر دو نوع داده‌های عددی و غیر عددی هستند، گسترش داده می‌شوند.

۳-۱-۳ کاهش ابعاد

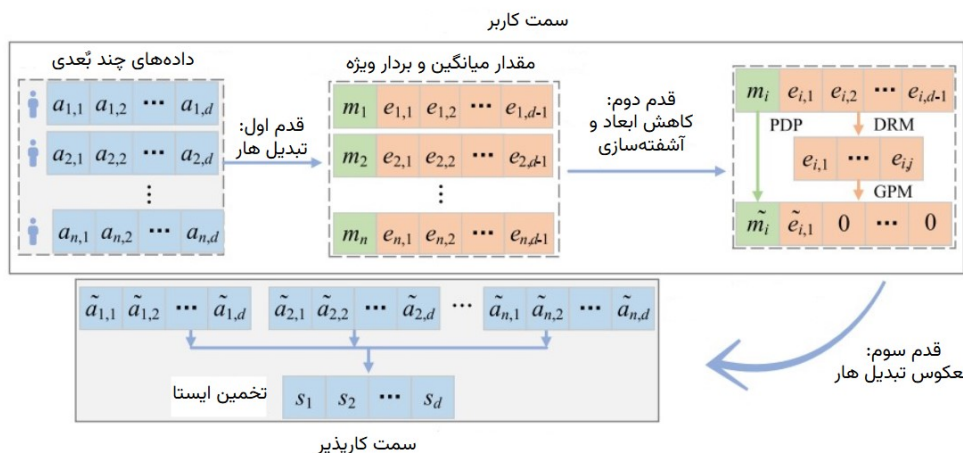
در بعضی از پژوهش‌هایی که قبل‌تر ذکر کردیم نیز کاهش ابعاد صورت می‌گرفت. برای مثال، خوشه‌بندی موجب کاهش ابعاد داده می‌شود. پژوهش‌هایی هم وجود دارند که خوشه‌بندی انجام نداده‌اند ولی به نوعی ابعاد داده را کاهش داده‌اند تا بودجه‌ی حریم خصوصی به صورت مناسب پخش شود.

۱-۳-۱-۳ پژوهش دونگیو ژانگ و همکاران

پژوهش دونگیو ژانگ و همکاران [۴] یک راهکار نوآورانه به نام پی.پی.ام.سی^{۲۹} برای جمع‌آوری داده‌های چندبُعدی با حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد. پژوهش برای غلبه بر این چالش داده‌های با ابعاد بالا، یک فرآیند هوشمندانه سه مرحله‌ای را با استفاده از تبدیل هار^{۳۰} پیشنهاد می‌کند. شکل ۳-۴ این سه مرحله را به خوبی نمایش می‌دهد. ایده اصلی این است که به جای افزودن نوفه به تک‌تک ابعاد داده‌ی اصلی، ابتدا ساختار داده را تغییر داده، ابعاد آن را کاهش دهیم و سپس به داده‌ی تبدیل‌شده نوفه اضافه کنیم.

²⁹PPMC

³⁰Haar Transform



شکل ۳-۴: ساختار روش پی.پی.ام.سی [۴]

تبدیل هار یکی از قدیمی‌ترین، ساده‌ترین و در عین حال بنیادی‌ترین ابزارهای ریاضی در خانواده تبدیل‌های موجک^{۳۱} است. این تبدیل، یک سیگنال یا مجموعه‌ای از داده‌ها (مانند یک تصویر یا یک فایل صوتی) را به دو بخش اصلی تجزیه می‌کند:

- اطلاعات کلی

- اطلاعات جزئی

به بیان دیگر تبدیل هار یک تبدیل خطی است که سیگنال یا ورودی خاص را به نمایشی تبدیل می‌کند که الگوها و جزئیات داده را در مقیاس‌های مختلف برجسته می‌کند. در رابطه با کاربرد این تبدیل در حریم خصوصی تفاضلی محلی، تبدیل هار، داده‌ها را به دو بخش اصلی تجزیه می‌کند:

- مقدار میانگین^{۳۲}: این یک مقدار واحد است که یک تقریب کلی و چکیده از تمام ابعاد داده را در خود نگه می‌دارد. بخش عمده‌ای از اطلاعات مهم داده‌ها در همین مقدار میانگین متمرکز می‌شود.
- بردار ویژه^{۳۳}: این بردار، اطلاعات جزئی‌تر و تفاوت‌های بین ابعاد مختلف را نشان می‌دهد. این مقادیر معمولاً کوچک‌تر هستند و اطلاعات کمتری نسبت به مقدار میانگین در خود دارند.

مزیت کلیدی این کار این است که جای داشتن تعداد زیادی بُعد که همگی به یک اندازه مهم به نظر می‌رسند، ما یک «مقدار میانگین» بسیار مهم و یک «بردار ویژه» با اهمیت کمتر داریم. این‌ها پایه و اساس کاهش ابعاد را فراهم می‌کنند. در ادامه با یک مثال نحوه‌ی عملکرد این تبدیل را مشخص کنیم.

³¹Wavelet Transforms

³²Average Value

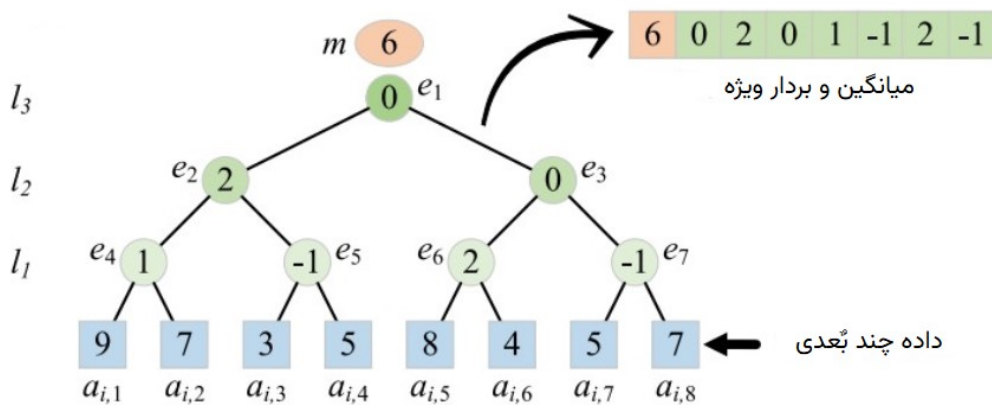
³³Eigenvector

تصور کنید یک لیست از اعداد مانند $[9, 7, 3, 5, 8, 4, 5, 7]$ داریم. به راحتی با جمع تک تک اعداد و تقسیم بر تعداد آنها، مقدار میانگین را محاسبه می‌کنیم:

$$m = \frac{9 + 7 + 5 + 4 + 8 + 5 + 3 + 7}{8} = 6$$

برای محاسبه‌ی بردار ویژه، ابتدا یک درخت دودویی کامل می‌سازیم که برگ‌های درخت همان اعداد (ابعاد داده) اصلی هستند. سپس، برای هر گره داخلی N ، مقدار ویژه $e = (ml - mr) / 2$ محاسبه می‌شود، که در آن ml و mr مقدار میانگین گره‌های برگ در زیردرخت‌های چپ و راست N است. پس از پردازش تمام گره‌های داخلی، با نوشتن آنها به ترتیب جستجوی اول سطح^{۳۴} مقدار بردار ویژه بدست می‌آید. دقت کنید مقدار میانگین را می‌توان به عنوان اطلاعات اصلی داده‌های چند بعدی در نظر گرفت و هر مقدار ویژه را می‌توان به چشم اطلاعات محلی داده‌های چند بعدی مشاهده کرد. بنابراین، هر بعد را می‌توان به عنوان مجموعه‌ای از مقدار میانگین و مقادیر ویژه در نظر گرفت. شکل ۳-۵ تبدیل هار را روی داده‌های چند بعدی نشان می‌دهد.

$$E = [0, 2, 0, 1, -1, 2, -1]$$



شکل ۳-۵: نحوه محاسبه‌ی بردار ویژه در تبدیل هار. $a_{i,j}$ نشان‌دهنده‌ی ویژگی j ام از کاربر i ام است [۴].

نکته کلیدی: این فرآیند بازگشت‌پذیر است. یعنی با داشتن میانگین و بردار ویژه، می‌توان داده اصلی را دقیقاً بازسازی کرد. برای پیدا کردن مقدار هر داده (که در برگ‌های درخت قرار دارد)، از ریشه درخت (که همان مقدار میانگین m است) شروع کرده و با اضافه یا کم کردن مقادیر ویژه‌ای که در مسیر رسیدن به آن برگ قرار دارند، به مقدار نهایی می‌رسیم:

³⁴Breadth First Search

$$a_{i,j} = m + \sum_{k=1}^l (g_k \cdot e_k) \quad (4-3)$$

$$g_k = \begin{cases} 1, & \text{if } a_{i,j} \text{ in the left subtree of } e_k, \\ -1, & \text{if } a_{i,j} \text{ in the right subtree of } e_k. \end{cases}$$

$$l = \lfloor \log(d+1) - 1 \rfloor$$

به عبارت دیگر، برای بازسازی یک مقدار، از میانگین کل شروع می‌کنیم و سپس در هر مرحله از مسیر درخت، مقدار ویژه آن مرحله را بر اساس اینکه در سمت چپ یا راست آن قرار داریم، اضافه یا کم می‌کنیم. به عنوان مثال در شکل ۳-۵ ویژگی $a_{i,v}$ دارای اجداد e_v ، e_3 و e_1 است. معکوس تبدیل هار برای این ویژگی به شکل زیر محاسبه می‌شود:

$$a_{i,v} = m - e_1 - e_3 + e_v = 5$$

همانطور که می‌بینید، مقدار بازسازی شده دقیقاً با مقدار اصلی در داده‌های خام (عدد ۵) برابر است، که نشان می‌دهد فرآیند معکوس به درستی کار می‌کند.

سادگی و سرعت محاسباتی تبدیل هار باعث شده تا در حوزه‌های مختلفی کاربرد داشته باشد:

- فشرده‌سازی داده‌ها^{۳۵}: فشرده‌سازی یکی از مهم‌ترین کاربردهای تبدیل هار است. بسیاری از داده‌ها (مانند تصاویر) شامل ضرایبی با مقادیر کوچک و نزدیک به صفر هستند. با حذف این ضرایب کم‌اهمیت و نگهداری ضرایب تقریبی و بزرگ، می‌توان حجم داده را به شدت کاهش داد بدون اینکه کیفیت آن به طور محسوس افت کند. فرمت تصویر JPEG از نسخه‌های پیشرفته‌تر موجک‌ها (که بر پایه همین ایده هستند) استفاده می‌کند.
- تشخیص لبه^{۳۶}: ضرایب جزئی در یک تصویر، نماینده تغییرات ناگهانی روشنایی هستند که دقیقاً همان لبه‌های اشیاء را مشخص می‌کنند.

³⁵Data Compression

³⁶Edge Detection

- کاهش نوفه^{۳۷}: نوفه در تصویر معمولاً به صورت ضرایب جزئی کوچک ظاهر می‌شود. با حذف این ضرایب و بازسازی تصویر، می‌توان نوفه را تا حد زیادی از بین برد.
- تحلیل سیگنال‌های دیجیتال: برای بررسی و تحلیل فرکانس‌های مختلف در سیگنال‌های صوتی یا دیگر سیگنال‌های دیجیتال استفاده می‌شود.
- پایگاه داده: برای جستجوی سریع‌تر و بهینه در پایگاه داده‌های بزرگ به کار می‌رود.

به طور خلاصه، تبدیل هار یک ابزار قدرتمند برای تجزیه داده‌ها به بخش‌های کلی و جزئی است که این ویژگی آن را برای کاربردهای متنوعی از فشرده‌سازی گرفته تا حفظ حریم خصوصی، بسیار مفید می‌سازد. پژوهش [۴] در سه مرحله چالش حفظ حریم خصوصی برای داده‌های با ابعاد بالا را حل کرده است:

اولین و مهم‌ترین قدم، استفاده از تبدیل هار برای تبدیل داده‌های چندبعدی هر کاربر است. در مرحله‌ی بعد حفاظت از حریم خصوصی داده‌های تبدیل‌شده صورت می‌گیرد. اکنون به جای کار با داده خام، الگوریتم روی دو بخش تبدیل‌شده کار می‌کند و برای هر کدام، یک سازوکار بهینه‌سازی شده برای افزودن نوفه ارائه می‌دهد:

- **حفاظت از مقدار میانگین:** برای محافظت از مقدار میانگین، مقاله یک سازوکار به نام آشفته‌سازی مبتنی بر چگالی احتمال^{۳۸} (به اختصار، پی.دی.پی^{۳۹}) طراحی کرده است. این سازوکار به جای افزودن نوفه‌ی کاملاً تصادفی، به صورت هوشمندانه عمل می‌کند. مقدار نوفه به گونه‌ای اضافه می‌شود که مقدار نهایی با احتمال بالاتری نزدیک به مقدار واقعی باقی بماند و با احتمال کمتری از آن دور شود. این کار باعث می‌شود که با حفظ حریم خصوصی، دقت و کارایی این مقدار کلیدی تا حد امکان حفظ شود. به طور دقیق‌تر، مقدار نوفه‌دار شده‌ی $\tilde{m} \in [-b, b]$ از رابطه‌ی زیر بدست می‌آید.

$$\text{PDF}[\psi(m) = \tilde{m}] = \begin{cases} q \cdot e^{\epsilon} & \text{if } \tilde{m} \in L(\Delta, m), \\ q & \text{otherwise,} \end{cases} \quad (5-3)$$

در عبارت بالا q یک مقدار ثابت است که باعث می‌شود مجموع همه احتمالات در تابع چگالی احتمال برابر با ۱ شود. پارامترهای دیگر عبارت به صورت زیر بهینه سازی می‌شوند:

$$L(\delta, m) = \left[m - \frac{\delta}{4}, m + \frac{\delta}{4} \right]$$

³⁷Denoising

³⁸Probability Density-based Perturbation


³⁹PDP

$$\Delta = \frac{24}{e^{\epsilon/6}(6 + 5\epsilon) - 6}$$

$$b = \frac{(e^{\epsilon} - 1)\Delta(\Delta + 2)}{2[(e^{\epsilon} - 1)\Delta - 2]}$$

$$q = \frac{2}{(e^{\epsilon} - 1)\Delta(2b - \Delta)}$$

در شکل ۳-۶ مثالی از آشفته‌سازی مقدار میانگین نمایش داده شده است.



شکل ۳-۶: آشفته‌سازی مقدار m_i بر اساس پی.دی.پی [۴]

- **حفاظت از بردار ویژه:** برای این بخش که هنوز چندبعدی است، ابتدا کاهش ابعاد صورت می‌گیرد. از آنجایی که بسیاری از مقادیر در بردار ویژه کوچک و کم‌اهمیت هستند، این مدل مقادیری را که از یک آستانه مشخصی کوچک‌تر هستند، حذف کرده و آن‌ها را با صفر جایگزین می‌کند. سپس از سازوکاری به اسم آشفته‌سازی سراسری^{۴۰} (به اختصار جی.پی.ام^{۴۱}) به منظور اضافه کردن نوفه به بردار ویژه استفاده می‌شود. به جای تقسیم بودجه حریم خصوصی بین ابعاد باقی‌مانده‌ی بردار ویژه، این نوفه کل بردار را به عنوان یک واحد در نظر گرفته و به صورت سراسری به آن نوفه اضافه می‌کند. این رویکرد از تقسیم بیش از حد بودجه جلوگیری کرده و کارایی آماری را به مراتب بهتر حفظ می‌کند. رویکرد اضافه کردن نوفه به بردار ویژه در الگوریتم ۱ نوشته شده است.

ابتدا کاهش ابعاد با استفاده از حد آستانه (خطوط ۱ تا ۵) انجام می‌شود. این مرحله یک پیش‌پردازش برای بهینه‌سازی است. الگوریتم تک‌تک مقادیر داخل بردار ویژه را بررسی می‌کند. اگر قدر مطلق یک مقدار از آستانه θ کوچک‌تر باشد، آن را با صفر جایگزین می‌کند. مقادیر بسیار کوچک در بردار ویژه، اطلاعات کمی را در خود دارند اما همچنان بخشی از بودجه حریم خصوصی را مصرف می‌کنند. با حذف (صفر کردن) آن‌ها، الگوریتم می‌تواند بودجه حریم خصوصی را برای محافظت از مقادیر مهم‌تر متمرکز کند.

سپس یک بردار دودویی به نام \tilde{V} ایجاد می‌شود. این بردار مشخص می‌کند که به هر بعد از بردار ویژه چه نوع نوفه‌ای اضافه شود. نکته هوشمندانه اینجاست که خود این بردار \tilde{V} به روشی انتخاب

⁴⁰Global Perturbation Mechanism

⁴¹GPM

می‌شود که حریم خصوصی را تضمین کند. الگوریتم دو مجموعه از بردارهای ماسک را تعریف می‌کند:

– مجموعه A : تمام بردارهای ماسک ممکن که تعداد زوجی از عدد ۱ دارند.

– مجموعه B : تمام بردارهای ماسک ممکن که تعداد فردی از عدد ۱ دارند.

سپس با یک پرتاب سکه (متغیر X) که احتمال آن به بودجه حریم خصوصی ϵ بستگی دارد، تصمیم می‌گیرد که بردار ماسک نهایی را از مجموعه A انتخاب کند یا از مجموعه B . به بیان دیگر حفظ حریم خصوصی از عدم قطعیتی ناشی می‌شود که ناظر خارجی نمی‌داند ماسک نهایی از کدام مجموعه انتخاب شده است. اکنون که بردار ماسک انتخاب شده است، نوبت به افزودن نوبه به مقادیر بردار ویژه می‌رسد.

الگوریتم به ازای هر مقدار e_i از بردار ویژه، به بیت متناظر آن در بردار ماسک نگاه می‌کند. اگر بیت متناظر برابر ۰ بود، مقدار e_i با انتخاب یک عدد تصادفی از بازه توزیع یکنواخت باریک، نوبه‌دار می‌شود. در غیر این صورت مقدار e_i با انتخاب یک عدد تصادفی از یک بازه‌ی پهن‌تر، نوبه‌دار می‌شود. بازه این توزیع‌ها به دقت و بر اساس بودجه حریم خصوصی طراحی شده‌اند تا کل فرآیند، حریم خصوصی تفاضلی محلی را برآورده کند.

در گام سوم، فرآیند بازسازی داده‌ها در سمت کارپذیر صورت می‌گیرد. در این مرحله، کارپذیر پس از دریافت مؤلفه‌های نوبه‌دار (شامل مقدار میانگین و بردار ویژه) از کاربران، با به‌کارگیری رابطه تبدیل معکوس هار ۳-۴، اقدام به ترکیب این اطلاعات و استخراج نسخه‌ای تخمینی از داده‌های چندبعدی اولیه می‌نماید. ویژگی حائز اهمیت در این معماری آن است که کارپذیر در هیچ‌یک از مراحل، دسترسی مستقیم به داده‌های خام و حساس کاربران ندارد؛ بلکه تمامی عملیات بازسازی صرفاً بر پایه داده‌های محافظت‌شده (نوبه‌دار) انجام می‌شود. نتیجه این رویکرد، دستیابی به داده‌هایی است که ضمن تضمین کامل حریم خصوصی، از دقت و کارایی آماری به‌مراتب بالاتری نسبت به روش‌های پیشین برخوردارند.

۳-۲ داده‌های در حال تغییر

در اکثر اوقات، نیاز به جمع‌آوری و تحلیل داده‌ها در طول زمان و به صورت مداوم وجود دارد. به عنوان مثال، یک شرکت نرم‌افزاری ممکن است بخواهد آمار استفاده از یک قابلیت خاص را به صورت روزانه یا

الگوریتم ۱ سازوکار آشفته‌سازی بردار ویژه

ورودی: بردار ویژه $e_i \in [-1, 1]^{d-1}$ و بودجه‌ی حریم خصوصی ϵ_2 و حد آستانه‌ی θ .

خروجی: مقدار نوفه‌دار شده‌ی $\tilde{e}_i \in [-\frac{e^\epsilon+1}{e^\epsilon-1}, \frac{e^\epsilon+1}{e^\epsilon-1}]^{d-1}$

۱: به ازای هر e_i از بردار ویژه:

۲: اگر $|e_i| \leq \theta$:

۳: $e_i = 0$

۴: $V = \{0\}^{d-1-\theta d}$

۵: به صورت تصادفی k بیت از لیست V را ۱ قرار بده.

۶: قرار بده A را برابر با لیست‌هایی که k ی آنها زوج است.

۷: قرار بده B را برابر با لیست‌هایی که k ی آنها فرد است.

۸: یک متغیر برنولی X را با احتمال $\frac{e^\epsilon}{e^\epsilon+1}$ مقدار ۱ قرار بده.

۹: اگر $X = 1$:

۱۰: لیست \tilde{V} را به صورت تصادفی یکنواخت از A انتخاب کن.

۱۱: در غیر این صورت:

۱۲: لیست \tilde{V} را به صورت تصادفی یکنواخت از B انتخاب کن.

۱۳: به ازای هر e_i از بردار ویژه:

۱۴: اگر $v_i = 0$:

۱۵: مقدار \tilde{e}_i را به صورت تصادفی یکنواخت از $[\frac{e_i \cdot e^\epsilon - 1}{e^\epsilon - 1}, \frac{e_i \cdot e^\epsilon + 1}{e^\epsilon - 1}]$ انتخاب کن.

۱۶: در غیر این صورت:

۱۷: مقدار \tilde{e}_i را به صورت تصادفی یکنواخت از $(\frac{e_i \cdot e^\epsilon + 1}{e^\epsilon - 1}, \frac{e^\epsilon + 1}{e^\epsilon - 1}] \cup [-\frac{e^\epsilon + 1}{e^\epsilon - 1}, \frac{e_i \cdot e^\epsilon - 1}{e^\epsilon - 1})$ انتخاب کن.

۱۸: $\tilde{e}_i \in [-\frac{e^\epsilon+1}{e^\epsilon-1}, \frac{e^\epsilon+1}{e^\epsilon-1}]^{d-1}$ را برگردان

هفتگی رصد کند. این کار مستلزم پرسش‌های مکرر از داده‌های کاربران است. چالش اصلی این است که حتی اگر هر پاسخ به صورت جداگانه با استفاده از سازوکارهای حفظ حریم خصوصی محافظت شود، تکرار این فرآیند می‌تواند به مرور زمان حریم خصوصی را تضعیف کند.

یکی از چالش‌های امنیتی جدی در فرآیند جمع‌آوری مکرر داده‌ها، آسیب‌پذیری در برابر «حملات میانگین‌گیری»^{۴۲} است. در این حالت، مهاجم با رصد و جمع‌آوری مجموعه‌ای از پاسخ‌های تصادفی شده‌ی یک کاربر در طول زمان، اقدام به میانگین‌گیری از آن‌ها می‌کند. این عمل باعث می‌شود اثر نوفه‌ی تزریق شده به مرور خنثی شده و مهاجم بتواند با دقتی بالا، مقدار واقعی داده‌ی کاربر را تخمین بزند. این تهدید به‌ویژه زمانی شدت می‌یابد که داده‌ی واقعی کاربر در بازه‌های زمانی متوالی ثابت باشد، چرا که تعدد نمونه‌گیری از یک مقدار واحد، خطای تخمین را به حداقل می‌رساند.

به بیان دیگر بر اساس قضیه ترکیب متوالی در حریم خصوصی تفاضلی، هر بار که یک پرسش در مورد داده‌های یک فرد پرسیده می‌شود، مقداری از بودجه حریم خصوصی مصرف می‌شود. تکرار پرسش‌ها باعث انباشت این مصرف و در نتیجه افت حریم خصوصی می‌شود. یعنی با هر پرسش جدید، تضمین‌های حریم خصوصی ضعیف‌تر می‌شوند.

روش حفظ کردن (در قسمت بعد شرح می‌دهیم) تا حد قابل قبولی مشکل پرسش‌های مکرر را حل کرده است ولی در حوزه‌ی داده‌های در حال تغییر همچنان مشکلاتی وجود دارد. داده‌های بسیاری از کاربران در دنیای واقعی ثابت نیستند و در طول زمان تغییر می‌کنند. به عنوان مثال، موقعیت مکانی یک فرد یا میزان استفاده از یک برنامه کاربردی، همگی در حال تحول هستند. این داده‌های در حال تغییر چالش‌های منحصر به فردی را ایجاد می‌کنند:

- ردیابی تغییرات داده‌ها: اگر یک کاربر مقدار داده خود را تغییر دهد (مثلاً از یک مکان به مکان دیگر برود)، حتی با استفاده از روش حفظ کردن، یک پاسخ تصادفی شده جدید باید تولید شود. مهاجم با مشاهده این تغییر در پاسخ تصادفی شده، می‌تواند متوجه شود که داده‌های کاربر تغییر کرده است. اگرچه ممکن است مهاجم نتواند مقادیر دقیق قبلی و فعلی را بفهمد، اما صرفاً آگاهی از زمان و تعداد تغییرات، خود یک نوع نشت اطلاعاتی محسوب می‌شود که می‌تواند در تحلیل‌های پیشرفته‌تر مورد سوءاستفاده قرار گیرد.
- افزایش خطای افت حریم خصوصی با تغییرات ریز داده: وجود تغییرات کوچک در داده باعث می‌شود قانون ترکیب متوالی در این شرایط هم صدق کرده و بدین ترتیب حریم خصوصی نقض شود. این حالت معمولاً در ویژگی‌هایی که دامنه‌ی ورودی بزرگی دارند رخ می‌دهد.

⁴² Averaging Attacks

- یافتن الگوی تغییرات: در بعضی حالات مهاجم می‌تواند با مشاهده تطابق بین داده‌های تغییر یافته و داده‌های اصلی، الگوی تغییرات حساس داده را شناسایی کرده و اطلاعات شخصی کاربران را استنتاج نماید.

۳-۲-۱ حفظ کردن

همانطور که قبل‌تر گفتیم، در حوزه‌ی پرسش‌های مکرر، مهاجم می‌تواند از نتایج تصادفی‌سازی میانگین گرفته تا به اطلاعات شخصی کاربران نزدیک‌تر شود. دلیل وجود این مشکل هم قانون ترکیب متوالی است. به بیان دیگر، اگر برای هر بار تصادفی‌سازی، از بودجه‌ی حریم خصوصی استفاده کنیم، در نهایت بودجه‌ی محدود ما رو به اتمام می‌رود.

روش حفظ کردن^{۴۳} یک رویکرد بسیار ساده ولی کارآمد است. به این صورت که کافیسیت با یکبار تصادفی‌سازی داده، مقدار حاصل ذخیره شده و در صورت پرسش دوباره روی همان داده، مقدار ذخیره شده برگردانده شود. اینکار از مصرف چند باره‌ی بودجه‌ی حریم خصوصی جلوگیری می‌کند. همچنین سرعت اجرای سازوکار افزایش می‌یابد زیرا برای هر داده فقط یکبار آشفته‌سازی انجام می‌شود.

۳-۲-۱-۱ پژوهش الینگسون و همکاران

پژوهش الینگسون و همکاران [۱۹] روشی به اسم رپور^{۴۴} به منظور حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد. به بیان دیگر رپور یک فناوری توسعه‌یافته توسط گوگل است که به شرکت‌ها اجازه می‌دهد آمار کلی رفتار کاربران را جمع‌آوری کنند، بدون اینکه بتوانند به اطلاعات خصوصی یک کاربر خاص دسترسی پیدا کنند. رپور دارای یک فرایند چهار مرحله‌ای است:

۱. تبدیل داده با استفاده از بلوم فیلتر: ابتدا، داده خام کاربر توسط بلوم فیلتر به یک رشته از صفر و یک تبدیل می‌شود. این کار داده‌ها را استاندارد و غیرقابل شناسایی می‌کند.

۲. پاسخ تصادفی دائمی^{۴۵}: این مرحله کلید اصلی حفظ حریم خصوصی بلندمدت^{۴۶} است. سیستم یک بار و برای همیشه، روی رشته‌ی تولید شده از مرحله قبل، یک پاسخ تصادفی اعمال می‌کند. یعنی برخی از بیت‌های ۰ به ۱ و برعکس، با یک احتمال مشخص تغییر می‌کنند. نتیجه این مرحله در دستگاه کاربر ذخیره می‌شود. این ذخیره‌سازی باعث می‌شود حتی اگر کاربر بارها گزارشی درباره

⁴³Memoization

⁴⁴Rappor

⁴⁵Permanent Randomized Response

⁴⁶Longitudinal Privacy

همان داده ارسال کند، از حملات میانگین‌گیری جلوگیری شود. به صورت دقیق‌تر، برای هر رشته‌ی B تولید شده توسط بلوم فیلتر، رشته‌ی تصادفی‌سازی شده‌ی B' با استفاده از سازوکار زیر تولید می‌شود:

$$B'_i = \begin{cases} 1, & \text{with probability } \frac{1}{f} \\ 0, & \text{with probability } \frac{1}{f} \\ B_i, & \text{with probability } 1 - f \end{cases}$$

در عبارت بالا، B_i نشان‌دهنده‌ی بیت i ام از رشته‌ی B است. f یک پارامتر قابل تنظیم برای کاربر است که سطح ضمانت حریم خصوصی را کنترل می‌کند. بدین ترتیب، B' به عنوان پایه‌ای برای تمام گزارش‌های آینده مورد استفاده مجدد قرار می‌گیرد.

۳. پاسخ تصادفی آنی^{۴۷}: قبل از ارسال گزارش به کاربر، یک بار دیگر نوفه اضافه می‌شود. این بار، روی نتیجه پاسخ تصادفی دائمی، مجدداً یک فرآیند پاسخ تصادفی اجرا می‌شود. این کار باعث می‌شود هر گزارش ارسالی، حتی برای یک داده یکسان، با گزارش قبلی متفاوت به نظر برسد. این مرحله از ردیابی کاربر بر اساس گزارش‌های متوالی جلوگیری کرده و از شفاف شدن الگوی تغییرات جلوگیری می‌کند. به طور دقیق‌تر، آرایه‌ی تمام صفر S با اندازه B' ساخته می‌شود. سپس هر بیت از این آرایه با احتمال زیر، ۱ می‌شود:

$$P(S_i = 1) = \begin{cases} q, & \text{if } B'_i = 1 \\ p, & \text{if } B'_i = 0 \end{cases}$$

۴. ارسال گزارش به کاربر: در نهایت، این رشته بیت که دو بار دستخوش تغییر تصادفی شده، سمت کاربر ارسال می‌شود. گزارش نهایی برای کاربر به تنهایی بی‌معنی و پر از نوفه است. اما قدرت رپور زمانی مشخص می‌شود که میلیون‌ها گزارش از کاربران مختلف جمع‌آوری شود. کاربر با استفاده از تکنیک‌های آماری پیشرفته، می‌تواند نوفه‌های تصادفی را از داده‌های تجمیع‌شده حذف کرده و الگوهای واقعی را در سطح کل جمعیت کشف کند. برای مثال، می‌تواند بفهمد که چند درصد از کاربران از یک وب‌سایت خاص به عنوان صفحه اصلی خود استفاده می‌کنند، بدون اینکه بداند کدام کاربران این کار را انجام داده‌اند.

⁴⁷Instantaneous Randomized Response

این روش توسط گوگل در مرورگر کروم برای جمع‌آوری آمار درباره تنظیمات کاربران (مانند صفحه اصلی، موتور جستجوی پیش‌فرض و افزونه‌های نصب‌شده) استفاده شده است. همچنین گوگل می‌تواند بدون نقض حریم خصوصی، نرم‌افزارهای مخربی که این تنظیمات را بدون اجازه تغییر می‌دهند، شناسایی کند.

۳-۲-۲ رُند کردن

پژوهش رپور فرض می‌کند که داده‌ها تغییر نکرده یا به ندرت تغییر می‌کنند. اگر اطلاعات کاربر در طول زمان دچار تغییرات کوچک ولی مداوم باشد، رپور دیگر کارآمد نخواهد بود. به عنوان مثال در هنگام جمع‌آوری میزان مصرف انرژی دستگاه کاربران، هر بار که کاربر بخواهد این اطلاعات را دریافت کند، کاربران باید به داده‌های خود نوبه اضافه کرده و آنرا حفظ کنند. ولی از آنجایی که این داده هر بار تغییر کوچکی خواهد کرد، کاربران باید هر بار عملیات تصادفی‌سازی را انجام داده و از بودجه‌ی حریم خصوصی مصرف کنند.

نکته مهم اینجاست که داده‌ی تصادفی شده هر بار تغییر کوچکی کرده و از یک جنس خواهد بود. پس قانون ترکیب متوالی روی آن اعمال شده و با هر بار آشفته‌سازی، بخشی از بودجه‌ی کل حریم خصوصی مصرف می‌شود. این اتفاق معمولاً در داده‌های با دامنه‌ی بزرگ رخ خواهد داد.

ایده‌ی رُند کردن، روشی ساده ولی موثر برای حل این مشکل است. مشکل ما در هنگام تغییرات کوچک بوجود می‌آید، پس کافیسست کاربر پس از هر تغییر، داده‌ی خود را به یک مقدار مشخص سوق دهد و از تصادفی‌سازی دوباره جلوگیری کند. به بیان دیگر، داده‌ها به مقادیر گسسته و با دامنه‌ی کوچکتر تبدیل می‌شوند.

۳-۲-۱ پژوهش دینگ و همکاران

پژوهش دینگ و همکاران [۳۳] تغییرات کوچک را از طریق سازوکار رُند کردن مدیریت می‌کند. این پژوهش یک چارچوب جدید و قدرتمند برای جمع‌آوری داده‌های دورسنجی (مانند آمار استفاده از برنامه‌های کاربردی) به صورت مکرر و در طول زمان ارائه می‌دهد، در حالی که حریم خصوصی کاربران به طور کامل حفظ می‌شود. همچنین این روش در محصول ویندوز^{۴۸} مایکروسافت برای جمع‌آوری داده‌های مربوط به میزان استفاده از برنامه‌های کاربردی پیاده‌سازی شده است.

⁴⁸Windows

مشکل داده‌های در حال تغییر به خصوص برای داده‌های شمارنده^{۴۹} جدی است؛ داده‌هایی که مقادیر عددی دارند و به طور مکرر اما با تغییرات جزئی عوض می‌شوند (مثلاً زمان استفاده از یک اپلیکیشن که بر حسب ثانیه گزارش می‌شود). نویسندگان مقاله برای حل این مشکل یک چارچوب جامع با چهار جزء اصلی معرفی می‌کنند:

۱. سازوکار تک بیتی: سازوکاری ساده به منظور حفظ حریم خصوصی تفاضلی محلی هنگام جمع‌آوری داده در یک مرحله را نشان می‌دهد. به طور دقیق‌تر، هر کاربر i یک بیت $b_i(t)$ را در زمان t با احتمال زیر مقداردهی کرده و برای کارپذیر می‌فرستد.

$$b_i(t) = \begin{cases} 1, & \text{with probability } \frac{1}{e^\epsilon + 1} + \frac{x_i(t)}{m} \cdot \frac{e^\epsilon - 1}{e^\epsilon + 1}, \\ 0, & \text{otherwise.} \end{cases}$$

سپس کارپذیر بیت‌های n کاربر را جمع‌آوری کرده و مقدار میانگین $\hat{\sigma}(t)$ را تخمین می‌زند:

$$\hat{\sigma}(t) = \frac{m}{n} \sum_{i=1}^n \frac{b_i(t) \cdot (e^\epsilon + 1) - 1}{e^\epsilon - 1}.$$

این روش را یک.بیت.فلیپ.پی.ام^{۵۰} می‌نامد. البته این مقاله روش دیگری به نام دی.بیت.فلیپ.پی.ام^{۵۱} نیز ارائه می‌دهد که در آن هر کاربر به جای ارسال یک بیت، d بیت را برای کارپذیر ارسال می‌کند. یک.بیت.فلیپ.پی.ام نسخه‌ای بهینه با $d = 1$ است که کمترین هزینه ارتباطی و قوی‌ترین تضمین حریم خصوصی را ارائه می‌دهد، اما ممکن است دقت کمتری داشته باشد. دی.بیت.فلیپ.پی.ام سازوکاری عمومی‌تر است که به شما اجازه می‌دهد با افزایش d ، دقت را بالا ببرید، اما هزینه ارتباطی افزایش یافته و کاهش جزئی در سطح حریم خصوصی بوجود می‌آید. یک.بیت.فلیپ.پی.ام با تعداد زیاد کاربر (در حد چند میلیون) دقت قابل قبولی کسب می‌کند، پس اگر تعداد کاربران کمتر باشد، بهتر است از دی.بیت.فلیپ.پی.ام استفاده کرد. جدول ۱-۳ مقایسه‌ای از این دو روش را نمایش می‌دهد.

۲. گرد کردن نقطه آلفا^{۵۲}: یک روش گرد کردن هوشمندانه و تصادفی برای مقابله با تغییرات جزئی داده‌ها را ارائه می‌کند. هدف اصلی این روش، تبدیل یک مقدار عددی (مانند ۲۳۷ ثانیه) به یک مقدار گسسته (مثلاً ۲۰۰ یا ۳۰۰) است، اما به گونه‌ای که دو مشکل بزرگ را حل کند:

⁴⁹Counter Data

⁵⁰1BitFlipPM

⁵¹dBitFlipPM

⁵² α -point

جدول ۳-۱: مقایسه‌ی یک.بیت.فلیپ.پی.ام و دی.بیت.فلیپ.پی.ام

ویژگی	دی.بیت.فلیپ.پی.ام (حالت عمومی)	یک.بیت.فلیپ.پی.ام (حالت خاص)
تعداد بیت ارسالی	d بیت	یک بیت
دقت	معمولاً بالاتر است	معمولاً پایین‌تر است
حریم خصوصی	قوی	قوی‌ترین حالت ممکن

- حفظ حریم خصوصی: از نشت اطلاعات به دلیل تغییرات جزئی جلوگیری کند.
- حفظ دقت آماری: از خطاهای منطقی که باعث کاهش دقت در سطح کلان می‌شود، جلوگیری کند.

مشکل روش گرد کردن معمولی: فرض کنید می‌خواهیم زمان استفاده روزانه از یک برنامه کاربردی را جمع‌آوری کنیم و برای حفظ حریم خصوصی، تصمیم می‌گیریم مقادیر را به نزدیک‌ترین مضرب ۱۰ گرد کنیم (یعنی به نقاط ثابت ۰، ۱۰، ۲۰، ۳۰، ...). اکنون یک حالت بد را در نظر بگیرید. فرض کنید ۱۰۰۰ کاربر داریم که همگی در یک روز خاص، دقیقاً ۱۹ دقیقه از اپلیکیشن استفاده کرده‌اند. نتیجه گرد کردن معمولی این می‌شود که همه این ۱۰۰۰ نفر مقدار خود را به ۲۰ گرد کنند. دقت کنید میانگین واقعی استفاده ۱۹ دقیقه است، اما میانگین تخمینی ما ۲۰ دقیقه می‌شود. این یک خطای منطقی و بزرگ است. ما همیشه به سمت بالا خطا داریم. اگر همه کاربران ۱۱ دقیقه استفاده می‌کردند، همگی به ۱۰ گرد می‌کردند و ما همیشه به سمت پایین خطا داشتیم. از این رو برای جمع‌آورنده داده (مانند مایکروسافت) که به دنبال آمار دقیق است، فاجعه رخ می‌دهد.

در راهکار هوشمندانه‌ی گرد کردن نقطه آلفا، هر کاربر مقیاس شخصی خود را برای گرد کردن دارد. در واقع به جای اینکه همه کاربران مقادیر خود را به نقاط ثابتی گرد کنند (مثلاً ۰، ۱۰ و ۲۰)، هر کاربر به صورت تصادفی و مستقل یک نقطه شروع برای گرد کردن انتخاب می‌کند. برای مثال، کاربر علی مقادیر خود را به نزدیک‌ترین مضرب از ۲، ۱۲ و ۲۲ و محمد به نزدیک‌ترین مضرب از ۷، ۱۷ و ۲۷ گرد می‌کند. این کار باعث می‌شود خطاهای ناشی از گرد کردن در سطح کل جمعیت خنثی شوند و دقت کلی بالا بماند.

وقتی میلیون‌ها کاربر این کار را انجام دهند، به طور میانگین، خطاهای گرد کردن به سمت بالا و پایین یکدیگر را خنثی می‌کنند. در نهایت، میانگینی که جمع‌آورنده داده به دست می‌آورد، به شکل شگفت‌انگیزی به میانگین واقعی نزدیک خواهد بود. یعنی خطای منطقی که قبل‌تر ذکر شد، از بین می‌رود. همچنین این روش به یکی از اهداف پژوهش، یعنی حفظ کردن، کمک می‌کند. فرض کنید

روز بعد، علی به جای ۱۹ دقیقه، ۱۸ دقیقه از اپلیکیشن استفاده کند. مقدار گرد شده او همچنان ۲۲ خواهد بود (چون ۱۸ هنوز به ۲۲ نزدیک‌تر از ۱۲ است). بنابراین، پاسخ ارسالی او تغییر نمی‌کند و اطلاعات جدیدی درباره این تغییر جزئی فاش نمی‌شود.

به طور خلاصه، گرد کردن نقطه آلفا یک تکنیک گرد کردن تصادفی است که با دادن یک نقطه شروع تصادفی به هر کاربر، باعث می‌شود خطاهای گرد کردن در سطح جمعیت خنثی شوند. این کار هم دقت آماری را به شدت بالا می‌برد و هم زیربنای لازم برای حفظ حریم خصوصی در جمع‌آوری داده‌های مداوم را فراهم می‌کند.

۳. حفظ کردن: عملیات حفظ کردن داده‌های تصادفی‌سازی شده به منظور جلوگیری از نشت اطلاعات در گزارش‌های تکراری انجام می‌شود. پس از گرد کردن، هر کاربر پاسخ‌های رمزگذاری‌شده (یک بیت ۰ یا ۱) برای هر بازه ممکن را یک‌بار محاسبه و ذخیره می‌کند. از آن پس، تا زمانی که مقدار واقعی داده کاربر در همان بازه گرد شده باقی بماند، او همان پاسخ ذخیره‌شده قبلی را ارسال می‌کند. این کار از نشت اطلاعات به دلیل تغییرات کوچک و مکرر جلوگیری می‌کند، زیرا پاسخ کاربر ثابت می‌ماند.

۴. ایجاد اختلال در خروجی: لایه‌ای از نوفه برای پنهان کردن زمان دقیق تغییر رفتار کاربر تزریق می‌شود. یکی از محدودیت‌های روش حفظ کردن این است که اگر رفتار کاربر به طور قابل توجهی تغییر کند (مثلاً استفاده از یک اپلیکیشن را به طور کامل متوقف کند)، پاسخ ارسال‌شده او تغییر می‌کند و جمع‌آورنده داده متوجه چنین تغییری می‌شود. برای حل این مشکل، مقاله اختلال در خروجی را پیشنهاد می‌دهد. سیستم با احتمال بسیار کمی، پاسخ نهایی کاربر را قبل از ارسال برعکس می‌کند (۰ را به ۱ یا برعکس). این کار باعث می‌شود جمع‌آورنده داده هرگز نتواند با قاطعیت بگوید که آیا تغییر در پاسخ به دلیل تغییر واقعی در رفتار کاربر بوده یا صرفاً یک اختلال تصادفی است.

مقاله مفهومی به نام «الگوی رفتاری»^{۵۳} را معرفی می‌کند که به دنباله مقادیر گردشده کاربر در طول زمان اشاره دارد. این چارچوب تضمین می‌کند که اگر دو کاربر الگوی رفتاری یکسانی داشته باشند (مثلاً هر دو در اکثر روزها از یک اپلیکیشن به میزان کمی استفاده می‌کنند)، جمع‌آورنده داده نمی‌تواند آن‌ها را از یکدیگر تشخیص دهد.

⁵³Behavior Pattern

۳-۲-۳ ارسال تغییرات داده

چندین پژوهش به جای ارسال داده برای کاربر، تغییرات داده را می‌فرستند. این روش به خصوص برای داده‌های سری زمانی^{۵۴} که مقادیرشان به تدریج در طول زمان تغییر می‌کند، بسیار کارآمد است. پس از محاسبه‌ی تغییرات، باید آنها را نوبه‌دار کرد و برای کاربر فرستاد. به بیان دیگر دستگاه کاربر فقط تغییر نوبه‌دار را برای جمع‌آورنده داده ارسال می‌کند. کاربر مقدار تخمینی قبلی کاربر را نگه می‌دارد و با دریافت تغییر جدید، مقدار تخمینی فعلی را بازسازی می‌کند.

این رویکرد از چند جنبه کلیدی، تضمین‌های قدرتمندی برای حریم خصوصی ایجاد می‌کند:

۱. محدود کردن حساسیت^{۵۵}

محدود کردن حساسیت مهم‌ترین مزیت فنی این روش است. در حریم خصوصی تفاضلی، میزان نوبه‌ای که باید به داده اضافه کنیم مستقیماً به حساسیت آن بستگی دارد. فرض کنید مقدار زمان استفاده از یک برنامه کاربردی می‌تواند بین ۰ تا ۱۴۴۰ دقیقه (۲۴ ساعت) باشد. این بازه بسیار بزرگ است و برای پوشش آن به نوبه‌ی زیادی نیاز داریم که دقت را کاهش می‌دهد.

نکته اینجاست که تغییر روزانه در استفاده از یک برنامه کاربردی معمولاً بسیار کمتر است. مثلاً می‌توانیم منطقاً فرض کنیم که استفاده یک کاربر در یک روز نسبت به روز قبل، بیشتر از ۶۰ دقیقه تغییر نمی‌کند. پس بازه تغییرات بین $[-60, 60]$ است. چون بازه تغییرات بسیار کوچک‌تر از بازه مقادیر است، حساسیت مقدار کمی دارد. بنابراین می‌توانیم با افزودن نوبه بسیار کمتر، به همان سطح از حریم خصوصی (مثلاً $\epsilon-LDP$) برسیم. نوبه‌ی کمتر به معنای دقت بالاتر در تخمین نهایی است.

۲. پنهان کردن نقطه شروع

وقتی کاربران فقط تغییرات را ارسال کنند، جمع‌آورنده داده هرگز از مقدار مطلق داده کاربران باخبر نمی‌شود. مگر اینکه مقدار اولیه را داشته باشد ولی آن هم به صورت نوبه‌دار شده ارسال می‌شود. این ویژگی باعث می‌شود که داده‌های حساس مانند موقعیت مکانی (ارسال تغییرات مختصات به جای خود مختصات) یا داده‌های مالی با امنیت بسیار بیشتری جمع‌آوری شوند.

نقطه ضعف ذاتی و مهم این روش **انباشت خطا**^{۵۶} است. از آنجا که کاربر هر روز مقدار جدید را بر اساس مقدار تخمینی دیروز محاسبه می‌کند، اگر در تخمین یک روز خطایی رخ دهد، آن خطا به تمام

⁵⁴Time-Series⁵⁵Bounding Sensitivity⁵⁶Error Accumulation

روزهای بعد نیز منتقل می‌شود. برای مدیریت این مشکل، معمولاً از راهکارهایی مانند ارسال مجدد مقدار کامل به صورت تصادفی‌شده در بازه‌های زمانی طولانی (مثلاً هر ماه یک بار) استفاده می‌شود تا خطاها بازنشانی^{۵۷} شوند.

۳-۲-۳ پژوهش کیائو ژو و همکاران

پژوهش کیائو ژو و همکاران [۵] یک راهکار جدید به نام دی.دی.آر.ام^{۵۸} برای جمع‌آوری مداوم داده‌ها (مانند داده‌های سری زمانی) با حفظ حریم خصوصی کاربران ارائه می‌دهد. در این روش به جای گزارش خود داده، تفاوت آن با داده قبلی گزارش می‌شود.

در بسیاری از داده‌های سری زمانی، مقادیر برای مدتی ثابت می‌مانند. در این حالت، تفاوت آن‌ها صفر می‌شود. روش دی.دی.آر.ام یک پروتکل آشفته‌سازی ویژه طراحی کرده است که وقتی تغییر نداشته باشیم، مقدار صفر برگردانده شده و هیچ بخشی از بودجه حریم خصوصی کاربر مصرف نمی‌شود. همچنین از آنجایی که در هر مرحله یک نوفه تازه تزریق می‌شود، دیگر یک نگاشت ثابت بین داده واقعی و داده تصادفی‌شده وجود ندارد. این کار باعث می‌شود مهاجم نتواند زمان دقیق تغییر داده‌ها را تشخیص دهد. همچنین با استفاده از ساختار درختی و گزارش تغییرات در بازه‌های زمانی مختلف، از انباشته شدن خطا در طول زمان جلوگیری می‌کند.

روند کار دی.دی.آر.ام شامل چند مرحله کلیدی در سمت کاربر و سمت کارپذیر می‌باشد. هر کاربر مراحل زیر را به صورت محلی روی دستگاه خود انجام می‌دهد:

۱. ساخت و به‌روزرسانی «درخت تفاوت^{۵۹}»

مقاله برای ثبت تغییرات داده در بازه‌های زمانی مختلف، از ساختاری به نام درخت تفاوت استفاده می‌کند. در هر لحظه کاربر تفاوت مقدار فعلی با مقدار قبلی را محاسبه می‌کند. این تفاوت یک گره برگ جدید در درخت محسوب می‌شود. گره‌های بالاتر در درخت، جمع تغییرات گره‌های فرزند خود هستند. برای مثال، ریشه درخت نشان‌دهنده تغییر کلی در یک بازه زمانی طولانی‌تر است. این ساختار به سیستم اجازه می‌دهد تغییرات را در مقیاس‌های زمانی مختلف ببیند.


برای مثال در درخت شکل ۳-۷، برگ‌ها تغییر دو مقدار متوالی را نمایش می‌دهند و هر گره غیر برگ حاصل جمع فرزندان خود است. همچنین چون داده‌ها دودویی هستند، مقادیر ممکن برای هر

⁵⁷Reset

⁵⁸DDRM

⁵⁹Difference Tree

گره فقط می‌تواند از سه مقدار ۰، ۱ و -۱ باشد. کاربر در هر مرحله یکی از گره‌های نارنجی رنگ را انتخاب کرده و بعد از تصادفی‌سازی آن، به همراه ارتفاع درخت، سمت کارپذیر می‌فرستد.



شکل ۳-۷: تهیه‌ی درخت تفاوت از داده‌ها [۵]

۲. تصادفی‌سازی گره ارسالی

پس از انتخاب گره، باید به آن نوفه اضافه کنیم. با توجه به مقدار گره، طبق الگوریتم ۲ عمل می‌کنیم. اگر مقدار گره ۰ باشد (داده تغییر نکرده)، با احتمال برابر به ۱ یا -۱ تبدیل می‌شود و هیچ بودجه حریم خصوصی مصرف نمی‌کند. اگر مقدار گره غیر ۰ باشد (داده تغییر کرده)، با احتمال خاصی که حریم خصوصی تفاضلی را ارضا کند، مقدار ۱ یا -۱ تنظیم می‌شود. این فرآیند بخشی از بودجه حریم خصوصی کاربر را مصرف می‌کند.

الگوریتم ۲ سازوکار آشفته‌سازی گره ارسالی

ورودی: گره $v \in \{-1, 0, 1\}$ و بودجه‌ی حریم خصوصی ϵ

خروجی: مقدار نوفه‌دار شده‌ی \tilde{v}

۱: اگر $v = 0$:

$$\tilde{v} = \begin{cases} 1, & \text{w.p. } 0.5 \\ -1, & \text{w.p. } 0.5 \end{cases} \quad 2:$$

۳: در غیر این صورت:

$$\tilde{v} = \begin{cases} 1, & \text{w.p. } \frac{1}{4} + \frac{v}{4} \cdot \frac{e^\epsilon - 1}{e^\epsilon + 1} \\ -1, & \text{w.p. } \frac{1}{4} - \frac{v}{4} \cdot \frac{e^\epsilon - 1}{e^\epsilon + 1} \end{cases} \quad 4:$$

۵: \tilde{v} را برگردان

۳. مدیریت بودجه حریم خصوصی

مقاله یک پارامتر به نام k تعریف می‌کند. هر کاربر تنها k بار مجاز است مقادیر غیرصفر را گزارش دهد. پس از آن، بودجه حریم خصوصی او تمام شده تلقی می‌شود و برای جلوگیری از نشت اطلاعات، همیشه مقادیر تصادفی ارسال می‌کند. همچنین روشی بهینه برای تعیین مقدار k ارائه می‌شود تا دقت کلی به حداکثر برسد.

کارپذیر داده‌های تصادفی را از همه کاربران دریافت می‌کند. سپس با روش‌های آماری، سعی می‌کند نوفه را حذف کند. از آنجایی که در هر لحظه دو نوع گزارش دریافت شده (از گره‌های برگ و گره‌های ریشه)، جمع‌کننده این دو تخمین را با یک میانگین وزنی هوشمند ترکیب می‌کند تا به یک تخمین نهایی و دقیق‌تر از فرکانس داده‌ها برسد.

درخت تفاوتی که این پژوهش ارائه می‌دهد مختص داده‌های دودویی است. با این حال مقاله راه حلی برای داده‌های غیر دودویی نیز بیان می‌کند. به این صورت که ورودی باید ابتدا با استفاده از کدگذاری یکانی به یک رشته دودویی تبدیل گردد. سپس برای هر بیت از این رشته، یک درخت تفاوت ساخته می‌شود.

روش دی.دی.آر.ام با یک روش منحصر به فرد، مشکل داده‌های در حال تغییر را حل کرده است. ولی همچنان از معایب آن می‌توان به این مورد اشاره کرد که با افزایش دامنه‌ی داده‌ها، رسم درخت‌های تفاوت سربار زیادی سمت کاربر اعمال کرده و سودمندی نهایی کاهش پیدا می‌کند.

۳-۲-۴ درهم‌سازی محلی

درهم‌سازی، فرآیندی است که داده‌های ورودی با هر طولی را به یک خروجی با طول ثابت تبدیل می‌کند. این فرآیند چند ویژگی کلیدی دارد:

- یک‌طرفه بودن: از روی مقدار درهم‌سازی، نمی‌توان به داده اصلی دست یافت.
- اثر بهمنی^{۶۰}: کوچکترین تغییری در داده ورودی، منجر به تغییری بزرگ و غیرقابل پیش‌بینی در خروجی می‌شود.
- طول ثابت خروجی: صرف‌نظر از حجم داده ورودی، خروجی همواره طول ثابتی دارد.

در روش درهم‌سازی محلی، هر کاربر قبل از ارسال داده خود، ابتدا آن را به صورت محلی درهم‌سازی می‌کند و سپس با استفاده از سازوکارهای حریم خصوصی تفاضلی محلی مانند پاسخ تصادفی، مقدار نتیجه

⁶⁰ Avalanche Effect

را نوبه‌دار کرده و آن را برای کارپذیر ارسال می‌کند. درهم‌سازی محلی با ویژگی‌های ذاتی خود، راه‌حل‌های مؤثری برای این چالش‌ها ارائه می‌دهد:

۱. کارایی و کاهش سربار محاسباتی و ذخیره‌سازی

از آنجایی که خروجی تابع هش همواره طولی ثابت دارد، فرقی نمی‌کند که داده اصلی یک کاربر چقدر حجیم باشد؛ در نهایت یک مقدار با اندازه ثابت تولید می‌شود. این ویژگی به شدت حجم داده‌های ارسالی را کاهش داده و فرآیندهای محاسباتی و ذخیره‌سازی را در سمت سرور بهینه‌تر می‌کند.

۲. مدیریت بهینه تغییرات در داده‌ها

هنگام وجود داده‌های پویا، اطلاعات یک کاربر ممکن است به طور مداوم تغییر کند. به لطف اثر بهمی در توابع درهم‌ساز، هر تغییر جزئی در داده‌های کاربر، نتیجه‌ی کاملاً متفاوت ایجاد می‌کند. این ویژگی باعث می‌شود که سیستم بتواند به سرعت تغییرات را ثبت کند، بدون آنکه نیاز به مقایسه کامل داده‌های جدید و قدیم باشد.

۳. افزایش حریم خصوصی در طول زمان

در داده‌های جریانی، یک مهاجم ممکن است تلاش کند با جمع‌آوری داده‌های یک فرد در طول زمان، به اطلاعات حساس او دست پیدا کند. از آنجایی که درهم‌سازی یک فرآیند یک‌طرفه است و با افزودن نوبه همراه می‌شود، حتی اگر مهاجم بتواند چندین داده تصادفی از یک کاربر را در طول زمان جمع‌آوری کند، بازسازی داده‌های اصلی یا مسیر تغییرات دقیق آنها عملاً غیرممکن خواهد بود.

۴. سادگی در پیاده‌سازی و انطباق‌پذیری

الگوریتم‌های درهم‌ساز به طور گسترده‌ای در دسترس بوده و پیاده‌سازی آنها نسبتاً ساده است. این سادگی باعث می‌شود که بتوان به راحتی آنها را در سیستم‌های مختلف، از دستگاه‌های اینترنت اشیا با منابع محدود گرفته تا برنامه‌های کاربردی موبایل، به کار گرفت.

در نتیجه، درهم‌سازی محلی با تبدیل داده‌های حجیم و متغیر به یک نمایش ثابت، فشرده و غیرقابل بازگشت، به یک ابزار قدرتمند در زرادخانه حریم خصوصی تفاضلی محلی تبدیل شده است. این روش نه تنها به حفظ حریم خصوصی کاربران در برابر جمع‌آوردگان داده کمک می‌کند، بلکه با بهینه‌سازی فرآیندها، تحلیل داده‌های پویا را در مقیاس بزرگ امکان‌پذیر می‌سازد.

۳-۲-۴-۱ پژوهش تیانهائو وانگ و همکاران

پژوهش تیانهائو وانگ و همکاران [۳۴] یک کار تحقیقاتی مهم در زمینه حریم خصوصی تفاضلی است. این مقاله یک چارچوب کلی برای تحلیل و مقایسه پروتکل‌های مبتنی بر حریم خصوصی تفاضلی محلی معرفی می‌کند و سپس با استفاده از این چارچوب، پروتکل‌های موجود را بهینه‌سازی کرده و پروتکل‌های جدیدی ارائه می‌دهد.

مقاله نشان می‌دهد که پروتکل‌هایی مانند بازتاب ماتریس تصادفی^{۶۱} در واقع یک نوع درهم‌سازی محلی دودویی^{۶۲} هستند. در این روش، داده‌ی هر کاربر به یک بیت (۰ یا ۱) تبدیل می‌شود. این کار باعث از دست رفتن حجم زیادی از اطلاعات، حتی قبل از اضافه کردن نوفه برای حفظ حریم خصوصی می‌شود و دقت را کاهش می‌دهد.

محققان با شناسایی این ضعف، روشی به نام درهم‌سازی محلی بهینه^{۶۳} (به اختصار ا.ا.ل.اچ^{۶۴}) را معرفی می‌کنند. ایده اصلی این است که به جای درهم‌سازی داده به یک بیت، آن را به دامنه‌ای بزرگتر با اندازه g تبدیل می‌کنند. مهم‌ترین نوآوری مقاله این است که به صورت ریاضی ثابت می‌کند مقدار بهینه برای اندازه دامنه g برابر با $1 + e^\epsilon$ است. با انتخاب این مقدار بهینه، به حداکثر دقت ممکن برای تخمین فرکانس دست می‌یابیم.

نتیجه نهایی، ارائه پروتکلی است که هم دقت بسیار بالایی دارد و هم هزینه ارتباطی بسیار پایینی در حد $O(\log n)$ دارد، که آن را برای کاربردهایی با مقادیر داده بسیار متنوع و زیاد، ایده‌آل می‌سازد. در مقاله، اثبات حفظ حریم خصوصی برای پروتکل عمومی درهم‌سازی محلی ارائه شده است. احتمال اینکه مقدار درهم‌سازی صحیح، به درستی گزارش شود را p می‌نامیم. همچنین احتمال اینکه یک مقدار درهم‌سازی غلط، به اشتباه به جای مقدار صحیح گزارش شود را q می‌نامیم.

این احتمالات را بر اساس بودجه حریم خصوصی و اندازه دامنه به شکل زیر تعریف می‌شوند:

$$p = \frac{e^\epsilon}{e^\epsilon + g - 1}$$

$$q = \frac{1}{e^\epsilon + g - 1}$$

برای اثبات حریم خصوصی، کافی است نشان دهیم که نسبت احتمال مشاهده خروجی برای هر دو ورودی دلخواه، از e^ϵ بیشتر نشود. این نسبت در بدترین حالت برابر با $\frac{p}{q}$ است.

⁶¹Random Matrix Projection

⁶²Binary Local Hashing

⁶³Optimized Local Hashing

⁶⁴OLH

$$\frac{p}{q} = \frac{\frac{e^\epsilon}{e^\epsilon + g - 1}}{\frac{1}{e^\epsilon + g - 1}} = e^\epsilon \quad (۳-۶)$$

از آنجایی که این نسبت دقیقاً برابر با e^ϵ است، پروتکل تعریف شده، معیار حریم خصوصی تفاضلی محلی را برآورده می‌کند. یعنی حتی اگر مهاجم به خروجی دسترسی پیدا کند، اطلاعات بسیار محدودی درباره ورودی اصلی کاربر به دست می‌آورد.

۳-۲-۵ ترکیب حفظ کردن و درهم‌سازی محلی

برای اینکه بتوانیم هم مزایای درهم‌سازی را داشته باشیم و هم مشکل پرسش‌های مکرر را حل کنیم، باید قبل از درهم‌سازی نتیجه را ذخیره کرده تا بعداً از آن استفاده کنیم.

۳-۲-۵-۱ پژوهش آرکولزی و همکاران

پژوهش آرکولزی و همکاران [۳۵] با معرفی یک پروتکل جدید به نام لولوها^{۶۵} حریم خصوصی را روی داده‌های در حال تغییر تضمین می‌کند. پروتکل‌های موجود مانند رپور گوگل یا دی.بیت.فلیپ.پی.ام. مایکروسافت، در مواجهه با داده‌هایی که مدام تغییر می‌کنند، با یک مشکل جدی روبرو هستند. عملکرد کلی در این پروتکل‌ها با افزایش دامنه مقادیر ورودی کاهش پیدا می‌کند. برای مثال، اگر بخواهیم آدرس وب‌سایت‌های بازدید شده را جمع‌آوری کنیم، مقدار دامنه یک عدد میلیونی خواهد بود و این باعث می‌شود حفظ حریم خصوصی در طولانی مدت تقریباً غیرممکن شود.

لولوها از نقاط قوت پروتکل‌های قبلی الهام گرفته اما ضعف بزرگ آن‌ها را برطرف می‌کند. عملکرد این پروتکل در سه قدم اصلی خلاصه می‌شود:

۱. کاهش دامنه

به جای کار با دامنه بزرگ k ، هر کاربر قبل از هر کاری، داده واقعی خود را با استفاده از یک تابع درهم‌ساز، به یک عدد در یک دامنه بسیار کوچک‌تر به نام g تبدیل می‌کند. پس از این کار تعداد زیادی از مقادیر اصلی به یک مقدار یکسان نگاشت می‌شوند. بنابراین یک لایه ابهام و عدم قطعیت ایجاد می‌شود، زیرا کاربر پذیر حتی با داشتن نتیجه درهم‌سازی، مقدار واقعی را نمی‌داند.

۲. تصادفی‌سازی و حفظ کردن نتیجه

⁶⁵LOLOHA

پس از اینکه داده به یک مقدار در دامنه کوچک تبدیل شد، به آن نوبه اضافه کرده و نتیجه را در حافظه دستگاه ذخیره می‌کند. اگر در آینده داده کاربر تغییر کند اما مقدار درهم‌سازی آن همان مقدار قبلی باشد، پروتکل همان گزارش نوبه‌دار قبلی را دوباره ارسال می‌کند. این کار از هدر رفتن بودجه حریم خصوصی جلوگیری کرده و سرعت عملیات را بالا می‌برد.

به منظور آشفته‌سازی از سازوکار پاسخ تصادفی عمومی استفاده می‌شود. مقادیر p و q بر اساس قاعده‌ی ۸-۲ به صورت زیر مقداردهی می‌شوند. دقت کنید از k به عنوان دامنه‌ی جدید استفاده شده است.

$$p = \frac{e^\epsilon}{e^\epsilon + k - 1}, \quad q = \frac{1 - p}{k - 1} \quad (۷-۳)$$

برای تخمین شمارش هر ورودی $v \in V$ ، تعداد باری که v گزارش شده است را می‌شماریم (با نماد $C(v)$) و در فرمول زیر جایگذاری می‌کنیم:

$$\hat{f}(v) = \frac{C(v) - nq}{n(p - q)} \quad (۸-۳)$$

در عبارت بالا، n تعداد کاربران را نمایش می‌دهد. در پژوهش تیانهائو وانگ و همکاران [۳۴] اثبات می‌شود که ارزش مورد انتظار^{۶۶} $\hat{f}(v)$ برابر با شمارش واقعی داده‌ها است.

$$E(\hat{f}(v)) = f(v)$$

۳. تصادفی‌سازی دوباره

روش لولوها برای افزایش بیشتر امنیت و جلوگیری از حملات ردیابی، یک قدم دیگر نیز اضافه می‌کند. مانند رپور قبل از ارسال نهایی گزارش، یک لایه‌ی دیگر از نوبه به نتیجه مرحله قبل اضافه می‌کند. این کار باعث می‌شود حتی اگر مقدار درهم‌سازی کاربر تغییر کند، تشخیص این تغییر برای کاربرپذیر بسیار دشوار شود و حریم خصوصی کاربر در برابر تحلیل‌های زمانی محافظت شود.

تصادفی‌سازی مانند مرحله‌ی قبل انجام می‌شود. از آنجایی که دوبار از پاسخ تصادفی عمومی استفاده شده است، باید از عبارت زیر برای تخمین شمارش داده‌ها استفاده کنیم:

^{۶۶}Expected Value

$$\hat{f}_L(v) = \frac{\frac{C(v)-nq_2}{(p_2-q_2)} - nq_1}{n(p_1-q_1)} = \frac{C(v) - nq_1(p_2-q_2) - nq_2}{n(p_1-q_1)(p_2-q_2)} \quad (9-3)$$

در عبارت بالا، p_1 و q_1 ضرایب احتمالی تصادفی سازی اول، و p_2 و q_2 ضرایب احتمالی تصادفی سازی دوم هستند.

این پژوهش دو پارامتر ϵ_1 و ϵ_∞ را روی بودجه‌ی حریم خصوصی معرفی می‌کند. ϵ_∞ حد نهایی برداشت از بودجه‌ی حریم خصوصی شما برای یک داده خاص است. مهم نیست چند بار آن داده را گزارش می‌کنید، کل هزینه حریم خصوصی که برای این داده می‌پردازید، هرگز از ϵ_∞ بیشتر نخواهد شد. این پارامتر به صورت مستقیم در تصادفی‌سازی دائمی (مرحله اول تصادفی سازی) استفاده می‌شود.

پارامتر ϵ_1 هزینه اولین گزارش شما برای آن داده خاص است. این هزینه، میزان نشت اطلاعات در اولین باری که داده را گزارش می‌دهید، مشخص می‌کند. از ϵ_1 در محاسبه‌ی بودجه‌ی حریم خصوصی برای لایه دوم نوفه استفاده می‌شود. ما می‌خواهیم تضمین کنیم که حریم خصوصی کل برای یک گزارش واحد پس از دو مرحله تصادفی‌سازی، دقیقاً برابر با ϵ_1 باشد. پس باید بودجه‌ی حریم خصوصی تصادفی‌سازی آنی (مرحله دوم تصادفی سازی) را طوری تنظیم کنیم تا مجموع این دو لایه نوفه، ما را دقیقاً به ϵ_1 برساند. احتمال پاسخ نهایی صحیح به دو صورت ممکن است رخ دهد:

- سازوکار اول و دوم هر دو پاسخ درست را برگردانند.

$$p = p_1 \times p_2$$

- سازوکار اول جواب غلط برگرداند ولی سازوکار دوم با تغییر پاسخ این اشتباه را جبران کند.

$$p = q_1 \times q_2$$

پس احتمال کل پاسخ صحیح برابر است با:

$$p_{total} = (p_1 \times p_2) + (q_1 \times q_2)$$

احتمال پاسخ نهایی غلط نیز به دو صورت ممکن است رخ دهد:

- سازوکار اول جواب درست را برگردانده ولی سازوکار دوم پاسخ اشتباه را ارائه دهد.

$$q = p_1 \times q_2$$

- سازوکار اول جواب غلط برگرداند و سازوکار با تغییر ندادن پاسخ، نتیجه را ثابت نگه دارد.

$$q = q_1 \times p_2$$

پس احتمال کل پاسخ غلط برابر است با:

$$q_{total} = (p_1 \times q_2) + (q_1 \times p_2)$$

اکنون با توجه به عبارت ۳-۶ می‌توان مقدار ϵ_1 را محاسبه کرد:

$$\epsilon_1 = \ln \left(\frac{p_{total}}{q_{total}} \right) = \ln \left(\frac{p_1 p_2 + q_1 q_2}{p_1 q_2 + q_1 p_2} \right)$$

همچنین مقادیر ϵ_∞ و ϵ_{IRR} بر اساس عبارت ۳-۶ به صورت زیر بدست می‌آیند:

$$\epsilon_\infty = \ln \left(\frac{p_1}{q_1} \right), \quad \epsilon_{IRR} = \ln \left(\frac{p_2}{q_2} \right)$$

اکنون با توجه به عبارات قبل، مقدار ϵ_{IRR} به صورت زیر بدست می‌آید:

$$\epsilon_{IRR} = \ln \left(\frac{e^{\epsilon_\infty + \epsilon_1} - 1}{e^{\epsilon_\infty} - e^{\epsilon_1}} \right)$$

الگوریتم ۳ نحوه‌ی عملکرد لولوها در سمت کاربر را نشان می‌دهد. این پژوهش دو رویکرد فراهم می‌کند تا مدیران سامانه بتوانند بر اساس نیاز خود بین حریم خصوصی و دقت، توازن برقرار کنند:

- لولوهای دودویی^{۶۷}: با انتخاب مقدار ۲ برای g ، می‌توان به قوی‌ترین سطح از حریم خصوصی طولی دست یافت که برای شرایط بسیار حساس ایده‌آل است.
- لولوهای بهینه^{۶۸}: پروتکل می‌تواند مقدار بهینه g را برای به حداکثر رساندن دقت آماری پیدا کند، در حالی که همچنان هزینه حریم خصوصی بسیار پایین‌تر از پروتکل‌های دیگر باقی می‌ماند.

⁶⁷BiLOLOHA

⁶⁸OLOLOHA

الگوریتم ۳ عملکرد لولوها سمت کاربر

ورودی: مقادیر ورودی کاربر $[v_1, v_2, \dots, v_T]$ ، توابع درهم‌سازی \mathcal{H} و بودجه‌های حریم خصوصی $\epsilon_1 < \epsilon_\infty$

$$\epsilon_1 < \epsilon_\infty$$

خروجی: ارسال مقدار نوفه‌دار شده‌ی x_t'' به و تابع درهم‌سازی \mathcal{H} کاربر

۱: انتخاب تابع \mathcal{H} از \mathcal{H} به صورت تصادفی و ارسال به کاربر

$$2: \epsilon_{IRR} = \ln \left(\frac{e^{\epsilon_\infty + \epsilon_1} - 1}{e^{\epsilon_\infty} - e^{\epsilon_1}} \right)$$

۳: به ازای هر واحد زمانی $t \in [1..T]$:

$$4: x = \mathcal{H}(v_t)$$

۵: اگر x حفظ نشده بود:

$$6: x' = M_{GRR}(x; \epsilon_\infty)$$

۷: حفظ کن مقدار x' را برای x

۸: در غیر این صورت:

۹: بازسازی مقدار x' برای x

$$10: x_t'' = M_{GRR}(x'; \epsilon_{IRR})$$

۱۱: ارسال x_t''

۳-۲-۶ سایر روش‌ها

علاوه بر رویکردهای اصلی ذکر شده نظیر حفظ کردن، رُند کردن و درهم‌سازی، پژوهش‌های دیگری نیز وجود دارند که با دیدگاه‌های متفاوت و نوآورانه به چالش داده‌های در حال تغییر پرداخته‌اند. این روش‌ها اغلب بر بهبود جنبه‌های خاصی نظیر شناسایی داده‌های پرتکرار، شخصی‌سازی حریم خصوصی برای کاربران مختلف و یا استفاده از تکنیک‌های ترکیبی و تطبیقی تمرکز دارند. در ادامه، به بررسی و تشریح این راهکارهای نوین می‌پردازیم که هرکدام زاویه‌ی دید جدیدی را برای غلبه بر محدودیت‌های موجود پیشنهاد می‌کنند.

۳-۲-۶-۱ پژوهش سونر و همکاران

پژوهش سونر و همکاران [۳۶] یک چارچوب جدید و تطبیقی برای جمع‌آوری داده‌های حساس از کاربران با حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد. در اکثر روش‌های موجود برای آشفته‌سازی، پاسخ هر فرد از طریق انتخاب یک پاسخ تصادفی با افزودن نوفه همراه می‌شود. این پاسخ تصادفی از میان تمام گزینه‌های موجود انتخاب می‌شود.

این پژوهش، راهکار نوینی بر اساس پاسخ تصادفی به طور تصادفی محدود شده است، را ارائه می‌دهد. سازوکار هوشمند و پویایی که به جای تصادفی‌سازی پاسخ از میان تمام گزینه‌ها، به شکل زیر عمل می‌کند:

- یادگیری از گذشته: الگوریتم با استفاده از داده‌هایی که تاکنون به صورت نوفه‌دار شده جمع‌آوری کرده است، یاد می‌گیرد که کدام پاسخ‌ها در کل جمعیت محتمل‌تر هستند.
- محدود کردن گزینه‌ها: برای هر کاربر جدید، به جای در نظر گرفتن همه پاسخ‌های ممکن، الگوریتم یک زیرمجموعه کوچک از محتمل‌ترین گزینه‌ها را پیش‌بینی می‌کند.
- تصادفی‌سازی هوشمند: سپس، فرآیند پاسخ تصادفی‌شده را فقط در داخل همین زیرمجموعه محدود و محتمل اجرا می‌کند.

این الگوریتم به طور خاص برای مدیریت داده‌هایی که توزیع آن‌ها در طول زمان تغییر می‌کند، طراحی شده است. الگوریتم منتظر نمی‌ماند تا حجم زیادی از داده‌ها جمع‌آوری شود و بعد یک مدل ثابت بسازد. بلکه هر داده جدید را به محض دریافت، به صورت ترتیبی و لحظه به لحظه پردازش می‌کند. با دریافت پاسخ نوفه‌دار شده‌ی هر کاربر جدید، از روش‌های تخمین بیزی^{۶۹} استفاده می‌کند تا مدل خود را کمی

⁶⁹Bayesian Estimation

اصلاح و به‌روز کند. از این رو، بازتاب دقیق‌تری از وضعیت فعلی داده‌ها دارد. در نهایت چون فضای تصادفی‌سازی کوچک‌تر و مرتبط‌تر است، نوفه‌ی کمتری به داده‌ها اضافه می‌شود.

۲-۶-۲-۳ پژوهش یومین و همکاران

پژوهش یومین و همکاران [۳۷] یک راهکار جدید برای تحلیل داده‌های پرتکرار با حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد. به بیان دیگر سازوکار جدیدی به نام درخت پیشوندی هدف-تراز^{۷۰} برای شناسایی داده‌های پرتکرار، ارائه می‌شود. راهکار پیشنهادی این پژوهش دو رویکرد اصلی را معرفی می‌کند:

- رویکرد توسعه انطباقی: این روش به جای استفاده از یک رویکرد ثابت، به صورت هوشمند و با توجه به توزیع فراوانی داده‌ها، تصمیم می‌گیرد که کدام پیشوندها برای شناسایی موارد پرتکرار مناسب‌تر هستند. این کار به افزایش دقت و کاهش نوفه همراه است.

- رویکرد هرس مبتنی بر اجماع^{۷۱}: در این راهکار، از دانش قبلی که به صورت تصادفی از کاربران به دست آمده، برای حذف نامزدهای غیرضروری استفاده می‌شود.

۳-۶-۲-۳ پژوهش ژنگ و همکاران

پژوهش ژنگ و همکاران [۳۸]، یک راهکار نوآورانه به نام «پاسخ تصادفی مشترک» را برای بهبود فرآیندهای مبتنی بر حریم خصوصی تفاضلی محلی ارائه می‌دهد. در روش‌های قدیمی مانند پاسخ تصادفی، هر فرد به صورت مستقل داده‌های خود را قبل از ارسال، کمی تغییر می‌دهد تا حریم خصوصی‌اش حفظ شود. مشکل اصلی این است که هرچه سطح حفاظت از حریم خصوصی بالاتر باشد، دقت و کارایی داده‌های جمع‌آوری‌شده برای تحلیل آماری (مانند تخمین فراوانی) کاهش می‌یابد.

در راهکار پیشنهادی این پژوهش به جای اینکه هر فرد به تنهایی عمل کند، کاربران به صورت تصادفی به گروه‌های دونفره تقسیم می‌شوند. سپس، اعضای هر گروه داده‌های خود را به صورت هماهنگ و مشترک تغییر می‌دهند. نکته کلیدی این است که هویت اعضای هر گروه برای تحلیلگر داده مخفی باقی می‌ماند. در نهایت همان سطح از ضمانت حریم خصوصی را که روش‌های قدیمی داشتند، ارائه می‌کند، اما در عین حال، دقت تخمین فراوانی را بهبود می‌بخشد.

⁷⁰Target-Aligning Prefix Tree

⁷¹Consensus-Based Pruning

۳-۲-۶-۴ پژوهش یونفی لی و همکاران

پژوهش یونفی لی و همکاران [۳۹] مدلی جدید به نام «حریم خصوصی تفاضلی محلی شخصی سازی شده چند دامنه‌ای» را معرفی می‌کند. یکی از مشکلات روش‌های فعلی این است که در جمع‌آوری داده‌ها، نیازهای کاربران برای تجمیع اطلاعات در دامنه‌های مختلف داده و همچنین ترجیحات شخصی آن‌ها برای سطوح مختلف حریم خصوصی را نادیده می‌گیرند.

راهکار ارائه شده در این مدل به کاربران این امکان را می‌دهد که بر اساس ترجیحات شخصی خود، آزادانه هم دامنه داده و هم بودجه حریم خصوصی را انتخاب کنند. بنابراین کاربران می‌توانند با انتخاب دامنه‌های کوچک‌تر، از کاهش سودمندی ناشی از افزودن نوفه جلوگیری کنند. همچنین این مدل به نیازهای متنوع کاربران برای حفاظت از داده‌هایشان در سطوح مختلف پاسخ می‌دهد و به آن‌ها کنترل بیشتری بر روی حریم خصوصی خود می‌دهد.

۳-۲-۶-۵ پژوهش بو جیانگ و همکاران

پژوهش بو جیانگ و همکاران [۴۰] یک راهکار جامع و چندوجهی برای جمع‌آوری و تحلیل داده‌ها با حفظ حریم خصوصی تفاضلی محلی ارائه می‌دهد. به طور خلاصه، راهکار این پژوهش در دو بخش اصلی قابل توضیح است:

- بهبود تخمین شمارش برای داده‌های شناخته‌شده: پژوهشگران یک سازوکار جدید و انعطاف‌پذیر را معرفی می‌کنند که در آن، روش‌های موجود را به طور قابل توجهی بهبود می‌یابند و تعادل بهتری میان سه عامل حریم خصوصی، دقت و هزینه ارتباطی برقرار می‌شود.
- جمع‌آوری داده‌ها با دامنه‌ی ناشناخته: برای حل چالش جمع‌آوری داده‌هایی که از قبل مشخص نیستند (مانند کلمات جدید در یک زبان)، این پژوهش یک راهکار کاملاً نوآورانه ارائه می‌دهد. این راهکار از یک معماری پیشرفته مبتنی بر رمزنگاری، درهم‌سازی و تحلیل استفاده می‌کند. داده‌های هر کاربر قبل از ارسال، روی دستگاه خود او رمزنگاری می‌شود. یک کارپذیر واسط، پیام‌های رمزنگاری شده از کاربران مختلف را با هم مخلوط می‌کند تا ارتباط بین کاربر و پیامش از بین برود. سپس کارپذیر دیگری، پیام‌های درهم‌شده را دریافت کرده و بدون اینکه به محتوای اصلی داده‌ها دسترسی داشته باشد، به فراوانی داده‌ها را محاسبه می‌کند.

۳-۲-۶ پژوهش ماریراس نتو و همکاران

پژوهش ماریراس نتو و همکاران [۴۱] به چگونگی حفظ حریم خصوصی کاربران حین تخمین شمارش داده‌های طولی می‌پردازد. این مقاله پروتکل جدیدی ارائه نمی‌دهد، بلکه به صورت جامع و روشمند، عملکرد ترکیبی از پروتکل‌های حریم خصوصی تفاضلی محلی برای داده‌های طولی ارزیابی می‌کند. هدف این است که مشخص شود کدام روش، بهترین سودمندی را ضمن حفظ حریم خصوصی ارائه می‌دهد. بر اساس تحلیل‌های انجام‌شده، بهینه‌شده‌ی روش‌های کدگذاری یکانی متقارن و لولوها به عنوان کارآمدترین پروتکل‌ها برای تخمین شمارش در داده‌های طولی شناسایی شدند.

۳-۳ جمع‌بندی

با بررسی سازوکارهای مربوط به حل چالش داده‌های با ابعاد بالا، مشکلاتی یافت می‌شود:

- نمونه‌برداری: سازوکارهای مربوط به این روش با در نظر گرفتن بخشی از داده به عنوان نماینده‌ی کل داده، موجب کاهش دقت تحلیل‌های آماری می‌شوند. مخصوصاً اگر حجم داده‌ی دریافتی از کاربران کم باشد، سودمندی به شدت کاهش می‌یابد.
- خوشه‌بندی: خوشه‌بندی به خودی خود روشی کارآمد محسوب می‌شود. منتها برای بدست آوردن خوشه‌های مناسب، باید میزان وابستگی میان ابعاد داده مشخص گردد. طبیعتاً سمت کاربر نمی‌توان این وابستگی‌ها را مشخص کرد، زیرا هم حجم داده سمت یک کاربر کم بوده و همچنین منابع محاسباتی محدودی خواهد داشت. پس کاربران باید داده‌ی خود را برای کاربرپذیر فرستاده و سپس کاربرپذیر همبستگی میان ابعاد را مشخص کند. اگر در همین ابتدا، کاربران داده‌ی خود را به صورت خام برای کاربرپذیر بفرستند، حریم خصوصی نقض می‌گردد. بنابراین باید به داده‌های خود نوفه اضافه کنند تا حریم خصوصی حفظ گردد. با اضافه کردن نوفه، دیگر نمی‌توان تخمین درستی از احتمال توزیع مشترک داده‌ها بدست آورد. در نتیجه خوشه‌بندی انجام شده توسط کاربرپذیر سالم نخواهد بود و سودمندی الگوریتم‌ها زیر سوال می‌رود.
- یافتن میزان همبستگی با کمک داده‌های تاریخی یا دانش قبلی: به این نکته هم اشاره کردیم که نمی‌توان همیشه روی داشتن این اطلاعات حساب باز کرد و بنابراین نیازمند الگوریتم مطمئن‌تری هستیم.

همچنین در حوزه‌ی داده‌های در حال تغییر، الگوریتم‌هایی مانند رپور و دی.دی.آر.ام کارایی خود را با

افزایش دامنه ورودی از دست می‌دهند. در پژوهش آرکولزی و همکاران [۳۵]، سازوکار لولوها با کاهش دامنه و استفاده از درهم‌سازی، نوعی عدم قطعیت به داده‌ها اضافه کرده و حریم خصوصی را به خوبی حفظ می‌کند. اما باید این نکته را در نظر داشت که پس از درهم‌سازی، دسترسی ما به داده‌های اصلی قطع شده و عملاً خروجی این سازوکار کاربرد محدودی برای ما خواهد داشت.

با وجود مشکلات بالا، الگوریتم پی.پی.ام.سی با استفاده از تبدیل هار و روش دی.بیت.فلیپ.پی.ام با کمک گرد کردن نقطه آلفا توانسته‌اند توازن خوبی بین حریم خصوصی و سودمندی بدست آورند. بنابراین در فصل بعد راهکاری ارائه می‌دهیم که با ترکیب روش گرد کردن نقطه آلفا و تبدیل هار، حریم خصوصی داده‌های با ابعاد بالا و در حال تغییر را به صورت یکجا تضمین کند.

فصل ۴

راهکار پیشنهادی

راهکار پیشنهادی شامل ترکیب روش **پی.پی.ام.سی** و بخشی از ایده‌ی سازوکار **دی.بیت.فلیپ.پی.ام** می‌باشد. این راهکار به طور همزمان دو چالش اساسی در دنیای حریم خصوصی تفاضلی محلی برای داده‌های با ابعاد بالا و در حال تغییر را هدف قرار می‌دهد. در این فصل ابتدا کلیت ساختار الگوریتم و نحوه‌ی عملکرد آن در طول زمان شرح داده می‌شود. سپس جزئیات پیاده‌سازی به تفصیل بیان خواهد شد؛ در نهایت نیز راهکار پیشنهادی حاضر مورد ارزیابی قرار خواهد گرفت.

۴-۱ نوآوری پژوهش

پژوهش حاضر با تمرکز بر جنبه‌های نوآورانه، سعی در ارائه‌ی راه‌حل‌هایی عملی و مؤثر برای حفظ حریم خصوصی داده‌های با ابعاد بالا و در حال تغییر دارد. مهم‌ترین نوآوری‌های این پژوهش عبارت‌اند از:

۱. استفاده از سازوکار گرد کردن نقطه **آلفا**: این پژوهش با به‌کارگیری تکنیک گرد کردن تصادفی نقطه **آلفا**، که در حقیقت بخشی از ایده‌ی روش **دی.بیت.فلیپ.پی.ام** است، راهکاری نوین برای مدیریت چالش داده‌های در حال تغییر ارائه کرده است. برخلاف روش‌های متداول که هرگونه تغییر جزئی در داده‌های ورودی را نیازمند مصرف مجدد بودجه حریم خصوصی می‌دانند، این سازوکار با حذف نوسانات بی‌اهمیت و گذرا^۱، پایداری پاسخ‌های کاربران را در طول زمان تضمین می‌کند. این امر امکان استفاده مؤثر از تکنیک حفظ کردن را فراهم آورده و مانع از هدررفت سریع بودجه حریم خصوصی در جمع‌آوری‌های مکرر می‌شود.

¹Jitter

۲. استفاده از روش تبدیل هار به همراه حفظ کردن: بهره‌گیری از سازوکار تبدیل هار در این طرح، پاسخی راهبردی به مسئله نفرین ابعاد است. نوآوری این بخش در تلفیق این تبدیل با پروتکل‌های حریم خصوصی محلی نهفته است؛ بدین صورت که با تجزیه داده‌های چندبعدی به مؤلفه‌های میانگین و جزئیات، انرژی سیگنال در تعداد محدودی از ضرایب متمرکز می‌شود. همچنین از سازوکار حفظ کردن استفاده می‌کنیم تا از مصرف بیش از حد بودجه‌ی حریم خصوصی هنگام تکرار درخواست داده جلوگیری کنیم. نکته‌ی مهم اینجاست که تزریق نوفه از طریق این سازوکار، می‌تواند به راحتی روی ابعاد در حال تغییر نیز اعمال شود. از این رو لازم نیست از سازوکار تصادفی‌سازی پیچیده‌ای مثل روش دی.بیت.فلیپ.پی.ام استفاده کرد.

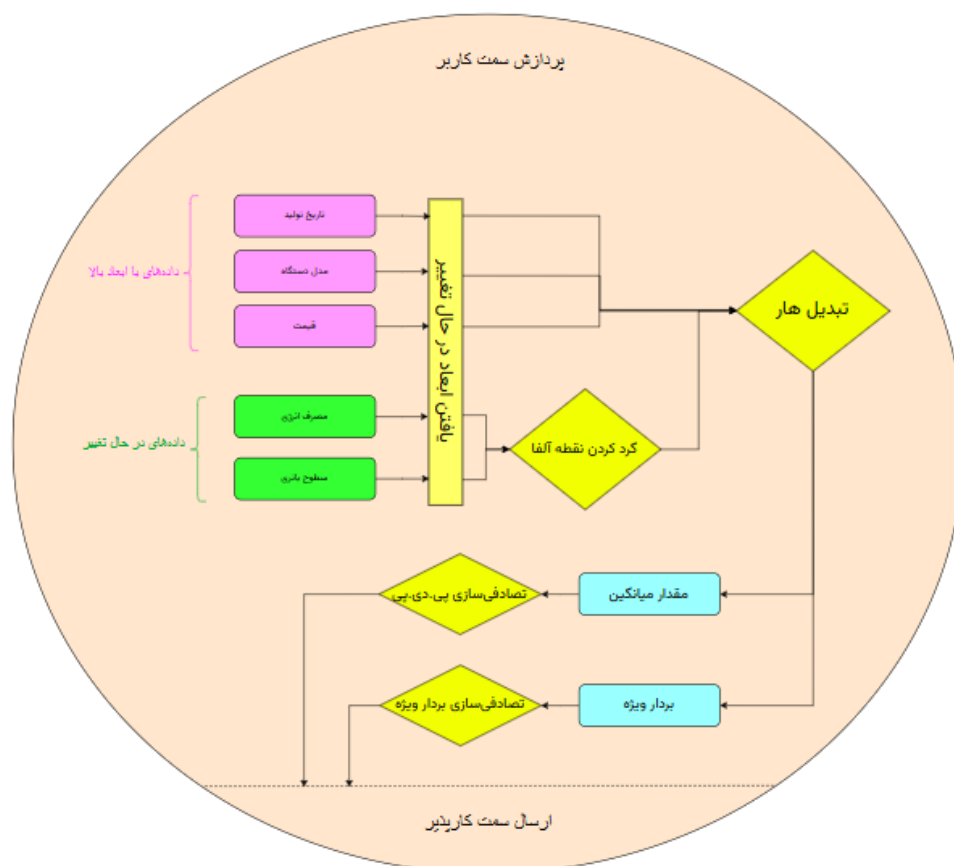
۳. یافتن مقدار بهینه برای گام گسسته‌سازی: تعیین مقدار گام گسسته‌سازی در فرآیند گرد کردن نقطه آلفا، چالش مهمی است که در این پژوهش به آن پرداخته‌ایم. برخلاف رویکردهای خلاقانه یا تجربی گذشته که مقدار گام گسسته‌سازی را ثابت فرض می‌کردند، این پژوهش یک فرمول‌بندی ریاضی دقیق برای استخراج مقدار بهینه آن ارائه می‌دهد. این نوآوری با حل مسئله‌ی کمینه‌سازی خطا، تعادلی هوشمندانه میان دقت و حریم خصوصی برقرار می‌کند. بدین ترتیب، سیستم تضمین می‌کند که سطح دانه‌بندی انتخاب شده، دقیقاً متناسب با دامنه و حساسیت داده‌ها تنظیم شود تا بیشترین مطلوبیت ممکن حاصل گردد.

۴. یافتن ابعاد نیازمند به گرد کردن به صورت خودکار: این پژوهش با ارائه یک سازوکار تشخیص تطبیق‌پذیر^۲، هوشمندی سیستم را در سمت کاربر ارتقا داده است. با محاسبه‌ی محلی «نرخ نوسانات» برای هر بُعد، این الگوریتم قادر است ابعاد پویا و در حال تغییر را از ابعاد ایستا تفکیک نماید. نوآوری مذکور باعث می‌شود که فرآیند گرد کردن تنها بر روی ابعادی اعمال شود که واقعاً نیازمند تثبیت هستند و از تحمیل خطای ناخواسته به ابعاد ثابت جلوگیری شود؛ رویکردی که منجر به حفظ حداکثری اطلاعات در داده‌های چندبعدی ناهمگن می‌گردد.

۲-۴ بررسی چارچوب راهکار پیشنهادی

به صورت خلاصه، با استفاده از تبدیل هار تمام داده‌ها به دو جزء میانگین و بردار ویژه تجزیه شده، در فرایند تصادفی‌سازی قرار گرفته و سمت کاربر پذیر ارسال می‌شوند. قبل از شروع این فرایند، باید اعمال اضافه‌تری روی داده‌های در حال تغییر انجام داد تا بتوان آنها را وارد فرایند تصادفی‌سازی کرد. شکل ۴-۱ به طور کلی رفتار الگوریتم سمت کاربر را نشان می‌دهد.

²Adaptive



شکل ۴-۱: عملکرد روش پیشنهادی سمت کاربر

ابتدا ابعاد داده بر اساس ماهیت تغییراتشان دسته بندی می شوند. تمامی ابعاد لزوماً نرخ تغییر یکسانی ندارند. ابعادی که دارای تغییرات مداوم و نوسانی هستند (مانند میزان مصرف انرژی لحظه ای یا مختصات جغرافیایی دقیق) باید به نوعی تثبیت شوند تا تغییرات ریز باعث بروز مصرف زیاد حریم خصوصی نشود. این تثبیت باید به نوعی باشد که امید ریاضی داده های گرد شده برابر با داده های واقعی باشد و صحت آماری حفظ شود. در نهایت به تمامی ابعاد نوفه ای اضافه می شود تا حریم خصوصی آنها تضمین گردد.

۴-۳ یافتن ابعاد در حال تغییر

در داده های چندبعدی واقعی، تمام ویژگی ها رفتار زمانی یکسانی از خود نشان نمی دهند. برخی از ابعاد دارای تغییرات مداوم و نوسانات سریع هستند (مانند مختصات مکانی یا مصرف لحظه ای منابع)، در حالی که برخی دیگر ممکن است در طول زمان ثابت مانده یا تغییرات بسیار کندی داشته باشند (مانند تنظیمات سیستمی کاربر). اعمال سازوکار گرد کردن نقطه آلفا بر روی تمامی ابعاد، رویکردی غیربهبینه است؛ زیرا

گرد کردن ابعاد ثابت یا کم‌نوسان، بدون اینکه دستاورد امنیتی خاصی داشته باشد، تنها منجر به کاهش سودمندی داده‌ها می‌گردد.

برای حل این چالش، رویکرد هوشمندانه‌ای پیاده‌سازی شده است. در این روش، پیش از اعمال هرگونه پیش‌پردازش، سیستم به صورت محلی در سمت کاربر، رفتار هر بُعد را پایش کرده و تصمیم می‌گیرد که آیا آن بُعد نیازمند عبور از سازوکار گرد کردن است یا خیر. مبنای این تصمیم‌گیری، محاسبه‌ی یک معیار کمی تحت عنوان «امتیاز نوسان نرمال‌شده^۳» است.

برای محاسبه این امتیاز، یک پنجره زمانی لغزان به طول W را برای هر بُعد j در نظر می‌گیریم. میزان تغییرات مطلق داده‌ها در این پنجره محاسبه شده و نسبت به دامنه تغییرات مجاز آن بُعد نرمال‌سازی می‌شود. امتیاز نوسان $score_j$ برای بُعد j از رابطه زیر به دست می‌آید:

$$score_j = \frac{\sum_{t=1}^W |v_{j,t} - v_{j,t-1}|}{W \times (Max_j - Min_j)} \quad (1-4)$$

در رابطه فوق، $v_{j,t}$ مقدار بُعد j در لحظه t است و Max_j و Min_j به ترتیب کران بالا و پایین مجاز برای آن بُعد هستند. مخرج کسر تضمین می‌کند که این معیار مستقل از مقیاس داده‌ها بوده و برای تمامی ابعاد قابل مقایسه است. مقدار $score_j$ همواره عددی بین ۰ و ۱ خواهد بود که مقادیر نزدیک به صفر نشان‌دهنده پایداری و مقادیر بزرگ‌تر نشان‌دهنده پویایی و نوسان شدید داده است.

در نهایت، تصمیم‌گیری برای فعال‌سازی مکانیزم گرد کردن بر اساس یک مقدار آستانه تجربی τ (برای مثال ۰/۰۱) انجام می‌شود. اگر $score_j > \tau$ باشد، سیستم آن بُعد را به عنوان یک «بُعد پویا» شناسایی کرده و برای حذف نوسانات جزئی، سازوکار گرد کردن نقطه آلفا را روی آن اعمال می‌کند. در غیر این صورت، بُعد مورد نظر به عنوان «بُعد ایستا» تلقی شده و مقدار خام آن مستقیماً به مرحله بعد، یعنی تصادفی‌سازی با کمک تبدیل هار، ارسال می‌شود. این تفکیک هوشمندانه سبب می‌شود تا خطای ناشی از گرد کردن تنها در جایی که برای حفظ حریم خصوصی و پایداری ضروری است، هزینه شود.

۴-۴ اعمال سازوکار گرد کردن نقطه آلفا

هسته اصلی تثبیت داده‌های در حال تغییر در این پژوهش، استفاده از روش «گرد کردن تصادفی» موسوم به نقطه آلفا است. این روش به جای گرد کردن قطعی داده‌ها به نزدیک‌ترین عدد صحیح (که منجر به خطای منطقی می‌شود)، از یک متغیر تصادفی کمکی برای تصمیم‌گیری استفاده می‌کند. این رویکرد تضمین می‌کند

³Normalized Volatility Score

که اگرچه تک تک داده‌ها تغییر می‌کنند، اما امید ریاضی داده‌های گرد شده برابر با مقدار واقعی داده باقی می‌ماند.

فرض کنید مقدار ورودی کاربر x در یک بازه مشخص با کران پایین L و کران بالا R قرار دارد، به طوری که طول این بازه (گام گسسته‌سازی) برابر با s است ($R - L = s$). برای انجام عملیات گرد کردن، کاربر یک مقدار تصادفی α را از بازه $[0, s)$ انتخاب می‌کند. قاعده گرد کردن برای تولید خروجی y به صورت زیر تعریف می‌شود:

۱. اگر $x + \alpha < R$ باشد، آنگاه مقدار x به سمت پایین گرد شده و $y = L$ خواهد شد.

۲. در غیر این صورت (یعنی $x + \alpha \geq R$)، مقدار x به سمت بالا گرد شده و $y = R$ خواهد شد.

در ادامه به تحلیل سودمندی این روش پرداخته و مواردی مانند اریب‌ناپذیری^۴ و خطای میانگین مربعات را بررسی می‌کنیم.

۴-۴-۱ تخمین گام گسسته‌سازی بهینه

تعیین مقدار گام گسسته‌سازی در فرآیند گرد کردن نقطه آلفا، یک چالش بهینه‌سازی با دو هدف متضاد است. از یک سو، انتخاب مقادیر بزرگ باعث افزایش «خطای کوانتیزاسیون»^۵ و از دست رفتن جزئیات داده می‌شود. از سوی دیگر، انتخاب مقادیر بسیار کوچک، حساسیت سیستم نسبت به نوسانات جزئی را افزایش داده و منجر به ناپایداری پاسخ‌ها و مصرف سریع بودجه حریم خصوصی می‌گردد. خطای کوانتیزاسیون یا خطای گسسته‌سازی، تفاوت میان «مقدار واقعی و دقیق ورودی» و «مقدار گرد شده خروجی» است. وقتی یک داده پیوسته را به یک داده گسسته (با دقت کمتر) تبدیل می‌کنیم، بخشی از اطلاعات دقیق آن حذف می‌شود. این مقدار حذف شده، همان خطای کوانتیزاسیون است.

پس از شناسایی ابعاد پویا، گام حیاتی بعدی تعیین مقدار بهینه‌ی گام گسسته‌سازی برای این ابعاد است. چالش اصلی در اینجا برقراری تعادل میان دو مؤلفه است: (۱) حفظ دقت داده‌ها و (۲) تضمین پایداری پاسخ‌های مربوط پرسمان‌ها.

برای استخراج یک رابطه ریاضی، ما از معیار $score_j$ بدست آمده در فرمول ۴-۱ بهره می‌بریم. هدف این است که احتمال تغییر وضعیت خروجی^۶ ناشی از نوسانات طبیعی داده، از یک حد آستانه مشخص

⁴Unbiasedness

⁵Quantization Error

⁶Flipping Probability

(η) فراتر نرود. در سازوکار گرد کردن نقطه آلفا، احتمال Pr_{flip} که نشان می‌دهد یک تغییر کوچک δ در ورودی باعث تغییر در خروجی گرد شده می‌شود، برابر است با نسبت تغییرات به اندازه گام:

$$Pr_{flip} \approx \frac{\delta}{step_j}$$

ما می‌خواهیم این احتمال کمتر یا مساوی یک حد پایداری (η) باشد (مثلاً $\eta = 0.1$) یعنی حداکثر ۱۰ درصد احتمال تغییر وضعیت). بنابراین:

$$\frac{\delta}{step_j} \leq \eta \Rightarrow step_j \geq \frac{\delta}{\eta}$$

از طرفی، طبق تعریف ارائه‌شده در فرمول ۴-۱، می‌دانیم که ارتباط میان تغییرات میانگین (δ) و امتیاز نوسان ($score_j$) و دامنه داده ($R_j = Max_j - Min_j$) به صورت زیر است:

$$score_j = \frac{\delta}{R_j} \Rightarrow \delta = score_j \times R_j$$

با جایگذاری رابطه دوم در رابطه اول، به معادله زیر می‌رسیم:

$$step_j \geq \frac{score_j \times R_j}{\eta}$$

این نابرابری حداقل مقدار $step_j$ را برای تضمین پایداری مشخص می‌کند. اما برای جلوگیری از کوچک شدن بیش از حد $step_j$ در زمانی که نوسانات بسیار ناچیز است ($score_j \rightarrow 0$)، باید یک محدودیت حداقلی (K_{base}) نیز در نظر بگیریم. بنابراین، فرمول نهایی و جامع برای محاسبه خودکار گام گسسته‌سازی بُعد j به صورت زیر پیشنهاد می‌شود:

$$step_j = (Max_j - Min_j) \times \max\left(\frac{1}{K_{base}}, \frac{score_j}{\eta}\right) \quad (2-4)$$

کسر $\frac{score_j}{\eta}$ مستقیماً از رفتار داده نشأت می‌گیرد. هرچه نوسانات بُعد j (یعنی $score_j$) بیشتر شود، کسر $\frac{S_j}{\eta}$ بزرگتر شده و سیستم به صورت خودکار اندازه گام ($step_j$) را افزایش می‌دهد تا نوسانات را پوشش دهد و پایداری حفظ شود.

کسر $\frac{1}{K_{base}}$ کران پایین برای اندازه گام است. متغیر K_{base} (مثلاً ۱۰۰) تعیین می‌کند که حتی اگر داده

کاملاً ایستا باشد، دامنه به بیش از ۱۰۰ قسمت تقسیم نشود تا سربار محاسباتی و خطای احتمالی کنترل شود.

متغیر η در فرمول پیشنهادی، نقش یک «دریچه کنترل» را ایفا می‌کند که تعادل میان فرکانس به‌روزرسانی داده‌ها و خطای گسسته‌سازی را تنظیم می‌نماید. تعیین مقدار این متغیر وابسته به سیاست‌های کلان حفظ حریم خصوصی و محدودیت‌های سیستم است و می‌توان آن را از دو منظر تعیین نمود:

۱. رویکرد مبتنی بر سطح اطمینان: از منظر آماری، η بیانگر حداکثر احتمال مجاز برای تغییر خروجی در اثر نوفه‌های محیطی است. اگر هدف سیستم تضمین پایداری ۹۰ درصدی برای داده‌های کاربر باشد، مقدار η برابر با ۰/۱ تنظیم می‌شود. این رویکرد در کاربردهایی که ثبات داده‌ها اولویت دارد (مانند دسته‌بندی کاربران)، مقادیر کوچکتر (مانند ۰/۰۵) و در کاربردهایی که حساسیت به تغییرات آنی مهم است، مقادیر بزرگتر (مانند ۰/۲) را می‌طلبد. در این پژوهش، بر اساس آزمایش‌های تجربی و با هدف ایجاد مصالحه میان دقت و پایداری، مقدار پیش‌فرض $\eta = 0.1$ در نظر گرفته شده است.

۲. رویکرد مبتنی بر بودجه حریم خصوصی: در سازوکارهای حریم خصوصی تفاضلی که از تکنیک حفظ کردن استفاده می‌کنند، هر بار تغییر در مقدار خروجی، منجر به مصرف بخشی از بودجه حریم خصوصی می‌شود. با وجود محدود بودن کل بودجه حریم خصوصی باید مقدار η را طوری تعیین کنم تا در بازه زمانی بزرگ و پایش‌های طولانی مدت، از اتمام سریع بودجه حریم خصوصی جلوگیری شود.

۴-۴-۲ اثبات اریب‌ناپذیری

برای اثبات اینکه این سازوکار مطلوبیت آماری داده‌ها را حفظ می‌کند، نشان می‌دهیم که امید ریاضی مقدار خروجی ($E[y]$) دقیقاً برابر با مقدار ورودی x است. با توجه به توزیع یکنواخت α ، احتمال گرد کردن به سمت پایین ($P(y = L)$) و بالا ($P(y = R)$) به شرح زیر محاسبه می‌شود:

$$P(y = L) = P(x + \alpha < R) = P(\alpha < R - x) = \frac{R - x}{s}$$

$$P(y = R) = P(x + \alpha \geq R) = 1 - \frac{R - x}{s} = \frac{s - (R - x)}{s} = \frac{x - (R - s)}{s} = \frac{x - L}{s}$$

حال امید ریاضی y را محاسبه می‌کنیم:

حفظ حریم خصوصی تفاضلی محلی هنگام انتشار داده‌های با ابعاد بالا و در حال تغییر

$$E[y] = L \cdot P(y = L) + R \cdot P(y = R)$$

با جایگذاری احتمالات محاسبه شده:

$$E[y] = L \cdot \left(\frac{R - x}{s} \right) + R \cdot \left(\frac{x - L}{s} \right)$$

$$E[y] = \frac{1}{s} \cdot (L \cdot R - L \cdot x + R \cdot x - R \cdot L)$$

$$E[y] = \frac{1}{s} \cdot (x \cdot (R - L))$$

از آنجا که طبق تعریف بازه، $R - L = s$ است، داریم:

$$E[y] = \frac{1}{s} \cdot (x \cdot s) = x$$

بنابراین، $E[y] = x$ اثبات می‌کند که گرد کردن نقطه آلفا یک تخمین‌گر اریب‌ناپذیر است و میانگین داده‌ها را تغییر نمی‌دهد.

۳-۴-۴ تحلیل خطای میانگین مربعات

علاوه بر صحت میانگین، بررسی میزان پراکندگی خطا برای هر کاربر منفرد نیز حائز اهمیت است. خطای میانگین مربعات برای یک ورودی واحد به صورت $E[(y - x)^2]$ تعریف می‌شود:

$$E[(y - x)^2] = P(y = L) \cdot (L - x)^2 + P(y = R) \cdot (R - x)^2$$

با جایگذاری احتمالات:

$$E[(y - x)^2] = \left(\frac{R - x}{s} \right) \cdot (L - x)^2 + \left(\frac{x - L}{s} \right) \cdot (R - x)^2$$

با فاکتورگیری و ساده‌سازی روابط جبری (با علم به اینکه $R = L + s$)، به رابطه نهایی زیر می‌رسیم که نشان می‌دهد خطا حاصل ضرب فاصله داده تا دو کران بازه است:

$$E[(y - x)^2] = (R - x)(x - L) \quad (3-4)$$

این رابطه نشان می‌دهد که خطای گرد کردن زمانی که x به یکی از مرزهای L یا R نزدیک باشد به حداقل (صفر) می‌رسد و زمانی که x دقیقاً در وسط بازه باشد، بیشینه خواهد بود. این رفتار تضمین می‌کند که خطای تحمیل شده همواره کراندار و کنترل‌شده باقی می‌ماند.

۴-۵ استفاده از روش تبدیل هار به همراه حفظ کردن

ابتدا تمام داده‌ها باید در بازه‌ی $[-1, 1]$ یکنواخت^۷ شوند. سپس با استفاده از تبدیل هار^۸، داده‌های چند بعدی به دو مؤلفه مقدار میانگین و بردار ویژه تجزیه می‌شوند. مقدار میانگین با استفاده از روش پی.دی.پی (شکل ۳-۶) نوفه‌دار می‌شود. به منظور تصادفی‌سازی بردار ویژه نیز از الگوریتم جی.پی.ام^۱ استفاده می‌کنیم. همچنین در هر دو تصادفی‌سازی از روش حفظ کردن بهره می‌گیریم تا هم در برابر پرسش‌های مکرر ایمن باشیم و هم سرعت عملیات را افزایش دهیم. در نهایت همگی داده‌ها برای کارپذیر ارسال می‌شوند. الگوریتم ۴ این مرحله را به صورت کلی نشان می‌دهد.

۴-۶ جمع‌آوری و تحلیل داده‌ها توسط کارپذیر

کارپذیر پس از دریافت مقدار میانگین و بردار ویژه‌ی نوفه‌دار شده، معکوس تبدیل هار را اجرا کرده و داده‌هایی نزدیک به داده‌های اصلی را بدست می‌آورد. به منظور ارزیابی، روی داده‌های در حال تغییر تخمین شمارش صورت گرفته و روی دیگر ابعاد دو معیار احتمال توزیع داده‌ها و خطای مجذور میانگین^۸ اندازه‌گیری می‌شود.

به منظور تخمین شمارش، برای هر بُعد لیستی به اندازه‌ی دامنه‌ی آن بُعد ساخته می‌شود که هر خانه از آن نشان‌دهنده‌ی فرکانس آن داده روی تمام داده‌های یک بُعد است. از آنجایی که داده‌ها کاملاً اعشاری هستند، روی خروجی ابعاد در حال تغییر، باید ابتدا به نزدیک‌ترین مقدار صحیح گرد شوند تا بتوان تخمین

^۷Normalize

^۸Mean Square Error

الگوریتم ۴ استفاده از روش تبدیل هار به همراه حفظ کردن

ورودی: داده‌های با ابعاد بالا $A = [a_1, a_2, \dots, a_d]$ ، دامنه تغییرات $domains$ و بودجه‌ی حریم خصوصی

ϵ

خروجی: میانگین و بردار ویژه به صورت نوفه‌دار شده

۱: $normalized = normalize(A, domains) : [-1, 1]$: یکنواخت سازی در بازه‌ی

۲: $avg, eigenvector = HaarTransform(A)$: استخراج میانگین و بردار ویژه:

۳: اگر مقدار avg و $eigenvector$ حفظ شده بود:

۴: استخراج مقادیر نوفه‌دار شده از حافظه:

۵: $avg', eigenvector' = getMemoized(A)$

۶: در غیر این صورت:

۷: اضافه کردن نوفه به میانگین و حفظ کردن آن: $avg' = PDP(avg, \epsilon)$

۸: اضافه کردن نوفه به بردار ویژه و حفظ کردن آن: $eigenvector' = GPM(eigenvector, \epsilon)$

۹: ارسال avg' و $eigenvector'$ سمت کارپذیر

شمارش را انجام داد. گفتیم که داده‌ها بر اساس متغیری به نام گام گسسته‌سازی به کران‌های بالا و پایین گرد می‌شوند. بنابراین الزاما مقدار خانه‌هایی که بین دو کران قرار می‌گیرند، صفر می‌شوند.

لیست‌های فرکانسی برای تمام ابعاد محاسبه شده و با کنار هم قرار دادن این لیست‌ها، یک ماتریس بدست می‌آید. دو بار این ماتریس محاسبه می‌شود. یکبار با داده‌های اصلی و بار دیگر با داده‌های نوفه‌دار شده. در نهایت با وارد کردن این دو ماتریس در تابع خطای مجذور میانگین، فرکانس الگوریتم خود را ارزیابی می‌کنیم.

۷-۴ یکنواخت‌سازی

روش پی.پی.ام.سی از تمام ابعاد میانگین گرفته و سمت کارپذیر می‌فرستد. در میانگین‌گیری اگر مقدار یک بُعد با اختلاف زیادی بیشتر از دیگر ابعاد باشد، نتیجه به سمت آن ویژگی سو می‌گیرد. پس قبل از تبدیل هار تمام ابعاد باید در یک بازه‌ی مشخص قرار گیرند. در روش پیشنهادی مانند الگوریتم پی.پی.ام.سی تمام ابعاد در بازه‌ی $[-1, 1]$ یکنواخت می‌شوند.

این عملیات طبق الگوریتم ۵ با استفاده از روش مقیاس‌بندی کمینه-بیشینه^۹ پیاده‌سازی شده است.

^۹Min-Max Normalization

الگوریتم ۵ یکنواخت سازی بر اساس مقیاس بندی کمینه- بیشینه

ورودی: عدد x و دامنه تغییرات $domain$

خروجی: یکنواخت شده x در بازه $[-1, 1]$

۱: قرار بده $a = \max(domain)$

۲: قرار بده $b = \min(domain)$

۳: مقدار $1 - ((2 * (x - b)) / (a - b))$ را بازگردان.

۸-۴ تضمین حریم خصوصی تفاضلی

در این بخش به اثبات ریاضی امن بودن روش پیشنهادی می پردازیم. روش پیشنهادی از راهکار تبدیل هار به منظور نوفه دار کردن داده ها استفاده شده است. در راهکار تبدیل هار، از دو سازوکار آشفته سازی پی.دی.پی و جی.پی.ام استفاده می شود. در ادامه اثبات امن بودن این دو سازوکار بیان می شود.

۱-۸-۴ اثبات امن بودن سازوکار جی.پی.ام

سازوکار آشفته سازی سراسری برای حفاظت از حریم خصوصی بردار ویژه طراحی شده است. در این سازوکار، مجموعه ای شامل بردارهای دودویی به صورت تصادفی و مستقل از ورودی ساخته می شود. سپس به دو مجموعه A و B افراز خواهد شد. مجموعه A شامل تمام بردارهایی است که تعداد اعضای 1 در آن ها زوج است. همچنین مجموعه B شامل تمام بردارهایی است که تعداد اعضای 1 در آن ها فرد است. بر اساس قضیه ی دوجمله ای اندازه ی این دو مجموعه کاملاً برابر خواهد بود. سپس یک متغیر تصادفی X تعریف می شود که با احتمالی وابسته به ϵ ، یکی از دو مجموعه A یا B را انتخاب کرده و یک بردار به صورت تصادفی از مجموعه ی انتخاب شده استخراج می شود. در نهایت بر اساس بردار استخراج شده، بردار ویژه نوفه دار می شود.

برای اثبات باید نسبت احتمال تولید خروجی یکسان برای ورودی های متفاوت را بدست آوریم و نشان دهیم که این عدد کوچک تر یا مساوی e^ϵ خواهد بود. اکنون می خواهیم نسبت احتمال را برای یک خروجی دلخواه y بررسی کنیم.

$$\Pr[X = 1] = \frac{e^\epsilon}{e^\epsilon + 1} \quad \Pr[X = 0] = \frac{1}{e^\epsilon + 1}$$

$$\Pr[y = v \mid V] = \begin{cases} \frac{e^\epsilon}{e^\epsilon + 1} \cdot \frac{1}{|A|}, & v \in A, \\ \frac{1}{e^\epsilon + 1} \cdot \frac{1}{|B|}, & v \in B. \end{cases}$$

نسبت خروجی در بدترین حالت برای دو ورودی از دو مجموعه‌ی مختلف به صورت زیر بدست می‌آید.

$$\text{since } |A| = |B|, \quad \frac{\frac{e^\epsilon}{e^\epsilon + 1} \cdot \frac{1}{|A|}}{\frac{1}{e^\epsilon + 1} \cdot \frac{1}{|B|}} = \frac{\frac{e^\epsilon}{e^\epsilon + 1}}{\frac{1}{e^\epsilon + 1}} = e^\epsilon$$

عبارت بالا نشان می‌دهد که مقدار بدست آمده همیشه کمتر از e^ϵ است. بنابراین سازوکار جی.پی.ام به دلیل ساختار احتمالی و مستقل از ورودی خود، حریم خصوصی را تضمین می‌کند.

۴-۸-۲ اثبات امن بودن سازوکار پی.دی.پی

سازوکار تصادفی یک مقدار آشفته‌شده را از یک توزیع احتمالی تولید می‌کند که شکل آن به ورودی الگوریتم بستگی دارد. توزیع احتمال به این صورت است که در ناحیه‌ی نزدیک به مقدار ورودی، احتمال انتخاب خروجی بیشتر از نواحی دیگر خواهد بود. برای اثبات ϵ -LDP بودن الگوریتم، باید نسبت تولید یک خروجی یکسان برای دو ورودی دلخواه را محاسبه کرده و بیشترین مقدار ممکن این نسبت را پیدا کنیم. بیشترین مقدار زمانی حاصل می‌شود که خروجی داخل بازه‌ی نزدیک به ورودی اول بوده و همچنین خارج از بازه‌ی نزدیک به ورودی دوم باشد:

$$\frac{\Pr[M(m_1) = y]}{\Pr[M(m_2) = y]} = \frac{q \cdot e^\epsilon}{q} = e^\epsilon$$

۴-۹ جمع‌بندی

در این فصل نشان دادیم که سازوکارهای مذکور همگی حریم خصوصی تفاضلی محلی را ارضا می‌کنند. روی تمام داده‌ها (چه پویا و چه غیر پویا) سازوکارهای جی.پی.ام و پی.دی.پی اجرا می‌شوند. پس با توجه به امن بودن چنین سازوکارهایی، می‌توان گفت حریم خصوصی به طور کامل تضمین می‌شود. از طرفی روی داده‌های در حال تغییر اعمال اضافه‌تری نیز انجام شده تا احتمال عدم قطعیت در خروجی نتایج آماری بالا رود. بنابراین می‌توان نتیجه گرفت راهکار پیشنهادی با موفقیت حریم خصوصی تفاضلی محلی را ارضا

می‌کند. همچنین راهکار پیشنهادی طوری طراحی شده است تا علاوه بر حفظ حریم خصوصی، سودمندی مناسبی روی نتایج آماری داشته باشیم.

فصل ۵

ارزیابی روش پیشنهادی

در این فصل به ارزیابی روش پیشنهادی و مقایسه‌ی آن با پنج روش پی.ام، تکه‌ای، رپور، لولوها و دی.بیت.فلیپ.پی.ام می‌پردازیم. معیارهای خطای مجذور میانگین و اختلاف احتمال توزیع داده‌ها برای داده‌های با ابعاد بالا (روش‌های پی.ام و تکه‌ای) در نظر گرفته شده است. همچنین تخمین شمارش داده‌ها در مقایسه با پژوهش‌های مربوط به داده‌های در حال تغییر (روش‌های رپور، لولوها و دی.بیت.فلیپ.پی.ام) بررسی می‌شود.

در این بخش ابتدا مجموعه داده ورودی معرفی شده و سپس نتایج ارزیابی روی دو دسته‌ی مذکور از داده‌ها بیان می‌شود. لازم به ذکر است که روش پیشنهادی همواره روی مجموعه‌ای از داده‌ها اجرا شده است که هم دارای ابعاد بالا بوده و هم به صورت مکرر تغییر می‌کنند. نتایج نشان می‌دهد که روش پیشنهادی با حفظ حریم خصوصی تفاضلی محلی، کارایی بهتری نسبت به الگوریتم‌های پیشین دارد.

۵-۱ مجموعه داده‌ی ورودی

به منظور ارزیابی راهکار پیشنهادی از مجموعه داده‌ی بزرگسالان^۱ استفاده شده است. این پایگاه داده از سرشماری سال ۱۹۹۴ ایالات متحده استخراج شده و یکی از معروف‌ترین مجموعه داده‌ها در حوزه یادگیری ماشین برای کارهای طبقه‌بندی است.

داده‌ها از نوع اعداد صحیح بوده و شامل اطلاعات شخصی و جمعیت‌شناختی افراد است. در این مجموعه داده ویژگی‌هایی مانند سن، سطح تحصیلات، وضعیت تاهل، نژاد و جنسیت وجود دارد. ۱۵ ویژگی و ۴۵۲۲۲ رکورد از کاربران در این مجموعه داده گنجانده شده است و برای تست عملکرد الگوریتم

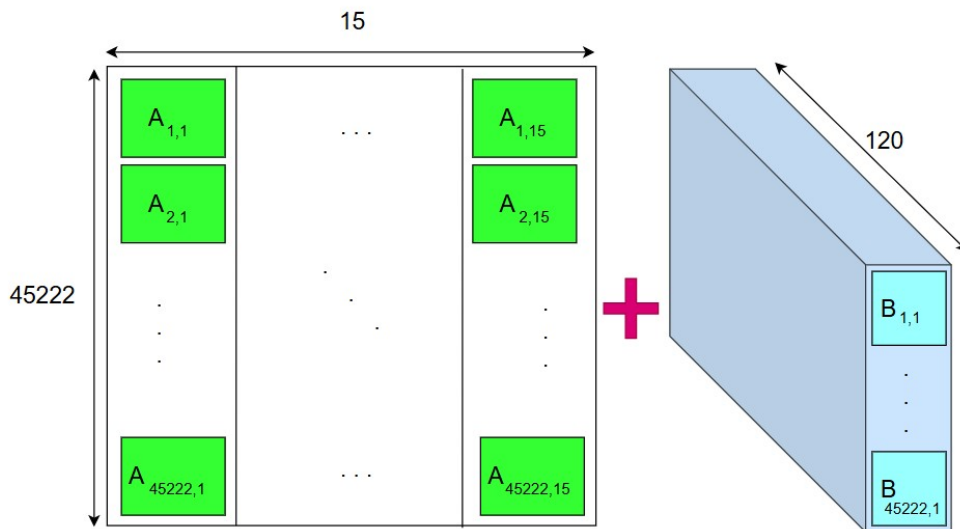
¹Adult

روی داده‌های غیر دودویی و عددی که دارای همبستگی‌های پیچیده بین ویژگی‌های مختلف هستند، بسیار مفید است.

به منظور ارزیابی عملکرد راهکار پیشنهادی روی داده‌های در حال تغییر، از مجموعه داده‌ی گردآوری شده در پژوهش لولوها استفاده شده است. نویسندگان این پژوهش یک مجموعه داده‌ی مصنوعی به اسم «سین^۲» تهیه کرده‌اند. این مجموعه داده برای شبیه‌سازی دنیای واقعی طراحی شده است که در آن، داده‌ها به صورت دوره‌ای و مکرر (هر ۶ ساعت یکبار) جمع‌آوری شده‌اند.

اندازه دامنه ۳۶۰ است که در واقع همان تعداد دقایق در یک بازه ۶ ساعته است. مجموعه داده سین از ۱۰۰۰۰ کاربر به تعداد ۱۲۰ بار جمع‌آوری شده است. نحوه ساخت این داده‌ها طوری است که به خوبی وضعیت داده‌های در حال تغییر را شبیه‌سازی می‌کند.

به منظور ساخت مجموعه داده‌ای که هر دو ویژگی مطرح را داشته باشد باید دو مجموعه داده‌ی ذکر شده را با یکدیگر ترکیب کنیم. مطابق شکل ۵-۱ مجموعه داده‌ی سین به صورت یک بُعد در کنار ۱۵ بُعد مجموعه داده بزرگسالان قرار می‌گیرد.



شکل ۵-۱: نحوه ترکیب دو مجموعه داده‌ی بزرگسالان و سین. مشخصه‌ی $A_{i,j}$ نشان دهنده‌ی ویژگی j ام از کاربر i ام است. همچنین نشان $B_{i,t}$ ، داده‌ی پویای کاربر i ام در واحد زمانی t ام را نمایش می‌دهد.

²Syn


۲-۵ ارزیابی روی داده‌های با ابعاد بالا

در این بخش معیار میانگین مربعات خطا و میانگین اختلاف توزیع احتمال داده‌ها با دو روش پی.ام و تکه‌ای مقایسه می‌شود. لازم به ذکر است که مقایسه نتایج بین روش پیشنهادی و سایر روش‌ها در صورتی انجام شده است که خروجی روش پیشنهادی شامل محاسبات ابعاد در حال تغییر نیز می‌باشد.

۱-۲-۵ ارزیابی حین تغییر بودجه‌ی حریم خصوصی

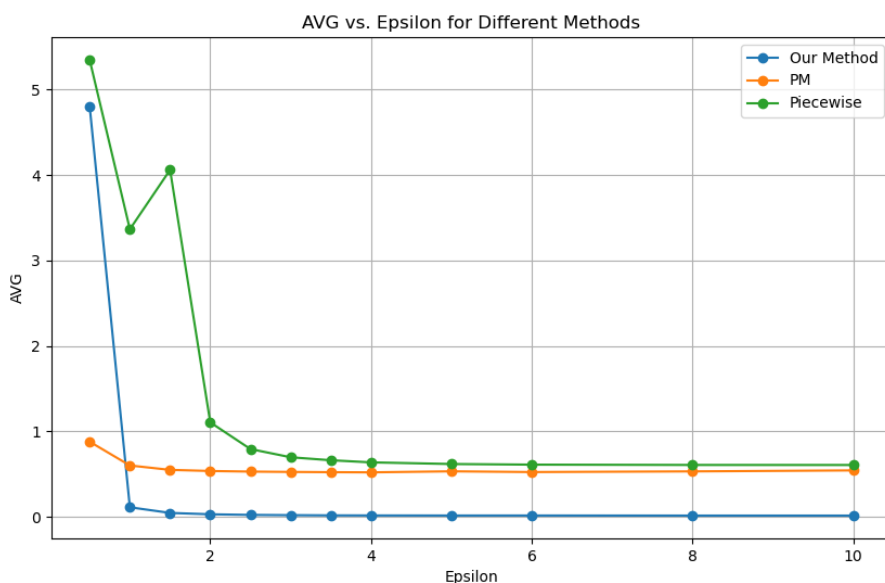
نمودار ۲-۵، میانگین مربعات خطا را برای سه روش مختلف حفظ حریم خصوصی در برابر بودجه‌ی حریم خصوصی مقایسه می‌کند. محور عمودی نشان‌دهنده خطای روش و محور افقی، میزان بودجه حریم خصوصی است؛ هرچه ϵ بزرگ‌تر باشد، سطح حریم خصوصی کمتر و دقت مورد انتظار بالاتر است.

همانطور که در نمودار مشخص است، روش پیشنهادی (خط آبی) در تمام نقاط، به طور مداوم کمترین میزان خطا را نسبت به دو روش دیگر، یعنی روش پی.ام و روش تکه‌ای، به ثبت رسانده است. این موضوع بیانگر عملکرد برتر و دقت بالاتر الگوریتم ارائه‌شده است. روش تکه‌ای در مقادیر پایین ϵ ، خطای بسیار بالایی دارد که با افزایش ϵ به سرعت کاهش می‌یابد اما همچنان بالاتر از دو روش دیگر باقی می‌ماند. روش پی.ام عملکرد بهتری نسبت به روش تکه‌ای دارد اما کماکان خطای آن به مراتب بیشتر از روش پیشنهادی ما است. این نتایج به وضوح نشان می‌دهد که الگوریتم جدید توانسته است مصالحه بهتری میان حفظ حریم خصوصی و دقت نتایج برقرار کند و کارایی بالاتری در تحلیل داده‌ها داشته باشد.



شکل ۲-۵: مقایسه‌ی میانگین مربعات خطای روش پیشنهادی با دو روش پی.ام و تکه‌ای

همچنین نمودار ۵-۳، میانگین اختلاف توزیع احتمال را برای سه روش مختلف و در سطوح بودجه‌ی حریم خصوصی، به تصویر می‌کشد. معیار میانگین اختلاف توزیع احتمال نشان می‌دهد که توزیع داده‌های نوفه‌دار شده تا چه حد به توزیع داده‌های اصلی شباهت دارد و مقدار کمتر آن، به معنای عملکرد بهتر است. روش پیشنهادی (خط آبی)، پایداری مطلوبی داشته و در تقریباً تمام بازه ϵ ، کمترین میزان اختلاف را با توزیع اصلی داده‌ها نشان می‌دهد. این موضوع حاکی از توانایی بالای این روش در حفظ ساختار آماری و ویژگی‌های بنیادین داده‌هاست. در مقابل، روش تکه‌ای (خط سبز) نه تنها در اکثر محدوده‌ها بیشترین میزان اختلاف را دارد، بلکه در مقادیر پایین ϵ رفتاری نامنظم و غیریکنواخت از خود بروز می‌دهد. این نوسان شدید، که احتمالاً ناشی از ماهیت تصادفی برخی عملیات‌های به کار رفته در این الگوریتم است، قابلیت اطمینان آن را کاهش می‌دهد. روش پی.ام اگرچه از روش تکه‌ای بهتر عمل می‌کند، اما همچنان با اختلاف قابل توجهی ضعیف‌تر از روش پیشنهادی ظاهر شده است. در نتیجه، می‌توان گفت الگوریتم ارائه شده در شرایطی که بودجه‌ی حریم خصوصی محدودی داریم، راهکاری بسیار دقیق‌تر و پایدارتر برای حفظ توزیع اصلی داده‌ها است.




شکل ۵-۳: مقایسه‌ی میانگین اختلاف توزیع احتمال داده‌ها در روش پیشنهادی با دو روش پی.ام و تکه‌ای

۵-۲-۲ ارزیابی حین تغییر تعداد ابعاد داده

نمودار ۵-۴، عملکرد سه روش مختلف را در مواجهه با افزایش تعداد ابعاد داده‌ها ارزیابی می‌کند. محور افقی نشان‌دهنده تعداد ابعاد و محور عمودی، میانگین خطای هر روش است. در تحلیل داده‌های پیچیده، پایداری یک الگوریتم در برابر افزایش ابعاد، یک شاخص کلیدی برای سنجش کارایی آن محسوب می‌شود.

روش پیشنهادی (خط آبی) برتری مطلق خود را به نمایش می‌گذارد. این روش در تمام طول بازه، با حفظ میانگین خطا در سطحی بسیار پایین و نزدیک به صفر، عملکردی بسیار پایدار از خود نشان می‌دهد. این ثبات، یک مزیت کلیدی است، زیرا نشان می‌دهد که با پیچیده‌تر شدن داده‌ها و افزایش ابعاد، کارایی الگوریتم کاهش پیدا نمی‌کند. روش پی‌ام (خط نارنجی) اگرچه از پایداری نسبی برخوردار است، اما سطح خطای آن به مراتب بالاتر از روش ما باقی می‌ماند. در مقابل، روش تکه‌ای (خط سبز) نه تنها با اختلاف زیادی بیشترین خطا را دارد، بلکه با افزایش ابعاد، رفتاری نامنظم و غیرقابل پیش‌بینی از خود نشان می‌دهد. این نوسانات شدید بیانگر آن است که این روش به شدت به تغییرات در تعداد ابعاد حساس است و قابلیت اطمینان پایینی دارد.




شکل ۵-۴: مقایسه‌ی خطا در روش پیشنهادی حین تغییر تعداد ابعاد با دو روش پی‌ام و تکه‌ای

۵-۲-۳ ارزیابی روی مجموعه داده‌های مختلف


نمودار ۵-۵، به ارزیابی عملکرد و قابلیت تعمیم‌پذیری سه روش مختلف در مواجهه با مجموعه داده‌های گوناگون می‌پردازد. روی محور افقی، برای هر مجموعه داده‌ی ورودی یک عدد تخصیص داده شده است و محور عمودی، میانگین مربعات خطا را نشان می‌دهد که مقدار کمتر آن، نشان‌دهنده دقت بالاتر است. بعضی از مجموعه داده‌ها نیز شامل مقادیر دودویی هستند.

روش پیشنهادی به‌طور پیوسته، کمترین میزان خطا را در تمامی مجموعه داده‌ها به ثبت رسانده است. این پایداری و دقت بالا نشان می‌دهد که الگوریتم ما از قابلیت تعمیم‌پذیری بسیار خوبی برخوردار است و عملکرد آن وابسته به نوع خاصی از توزیع داده نیست. در برخی نقاط، روند تغییرات خطا در روش

پیشنهادی و روش پی.ام شباهت‌هایی دارد؛ برای مثال، بین مجموعه داده‌های شماره ۱۰ تا ۱۱، هر دو روش شاهد کاهش خطا بوده‌اند. این شباهت عملکرد در نمودار ۵-۶ که خطای احتمال توزیع مشترک داده‌ها را می‌سنجد، بیشتر به چشم می‌خورد.



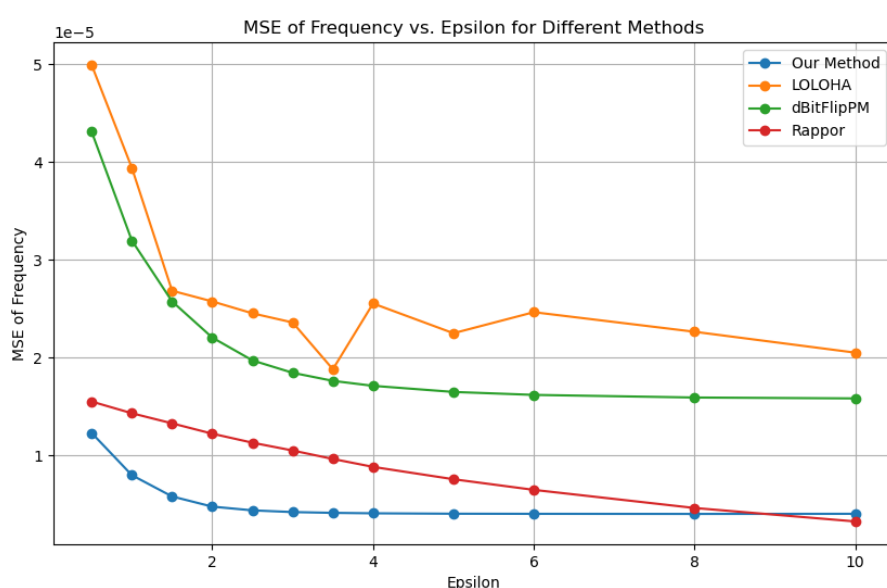
شکل ۵-۵: مقایسه‌ی میانگین مربعات خطا در روش پیشنهادی حین تغییر مجموعه داده ورودی




شکل ۵-۶: مقایسه‌ی میانگین اختلاف توزیع احتمال داده‌ها حین تغییر مجموعه داده ورودی

۳-۵ ارزیابی روی داده‌های در حال تغییر

محور عمودی نمودار ۵-۷ میانگین خطای تخمین شمارش را نشان داده و محور افقی نمایانگر تغییر بودجه‌ی حریم خصوصی است. الگوریتم پیشنهادی از نظر دقت، در سطحی کاملاً رقابتی و با فاصله‌ای ناچیز از روش رپور قرار دارد. در مقادیر بالای ϵ بهبودهایی که روی حفظ حریم خصوصی داده‌های با ابعاد بالا انجام شده است، کمی دقت و سودمندی را نسبت به رپور کاهش داده است.



شکل ۵-۷: مقایسه‌ی میانگین خطای تخمین شمارش در روش پیشنهادی حین تغییر بودجه‌ی حریم خصوصی البته همانطور که در نمودار ۵-۸ مشاهده می‌کنید، با افزایش تعداد کاربران، زمان اجرای الگوریتم دی.بیت.فلیپ.پی.ام به صورت قابل توجهی افزایش می‌یابد. در مقابل، روش پیشنهادی با یک شیب بسیار ملایم‌تر، بهینگی مطلوبی را در مقیاس‌های بزرگ به نمایش می‌گذارد. این برتری در زمان اجرا، الگوریتم ما را به گزینه‌ای بسیار کارآمدتر برای پیاده‌سازی در سیستم‌های واقعی با میلیون‌ها کاربر تبدیل می‌کند. این مورد را هم باید در نظر گرفت که الگوریتم رپور، با وجود خطای کم و سرعت بالا، دارای یک ضعف ذاتی در مواجهه با داده‌های در حال تغییر است. همانطور که قبل‌تر گفته شد، رپور در مواجهه با داده‌هایی که به صورت مکرر تغییر می‌کنند ضعف داشته و به ازای هر تغییر کوچک، باید مقدار جدیدی حفظ کند. این فرایند روش حفظ کردن را زیر سوال برده و باعث نقض حریم خصوصی می‌شود. الگوریتم پیشنهادی این چالش کلیدی را به طور مستقیم هدف قرار داده و با ارائه‌ی یک سازوکار مقاوم، تضمین می‌کند که حریم خصوصی تفاضلی محلی حتی در صورت تغییر مداوم داده‌ها نیز به قوت خود باقی بماند.



شکل ۵-۸: مقایسه‌ی زمان اجرای الگوریتم پیشنهادی با سه روش رپور ، لولوها و دی.بیت.فلیپ.پی.ام

۴-۵ جمع‌بندی

راهکار پیشنهادی به درستی توانسته است توازن خوبی بین حریم خصوصی و سودمندی برقرار کند. همچنین مناسب بودن زمان اجرای الگوریتم باعث می‌شود سربار کمتری داشته و در کارکردهای عملی مورد استقبال قرار گیرد. مجموعه کدهای پیاده‌سازی شده برای این پروژه داخل گیت‌هاب^۳ قرار گرفته است [۴۲]. به منظور اجرای الگوریتم از ابزار داکر^۴ استفاده شده است تا در راه‌اندازی آن تسهیل شود. به این ترتیب با داشتن سیستم عامل لینوکس^۵ و نصب داکر، می‌توانید به راحتی روش پیشنهادی را در محیط‌های مختلف اجرا کرده و نتایج را به صورت کامل دریافت کنید.

³Github

⁴Docker

⁵Linux

فصل ۶

جمع‌بندی

این پایان‌نامه در شش فصل به صورت جامع، چالش حفظ حریم خصوصی تفاضلی محلی را در مواجهه با دو معضل اساسی داده‌های مدرن یعنی ابعاد بالا و تغییرات مداوم، مورد بررسی قرار داده و یک راهکار ترکیبی و نوآورانه برای حل آن‌ها ارائه می‌دهد.

فصل اول، مقدمه، با تبیین اهمیت روزافزون حفاظت از داده‌ها در عصر اطلاعات، مسئله اصلی پژوهش را معرفی می‌کند. در این فصل، چالش‌های کلیدی مانند «نفرین ابعاد بالا» که منجر به افت کارایی سازوکارهای حریم خصوصی می‌شود، و مشکلات ناشی از داده‌های پویا و در حال تغییر که بودجه حریم خصوصی را به سرعت تخلیه می‌کنند، تشریح شده است. اهداف اصلی پژوهش، شامل طراحی یک ابزار سبک، کارآمد و کاربرپسند برای حفظ همزمان سودمندی و حریم خصوصی، به همراه ساختار کلی پایان‌نامه ارائه گردیده است.

فصل دوم، مفاهیم اولیه، به عنوان پایه‌ای نظری، به تشریح دقیق مفاهیم و ابزارهای ریاضی مورد استفاده در این حوزه می‌پردازد. در این بخش، تعریف رسمی حریم خصوصی تفاضلی، مفهوم کلیدی بودجه حریم خصوصی به عنوان معیاری برای سنجش سطح حفاظت، و حساسیت تابع به عنوان عاملی برای تعیین میزان نوفه لازم، مورد بحث قرار می‌گیرد. همچنین، سازوکارهای بنیادی مانند سازوکار لاپلاس برای داده‌های عددی، پاسخ تصادفی برای داده‌های دسته‌ای، و روش‌های کدگذاری و درهم‌سازی محلی به عنوان تکنیک‌های اساسی برای پیاده‌سازی در مدل محلی، به تفصیل معرفی شده‌اند.

فصل سوم، کارهای پیشین، یک مرور جامع بر ادبیات تحقیق و راهکارهای موجود برای مقابله با چالش‌های ذکر شده ارائه می‌دهد. این فصل به دو بخش اصلی تقسیم می‌شود: ابتدا، روش‌های مرتبط با داده‌های با ابعاد بالا مانند نمونه‌برداری، خوشه‌بندی، و کاهش ابعاد بررسی می‌شوند. سپس، راهکارهای ارائه‌شده برای داده‌های در حال تغییر، از جمله روش‌های مبتنی بر حفظ کردن، رند کردن و ارسال تغییرات

داده تحلیل می‌گردند. این فصل با شناسایی نقاط قوت و ضعف هر روش، خلاء موجود در تحقیقات را که نیازمند یک راهکار یکپارچه است، آشکار می‌سازد.

فصل چهارم، راهکار پیشنهادی، هسته اصلی این پژوهش را تشکیل می‌دهد و یک معماری ترکیبی جدید را معرفی می‌کند که از ترکیب بهینه‌شده‌ی روش‌های پی.پی.ام.سی و لولوها بهره می‌برد. این راهکار، داده‌های ورودی را به دو دسته ایستا (با ابعاد بالا) و پویا (در حال تغییر) تقسیم می‌کند. برای داده‌های ایستا، از تبدیل هار برای تجزیه داده به دو مؤلفه مقدار میانگین و بردار ویژه استفاده شده و هر بخش با سازوکار نوفه متناسب خود آشفته‌سازی می‌شود. برای داده‌های پویا، ابتدا از درهم‌سازی محلی برای کاهش دامنه مقادیر استفاده شده و سپس با یک سازوکار پاسخ تصادفی دائمی، حریم خصوصی در طول زمان تضمین می‌گردد. جزئیات پیاده‌سازی، از جمله نحوه بهینه‌سازی ورودی‌ها، در این فصل به طور کامل شرح داده شده است.

فصل چهارم، راهکار پیشنهادی، هسته اصلی این پژوهش را تشکیل می‌دهد و یک معماری ترکیبی نوین را معرفی می‌کند که بر پایه توسعه‌ی روش پی.پی.ام.سی بنا شده است. این راهکار برای مدیریت داده‌های با ابعاد بالا، از تبدیل هار جهت تجزیه داده به دو مؤلفه مقدار میانگین و بردار ویژه استفاده می‌کند که هر بخش با سازوکار نوفه متناسب خود محافظت می‌شود. نوآوری کلیدی این فصل در مدیریت داده‌های پویا (در حال تغییر) نهفته است؛ جایی که به جای روش‌های سنتی، از روش گرد کردن نقطه آلفا به همراه سازوکار حفظ کردن بهره گرفته شده است. این رویکرد با حذف نوسانات جزئی و بی‌اهمیت، مانع از هدررفت بودجه حریم خصوصی شده و پایداری پاسخ‌های کاربران را در طول زمان تضمین می‌کند. جزئیات کامل پیاده‌سازی و تحلیل‌های ریاضی مرتبط با این راهکار، در این فصل به تفصیل شرح داده شده است.

فصل پنجم، ارزیابی روش پیشنهادی، به سنجش عملکرد و کارایی راهکار ارائه‌شده در مقایسه با چهار روش برجسته پیشین می‌پردازد. با استفاده از مجموعه داده‌های بزرگسالان و مصنوعی سین، آزمایش‌های گسترده‌ای تحت شرایط مختلف، از جمله تغییر بودجه حریم خصوصی، افزایش ابعاد داده، و افزایش تعداد کاربران، انجام شده است. معیارهای ارزیابی شامل خطای مجذور میانگین، اختلاف توزیع احتمال و دقت تخمین شمارش بوده است.

در نهایت فصل ششم، فصل حاضر، ضمن مرور کلی بر مباحث مطرح شده، دستاوردهای اصلی پژوهش را خلاصه می‌کند. این فصل تأکید می‌کند که راهکار ترکیبی ارائه‌شده، یک چارچوب قدرتمند و عملی برای پیاده‌سازی حریم خصوصی تفاضلی محلی در شرایط واقعی و پیچیده است.

۱-۶ دستاوردها

راهکار ترکیبی ارائه شده، یک رویکرد جامع و قدرتمند برای پیاده‌سازی حریم خصوصی تفاضلی محلی در شرایط معمول دنیای واقعی است. این معماری با تفکیک هوشمندانه داده‌های ایستا و پویا، بهترین تکنیک‌ها را برای هر کدام به کار می‌گیرد:

- تبدیل هار با موفقیت نفرین ابعاد بالا را مهار کرده و امکان جمع‌آوری داده‌های چندبعدی با کارایی بالا را فراهم می‌آورد.
- سازوکار گرد کردن نقطه آلفا به طور مؤثری چالش داده‌های در حال تحول را مرتفع می‌سازد. این روش با نادیده گرفتن نوسانات جزئی و تثبیت هوشمندانه‌ی پاسخ‌ها، مانع از هدررفت بودجه حریم خصوصی شده و تضمین قدرتمندی برای حفاظت از داده‌ها در طول زمان ارائه می‌دهد.

پیاده‌سازی و ارزیابی این راهکار ترکیبی نشان داد که می‌توان به طور همزمان به سطح بالایی از حریم خصوصی و دقت آماری دست یافت. نتایج به‌دست‌آمده، برتری مشهود این روش را در مقایسه با راهکارهای پیشین، هم از نظر میزان خطای کمتر و هم از نظر مقیاس‌پذیری در برابر افزایش تعداد کاربران، به اثبات رساند. این موفقیت، مسیر را برای توسعه سیستم‌های تحلیل داده امن و قابل اعتماد هموارتر می‌سازد و به سازمان‌ها این امکان را می‌دهد که بدون به خطر انداختن حریم خصوصی افراد، از داده‌های ارزشمند خود بهره‌برداری کنند. در نهایت، این پژوهش گامی مهم در جهت کاربردی‌تر کردن مفاهیم حریم خصوصی تفاضلی برداشت و نشان داد که با ترکیب هوشمندانه روش‌ها، می‌توان بر پیچیده‌ترین چالش‌های این حوزه غلبه کرد.

۲-۶ کارهای آتی

با توجه به نتایج و ساختار راهکار پیشنهادی در فصل چهارم، مسیرهای پژوهشی زیر برای توسعه و بهبود این راهکار در آینده پیشنهاد می‌گردد:

۱. بهینه‌سازی تطبیقی پارامترهای کنترلی: در الگوریتم گرد کردن نقطه آلفا، متغیرهایی نظیر ضریب پایداری (η) و حد آستانه نوسان (τ) نقش کلیدی در ایجاد تعادل میان حریم خصوصی و دقت ایفا می‌کنند. در حال حاضر این مقادیر به صورت تجربی تعیین می‌شوند. در پژوهش‌های آتی می‌توان

از روش‌های یادگیری ماشین سبک^۱ در سمت کاربر استفاده کرد تا این متغیرها به صورت پویا و بر اساس رفتار لحظه‌ای داده‌های هر کاربر تنظیم شوند.

۲. مدیریت همبستگی‌های غیرخطی: راهکار فعلی از تبدیل هار برای فشرده‌سازی و استخراج ویژگی‌ها استفاده می‌کند که ماهیتی خطی دارد. جایگزینی این تبدیل با مدل‌های فشرده‌سازی مبتنی بر یادگیری عمیق می‌تواند امکان مدیریت داده‌هایی با همبستگی‌های پیچیده و غیرخطی را فراهم کرده و استخراج ویژگی‌ها را هوشمندتر نماید.

۳. توسعه برای داده‌های غیرعددی: سازوکار گرد کردن ذاتاً برای داده‌های عددی و پیوسته طراحی شده است. توسعه‌ی مفهومی مشابه با نقطه آلفا برای داده‌های دسته‌ای^۲ و متنی که در آن‌ها مفهوم «نزدیکی» و «گرد کردن» متفاوت است، می‌تواند دامنه کاربرد این الگوریتم را به شدت گسترش دهد.

۴. تحلیل پیشرفته سمت کاربرپذیر: در این پژوهش، تمرکز اصلی بر پروتکل‌های سمت کاربر بود. در آینده می‌توان الگوریتم‌های تخمین و تجمیع پیشرفته‌تری را در سمت کاربرپذیر توسعه داد که با مدل‌سازی دقیق توزیع خطای ناشی از گرد کردن نقطه آلفا، نوفه باقی‌مانده را با دقت بیشتری حذف کنند.

در نهایت باید گفت حوزه حریم خصوصی تفاضلی همچنان نیازمند تحقیق و پژوهش به منظور یافتن الگوریتم کم هزینه و کارآمد خواهد بود.

^۱Lightweight ML

^۲Categorical

- [1] X. Ren, C.-M. Yu, W. Yu, S. Yang, X. Yang, J. A. McCann, and S. Y. Philip. Lopub: high-dimensional crowdsourced data publication with local differential privacy. *IEEE Transactions on Information Forensics and Security*, 13(9):2151–2166, 2018.
- [2] H. Zhang, K. Li, T. Huang, X. Zhang, W. Li, Z. Jin, F. Gao, and M. Gao. Publishing locally private high-dimensional synthetic data efficiently. *Information Sciences*, 633:343–356, 2023.
- [3] H. Jiang, H. Yu, X. Cheng, J. Pei, R. Pless, and J. Yu. Dp2-pub: Differentially private high-dimensional data publication with invariant post randomization. *IEEE Transactions on Knowledge and Data Engineering*, 2023.
- [4] D. Zhang, W. Ni, N. Fu, L. Hou, and R. Zhang. Locally differentially private multi-dimensional data collection via haar transform. *Comput. Secur.*, 130:103291, 2023.
- [5] Q. Xue, Q. Ye, H. Hu, Y. Zhu, and J. Wang. Ddrm: A continual frequency estimation mechanism with local differential privacy. *IEEE Transactions on Knowledge and Data Engineering*, 35:6784–6797, 2023.
- [6] Google. Source code of rappor in chromium. <https://chromium.googlesource.com/chromium/src/+71.0.3553.2/components/rappor/>, 2015.
- [7] Microsoft. Collecting telemetry data privately. <https://www.microsoft.com/en-us/research/blog/collecting-telemetry-data-privately/>, 2017.
- [8] C. Dwork, K. Kenthapadi, F. McSherry, I. Mironov, and M. Naor. Our data, ourselves: Privacy via distributed noise generation. In *Advances in Cryptology-EUROCRYPT 2006: 24th Annual International Conference on the Theory and Applications of Cryptographic Techniques, St. Petersburg, Russia, May 28-June 1, 2006. Proceedings 25*, pages 486–503. Springer, 2006.

- [9] S. P. Kasiviswanathan, H. K. Lee, K. Nissim, S. Raskhodnikova, and A. Smith. What can we learn privately? *SIAM Journal on Computing*, 40(3):793–826, 2011.
- [10] J. C. Duchi, M. I. Jordan, and M. J. Wainwright. Local privacy and statistical minimax rates. *2013 IEEE 54th Annual Symposium on Foundations of Computer Science*, pages 429–438, 2013.
- [11] C. Dwork. A firm foundation for private data analysis. *Communications of the ACM*, 54:86 – 95, 2011.
- [12] S. L. Warner. Randomized response: a survey technique for eliminating evasive answer bias. *Journal of the American Statistical Association*, 60 309:63–6, 1965.
- [13] P. Kairouz, K. A. Bonawitz, and D. Ramage. Discrete distribution estimation under local privacy. In *International Conference on Machine Learning*, 2016.
- [14] P. Kairouz, S. Oh, and P. Viswanath. Extremal mechanisms for local differential privacy. *J. Mach. Learn. Res.*, 17:17:1–17:51, 2014.
- [15] H. H. Arcolezi and S. Gambs. Revealing the true cost of locally differentially private protocols: An auditing perspective. *Proc. Priv. Enhancing Technol.*, 2024:123–141, 2023.
- [16] K. Nissim, R. Smorodinsky, and M. Tennenholtz. Approximately optimal mechanism design via differential privacy. In *Proceedings of the 3rd innovations in theoretical computer science conference*, pages 203–213, 2012.
- [17] F. D. McSherry. Privacy integrated queries: an extensible platform for privacy-preserving data analysis. In *Proceedings of the 2009 ACM SIGMOD International Conference on Management of data*, pages 19–30, 2009.
- [18] S. Wang, L. Huang, P. Wang, H. Deng, H. Xu, and W. Yang. Private weighted histogram aggregation in crowdsourcing. In *Wireless Algorithms, Systems, and Applications*, 2016.
- [19] Ú. Erlingsson, V. Pihur, and A. Korolova. Rappor: Randomized aggregatable privacy-preserving ordinal response. In *Proceedings of the 2014 ACM SIGSAC conference on computer and communications security*, pages 1054–1067, 2014.
- [20] C. Dwork, F. McSherry, K. Nissim, and A. Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of Cryptography: Third Theory of Cryptography Conference, TCC 2006, New York, NY, USA, March 4-7, 2006. Proceedings 3*, pages 265–284. Springer, 2006.

- [21] J. C. Duchi, M. J. Wainwright, and M. I. Jordan. Minimax optimal procedures for locally private estimation. *Journal of the American Statistical Association*, 113:182 – 201, 2016.
- [22] X. Chen, C. Wang, Q. Yang, T. Hu, and C. Jiang. Locally differentially private high-dimensional data synthesis. *Science China Information Sciences*, 66(1):1–18, 2023.
- [23] N. Wang, X. Xiao, Y. D. Yang, J. Zhao, S. C. Hui, H. Shin, J. Shin, and G. Yu. Collecting and analyzing multidimensional data with local differential privacy. *2019 IEEE 35th International Conference on Data Engineering (ICDE)*, pages 638–649, 2019.
- [24] H. H. Arcolezi, J.-F. Couchot, B. al Bouna, and X. Xiao. Improving the utility of locally differentially private protocols for longitudinal and multidimensional frequency estimates. *Digit. Commun. Networks*, 10:369–379, 2021.
- [25] S. R. Seeam, Y. Zheng, and Y. Hu. Frequency estimation of correlated multi-attribute data under local differential privacy. 2025.
- [26] Y. Yuan, X. Tang, Y. Huang, and J. Wang. Local differential privacy for tensors in distributed computing systems. 2025.
- [27] A. Hernandez-Matamoros and H. Kikuchi. Comparative analysis of local differential privacy schemes in healthcare datasets. *Applied Sciences*, 2024.
- [28] K. Yu, X. Wu, W. Ding, Y. Mu, and H. Wang. Markov blanket feature selection using representative sets. *IEEE Transactions on Neural Networks and Learning Systems*, 28:2775–2788, 2017.
- [29] R. Du, Q. Ye, Y. Fu, and H. Hu. Collecting high-dimensional and correlation-constrained data with local differential privacy. In *2021 18th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON)*, pages 1–9. IEEE, 2021.
- [30] G. hua Shen, M. Cai, Z. Huang, Y. Yang, F. Guo, and L. Wei. Lohdp: Adaptive local differential privacy for high-dimensional data publishing. *Concurrency and Computation: Practice and Experience*, 36, 2024.
- [31] H. Kikuchi. *Privacy-Preserving Clustering for Multi-dimensional Data Randomization Under LDP*, pages 15–29. 04 2024.

- [32] K. Song, M. Sun, K. Zhou, P. Tang, N. Wang, and S. Guo. Multi-dimensional data collection under personalized local differential privacy. *2024 IEEE 23rd International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom)*, pages 1438–1447, 2024.
- [33] B. Ding, J. Kulkarni, and S. Yekhanin. Collecting telemetry data privately. *Advances in Neural Information Processing Systems*, 30, 2017.
- [34] T. Wang, J. Blocki, N. Li, and S. Jha. Locally differentially private protocols for frequency estimation. In *USENIX Security Symposium*, 2017.
- [35] H. H. Arcolezi, C. Pinz’on, C. Palamidessi, and S. Gambs. Frequency estimation of evolving data under local differential privacy. In *International Conference on Extending Database Technology*, 2022.
- [36] S. Aydin and S. Yildirim. Bayesian frequency estimation under local differential privacy with an adaptive randomized response mechanism. *ACM Transactions on Knowledge Discovery from Data*, 19:1 – 40, 2024.
- [37] Y. Zhang, Q. Ye, and H. Hu. Federated heavy hitter analytics with local differential privacy. *Proceedings of the ACM on Management of Data*, 3:1 – 27, 2024.
- [38] Y.-Z. Liu, S. R. Seeam, Y. Hu, R. Zhang, and Y. Zhang. Locally differentially private frequency estimation via joint randomized response. *Proc. Priv. Enhancing Technol.*, 2025:242–260, 2025.
- [39] Y. Li, X. Fu, L. Liu, J. Ding, W. Peng, and L. Jia. Multi-domains personalized local differential privacy frequency estimation mechanism for utility optimization. *Comput. Secur.*, 150:104273, 2024.
- [40] B. Jiang, W. Zhang, D. Lu, J. Du, and Q. Yan. When focus enhances utility: Target range ldp frequency estimation and unknown item discovery. *ArXiv*, abs/2412.17303, 2024.
- [41] A. A. M. Neto, E. R. D. Neto, J. S. C. Filho, and J. C. Machado. Locally differentially private and consistent frequency estimation of longitudinal data. *Anais do XXXIX Simpósio Brasileiro de Banco de Dados (SBBD 2024)*, 2024.
- [42] Arash Saatchi. Wheel of differential is a solution to preserve local differential privacy in the release of high-dimensional and evolving data. <https://github.com/differentialprivacyir/WOD>, 2025.

واژه‌نامه

الف

cover پوشش

complexity پیچیدگی

ت

function تابع

experimental تجربی

composition ترکیب

detection تشخیص

intersection تقاطع

approximation تقریب

randomize تصادفی

collision تصادم

differential تفاضلی

distribution توزیع

چ

density چگالی

ح

privacy حریم خصوصی

sensitivity حساسیت

cache حافظه نهان

memoization حفظ کردن

ب

threshold آستانه

perturbation آشفتگی

consensus اجماع

probability احتمال

communication ارتباط

information اطلاعات

safe امن

transform انتقال

internet of things اینترنت اشیا

high dimensions ابعاد بالا

پ

reset بازنشانی

online برخط

adult بزرگسال

dimension بُعد

optimum بهینه

maximum بیشینه

entropy بی‌نظمی

پ

randomize response پاسخ تصادفی

query پرس‌وجو

ش	حمله	attack.....
pseudocode..... شبه کد	خ	
network..... شبکه	خطا	error.....
counter..... شمارنده	خطی	linear.....
object..... شیء	خوشه	cluster.....
ط	د	
longitudinal..... طولی	داده	data.....
ع	داده‌ی پرت	outlier data.....
general..... عمومی	داده‌ی دورسنجی	telemetry data.....
غ	داده‌کاوی	data mining.....
dominate..... غلبه	درخت اتصال	junction tree.....
ف	در حال تغییر	evolving.....
distance..... فاصله	درهم‌سازی	hash.....
compression..... فشردہ‌سازی	دوبرابر سازی	doubling.....
space..... فضا	دودویی	binary.....
ق	ر	
deterministic..... قطعی	رأس	vertex.....
ک	رسمی	formal.....
efficient..... کارا	ز	
candidate..... کاندیدا	زیرخطی	sublinear.....
reduction..... کاهش	س	
encode..... کدگذاری	سازوکار	mechanism.....
decode..... کدگشایی	سری زمانی	time-series.....
minimum..... کمینه	سلسه‌مراتبی	hierarchichal.....
	سودمندی	utility.....

average میانگین

گ

cohort گروه

ن

center point نقطه‌ی مرکزی

noise نوفه

م

local محلی

direct مستقیم

هـ

correlation همبستگی

neighbour همسایه

cost هزینه

metric معیار

mutual متقابل

symmetric متقارن

sequential متوالی

ی

edge یال

unary یکانی

expected مورد انتظار

trade off موازنه

parallel موازی

Abstract

Local Differential Privacy (LDP) is a leading approach in user data protection that guarantees privacy without requiring trust in the aggregator. This concept enables data analysis by injecting noise into user data prior to transmission to the aggregator. Privacy-preserving data utilization is critical in sensitive domains such as healthcare and the Internet of Things (IoT); utilizing these resources for key decision-making processes requires guaranteeing that personal information remains uncompromised during analysis. This research focuses on preserving Local Differential Privacy in high-dimensional and evolving data. Key challenges in this domain include feature correlation, increased data sensitivity, and rapid consumption of the privacy budget, all of which can severely degrade the accuracy and efficiency of statistical analyses. In addition to categorizing, reviewing, and comparing existing algorithms and prior works, this study proposes a novel solution for preserving privacy in high-dimensional and evolving data.

The primary innovation of this research lies in the integration of the Haar Transform and the Alpha-point Rounding mechanism. Data is first decomposed using the Haar Transform to concentrate the majority of information within a limited number of coefficients; this process facilitates more optimal management of the privacy budget. To manage dynamic data, the Alpha-point Rounding mechanism is employed. Unlike traditional methods that require budget consumption for every minor change, this solution eliminates insignificant and transient fluctuations (jitter), thereby guaranteeing the stability of user responses over time and preventing privacy budget wastage. The performance of the proposed solution has been evaluated through implementation and comparison with established methods. Experiments demonstrate that the proposed algorithm not only preserves privacy but also provides superior utility for statistical analyses.

Keywords: Local Differential Privacy, Evolving Data, High-Dimensional Data, Haar Transform, Alpha-point Rounding



Sharif University of Technology
Department of Computer Engineering

M.Sc. Thesis

Preserving Local Differential Privacy in the Release of High-Dimensional and Evolving Data

By:

Seyed Arash Saatchi

Supervisor:

Dr. Rasool Jalili

September 2025